

ModelArts
7.2.1-HCS

产品介绍

文档版本 01
发布日期 2025-10-30



版权所有 © 华为云计算技术有限公司 2026。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HUAWEI和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为云计算技术有限公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为云计算技术有限公司对本文档内容不做任何明示或暗示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为云计算技术有限公司

地址：贵州省贵安新区黔中大道交兴功路华为云数据中心 邮编：550029

网址：<https://www.huaweicloud.com/>

目 录


1 什么是 ModelArts.....	1
2 基础知识.....	2
2.1 ModelArts 中常用概念.....	2
2.2 模型训练.....	3
2.3 模型部署（旧版推理）.....	4
2.4 模型部署（新版推理）.....	5
2.5 昇腾云脑.....	5
3 支持的 AI 框架.....	7
4 约束与限制.....	9
5 与其他服务的关系.....	29
6 如何访问 ModelArts.....	31
7 权限管理.....	32

1 什么是 ModelArts

ModelArts提供了一站式AI开发平台，支持大规模分布式训练、模型管理和部署，可以帮助用户快速创建和部署模型，管理全周期AI工作流。在大模型场景下，ModelArts提供了超大规模集群管理，故障感知、诊断、恢复，以及训练过程快恢和部署过程加速。

“一站式”是指AI开发的各个环节，包括算法开发、模型训练、模型部署都可以在ModelArts上完成。从技术上看，ModelArts底层支持各种异构计算资源，开发者可以根据需要灵活选择使用，而不需要关心底层的技术。同时，ModelArts支持TensorFlow、PyTorch、MindSpore等主流开源的AI开发框架，也支持开发者使用自研的算法框架，匹配您的使用习惯。同时，ModelArts还提供了AI Hub功能，实现AI资产的共享。

图 1-1 ModelArts 架构



2 基础知识

2.1 ModelArts 中常用概念

推理

指按某种策略由已知判断推出新判断的思维过程。人工智能领域下，由机器模拟人类智能，使用构建的神经网络完成推理过程。

在线推理

在线推理是对每一个推理请求同步给出推理结果的在线服务（Web Service）。

批量推理

批量推理是对批量数据进行推理的批量作业。

边缘推理

边缘推理是通过ModelArts Edge或者IEF智能边缘平台，在边缘节点将模型部署为一个Web Service，与在线服务主要区别在线服务部署在ModelArts的资源池中，边缘服务主要部署在租户边缘侧的运行节点上。

根据模型的请求模式不同，分为边缘同步推理和边缘异步推理。

- 边缘同步推理：部署的边缘服务，单次推理可同步返回结果，例如图片、较小视频文件。
- 边缘异步推理：部署的边缘服务，单次推理需要异步处理返回结果，例如实时视频推理、大视频文件。

Ascend 芯片

Ascend芯片是高计算力低功耗的AI芯片。

自定义镜像

ModelArts底层采用容器技术，自定义镜像指的是用户自行制作容器镜像并在ModelArts上运行。自定义镜像功能支持自由文本形式的命令行参数和环境变量，灵活性比较高，便于支持任意计算引擎的作业启动需求。

- **用于训练模型**

如果您已经在本地完成模型开发或训练脚本的开发，且您可以基于ModelArts提供的基础镜像包制作自定义镜像，并上传至SWR服务。您可以在ModelArts使用此自定义镜像创建训练作业，使用ModelArts提供的资源训练模型。

- **用于导入模型**

如果您使用了ModelArts不支持的AI引擎开发模型，可通过制作自定义镜像将模型导入ModelArts，并支持进行统一管理和部署为服务。

资源池

ModelArts提供的大规模计算集群，可应用于模型开发、训练和部署。支持公共资源池和专属资源池两种，分别为共享资源池和独享资源池。专属资源池专属使用，不与其他用户共享。

边缘资源池

ModelArts Edge为客户提供了统一边缘部署和管理能力，支持统一纳管异构边缘设备，提供模型部署、模型和节点管理、资源池与负载均衡、License管控等能力，帮助客户快速构建高性价比的边云协同AI解决方案。

AI Hub

AI Hub是在ModelArts的基础上构建的开发者生态社区，您可以将自己开发的模型、算法分享至市场，共享给个人或者公开共享。

2.2 模型训练

训练

训练指的是模型训练，指通过分析手段、方法和技巧对准备好的数据进行探索分析，从中发现因果关系、内部联系和业务规律。训练模型的结果通常是一个或多个机器学习或深度学习模型，模型可以应用到新的数据中，得到预测结果。

调试训练作业

ModelArts集成了基于开源的JupyterLab，可为您提供在线的交互式开发调试。您无需关注安装配置，在ModelArts管理控制台创建调试模式的训练作业，编写和调测模型训练代码，然后基于该代码进行模型的训练。调试训练作业会开启SSH连接，用户本地IDE可以远程连接到ModelArts的调试训练作业中，调试和运行代码。

VS Code 插件

由于AI开发者会使用VS Code工具开发算法或模型，为方便快速将本地代码提交到ModelArts的训练环境、符合本地开发习惯地编写启动命令，ModelArts提供了一个训练作业场景下的IDE插件，用户可通过简易的操作，实现在本地IDE中进行训练配置、资源监控、作业管理、代码管理等能力。

PyCharm 插件

由于AI开发者会使用PyCharm工具开发算法或模型，为方便快捷将本地代码提交到ModelArts的训练环境，ModelArts提供了一个PyCharm插件工具PyCharm ToolKit，协助用户完成代码上传、提交训练作业、保存训练镜像、将训练日志获取到本地展示等。

分布式训练


当训练数据量很大时，深度学习模型的训练将会非常耗时，将严重阻碍了深度学习应用的开发进度。因此，深度学习训练加速一直是学术界和工业界所关注的重要问题。分布式训练加速需要从软硬件两方面协同来考虑，仅单一的调优手段无法达到期望的加速效果。所以分布式加速的调优是一个系统工程，需要从硬件角度（芯片、硬件设计）考虑分布式训练架构，如系统的整体计算规格、网络带宽、高速缓存、功耗、散热等因素，充分考虑计算和通信的吞吐量关系，以实现计算和通信时延的隐藏。软件设计需要结合高性能硬件特性，充分利用硬件高速网络实现高带宽分布式通信，实现分布式训练系统软硬件端到端的高效协同优化，实现多机多卡分布式环境下训练加速。

2.3 模型部署（旧版推理）

ModelArts提供模型、服务管理能力，支持多厂商多框架多功能的镜像和模型统一纳管。

通常AI模型部署和规模化落地非常复杂。

图 2-1 部署模型的流程



- 在线推理服务，可以实现高并发，低延时，并且支持多模型灰度发布、A/B测试、支持多机多卡和分离部署分布式推理。
- 支持各种部署场景，既能部署为云端的在线推理服务和批量推理任务，也能部署到端、边等各种设备。

- 一键部署，可以直接推送部署到边缘设备中，选择智能边缘节点，推送模型。
- ModelArts基于Snt3、Snt3P、Snt9B高性能AI推理芯片的深度优化，具有PB级别的单日推理数据处理能力，支持发布百万个以上云上推理API，推理网络时延为毫秒级。

2.4 模型部署（新版推理）

ModelArts新一代分布式弹性推理平台，结合了强大的大模型支持、弹性推理能力、请求调度优化、资源调度优化和高可靠性，为企业提供了一站式的大模型推理解决方案，显著降低了企业的推理成本和部署复杂度。通过这一平台，企业可以更加聚焦于业务逻辑与创新应用的设计，加速AI应用的落地和迭代，实现业务的高效增长。

- **资源调度优化**

原生k8s不提供多机编排能力，分布式推理场景中，多机角色编排复杂、负载形态缺乏统一标准，导致任务分配低效、资源协同困难，部署复杂度过高，难以实现规模化扩展，支持多机，分角色的推理实例资源编排，帮助客户规模部署多机多卡推理服务。

- **弹性推理能力**

支持按角色、pod和实例多维度的伸缩，支持复杂部署场景，如PD分离场景扩容，确保在不同负载下都能高效运行。提升资源利用率，支持按需扩展和缩减实例。

无缝切换：在实例扩展或缩减过程中，平台能够无缝切换，确保业务连续性和稳定性，避免因资源调整导致的服务中断。

- **请求调度优化**

智能负载均衡：平台内置智能负载均衡算法，能够根据当前请求负载动态调整任务分配，确保每个请求都能得到及时处理。

- **高可靠性**

故障快速恢复：平台具备完善的故障检测和恢复机制，能够快速定位和修复故障，确保业务的稳定运行。

多级故障快恢：支持实例级、单元级、用户自定义恢复的多级故障自动恢复策略，业务无感重调度，故障后推理服务零影响。


2.5 昇腾云脑

昇腾云脑是什么？

ModelArts为用户提供了深度学习和大模型的云上算力、云上训练、部署、推理能力。然而，大模型海量计算和强同步的特点，使得训练过程极其复杂且资源消耗巨大，例如，训练一个具有1750亿参数的GPT类的模型，可能需要在1000个NPU集群上运行两个月之久。在这样长时间的训练过程中，可能出现硬件故障，而硬件故障导致大规模训练稳定性差（业界平均2、3天中断一次），同时集群在扩展规模时，也存在通信流量冲突、慢节点、慢网络等问题，导致线性度下降严重（千卡线性度70%-80%）。为解决该类问题，ModelArts开发了昇腾云脑平台。昇腾云脑是为使用ModelArts的用户提供运维能力的平台，通过标准巡检、深度巡检、日志诊断、网络大脑诊断、存储诊断和Profiling诊断等能力，帮助用户诊断故障，提高故障定位和定界效率，从而快速恢复故障，提升运维的效率，降低运维成本。

功能介绍

图1 昇腾云脑产品能力地图



昇腾云脑提供全栈诊断与健康巡检两大核心服务能力。

- **健康巡检：**包括标准巡检和深度巡检。
 - 标准巡检主要用于常规检测，巡检项包括：ModelArts任务配置和状态、主机配置和状态、NPU健康检查、CCE集群插件配置和状态、依赖云服务状态、网络状态等分钟级快速巡检，不影响节点上的作业。
 - 深度巡检主要用于硬件压测和故障定位，巡检项包括：NPU压测、网络压测等，小时级巡检，影响节点上的作业。
- **全栈诊断**包含通用诊断、日志诊断、网络大脑诊断、存储诊断、Profiling诊断和标准巡检等能力，当用户作业发生故障时，可通过全栈诊断快速定界定位，识别出异常节点并给出可行的快恢建议。

昇腾云脑使用指导请参考《[ModelArts 7.2.1-HCS 维护指南\(for 华为云Stack 8.6.0\)](#)》> 昇腾云脑使用手册。

3 支持的 AI 框架

ModelArts预置镜像支持的常用AI框架请参见如下描述。

模型推理（旧版推理）

在ModelArts创建模型时，若使用预置镜像“从OBS中选择”或“从训练中选择”导入模型，则支持如下常用引擎及版本。若要使用除此之外的引擎，可以使用“从训练中选择”和“从容器镜像中选择”的方式导入模型，或者使用“从OBS中选择”的方式导入模型，选择使用Custom引擎。

表 3-1 支持的常用引擎及其 Runtime

模型使用的引擎类型	支持的运行环境（Runtime）	注意事项
TensorFlow	tf2.1-python3.7 tf1.13-python3.7-cpu tf1.13-python3.7-gpu	- 无后缀的Runtime表示CPU或GPU的模型都适用，带后缀cpu或gpu表示仅适用于CPU或GPU的模型。 - 默认使用的Runtime为tf2.1-python3.7。 - 默认启动命令：sh /home/mind/run.sh
PyTorch	pytorch1.4-python3.7	- 适用于CPU或GPU的模型。 - 默认使用的Runtime为pytorch1.4-python3.7。 - 默认启动命令：sh /home/mind/run.sh
Spark_MLlib	pyspark2.4.5-python3.7	- 仅适用于CPU的模型。 - 默认使用的Runtime为pyspark2.4.5-python3.7。 - 默认启动命令：bash /home/work/predict/bin/run.sh

模型使用的引擎类型	支持的运行环境 (Runtime)	注意事项
Scikit_Learn	xgb1.2.1-skl0.24.2-python3.7	• 仅适用于CPU的模型。 • 默认使用的Runtime为xgb1.2.1-skl0.24.2-python3.7。 • 默认启动命令：bash /home/work/predict/bin/run.sh
XGBoost	xgb1.2.1-skl0.24.2-python3.7	• 仅适用于CPU的模型。 • 默认使用的Runtime为xgb1.2.1-skl0.24.2-python3.7。 • 默认启动命令：bash /home/work/predict/bin/run.sh

4 约束与限制

本节介绍ModelArts在使用过程中的约束和限制。

浏览器约束限制

ModelArts部分组件WEB界面与浏览器不兼容，为了确保ModelArts组件能够正常运行，建议使用以下浏览器版本：

- Chrome浏览器：建议使用官方发布的最新的3个稳定版本。
- Microsoft Edge浏览器：作为Win10的默认浏览器，建议使用官方发布的最新的3个稳定版本。

工作空间约束限制

ModelArts中工作空间常见的约束限制：

分类	使用限制
流控约束	• 单用户：120次请求/分钟。 • 单接口：1000次请求/分钟。
创建工作空间数量	• 每个资源空间下可以创建工作空间总数≤ 200。
添加用户数&委托数	• 每个工作空间 ≤ 500。
批量鉴权接口	• 单次鉴权数 ≤ 128

模型训练-约束限制

ModelArts中模型训练常见的约束限制：

表 4-1 训练配置-常见参数的约束限制

分类	使用限制
流控约束	- 单用户：200次请求/分钟。 - 单接口：1000次请求/分钟。
训练作业数量	单用户默认支持创建10000条。
超参	总数 $\leq$ 100条。
环境变量	总数 $\leq$ 100条。
实例数	当节点数 $\geq$ 10时，系统会自动删除pip源配置，建议提前安装所有的pip依赖。

表 4-2 训练配置-OBS 桶的约束限制

分类	使用限制
代码目录	目录内文件总大小 $\leq$ 5GB，文件数 $\leq$ 1000个，文件深度 $\leq$ 32。
输入-数据存储位置	文件总大小 $\leq$ 10GB，文件数 $\leq$ 1000个，单文件大小 $\leq$ 1GB。最多添加128条输入数据。
输出-数据存储位置	文件总大小 $\leq$ 1GB，文件数 $\leq$ 128个，单文件大小 $\leq$ 128MB。最多添加128条输出数据。

表 4-3 功能使用限制

分类	使用限制
训练日志	- 训练日志仅保留30天，超过30天会被清理。如果用户需要永久保存日志，请在创建训练作业时，打开永久保存日志开关，设置作业日志路径即可将日志转存至OBS路径。 - Ascend训练场景下，默认要求填写作业日志在OBS的存放路径，其他资源的训练场景下，永久保存日志开关需要用户手动开启。
Cloud Shell	- 仅专属资源池支持使用Cloud Shell登录训练容器，且训练作业必须处于“运行中”状态。 - 使用订阅算法创建的训练作业，不支持使用Cloud Shell登录训练容器。
创建算法	在“创建算法”页面，来源于AI Hub中订阅的算法不支持另存为新算法。
作业优先级	仅使用新版专属资源池训练时，才支持设置训练作业优先级。公共资源池和旧版专属资源池均不支持设置训练作业优先级。

分类	使用限制
指定节点	创建训练作业时，开启此开关，可以手动将训练作业调度到合适的空闲节点。 手动指定节点有如下约束限制： - 仅支持物理池与逻辑子池，不支持公共池与逻辑池。不支持 Snt9b23规格的资源池。 - 逻辑子池需开启节点绑定
分布式训练和调测	仅支持PyTorch和MindSpore框架的分布式训练和调测，如果MindSpore要进行多机分布式训练调试，则每台机器上都必须有8张卡。
故障检测	- 由于检测规则的局限性，当前卡死检测存在一定的误检率。 - 卡死检测仅支持资源类型为GPU和NPU的训练作业。
自动重启	- 自动重启：仅环境问题导致训练作业异常时才会自动重启，其他问题导致训练作业异常时会直接返回“运行失败”。重启次数取值范围1~128，缺省值为3。创建训练后不支持修改重启次数。 - 无条件自动重启：只要系统检测到训练异常，就无条件重启训练作业。需开启“自动重启”开关。为了避免无效重启训练作业，造成算力资源浪费，最多支持连续无条件重启3次。
断点续训练	断点续训练是通过checkpoint机制实现。 使用断点续训练功能，需要满足以下条件： - 用户需要在代码里加上reload ckpt的代码，使能读取前一次训练保存的预训练模型。 - 需要在创建训练作业时，设置训练“输出”参数为“train_url”，在指定的训练输出的数据存储位置中保存Checkpoint，且“预下载至本地目录”选择“下载”。 - 同时建议开启“自动重启”开关。
镜像大小限制	公共资源池容器引擎空间的大小最大支持50G，专属资源池容器引擎空间的默认为50G。 镜像大小的计算方式为： - 使用的是OBS导入或训练导入，则包括基础镜像、模型文件、代码、数据文件和下载安装软件包的大小总和。 - 使用的是自定义镜像导入，则包含解压后镜像和镜像下载文件的大小总和。 - 自定义镜像大小推荐15GB以内，最大不要超过资源池的容器引擎空间大小的一半。镜像过大会直接影响训练作业的启动时间。
支持Snt9b23	仅支持专属池场景。

旧版推理约束限制

表 4-4 模型管理-常见约束限制

分类	使用限制
功能	- 元模型来源为容器镜像支持配置健康检查。 - 元模型来源为训练、对象存储服务（OBS）支持动态加载。 - 同步请求模式不限制部署类型的组合；异步请求模式只支持在线服务和边缘服务，且不支持多种部署类型组合。 - 异步在线服务支持的输入模式有：OBS、URL、Restful、VCN；支持的输出模式有：OBS、Webhook。 - 异步边缘服务支持的输入模式有：Restful、VCN、URL、EdgeCamera，其中ModelArts Edge边缘资源池仅支持Restful输入模式；支持的输出模式有：OBS、Webhook，其中ModelArts Edge边缘资源池仅支持Webhook输出模式。 - 模型大小 $\leq 2000\text{GB}$。 - 单个文件大小 $\leq 51200\text{MB}$。 - 镜像大小 $\leq 50\text{GB}$。
规格和性能	- 单个账号模型数量 ≤ 1000个。 - 模型大小 $\leq 300\text{GB}$。 - 并发创建模型 $\leq 2\text{TPM}$（模型大小 $\leq 500\text{MB}$）。即每分钟最多可以同时创建2个模型，且每个模型的大小不超过500MB。 - Roma Connect场景，API数量 ≤ 250个（如需扩容，请联系运维人员按需对环境中Roma实例的规格进行变更）。
支持Snt9b23	不支持Snt9b23。

表 4-5 在线服务-常见约束限制

分类	使用限制
功能	- 部署单个在线服务，实例数最大不超过2,147,683,647个。 - 部署在线服务支持使用公共资源池、专属资源池、逻辑子池、逻辑资源池。 - 在线服务预测请求支持IAM Token认证、AK/SK认证（依赖Roma Connect）、APP Code认证（依赖Roma Connect）。 - 算力切分只支持Snt3p类型专属池。 - 部署在逻辑子池的多机多卡服务不支持节点亲和。 - 在线服务支持配置调度优先级，但是推理服务本身不支持被抢占。

分类	使用限制
规格和性能	• 单个账号在线服务数量 <= 1000个。 • 并发部署在线服务 <= 10 TPM。 • 在线服务部署超时时间最大可设置为300分钟。 • 一个专属池内最多同时运行同步在线服务和批量服务共50个。 • 在线服务最多支持10个标签。 • 在线服务最大可配置的每秒流量限制为300QPS。 • 在线服务最大可配置请求体大小为12M。 • 在线服务最大可配置请求超时时间为600秒。
支持Snt9b23	• 不支持Snt9b23。

表 4-6 异步在线服务-常见约束限制

分类	使用限制
功能	• 部署单个异步在线服务，实例数最大不超过2,147,683,647个。 • 部署在线服务支持使用公共池、专属池、逻辑子池、逻辑池。 • 不支持多机多卡能力。
规格和性能	• 单个账号异步在线服务数量 <= 1000个。 • 并发部署异步在线服务 <= 10TPM。 • 异步在线服务部署超时时间最大可设置为300分钟。 • 异步在线服务最多支持10个标签。
支持Snt9b23	• 不支持Snt9b23。

表 4-7 批量服务-常见约束限制

分类	使用限制
功能	- 部署单个批量服务，实例数最大不超过2,147,483,647个。 - 部署批量服务支持使用公共池、专属池、逻辑子池。 - 批量服务不支持配置标签。 - 批量服务支持文本文件、图片的数据格式。 - 输入数据为图片时，单张图片小于12MB。 - 输入数据格式为csv时，不要包含中文。 - 输入数据格式为csv时，文件大小不超过12MB。 - 批量服务支持配置调度优先级，但是推理服务本身不支持被抢占。
规格和性能	- 单个账号批量服务数量 ≤ 100个。 - 并发部署批量服务 ≤ 10TPM。 - 批量服务部署超时时间最大可设置为300分钟。 - 一个专属池内最多同时运行同步在线服务和批量服务共50个。
支持Snt9b23	不支持Snt9b23。

边缘推理-约束限制

表 4-8 边缘推理-常见约束限制

分类	使用限制
配额	- 单个账号最多创建100个边缘节点。 - 单个账号最多创建60个边缘资源池。 - 单个账号最多创建500个边缘服务。
边缘节点	- 对于已经纳管为资源池的边缘节点，不允许更新证书。 - 节点网卡不能变更，否则导致节点异常。 - 新版本固件需要运维人员提前录入，且不支持批量升级。 - 边缘节点规格要求请参见表4-9。

分类	使用限制
边缘资源池	- 边缘资源池部署模式（容器镜像、AI大模型、CV大模型等场景），每个节点的根目录需$\geq 50\text{GB}$。 - 单次创建资源池时，最多选择3个主控节点，最多选择64个工作节点。主控节点和工作节点必须是同一架构类型的节点。 - 工作节点建议不大于16，否则可能触发超时导致创建失败。 - 创建资源池时，选择的所有节点需要能互相网络访问，否则会导致创建失败。 - 只支持对状态为“运行中”的资源池进行扩缩容，且不支持增删主控节点。
边缘服务	- 部署单个边缘服务，实例数最大不超过50个。 - 部署边缘服务支持使用公共池、专属池。 - 使用OBS挂载需要为节点安装NFS服务端。 - 使用OBS挂载支持模型断点续传，例如当网络不稳定引起模型下载中断时，网络恢复后模型将自动续传，无需重新部署。 - 服务事件最多保留1个月。 - 对于配置了端口映射的服务，在单节点的资源池中，不支持滚动升级。
负载均衡与访问端口	- 建议1个负载均衡最多绑定20个转发配置，超出数量时无法保证性能。 - 同一个边缘服务最多支持创建10个访问端口。
日志	- 本地日志：日志滚动数量默认为5天。每隔5天，对日志进行一次日志滚动，删除最旧的日志文件。每个日志文件固定10M。 - 日志上报LTS：日志存储时间默认为7天。 - 上传到云日志服务（LTS）：需要在节点详情页，开启日志上报功能。
规格和性能	- 单个账号边缘服务 ≤ 1000 个。 - 并发部署边缘服务 $\leq 10\text{TPM}$。即部署边缘服务时，每分钟最多可以同时部署10个边缘服务实例。
加速卡虚拟化	- 仅支持ModelArts Edge边缘资源池部署方式。 - 算力共享仅支持Snt3p物理机。

表 4-9 边缘节点规格要求

项目	规格
OS	x86_64 架构和arm64架构均选择Huawei Cloud EulerOS HCE 2.0.2412.1 。 说明 产品当前仅支持Huawei Cloud EulerOS HCE 2.0.2412.1，其它规格的OS无法保证功能，不建议使用。

项目	规格
内存	边缘节点内存基础开销约64M，根据业务不同，内存开销不同，建议配置大于256M。
CPU	基础开销>=1核，docker+k3s/k8s场景建议配置>=4核。
硬盘	- 边缘节点部署模式（算法包、摄像头视频推理等场景），节点的根目录需要>=512M。 - 边缘资源池部署模式（容器镜像、AI大模型、CV大模型等场景），每个节点的根目录均需要>=50GB。
GPU（可选）	同一个边缘节点/边缘池的GPU型号必须相同。注册边缘节点时，可以选择是否使用GPU。如果边缘节点要使用GPU，需要在注册边缘节点前安装GPU驱动。 当前支持Tesla系列Tnt004型号GPU，具体安装方式联系设备厂商获取支持。
NPU（可选）	昇腾AI加速处理器。注册边缘节点时，可以选择是否使用NPU加速。当前支持Snt9(包括Snt9B)/Snt3P/Snt3系列NPU加速卡，NPU驱动支持对应型号的NPU即可。 - 如果边缘节点要使用NPU，需求确保边缘节点已安装驱动，具体安装方式请联系设备厂商获取支持。 - 如果要在边缘资源池（集群）场景下使用NPU加速卡，还需要安装集群相关的插件，具体安装方式请参考《华为云Stack 8.6.0 技术中台与AI数据中台服务扩容指南》的“边缘资源池启用加速卡”章节。
容器引擎	Docker版本为19.03.11。打开 docker下载地址 ，根据CPU架构选择对应文件夹进入后下载。可参考边缘节点安装与配置。
K3s引擎	安装版本为v1.21.12+k3s1。打开 k3s下载地址 ，选择对应的CPU架构，下载k3s二进制文件和tar.gz镜像包。可参考边缘节点安装与配置。
网络要求	- 边缘节点需要访问ModelArts、SWR、OBS、AOM、LTS平台提供的接口。 - 边缘资源池内部的节点需要互相访问。 具体IP和端口请参考《华为云Stack 8.6.0 通信矩阵》>EI企业智能服务>《(ModelArts) 7.2.0-HCS 通信矩阵(for 华为云Stack 8.6.0)》的“正文(边缘节点)”sheet表。

项目	规格
端口使用	边缘节点安装的edge-agent固件需要使用5066、5067端口。 边缘资源池运行的k8s/k3s需要使用2379、2380、6443、53、8472端口。 挂载OBS模型需要启动NFS服务，需要使用111、2049、20048端口。 说明 启用防火墙策略时，需要放通给边缘池的所有节点IP，以确保集群内所有节点均能访问。添加以下策略： 主控节点：开放入方向5066、6443、2380。 工作节点：开放入方向5066。 需要挂载OBS模型时，安装了NFS服务的节点还需开放入方向111、2049、20048。
时间同步	边缘节点时间需要与UTC标准时间保持一致，否则会导致边缘节点的监控数据出现偏差。您可以选择合适的NTP服务器进行时间同步，从而保持时间一致。也可以保持和云端常连接，同步云端时间。

新版模型推理-约束限制

ModelArts中模型推理常见的约束限制：

表 4-10 在线服务-常见约束限制

分类	使用限制
规格	• 单个账号可创建的在线服务数量目前没有限制。 • 单个在线服务最多支持10个版本。 • 单个工作空间最多支持200个标签，单个在线服务最多支持10个标签。 • 最大昇腾卡规模支持384卡。

分类	使用限制
部署单元	- 部署在线服务只支持使用专属池、逻辑子池（Snt9b）。 - 部署单个在线服务，实例数最大不超过128个。 - 在线服务支持配置调度优先级，推理服务不支持被抢占。 - Snt9b23场景，用于部署多机多卡在线服务的专属池内只能有一个超节点。 - 镜像类型支持容器镜像服务(SWR)的自有镜像和共享镜像。 - 镜像拉取策略默认为 IfNotPresent，当节点上已经存在相同名称和标签（Tag）的镜像时，即使远端仓库中该标签对应的镜像内容已经更新（即Digest已变），也不会重新拉取。 - 模型来源支持对象存储服务 OBS、并行文件系统 PFS、弹性文件服务 SFS Turbo、资源池已预热模型，最多支持30个模型源地址，每个地址的挂载路径要求服务内唯一。 - 代码来源支持对象存储服务 OBS、并行文件系统 PFS、弹性文件服务 SFS Turbo，最多支持一个代码地址，地址的挂载路径要求服务内唯一。 - 在线服务容器实例注入环境变量最多支持30个。 - 健康检查支持启动探针、就绪探针和存活探针。 - 支持硬件故障自动重启，只支持针对整节点复位，请确保部署的在线服务为8*N卡规格，请谨慎评估对部署在该节点的其他服务的影响。 - 故障恢复策略支持实例恢复、单元恢复、自定义恢复。 - 开启高可用后，不同实例下的pod将尽量均匀分布到不同节点上，同一实例下的多个Pod尽量分配到相同节点上，保证推理服务高可用。 - 亲和调度支持节点亲和与节点反亲和类型，亲和强度支持弱亲和与强亲和。弱亲和尽量或避免将Pod调度到指定节点，不保证成功；强亲和必须或禁止将Pod调度到指定节点，否则不执行调度。 - 只有选择NPU规格部署的服务支持volcano调度和binpack紧凑装箱功能，选择CPU规格的默认不支持。
服务管理配置	- 自动停止预设时长最大支持24小时。 - 在线服务部署超时时间最大可设置为300分钟。 - 服务升级只支持滚动升级方式。 - 最大浪涌实例数支持100%。 - 最大无效实例数支持100%。

分类	使用限制
服务调用配置	• 服务调用接口协议支持HTTP、HTTPS、WS、WSS。 • 认证方式支持API Key、IAM Token、无认证方式，不支持AK/SK、APP Code认证方式。 • 在线服务最大可配置的每秒流量限制为2000QPS。 • 在线服务最大可配置请求体大小为50M。 • 在线服务最大可配置请求超时时间为7200秒。 • 在线服务最多支持添加10个IPv4的CIDR黑名单或白名单。
网络配置	• 外网访问关闭时不允许通过互联网访问在线服务。 • 内网连接审批关闭后三方用户的内网接入申请自动生效，无需审批。
在线服务日志	• 支持服务基础日志（默认日志），要求实例Pod处于“运行中”状态，在线服务处于“异常”或“停止”状态下默认日志将不可用且无法查询历史日志。默认日志不会以其他方式保存，如有需要可及时完成下载。 • 支持开启云日志服务LTS，要求在线服务所属资源池已安装云原生日志采集插件，LTS日志支持保留7天，超过7天会被清理。LTS其他使用约束与限制请参考表4-18。
高级配置	• 智能路由支持轮询、源IP哈希、最小连接数、最小首Token时延、综合负载、SLO优先级策略，智能路由不开启时为随机策略。 • 自定义密钥挂载最多支持30个，每个密钥的挂载路径要求服务内唯一。 • 自定义监控采集指标的接口协议支持http、https，接口需由镜像实现且接口返回数据格式需符合标准Open Metric规范，系统每30秒请求该接口对指标进行采集并上报至AOM，单次采集指标总长度最大支持32K，AOM使用约束与限制请参考表4-17。
对接资源池权重预热	• 只支持基于Snt9b专属池、逻辑子池部署在线服务。 • 权重预热被删除后，已关联预热任务的在线服务的扩容受影响，需要升级在线服务同时绑定新的权重预热任务才能解决。 • 挂载到在线服务容器内的权重预热目录只读，无写操作权限。
算力切分	• 暂不支持算力切分。
在线服务扩缩容	• 支持创建周期触发扩缩容规则。 • 周期触发时间支持每天、每周、每月、每年的某一分钟或最小粒度为分钟的cron表达式，同一分钟不允许出现多个扩缩容策略。 • 扩缩容目标实例数范围：1-128。

分类	使用限制
在线服务监控	支持在线服务请求统计类指标和资源使用类指标，指标上报与查询依赖AOM约束与限制，请参考 表4-17 。
Cloud Shell	支持使用Cloud Shell登录在线服务容器，且在线服务的实例Pod必须处于“运行中”状态。
在线服务事件	- 服务事件保存周期为1个月，1个月后自动清理数据。 - 事件保存周期为1个小时，1个小时后自动清理数据。
支持Snt9b23	- 只支持专属池场景。 - 专属池内只能存在一个物理超节点(主机组)，最大规模为384卡。 - 专属池内超节点的节点不能跨物理超节点(主机组)。 - 不支持跨超节点部署推理服务。 - 不支持镜像预热和权重预热。 - 不支持Snt9b23裸机形态部署。

专属资源池-约束限制

表 4-11 专属资源池-常见约束限制

分类	使用限制
规格	购买的所有类型的计算资源均不支持跨Region使用。
配额	单个账号最多创建50个专属资源池。
功能	单次创建专属资源池时，节点数建议不大于30，否则可能触发限流导致创建失败。
扩缩容	- 只支持对状态为“运行中”的专属资源池进行扩缩容。 - 缩容规格实例数时，当资源池中只剩一个实例节点时，无法进行缩容操作。因此，缩容操作必须确保至少保留一个节点。 - 缩容操作有可能影响正在运行中的任务，且该动作不可回退。
逻辑资源池	当前只支持Snt9系列的卡创建逻辑资源池。 说明 逻辑资源池是白名单功能，如有需求请联系运维人员处理。

分类	使用限制
逻辑子池	● Snt9b23的资源池不支持创建逻辑子池。 ● 逻辑子池创建时，物理资源池不能有作业。 ● 逻辑子池开启绑定节点时，不能有作业运行。 ● 物理池创建逻辑子池后，不能再设置高可用冗余节点。
节点	根据节点规格不同，节点默认最大实例数参考 表4-12 。
驱动升级	● 专属资源池状态处于运行中，且专属池中的节点需要含有GPU/Ascend资源才支持驱动升级。 ● 升级需要重启节点，建议在低峰期进行，以避免影响正在运行的任务。
作业类型修改	专属资源池状态处于“运行中”才能修改作业类型。
算力切分	Snt9b自动算力切分仅支持驱动版本大于等于24.1.rc2。
权重预热与镜像预热	● 物理池有模型预热作业时不能创建逻辑子池。 ● 物理池有逻辑子池时不能创建物理池模型预热作业，需要绑定节点后为子池创建模型预热作业。 ● 模型预热任务占用资源池节点内存空间，在资源池同时使用训练作业及推理作业的场景下，为保障训练作业不受模型预热任务影响，建议通过创建逻辑子池隔离推理、训练场景并开启节点绑定，然后在推理作业逻辑子池中创建模型预热任务。 ● 镜像预热仅支持Snt9b资源。
超节点	● 一个资源池仅支持一个物理超节点，单一任务不能跨物理超节点（最大384卡）。 ● 不支持修改已发放的超节点规格步长，无法升降配规格。 ● 小于48步长超节点不支持扩容到48，同理48超节点不支持缩容。 ● 机器故障后，不支持备机更换，如节点故障，会进行节点重调度、JOB重调度。 ● 无法支持Snt9b23超节点的物理资源池xpod规格拆分为多个更小颗粒度步长的逻辑子池，不支持多个子用户独立隔离使用。 ● 基于超节点发放出的物理资源池，不支持逻辑子池进行节点绑定。投递推理/训练作业，无法指定某几台节点。 ● 常规规格：设置2台、4台、8台、16台、32台、48台（不建议创建2台、4台规格，该场景下无法发挥超平面）。 ● Snt9b23只支持创建专属资源池，不支持创建逻辑资源池和逻辑子池。

表 4-12 节点默认最大实例数

内存	节点默认最大实例数
4G	20
8G	40
16G	60
32G	80
64G及以上	110

表 4-13 插件约束限制

分类	使用限制
AI套件（NV GPU）	- 创建专属资源池时，仅实例规格类型选择“GPU”时自动安装。 - 插件升级完成前，请勿进行GPU驱动升级，否则可能会导致驱动升级卡住或者失败。
AI套件（ModelArts Device Plugin）	- 创建专属资源池时，仅实例规格类型选择“Ascend”时自动安装。 - 创建训练作业、部署在线服务、部署批量服务时，升级ModelArts Device Plugin插件会影响作业调度，请谨慎执行升级操作。
Volcano调度器(Volcano Scheduler)	- 创建专属资源池时，作业类型选择训练作业时自动安装。 - 升级插件时，谨慎将高版本升级至低版本。版本降级可能存在任务无法调度风险。
指标监控插件(ModelArts Metric Collector)	- 创建资源池时自动安装，不支持卸载。 - 存量资源池，需要将节点故障检测（ModelArts Node Agent）插件版本升级到最新版本，自动安装该插件。 - 在插件升级期间，指标采集pod重启，可能存在短暂指标不上报，请谨慎执行升级操作。
节点故障检测(ModelArts Node Agent)	创建专属资源池时自动安装。
节点本地域名解析加速（NodeLocal DNSCache）	- 支持在专属资源池安装NodeLocal DNSCache。 - 支持CCE版本：v1.31。
云原生日志采集插件(Log Collector)	- 建议安装使用1.7.3及以上版本。 - 支持CCE版本：v1.21-v1.32。

昇腾云脑使用约束限制

表 4-14 昇腾云脑-常见约束限制

分类	使用限制
作业类型	仅支持对ModelArts Snt9b规格的训练作业进行巡检、诊断。
节点规格	仅支持对ModelArts Snt9b规格的节点进行巡检、诊断。
逻辑子池限制	逻辑子池下必须绑定节点才可以进行巡检、诊断。
健康巡检-基础约束	• 巡检作业排队中作业不能超过10个，当排队中的作业数量超过10个时，无法继续创建新的巡检作业。 • 下发压测作业对应节点最多支持同时运行3个巡检作业，超过3个作业，则会执行失败。 • 选择的压测用例需要确保节点空闲，非空闲节点会导致作业失败，巡检结果异常。确认相关节点的状态后，再下发压测作业。 • 深度巡检作业会长时间占用NPU资源（大约3-8小时），确保巡检期间集群无业务运行。 • 巡检作业只保留最近6个月的结果数据。
健康巡检-OBS告警	OBS告警巡检要求训练作业使用OBS存储。
健康巡检-SFS告警	SFS告警巡检要求训练作业绑定SFS Turbo。
健康巡检-多机HCCL参数面通信带宽测试	多机HCCL参数面通信带宽测试需要2个以上节点，且这些节点必须在同一个RoCE网络下。
健康巡检-RoCE网络带宽测试	RoCE网络带宽测试仅支持在2个节点中执行。

分类	使用限制
全栈诊断-日志分析诊断	- 输入目录的日志文件大小会影响执行清洗命令的效率，输入总文件大小应限制在5G以下，文件总数量不能超过1000000。 - CANN应用类日志文件单个文件应限制在20MB以下。 - 用户训练日志大小无限制，会默认读取最后1MB日志。 - Host OS系统日志当前支持messages、dmesg、vmcore_dmesg.txt和sysmonitor.log日志，其中单个文件的转储大小上限限制在512MB以下；dmesg日志取最新的日志，最大100000行。 - 主机侧操作系统日志和Device侧日志请在宿主机上采集。 - 日志诊断结果保留时长最多6个月。 - 状态为“排队中”的日志诊断作业超过20个时，新创建的作业会返回失败。 - 使用日志诊断时，您需要将需要分析的日志数据上传至对象存储服务（OBS）中，并确保上传内容符合OBS路径格式规范。 请规范日志路径格式，否则将导致作业失败。 - 在OBS路径下，每个节点对应一个文件夹，且每个节点文件夹下有且只有该节点的日志，示例： 路径示例格式 obs://OBS桶/子路径/ 目录示例格式 <pre> graph TD Root[] --- Worker0[worker-0/] Root --- Worker1[worker-1/] Worker0 --- Log0[日志/] Worker1 --- Log1[日志/] </pre> - 日志命名请符合昇腾云日志格式。 - 日志分析中填写OBS路径需要对承载租户授权。
全栈诊断-profiling诊断	- profiling巡检作业只保留最近6个月的结果数据。 - profiling分析中填写OBS路径需要对承载租户授权。

分类	使用限制
全栈诊断-网络大脑诊断	网络设备需要通过ManageOne页面进行esight纳管。创建交换机接口指标采集任务，并在esight性能监控中增加监控指标。
全栈诊断-存储诊断	• OBS指标存储诊断要求训练作业使用OBS存储，且OBS虚拟机管理规模大于5000。 • SFS指标存储诊断要求训练作业绑定SFS Turbo。
下载中心	• 下载记录仅支持健康巡检结果导出。 • 导出记录的文件在云端的保存期限为30天，过期的导出记录文件将无法恢复，如需再次查看，请重新导出。 • 导出记录的Excel文件，50000行以下性能无影响，超过50000行可能存在Excel打开缓慢等问题。 • 下载导出记录，需要配置ModelArts对应OBS日志桶的hosts信息。详细请参考 (ModelArts) 7.2.1-HCS 维护指南(for 华为云Stack 8.6.0) 01的“昇腾云脑使用手册>下载中心”章节。
配置中心	仅支持已有配置名称进行创建，且创建、修改与删除仅支持region级操作，非必要不使用，以防影响昇腾云脑功能。

AI Hub-约束限制

表 4-15 AI Hub-常见约束限制

分类	使用限制
单用户请求流控	单用户请求上限300次/分钟。
接口总流控	接口总请求上限3000次/分钟。

Workflow 约束限制

表 4-16 ModelArts 中 Workflow 常见的约束限制

分类	使用限制
流控约束	• 单用户：600次请求/分钟。 • 单接口：1000次请求/分钟。
执行记录的标签	每条执行记录最多5个标签。
最大运行时长	执行记录的单个节点最大运行时长，默认30天，可自定义配置。

依赖服务使用约束

表 4-17 AOM 指标限制

限制类型	小规格	中规格	大规格	超大规格	超大规格 II	使用建议
指标总量限制	500VCPU，约10万指标	1000VCPU，约20万指标	3000VCPU，约60万指标	15000VCPU，约150万指标	30000VCPU，约1000万指标	当指标总量超过限制时，建议通过扩容AOM规格提升性能（请联系运维人员扩容），AOM最大支持接入100000VCPU，约1000万指标。
告警总量限制	200万条	200万条	600万条	3000万条	3000万条	当告警总量超过限制时，建议通过扩容AOM规格提升性能（请联系运维人员扩容），AOM最大支持接入3000万告警。

说明

更多AOM使用约束参考《[应用运维管理 \(AOM\) 使用指南\(for 华为云Stack 8.6.0\)](#)》>产品介绍>约束与限制，如果规格不满足使用述求，需要独立扩容。

表 4-18 LTS 指标限制

限制类型	管理区中规格	管理区大规格	管理区超大规格	管理区超大规格II	下沉区大规格	下沉区超大规格	下沉区超大规格II	使用和建议
LTS 吞吐量	吞吐量基线 6MB/s	吞吐量基线 18MB/s	吞吐量基线 50MB/s	吞吐量基线 50MB/s	吞吐量基线 18MB/s	吞吐量基线 90MB/s	吞吐量基线 180MB/s	- 如果日志吞吐量超过标准规格基线，将会有日志积压，或磁盘写满，或 License 使用超限的风险。 - 平均流量约等于吞吐量基线。部署或扩容后，需要新增导入 License，避免当天日志使用量超过赠送额度，导致日志丢弃。 - 下沉区日志增量包扩容后吞吐量基线计算方法： LTS每天日志量： day_log/GB

限制类型	管理区中规格	管理区大规格	管理区超大规格	管理区超大规格II	下沉区大规格	下沉区超大规格	下沉区超大规格II	使用和建议
								平均流量MB/s=day_log*1024/3600/24

 说明

更多LTS使用约束参考[《云日志服务\(LTS\) 使用指南\(for 华为云Stack 8.6.0\)》](#)>产品介绍>使用限制>日志读写，如果规格不满足使用述求，需要独立扩容。

5 与其他服务的关系

与对象存储服务的关系

ModelArts使用对象存储服务（ Object Storage Service，简称OBS ）存储数据和模型，实现安全、高可靠和低成本的存储需求。OBS的更多信息请参见《 [对象存储服务 3.0\(OBS\) 使用指南\(for 华为云Stack 8.6.0\)](#) 》。

表 5-1 ModelArts 各环节与 OBS 的关系

任务	ModelArts与OBS的关系
模型训练	● 训练作业使用的输入数据存储在OBS中。 ● 训练作业的代码存储在OBS中。 ● 训练作业输出的模型存储在指定的OBS中。 ● 训练作业的过程日志存储在指定的OBS中。
模型管理	训练作业结束后，其生成的模型存储在OBS中，导入模型时，从OBS中导入已有的模型。
模型部署	将存储在OBS中的模型部署上线。 对于批量服务，输入输出数据存储在OBS中。 存储挂载可以挂载OBS桶。 存储挂载可以挂载OBS并行文件系统。

与 SFS Turbo 的关系

SFS Turbo（ Scalable File Service Turbo ）是高性能弹性文件服务，当环境中已安装 SFS Turbo服务后，ModelArts存储挂载可以选择SFS Turbo。SFS Turbo的更多信息请参见《 [高性能弹性文件服务\(SFS Turbo\) 使用指南\(for 华为云Stack 8.6.0\)](#) 》。

与容器镜像服务的关系

当使用ModelArts不支持的AI框架构建模型时，可通过构建的自定义镜像导入 ModelArts进行训练或推理。您可以通过容器镜像服务（ Software Repository for Container，简称SWR ）制作并上传自定义镜像，然后再通过容器镜像服务导入

ModelArts。SWR的更多信息请参见《[容器镜像服务\(SWR\) 使用指南\(for 华为云 Stack 8.6.0\)](#)》。

与智能边缘平台的关系

ModelArts可将模型部署至智能边缘平台（Intelligent EdgeFabric，简称IEF）纳管的边缘节点。IEF的更多信息请参见《[智能边缘平台\(IEF\) 使用指南\(for 华为云Stack 8.6.0\)](#)》。

与应用运维管理的关系

ModelArts使用应用运维管理（Application Operations Management，简称AOM）进行一站式立体化运维管理，实时监控应用及云资源，采集各项指标、日志及事件等数据分析应用健康状态，提供告警及数据可视化功能，帮助用户及时发现故障，全面掌握应用、资源及业务的实时运行状况。AOM的更多信息请参见《[应用运维管理\(AOM\) 使用指南\(for 华为云Stack 8.6.0\)](#)》。

与云容器引擎的关系

ModelArts使用云容器引擎（Cloud Container Engine，简称CCE）部署模型为在线服务，支持服务的高并发和弹性伸缩需求。CCE的更多信息请参见《[云容器引擎\(CCE\) 使用指南\(for 华为云Stack 8.6.0\)](#)》。

与云日志服务的关系

ModelArts创建边缘节点、资源池、新版推理时，可以通过开启LTS日志开关，将服务的运行日志输出存放到云日志服务（LTS）。LTS的更多信息请参见《[云日志服务\(LTS\) 使用指南\(for 华为云Stack 8.6.0\)](#)》。

6 如何访问 ModelArts

ModelArts服务提供了Web化的服务管理平台，即管理控制台和基于HTTPS请求的API（Application programming interface）管理方式。

- **管理控制台方式**

ModelArts提供了简洁易用的管理控制台，包含模型管理、模型部署等功能，您可以在管理控制台端到端完成您的AI开发。

- **API方式**

如果您需要将ModelArts集成到第三方系统，用于二次开发，请使用API方式访问ModelArts，具体操作和API详细描述，请参见《[ModelArts 7.2.1-HCS 使用指南 \(for 华为云Stack 8.6.0\)](#)》>API参考。


7 权限管理

ModelArts作为一个完备的AI开发平台，支持用户对其进行细粒度的权限配置，以达到精细化资源、权限管理之目的。用户在使用ModelArts时，参照用户指南中的“完成ModelArts权限管理”章节来进行初始权限设置。

为了支持客户对ModelArts的权限做精细化控制，提供了权限、委托方面的能力来支撑。下面分别讲解。

理解 ModelArts 的权限与委托

图 7-1 权限管理抽象



ModelArts与其他服务类似，对外暴露的每个功能，都通过权限来进行控制。例如，用户希望在ModelArts创建训练作业，则该用户必须拥有“modelarts:trainJob:create”的权限才可以完成操作（无论界面操作还是API调用）。

而ModelArts还有一个特殊的地方在于，为了完成AI计算的各种操作，AI平台在任务执行过程中需要访问用户的其他服务，典型的就训练过程中，需要访问OBS读取用户的训练数据。在这个过程中，就出现了ModelArts“代表”用户去访问其他云服务的情形。从安全角度出发，ModelArts代表用户访问任何云服务之前，均需要先获得用户的授权，而这个动作就是一个“委托”的过程。用户授权ModelArts再代表自己访问特定的云服务，以完成其在ModelArts平台上执行的AI计算任务。

综上，对于图7-1可以做如下解读：

- 用户访问任何云服务，均是通过标准的权限体系进行访问控制。用户首先需要具备相关云服务的权限（根据您具体使用的功能不同，所需的相关服务权限亦有差异）。
- **权限**：用户使用ModelArts的任何功能，也需要通过权限体系进行正确权限授权。
- **委托**：ModelArts上的AI计算任务执行过程中需要访问其他云服务，此动作需要获得用户的委托授权。

ModelArts 权限管理

默认情况下，管理员创建的用户没有任何权限，需要将其加入用户组，并给用户组授予策略，才能使得用户组中的用户获得对应的权限，这一过程称为授权。授权后，用户就可以基于授予的权限对云服务进行操作。



在对用户组授权的时候，并不是直接将具体的某个权限进行赋权，而是需要先将权限加入到“策略”当中，再把策略赋给用户组。为了方便用户的权限管理，各个云服务都提供了一些预置的“系统策略”供用户直接使用。如果预置的策略不能满足您的细粒度权限控制要求，则可以通过“自定义角色”来进行精细控制。

表7-1列出了ModelArts的所有预置系统策略。

表 7-1 ModelArts 系统策略

策略名称	描述	类型
ModelArts FullAccess	ModelArts管理员用户，拥有所有ModelArts服务的权限	系统策略
ModelArts CommonOperations	ModelArts操作用户，拥有ModelArts服务所有操作权限，不包括管理专属资源池的权限	系统策略
ModelArts Dependency Access	ModelArts服务的常用依赖服务的权限	系统策略

通常来讲，只给管理员开通“ModelArts FullAccess”，如果不需要太精细的控制，直接给所有用户开通“ModelArts CommonOperations”即可满足大多数小团队的开发场景诉求。

在赋予用户CommonOperations权限后，再去配置“允许”细粒度权限，细粒度权限将不会生效，权限仍以CommonOperations为准，因此，建议在配置细粒度权限时，不要同时赋予CommonOperations权限。

说明

ModelArts的权限不会凌驾于其他服务的权限之上，当您给用户进行ModelArts赋权时，系统不会自动对其他相关服务的相关权限进行赋权。这样做的好处是更加安全，不会出现预期外的“越权”，但缺点是，您必须同时给用户赋予不同服务的权限，才能确保用户可以顺利完成某些ModelArts操作。

举例，如果用户需要用OBS中的数据进行训练，当已经为用户配置ModelArts训练权限时，仍需同时为其配置对应的OBS权限（读、写、列表），才可以正常使用。其中OBS的列表权限用于支持用户从ModelArts界面上选择要进行训练的数据路径；读权限主要用于数据的预览以及训练任务执行时的数据读取；写权限则是为了保存训练结果和日志。

ModelArts 委托授权

前文已经介绍，ModelArts在执行AI计算任务过程中，需要“代表”用户去访问其他云服务，而此动作需要提前获得用户的授权，此类授权动作是通过“委托”来完成。

为了简化用户的委托授权操作，ModelArts增加了自动配置委托授权的支持，用户仅需在ModelArts控制台的“权限管理”页面中，为自己或特定用户配置委托即可。

说明

目前ModelArts的委托授权操作是分区操作，这意味着您需要在每个您所用到区域均执行委托授权操作。

在ModelArts控制台的“权限管理”页面，单击“添加授权”后，系统会引导您为特定用户或所有用户进行委托配置，若授权对象类型为“子用户”时，默认委托名称为“ma_agency_[授权对象名称]”。若授权对象类型为其他对象类型时，默认委托名称为“modelarts_agency”。若上述规则生成的委托名称已存在，则名称新增四位随机码后缀。

在权限配置区域，您可以选择ModelArts提供的预置配置，也可以自定义选择您所授权的策略。

图 7-2 添加授权

< | 添加授权

授权对象类型 子用户 委托用户 所有用户

授权对象

委托选择 已有委托 新增委托

委托名称

您最多可以创建200个委托，您还可以创建154个委托。 [命名策略](#)

权限配置

普通用户

包括用户使用ModelArts完成AI开发的所有必要功能权限，如数据的访问、任务的创建和管理等。

[查看权限列表](#)

自定义

可以灵活按需配置ModelArts创建的委托权限。如您有精细化权限管理的需求，可使用此模式。

在权限列表中按需选择所需权限。

如果这两种形态对于您的诉求均不够精细，您也可以直接在权限管理（登录控制台，进入“系统 > 权限管理”）页面里创建完全由您进行精细化配置的委托（需要委托给

ModelArts服务)，然后在ModelArts控制台“权限管理>添加授权”页面，委托选择“已有委托”。

在使用ModelArts时，您可能会注意到一个关键点：系统会将委托与用户进行关联，用户与委托的关系是多对1的关系。这意味着，当多个用户需要配置相同的委托时，无需为每个用户单独创建委托项，只需将这些用户统一指向同一个委托项即可。

说明

每个用户必须关联委托才可以使用ModelArts，但即使委托所赋之权限不足，在API调用之初也不会报错，只有到系统具体使用到该功能时，才会发生问题。当您做深入的“权限最小化”限制时，请确保您在ModelArts上将要执行的操作仍旧有足够的权限。

用工作空间限制资源访问

工作空间是ModelArts面向企业客户提供的-一个高阶功能，用于进一步将用户的资源划分在多个**逻辑隔离**的空间中，并支持以空间维度进行访问的权限限定。

系统会默认为您创建一个“default”空间，您之前所创建的所有资源，均在该空间下。当您创建新的工作空间之后，相当于您拥有了一个新的“ModelArts分身”，您可以通过菜单栏的左上角进行工作空间的切换，不同工作空间中的工作互不影响。

创建工作空间时，必须绑定一个企业项目。多个工作空间可以绑定到同一个企业项目，但一个工作空间**不可以**绑定多个企业项目。借助工作空间，您可以对不同用户的资源访问和权限做更加细致的约束，具体为如下两种约束：

- 只有被授权的用户才能访问特定的工作空间（在创建、管理工作空间的页面进行配置），这意味着，像数据集、算法等AI资产，均可以借助工作空间做访问的限制。
- 在前文提到的权限授权操作中，如果“授权类型”设定为“按企业项目授权”，那么该授权仅对绑定到该企业项目的工作空间生效。

说明

- 工作空间的约束与权限授权的约束是叠加生效的，意味着对于一个用户，必须同时拥有工作空间的访问权和训练任务的创建权限（且该权限覆盖至当前的工作空间），他才可以在这个空间里提交训练任务。
- 对于已经创建企业项目但没有创建工作空间的用户，其所有操作均相当于在“default”企业项目里进行，请确保对应权限已覆盖了名为default的企业项目。
- 对于未创建企业项目的用户，不受上述约束限制。

本章小结

对于ModelArts的权限管理，总结了如下关键点：

- 对于所有用户（包括个人用户），需要完成对ModelArts的**委托授权**（ModelArts > 权限管理 > 添加授权），才能使用特定的功能，否则会造成您的操作出现不可预期的错误。
- 对于创建了企业项目的用户，可以进一步申请创建ModelArts的**工作空间**，通过组合使用基础授权和工作空间，来达成更加复杂的权限控制目的。