

ModelArts 7.2.1-HCS 运维指南

文档版本 01
发布日期 2025-10-30



版权所有 © 华为云计算技术有限公司 2026。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HUAWEI和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为云计算技术有限公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为云计算技术有限公司对本文档内容不做任何明示或暗示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为云计算技术有限公司

地址：贵州省贵安新区黔中大道交兴功路华为云数据中心 邮编：550029

网址：<https://www.huaweicloud.com/>

目录

1 前言.....	1
2 运维场景指引.....	3
3 ModelArts 常见概念及对应操作.....	6
4 ModelArts 运维场景下常见租户介绍.....	8
5 配置指南.....	11
5.1 资源管理.....	11
5.1.1 资源管理简介.....	11
5.1.2 管理公共资源池.....	12
5.1.3 集群管理.....	21
5.1.4 资源池管理.....	22
5.1.5 节点管理.....	24
5.1.6 隔离节点及关闭节点隔离.....	27
5.1.7 规格管理.....	30
5.1.8 节点配置管理.....	53
5.1.9 资源租户.....	54
5.1.10 插件.....	55
5.1.11 RoCE 网络.....	57
5.2 审批流程管理.....	58
5.2.1 设置 ModelArts 审批流程.....	58
5.3 基础镜像注册.....	59
5.3.1 制作、上传并注册 ModelArts 推理预置镜像.....	59
5.3.2 注册 ModelArts 训练基础镜像.....	65
5.4 GPU/NPU 驱动管理.....	66
5.4.1 录入新的 GPU 驱动版本.....	66
5.4.2 全量升级 Snt9 Snt9b Snt9b23 NPU 固件驱动.....	68
5.5 添加白名单开关操作.....	69
5.5.1 增加使用节点本地存储缓存的白名单.....	69
5.5.2 添加终端节点服务白名单（去 roma 实例场景）.....	70
5.5.3 ModelArts 推理打开 IEF 服务相关开关.....	70
5.5.4 开启资源池不限制容器引擎空间大小上限.....	71
5.6 （旧版推理）模型及服务管理.....	71
5.6.1 调整单个模型的大小配额.....	71

5.6.2 配置域名证书.....	72
5.6.3 获取 ROMA Connect SDK.....	74
5.6.4 基于 ROMA 调用的流式输出卡顿问题优化.....	74
5.6.5 修改在线服务超时时间.....	75
5.6.6 修改批量服务超时时间.....	76
5.7 AI Hub 管理.....	77
5.7.1 AI Hub 管理员账户变更.....	77
5.7.2 AI Hub 管理员运营操作.....	79
5.7.3 AI Hub 管理员导入资产.....	80
5.8 ModelArts 安装部署后的后续操作.....	81
5.8.1 ModelArts 细粒度鉴权开启严格模式.....	81
5.8.2 ModelArts 部署或者升级完后，重新部署 SFS Turbo.....	82
5.8.3 适配 CCE 补丁升级后更改 ModelArts 参数.....	84
5.9 ModelArts-Common-Proxy 组件健康检查.....	87
5.9.1 修复 ModelArts-Common-Proxy os 漏洞后 ModelArts-Common-Proxy 组件健康检查与恢复.....	87
5.10 （旧版推理）在线服务迁移方案.....	90
5.10.1 存量 nativev1 子池推理在线服务迁移.....	90
5.10.2 存量 nativev1 物理池推理在线服务迁移.....	93
5.10.3 推理资源工作空间迁移的手动操作指导.....	97
5.11 （新版推理）ModelArts 推理服务创建物理专属网关操作指导.....	105
5.11.1 概述.....	105
5.11.2 前提条件.....	106
5.11.3 安装专属 Dispatcher.....	107
5.11.4 扩容 Dispatcher.....	110
5.11.5 专属 Dispatcher 升级.....	113
5.11.6 管理专属 Dispatcher 绑定的资源空间.....	114
5.11.7 新版推理在线服务迁移到新 Dispatcher 组手工方案.....	114
5.11.8 附录.....	118
5.11.8.1 获取公共 Dispatcher 节点规格信息.....	118
5.11.8.2 登录 Mysql 数据库.....	120
5.11.8.3 如何获取用户 ID、租户 ID 和资源空间 ID.....	120
5.11.8.4 命名规范.....	121
5.11.8.5 SQL 示例.....	122
5.12 ModelArts License 去除试用期校验.....	123
6 巡检指南.....	124
6.1 概述.....	124
6.2 检查 ModelArts 告警.....	124
6.3 使用 FusionCare 巡检.....	125
6.3.1 登录 FusionCare 界面.....	125
6.3.2 日常巡检.....	126
6.3.2.1 日常巡检项.....	126
6.3.2.2 创建巡检任务.....	137

6.3.2.3 查看巡检任务.....	140
6.3.2.4 查看巡检结果.....	141
6.3.3 自动化验收.....	143
6.3.3.1 自动化验收用例.....	143
6.3.3.2 新建自动化验收任务.....	144
6.3.3.3 查看自动化验收任务执行状态.....	146
6.3.3.4 查看验收任务详情.....	146
6.3.3.5 导出并查看任务报告.....	147
7 备份与恢复.....	148
7.1 概述.....	148
7.1.1 场景说明.....	148
7.1.2 备份与恢复策略.....	149
7.2 备份数据.....	150
7.2.1 ManageOne 统一备份数据库.....	151
7.3 恢复数据.....	151
7.3.1 恢复 ManageOne 统一备份的数据库.....	151
7.3.1.1 恢复 GaussDB.....	152
7.3.1.2 恢复 MySQL.....	153
8 安全管理.....	156
8.1 账户管理.....	156
8.1.1 账户一览表.....	156
8.1.2 账户安全设置.....	156
8.1.3 修改账户密码.....	156
8.1.3.1 修改操作系统账户密码.....	156
8.1.3.2 修改租户面账户密码.....	157
8.1.3.3 修改管理面 modelarts-common-proxy 组件的 proxy_admin 密码.....	157
8.1.3.4 修改管理面数据库密码.....	160
8.1.3.5 修改 Redis 数据库实例用户密码.....	162
8.2 证书管理.....	163
8.2.1 背景信息.....	163
8.2.2 modelarts-console-backend 证书替换.....	165
8.2.3 modelarts-webapp-gateway 证书替换.....	167
8.2.3.1 证书制作.....	167
8.2.3.2 证书替换.....	168
8.2.4 公共组件证书替换.....	169
8.2.5 推理管控面证书替换.....	170
8.2.5.1 证书制作.....	170
8.2.5.2 密钥和证书更新.....	173
8.2.5.3 证书格式转换.....	175
8.2.6 训练管控面证书替换.....	178
8.2.6.1 证书制作.....	178
8.2.6.2 证书替换.....	179

8.2.7 OS 管控面证书替换.....	181
8.2.7.1 证书制作.....	181
8.2.7.2 证书替换.....	186
8.2.8 AI Hub 管控面证书替换.....	191
8.2.8.1 证书制作.....	191
8.2.8.2 modelarts-market-manager 证书替换.....	192
8.2.8.3 modelarts-market-service 证书替换.....	193
8.2.9 开发环境管控面证书替换.....	195
8.2.9.1 证书制作.....	195
8.2.9.2 证书替换.....	196
8.2.10 昇腾云脑管控面证书替换.....	198
8.2.10.1 证书制作.....	198
8.2.10.2 证书替换.....	198
8.2.11 推理 2.0 管控面证书替换.....	199
8.2.11.1 证书制作.....	200
8.2.11.2 证书替换.....	202
8.2.12 system-gateway 管控面证书替换.....	203
8.2.12.1 证书制作.....	204
8.2.12.2 证书替换.....	204
8.2.13 Edge 管控面证书替换.....	205
8.2.13.1 证书制作.....	205
8.2.13.2 证书替换.....	206
8.3 安全加固.....	207
8.4 安全维护.....	207
9 服务监控.....	209
9.1 概述.....	209
9.2 查看监控指标.....	209
9.2.1 查看租户资源.....	209
9.2.2 查看云服务资源.....	210
9.2.3 查看虚拟机资源.....	211
9.3 监控指标一览表.....	212
9.4 设置阈值告警.....	239
10 高危操作.....	242
10.1 禁用操作一览表.....	242
10.2 高危操作一览表.....	243
11 附录.....	247
11.1 常用登录操作.....	247
11.2 登录 ModelArts-Common-Proxy 节点.....	251
11.3 登录 CDK master 节点.....	252
11.4 登录 CDK node 节点.....	253
11.5 登录 Dispatcher 集群节点.....	254

11.6 在 CDK master 节点获取组件日志.....	254
11.7 登录 ModelArts 数据库.....	255
11.8 数据老化清理机制.....	257
11.9 数据库修改 ModelArts 推理导入模型大小限制与本地缓存限制.....	258
11.10 ModelArts 数据库节点主备状态判断.....	259
11.11 获取管理员的 Token.....	260
11.12 获取资源租户账号并登录 CCE.....	263
11.13 登录 modelarts-os-apiserver 获取或修改对象.....	265
11.14 修改资源租户密码.....	268
11.15 登录 ModelArts 资源池的节点.....	270
11.16 登录 OpenStack 首节点.....	271
11.17 获取 ModelArts 二级 VDC 管理员的 AK/SK.....	272
11.18 打开 ModelArts UI 特定功能特性开关.....	273
11.19 获取新版推理 CA 证书.....	273

1 前言

概述

本文档详细描述了AI平台ModelArts服务自身的运维能力，主要涉及配置、巡检、安全管理、高危操作等运维场景，同时提供了常见的问题解答及故障处理方法。

读者对象

本文档主要适用于运维操作人员。操作人员必须具备以下经验和技能：

- 熟悉华为云Stack组网和相关网元的信息。
- 具备华为云Stack领域维护经验，熟悉常用操作维护方式。

符号约定

在本文中可能出现下列标志，它们所代表的含义如下。

符号	说明
 危险	表示如不可避免则将会导致死亡或严重伤害的具有高等级风险的危害。
 警告	表示如不可避免则可能导致死亡或严重伤害的具有中等级风险的危害。
 注意	表示如不可避免则可能导致轻微或中度伤害的具有低等级风险的危害。
 须知	用于传递设备或环境安全警示信息。如不可避免则可能会导致设备损坏、数据丢失、设备性能降低或其它不可预知的结果。 “须知”不涉及人身伤害。
 说明	对正文中重点信息的补充说明。 “说明”不是安全警示信息，不涉及人身、设备及环境伤害信息。

修改记录

文档版本	发布日期	修改说明
01	2025-10-30	第一次正式发布。

2 运维场景指引

软件安装完成且初始业务运行正常后，运维人员对整个系统进行操作与维护过程中所涉及到的场景、场景说明和操作指导如[表2-1](#)所示。

说明

华为云Stack通过ManageOne对系统进行日常运维，ManageOne运维界面相关详细功能介绍及场景操作请参考《[华为云Stack 8.6.0 产品文档](#)》的“运维指南”部分相关章节。

表 2-1 运维场景

运维场景	场景说明	操作指导
配置指南	针对管理面的资源管理，配额调整等操作，提供了一些配置指导。常用场景如下： - ModelArts服务如何创建和管理公共资源池和专属资源池。公共资源池是所有租户都可以使用的业务资源，专属资源池则为租户特有的业务资源。 - 制作、上传并注册ModelArts推理镜像和注册ModelArts训练基础镜像。 - 配置AI Hub管理员账户，并通过AI Hub管理员进行设置资产为精选、置顶推荐资产、缩小权限为私有和导入资产等操作。 - 上线裸金属Snt9 Snt9B规格。 - 设置ModelArts审批流程，通过设置审批流程实现对系统资源的审批和管理能力。 - ModelArts资源池支持多版本GPU驱动管理，安装部署时推荐的GPU驱动版本可能不适用有的用户，本文指导用户如何添加新的GPU驱动。 - ModelArts为在线服务注册的API，默认以IP形式对外提供。如果用户需要通过域名方式提供接口，以使用证书访问服务。可以为在线服务接口所属分组配置独立域名并添加SSL证书。 - 运维人员在接到客户调整“单个模型的大小”的配额请求时，通过DB变更的方式，完成配额的调整操作。 - ModelArts新版推理服务提供物理专属网关的相关操作指导，使用户业务可区分测试、生产或者生产内不同业务分组，用户网络流量分流。	具体操作请参见 配置指南 。
日常巡检/自动化验收	方便技术支持工程师和维护工程师快速了解系统的健康状况。FusionCare提供健康检查和信息收集功能，健康检查部分能够一键式检查相关节点的健康状态，并生成健康检查报告。 使用ManageOne运维面自带的巡检工具FusionCare对ModelArts管控面进行巡检，同时也提供自动化验收能力。	具体操作请参见 巡检指南 。
备份恢复	例行备份，或者在升级服务实例前、重大业务调整前对ModelArts服务的DB数据库内容进行备份。若系统变更后出现异常或未达到预期结果，需要对其进行回退，回退过程中需要进行数据恢复操作。	具体操作请参见 备份与恢复 。

运维场景	场景说明	操作指导
安全管理	- 账号管理：定期对产品的各部件所涉及的用户名、密码进行全面整改，保证密码等及时更新。 - 证书管理：为了提高系统安全性与防止证书过期，建议用户定期更新证书。 - 安全加固：介绍了ModelArts的安全加固项、安全加固项说明、加固途径和验证方法。 - 安全维护：提供日常安全维护方面的建议，包括账户、密码和日志维护建议。	具体操作请参见 安全管理 。
服务监控	对ManageOne系统服务以及云服务系统运行时的节点性能指标和进程性能指标进行实时监控，记录服务运行时节点和进程关键性能指标的变化趋势，提示服务运行时的告警信息，通过对服务、节点、实例等不同维度的监控呈现出所监控服务运行节点和进程的详细监控数据，帮助管理员及时预防潜在的服务运行风险。	具体操作请参见 服务监控 。
高危操作	- 对于属于高危的操作一定要严格按照要求执行操作。 - 高危重大操作在实施前需要经过试验环境模拟，实施时要有维护工程师重点支撑。 - 对于禁用操作，禁止在系统正常运行期间执行，否则可能造成业务中断或不可用。	具体操作请参见 高危操作 。

3 ModelArts 常见概念及对应操作

导入模型

指在ModelArts管理控制台中，将用户的模型导入至ModelArts中。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》>使用ModelArts 创建模型> 创建模型。

部署在线服务

将导入至ModelArts的模型，部署为一个在线服务，即部署为一个可直接调用的API。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》>将模型部署为服务 > 在线服务 > 部署为在线服务。

部署批量服务

将导入至ModelArts的模型，部署为一个批量服务。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》> 将模型部署为服务 > 批量服务 > 部署为批量服务。

部署边缘服务

将导入至ModelArts的模型，部署为一个边缘服务。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》> 将模型部署为服务 > 边缘服务 > 部署为边缘服务。

创建专属资源池

创建一个可用的专属资源池，用于训练作业和模型部署。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》> ModelArts资源管理 > 专属资源池。

使用专属资源池

在“创建训练作业”、“部署在线服务”和“部署批量服务”操作中，可选择专属资源池作为计算资源。

使用公共资源池

在“部署在线服务”和“部署批量服务”操作中，可选择公共资源池作为计算资源。公共资源池是由ModelArts承载租户创建的公共资源池。

创建边缘资源池

创建一个可用的边缘资源池，用于模型部署。相关的操作指导，请参见《[ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)](#)》> ModelArts资源管理 > 边缘资源池。

使用边缘资源池

在“部署边缘服务”操作中，可选择边缘资源池作为计算资源。

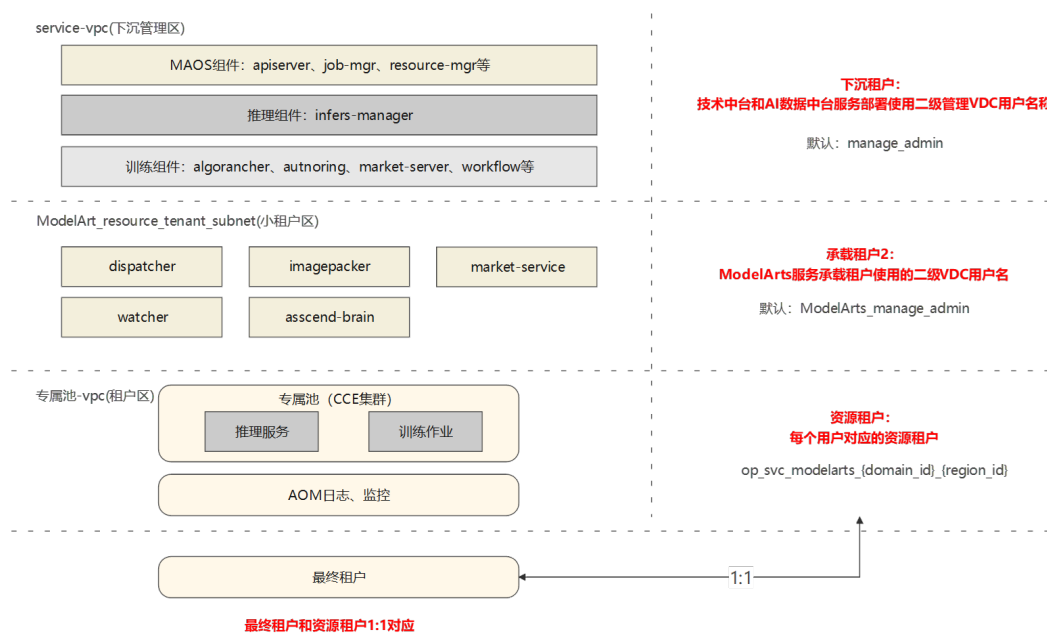
预测

部署为在线服务后，将自动生成一个可调用的API，用户可在界面进行预测测试，也可以调用API进行预测。

4 ModelArts 运维场景下常见租户介绍

在ModelArts的运维和管理场景中，租户分类主要基于资源管理、安全隔离、业务功能以及用户需求。承载租户负责资源的提供和管理，资源租户为最终租户提供特定资源，最终租户则是直接使用这些资源的用户等。

图 4-1 ModelArts 租户职责示例图



以下是ModelArts中常见的租户分类及其详细说明：

下沉租户

- 定义：下沉租户是ModelArts平台中用于部署管理组件的租户。主要用于申请CDK集群、ELB、OBS等资源，基于这些资源部署管理面组件，包括MAOS的apiserver、job-mgr、resource-mgr组件，推理的infer-manager组件，训练的algorancher、autnoring、market-server、workflow等组件。
- 默认账号：
 - 一级VDC默认账号用户：adv_admin
 - 二级VDC默认账号用户：manage_admin

- 使用场景：新部署ModelArts或扩容ModelArts新offering组件时，当下沉区资源创建失败时，用于排查资源的创建、网络的连通性等。

承载租户

- 定义：承载租户是指在ModelArts中负责管理和提供资源的租户。拥有较高的权限，可以申请和管理各种资源，以支持其他租户的业务需求。
- 默认账号：
承载租户使用的一级VDC默认账号：ModelArts_adv_admin
承载租户使用的二级VDC默认账号：ModelArts_manage_admin
- 功能介绍：
 - 承载租户在POD区申请所需的资源，如ImagePacker集群（用于处理和打包镜像）、APIC实例（用于管理和提供API服务）、Dispatcher集群（用于调度和分发任务，确保任务在不同的节点上高效执行）、IVA-Task集群（用于处理特定的任务）。
 - 承载租户在申请的资源上部署和管理各种服务组件，比如Dispatcher组件、APIC组件、batch-agent组件、iva-task组件，通过这些服务组件，为其他租户提供托管ModelArts，帮助他们快速部署和管理应用程序，而不需要关心底层的硬件和网络配置。
 - 通过一级VDC和二级VDC的账号管理实现服务层的多租户的资源管理和任务处理。
 - 提供监控和日志管理服务，帮助租户实时监控应用性能和故障排查。
- 使用场景：ModelArts承载租户用户登录Manageone后可见“资源管理”页面，用于管理ModelArts业务中的所有资源，如管理员创建的公共资源池以及普通用户创建的专属资源池。可以管理的资源包括集群、资源池、节点以及规格，更多详情请参考[资源管理](#)。当创建专属资源池失败，或专属资源池/公共资源池对应资源不足时，使用承载租户登录ManageOne去定位。
当dispatcher组件故障时，使用承载租户登录CCE定位问题。

资源租户（影子租户）

- 定义：资源租户是指在ModelArts中专门为普通租户创建的、用于管理和提供IaaS资源的租户。资源租户的主要职责是管理和分配底层的IaaS资源，以支持普通租户在PaaS层面上的资源需求。资源租户对普通租户是不可见的，由ModelArts统一管理。资源租户和最终租户一一对应。
- 默认账号：
op_svc_modelarts_{domain_id}_{region_id}
- 功能介绍：
 - 资源申请：资源租户在ModelArts中申请所需的IaaS资源，如计算资源、存储资源、网络资源等。
 - 资源管理：资源租户管理和分配这些资源，确保资源的合理使用和安全隔离。
 - 任务执行：资源租户负责在集群上执行普通租户提交的任务。
- 使用流程：
举例：普通租户在ModelArts平台申请创建资源池，ModelArts会为普通租户新建一个内部账号，即资源租户账号。申请资源任务会被映射到内部的资源租户，由资源租户在云平台中申请所需的IaaS资源，如计算资源、存储资源、网络资源等。资源租户管理和分配这些资源。用户在ModelArts平台上提交部署任务，

ModelArts平台将任务映射到资源租户申请的集群上执行，资源租户在集群上执行任务，并将结果返回给用户。

- 使用场景：
当用户需要查看创建的资源池的日志时或者proxy组件故障时，需使用资源租户登录到CCE集群。

最终租户

- 定义：最终租户是指直接使用ModelArts服务的用户或组织。拥有自己的资源（如VPC、ECS、存储等），ModelArts平台会与最终租户的VPC网络进行连接，以便资源池能够访问最终租户的云服务。最终租户即普通租户。
- 默认账号：无（由运营管理员创建）
- 与资源租户的关系：每个最终租户对应一个资源租户，资源租户负责管理和提供底层的IaaS资源，而最终租户在PaaS层面上使用这些资源，进行应用的开发和部署。
- 使用流程：
最终租户在ModelArts平台上提交一个任务，比如训练一个模型。ModelArts平台将该任务映射到资源租户申请的集群上执行。资源租户在集群上执行任务，并将结果返回给最终租户。

相关概念

- POD（Pod）是云平台中的一个逻辑区域，用于隔离和管理资源。在Kubernetes中，POD是最小的可部署单元，包含一个或多个容器。
- CDK集群：指用于开发和部署云原生应用的集群。CDK集群提供开发和测试环境，支持容器化应用的快速部署和管理。

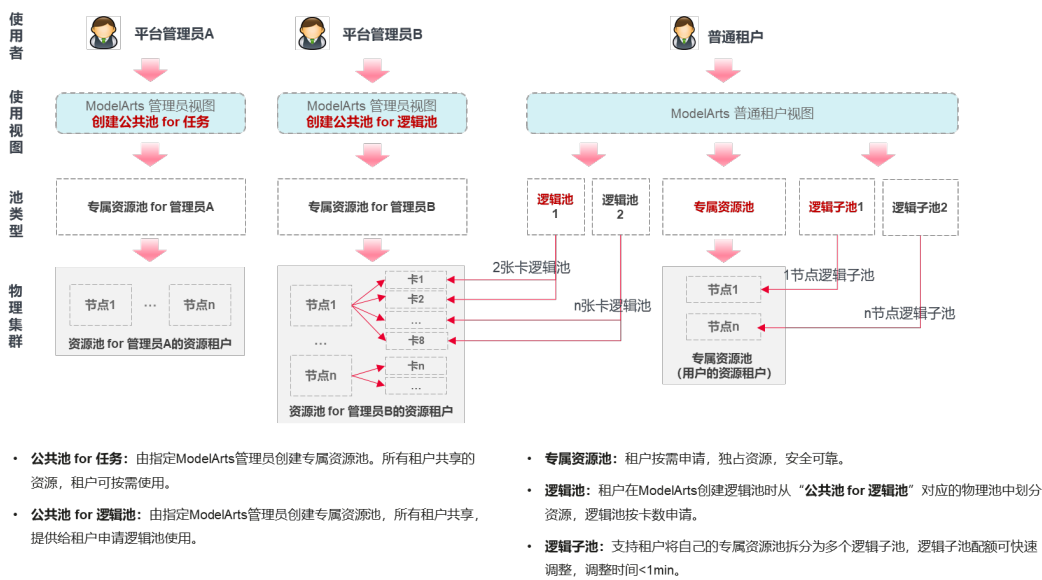
5配置指南

5.1 资源管理

5.1.1 资源管理简介

资源管理用于ModelArts承载租户用户管理ModelArts业务中的所有资源，包括管理员创建的公共资源池以及普通用户创建的专属资源池。当前可以管理的资源包括集群、资源池、节点以及规格。

图 5-1 ModelArts 资源池功能介绍



说明

仅ModelArts承载租户用户（ModelArts服务承载租户使用的二级VDC用户名）登录后可见“资源管理”页面。

- 集群管理：**用于查看详细的集群信息。

- **资源池管理**：用于管理公共资源池（创建、删除、扩缩容、驱动升级等）以及查看普通用户创建的专属资源池。
- **节点管理**：用于管理集群中的节点，可以查看节点详细信息，并管理节点。
- **规格管理**：用于查看和管理系统中的节点规格和资源规格。节点规格用于IAAS资源的申请，资源规格用于普通用户创建专属资源池。
- **节点配置管理**：用于查看和管理系统中的节点配置模板。
- **资源租户**：用于查看ModelArts的资源租户信息。
- **插件**：用于查看ModelArts的插件，同时也可对插件进行升级操作。
- **RoCE网络**：用于查看ModelArts给资源租户创建的RoCE子网信息，可对RoCE子网进行管理。

5.1.2 管理公共资源池

ModelArts支持使用公共资源池或专属资源池，公共资源池是所有租户都可以使用的业务资源，专属资源池则为租户特有的业务资源。

在安装过程中，ModelArts默认不会创建公共资源池，会预置一个不带增强型子网的ModelArts网络，需根据实际业务需求，使用ModelArts承载租户用户（ModelArts服务承载租户使用的二级VDC用户名）创建公共资源池，供租户使用。[创建公共资源池](#)、[扩缩容公共资源池](#)、[删除公共资源池](#)介绍了公共资源池的管理操作。

(可选)创建适配增强型裸机网关的 ModelArts 网络

说明

- ModelArts安装过程中，预置一个不带增强型子网的ModelArts网络，适用于CPU、GPU、NPU等不需要增强型子网的公共资源池创建场景。
 - 仅当公共资源池节点为NPU裸机，且裸机使用增强型裸机网关时，需要执行当前步骤。
1. 使用浏览器，以ModelArts承载租户一级管理VDC用户登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，
<https://console.demo.com>。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，
<https://tenant.demo.com>。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts承载租户一级管理VDC用户：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“firstlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
 2. 单击“登录”。
 3. 在服务列表中选择“ModelArts”，进入ModelArts管理控制台“AI专属资源池 > 弹性集群 Cluster > 网络”，进入网络列表，创建一个带增强型裸机子网的ModelArts网络，示例名：network-admin-02

进入资源池列表

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

a. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。

■ 登录地址：

非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。

B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。

访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。

■ ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。

■ 密码：联系环境管理员获取。

b. 单击“登录”。

2. 在服务列表中选择“AI开发平台ModelArts”，进入ModelArts管理控制台。

3. 在左侧菜单栏中选择“资源管理 > 资源池管理”进入资源池列表。

列表页面展现了所有资源池（包括公共资源池和专属资源池）的相关信息，其中包括资源池名称、集群名称、状态、类型、实例数等。
- 创建公共资源池
1. 在资源池列表，单击“创建”进入创建资源池页面。

2. 在“创建公共资源池”页面，参考表5-1完成参数填写，单击“立即创建”完成公共资源池的创建。
- 说明
- 同一种规格、同一个类型（训练作业、推理服务）只能创建一个公共资源池。若已经存在该规格、该类型的公共资源池，在单击“确定”创建资源池时，页面右上角会弹出“同一种规格只能创建一个资源池，请检查后重试”的提示，且最后资源池会创建失败。
 - 公共资源池可以使用在部署安装时创建的预置网络network-admin-01，但若规格使用了增强型裸机网关，则需额外以ModelArts服务承载租户使用的一级VDC重新创建一个带增强型子网的网络，eg：network-admin-02
- 表 5-1 公共资源池的参数说明
- | 参数名称 | 说明 |
|------|--|
| 名称 | 自定义公共资源池的名称。
只能以小写字母开头，由小写字母、数字、中划线组成，不能以中划线结尾。 |
| 描述 | 公共资源池的简要描述。 |
- 文档版本 01 (2025-10-30)

版权所有 © 华为云计算技术有限公司

13

参数名称	说明
作业类型	可选择“推理服务”和“训练作业”。如果局点已支持训推一体，则可以同时勾选训练作业和推理服务。
网络	在下拉框中选择，表示服务实例运行在指定的网络中，可以与该网络中的其它云服务资源实例互通。
规格类型	请根据界面提示选择需要使用的规格，包括架构、类型和详细规格。平台分配的资源规格包含了一定的系统损耗，实际可用的资源量小于规格标称的资源。
自定义驱动	当“规格类型”选择“GPU”时，显示此参数。开关默认关闭。当用户需要自主选择GPU驱动时，需打开“自定义驱动”开关。
GPU驱动	当“自定义驱动”开关打开时，显示此参数。用户可根据业务需要选择GPU驱动。
可用区	您可以根据实际情况选择“随机分配”或“手工指定”。可用区是在同一区域下，电力、网络隔离的物理区域。可用区之间内网互通，不同可用区之间物理隔离。 ● 随机分配：系统随机分配可用区。 ● 手工指定：指定资源池节点在不同可用区的数量。考虑系统容灾时，推荐手工指定节点在同一个可用区。
实例数	选择公共资源池的实例数，选择的实例数越多，计算性能越强。 CPU推理资源池实例数，请根据业务需求配置；GPU实例数请根据所需卡资源配置。 说明 单次创建时，实例数建议不大于30，否则可能触发限流导致创建失败。系统默认最多创建200个节点。

3. 返回资源池列表，当新建公共资源池的状态为“运行中”时，表示资源池已创建成功。

添加训练公共资源池规格

公共资源池创建好后，需要为公共资源池添加规格，具体步骤如下：

步骤1 在“资源管理 > 资源池管理”中找到要添加规格的公共资源池，并记录资源池对应的集群名称，记为{pool-name}。同时单击需要添加规格的公共资源池，单击资源池详情页面的规格标签，记录当前池子的规格信息，cpu，内存。

步骤2 登录CDK master节点。

步骤3 执行如下命令，可以查到pod列表。

```
kubectl get pod | grep "modelarts-os-apiserver"
```

图 5-2 pod 列表

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl get pod | grep "modelarts-os-apiserver"
modelarts-os-apiserver-75fbb5d965-4qxn6      1/1      Running    0          5d6h
modelarts-os-apiserver-75fbb5d965-ls5bc      1/1      Running    0          5d6h
```

然后从查到的结果中任意复制一个pod名称，记为{os-apiserver-name}。

步骤4 执行如下命令，进入pod。

```
kubectl exec -it {os-apiserver-name} bash
```

图 5-3 进入 pod

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl exec -it modelarts-os-apiserver-75fbb5d965-4qxn6 bash
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$
```

步骤5 执行如下命令，获取资源池列表信息。

```
kubectl get pool
```

图 5-4 获取资源池列表信息

```
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$ kubectl get pool
NAME                                TYPE      PHASE      AGE
pool-2024                          Dedicate  Running    4d22h
pool-3c62                          Dedicate  Running    41d
```

步骤6 执行如下命令，修改目标资源池的信息。命令中{pool_name}为步骤1中查到的资源池对应集群名称。

```
kubectl edit pool {pool-name}
```

1. 确认资源池标签（ labels ）中"os.modelarts.pool/biz"值是否为"public"。
"os.modelarts.pool/biz": "public"

图 5-5 labels

```
labels:
  os.modelarts.pool/biz: public
```

2. 在公共资源池annotation中添加规格信息。

用户可以在公共资源池的annotation内添加多个规格。下面为添加NPU公共资源池提供一个示例。各种规格的详细示例见[各种规格的详细示例](#)。

注：如果在添加规格信息过程中，相关信息填写错误，可以按下Esc，输入引号的内容“:q”，按下回车键退出。

- 对于NPU公共资源池，需要添加每个规格参数，包括flavor_id、billing.code、billing.unit和pool_info.accelerator_num。为Snt9b2公共资源池添加1卡、2卡、4卡、8卡规格（多规格）的示例如下：
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing": {"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]'

表 5-2 flavors 相关参数

参数	参数说明
flavor_id	规格uid
billing.code	计费码。对于有实际计费需求的公共资源池，请按照提供的详细示例填写该值

参数	参数说明
billing.unit_num	计费卡数
pool_info.accelerator_num	规格卡数

步骤7 保存修改。上述信息修改完后，按下Esc，输入引号的内容“:wq”，按下回车键保存。如果成功退出，并显示类似下图当前池子已经被修改的字样，即修改成功。如果未成功修改，则重新从**步骤6**开始执行，直至修改成功。

图 5-6 成功修改

```
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$ kubectl edit pool pool-train-b585
pool.os.modelarts.huaweicloud/pool-train-b585 edited
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$
```

步骤8 添加公共资源池配额。

1. 执行命令“exit”退出。然后查看algorancher状态。

```
exit
kubectl get pod | grep algorancher
```

图 5-7 查看 algorancher 状态

```
[root@ModelArts-Common-Region-P0D-Master-0001 ~]# kubectl get pod | grep algorancher
modelarts-algorancher-b449c59bc-jtz8f          1/1      Running    0          2d3h
modelarts-algorancher-b449c59bc-vj8br          1/1      Running    0          2d3h
```

2. 执行如下命令删除以上pod。删除后项目启动会自动添加配额。

```
kubectl delete pod {podname1} {podname2}
```

图 5-8 删除 pod

```
[root@ModelArts-Common-Region-P0D-Master-0001 ~]# kubectl delete pod modelarts-algorancher-b449c59bc-jtz8f modelarts-algorancher-b449c59bc-vj8br
pod "modelarts-algorancher-b449c59bc-jtz8f" deleted
pod "modelarts-algorancher-b449c59bc-vj8br" deleted
```

步骤9 经短暂延时后（1-2分钟左右），使用普通租户账号登录ModelArts控制台，在“模型训练 > 训练作业”的“创建训练作业”中，确认是否能够看到新增的公共资源池规格。

----结束

各种规格的详细示例

- NPU规格

Snt9b1规格：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b1", "billing":{"code": "modelarts.bm.npu.arm.1snt9b1", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b1", "billing":{"code": "modelarts.bm.npu.arm.2snt9b1", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b1", "billing":{"code": "modelarts.bm.npu.arm.4snt9b1", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b1", "billing":{"code": "modelarts.bm.npu.arm.8snt9b1", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]
```

Snt9b2规格：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]
```

```
"modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, {"pool_info": {"accelerator_num": 4}}, {"flavor_id":  
"modelarts.bm.npu.arm.8snt9b2", "billing": {"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1},  
"pool_info": {"accelerator_num": 8}}]
```

Snt9b3规格:

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b3", "billing": {"code":  
"modelarts.bm.npu.arm.1snt9b3", "unit_num": 1}, "pool_info": {"accelerator_num": 1}}, {"flavor_id":  
"modelarts.bm.npu.arm.2snt9b3", "billing": {"code": "modelarts.bm.npu.arm.2snt9b3", "unit_num": 1},  
"pool_info": {"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b3", "billing": {"code":  
"modelarts.bm.npu.arm.4snt9b3", "unit_num": 1}, "pool_info": {"accelerator_num": 4}}, {"flavor_id":  
"modelarts.bm.npu.arm.8snt9b3", "billing": {"code": "modelarts.bm.npu.arm.8snt9b3", "unit_num": 1},  
"pool_info": {"accelerator_num": 8}}]
```

Snt9a规格:

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.kat1.xlarge.public", "billing": {"code":  
"modelarts.bm.npu.arm.1snt9a", "unit_num": 1}, "pool_info": {"accelerator_num": 1}}, {"flavor_id":  
"modelarts.kat1.2xlarge.public", "billing": {"code": "modelarts.bm.npu.arm.2snt9a", "unit_num": 1},  
"pool_info": {"accelerator_num": 2}}, {"flavor_id": "modelarts.kat1.4xlarge.public", "billing": {"code":  
"modelarts.bm.npu.arm.4snt9a", "unit_num": 1}, "pool_info": {"accelerator_num": 4}}, {"flavor_id":  
"modelarts.kat1.8xlarge.public", "billing": {"code": "modelarts.bm.npu.arm.8snt9a", "unit_num": 1},  
"pool_info": {"accelerator_num": 8}}]
```

修改训练公共资源池规格

用户如果发现公共资源池规格信息配置错误，或需要更改公共资源池规格信息，可按照下述方式对公共资源池规格进行修改。

步骤1 在“资源管理 > 资源池管理”中找到要添加规格的公共资源池，并记录资源池对应的集群名称，记为{pool-name}。

步骤2 [登录CDK master节点](#)。

步骤3 执行如下命令，可以查到pod列表。

```
kubectl get pod | grep "modelarts-os-apiserver"
```

图 5-9 pod 列表

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl get pod | grep "modelarts-os-apiserver"  
modelarts-os-apiserver-75fbb5d965-4qxn6      1/1      Running    0      5d6h  
modelarts-os-apiserver-75fbb5d965-ls5bc      1/1      Running    0      5d6h
```

然后从查到的结果中任意复制一个pod名称，记为{os-apiserver-name}。

步骤4 执行如下命令，进入pod。

```
kubectl exec -it {os-apiserver-name} bash
```

图 5-10 进入 pod

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl exec -it modelarts-os-apiserver-75fbb5d965-4qxn6 bash  
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$
```

步骤5 执行如下命令，获取资源池列表信息。

```
kubectl get pool
```

图 5-11 获取资源池列表信息

```
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$ kubectl get pool  
NAME          TYPE    PHASE    AGE  
pool-2024     Dedicate Running  4d22h  
pool-3c62     Dedicate Running  41d
```

步骤6 执行如下命令，修改目标资源池的信息。命令中{pool_name}为步骤1中查到的资源池对应集群名称。

```
kubectl edit pool {pool-name}
```

1. 确认资源池标签（labels）中“os.modelarts.pool/biz”值是否为“public”。
`"os.modelarts.pool/biz": "public"`

图 5-12 labels

```
labels:
  os.modelarts.pool/biz: public
```

2. 修改公共资源池annotation中的“os.modelarts/public.train.flavors”参数，然后修改成期望的目标值。

修改billing示例如下，将flavor_id为modelarts.bm.npu.arm.8snt9b2规格的billing.code的值从modelarts.bm.npu.arm.8snt9b2改为modelarts.bm.npu.arm.1snt9b2，billing.unit_num从1改为8。

注：如果在修改规格信息过程中，相关信息填写错误，可以按下Esc，输入引号的内容“:q”，按下回车键退出。

注：修改规格信息时不建议修改flavor_id。修改flavor_id会删除当前规格后重新添加该规格。

更改前的值：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]
```

更改后的值：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 8}, "pool_info":{"accelerator_num": 8}}]
```

步骤7 保存修改。上述信息修改完后，按下Esc，输入引号的内容“:wq”，按下回车键保存。如果成功退出，即修改成功。如果未成功修改，则重新从**步骤6**开始执行，直至修改成功。

步骤8 经短暂延时后（1-2分钟左右），使用普通租户账号登录ModelArts控制台，在“模型训练 > 训练作业”的“创建训练作业”中，确认是否能够看到修改后的公共资源池规格。

----结束

移除训练公共资源池规格

步骤1 在“资源管理 > 资源池管理”中找到要添加规格的公共资源池，并记录资源池对应的集群名称，记为{pool-name}。

步骤2 登录CDK master节点。

步骤3 执行如下命令，可以查到pod列表。

```
kubectl get pod | grep "modelarts-os-apiserver"
```

图 5-13 pod 列表

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl get pod | grep "modelarts-os-apiserver"
modelarts-os-apiserver-75fbb5d965-4qxn6      1/1      Running    0          5d6h
modelarts-os-apiserver-75fbb5d965-1s5bc      1/1      Running    0          5d6h
```

然后从查到的结果中任意复制一个pod名称，记为{os-apiserver-name}。

步骤4 执行如下命令，进入pod。

```
kubectl exec -it {os-apiserver-name} bash
```

图 5-14 进入 pod

```
[root@ModelArts-Common-Region-P0D-Master-0002 ~]# kubectl exec -it modelarts-os-apiserver-75fbb5d965-4qxn6 bash
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$
```

步骤5 执行如下命令，获取资源池列表信息。

```
kubectl get pool
```

图 5-15 获取资源池列表信息

```
[service@modelarts-os-apiserver-75fbb5d965-4qxn6 modelarts-os-apiserver]$ kubectl get pool
NAME                TYPE        PHASE    AGE
pool-2024           Dedicate    Running  4d22h
pool-3c62           Dedicate    Running  41d
```

步骤6 执行如下命令，修改目标资源池的信息，将不需要的flavor移除。命令中{pool_name}为步骤1中查到的资源池对应集群名称。

```
kubectl edit pool {pool-name}
```

移除flavor规格需要通过修改公共资源池annotation中的"os.modelarts/public.train.flavors"参数。移除规格分为移除全部规格和移除部分规格，下面分别举例。

- 移除部分规格

示例如下：假设移除步骤6的Snt9b2的8卡规格，只需将flavor_id为modelarts.bm.npu.arm.8snt9b1的规格信息删除即可。

更改前的值：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]
```

更改后的值：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}]
```

- 移除全部规格

示例如下：假设移除步骤6的Snt9b2的全部规格。

更改前的值：

```
os.modelarts/public.train.flavors: '[{"flavor_id": "modelarts.bm.npu.arm.1snt9b2", "billing":{"code": "modelarts.bm.npu.arm.1snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 1}}, {"flavor_id": "modelarts.bm.npu.arm.2snt9b2", "billing":{"code": "modelarts.bm.npu.arm.2snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 2}}, {"flavor_id": "modelarts.bm.npu.arm.4snt9b2", "billing":{"code": "modelarts.bm.npu.arm.4snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 4}}, {"flavor_id": "modelarts.bm.npu.arm.8snt9b2", "billing":{"code": "modelarts.bm.npu.arm.8snt9b2", "unit_num": 1}, "pool_info":{"accelerator_num": 8}}]
```

更改后的值：

```
os.modelarts/public.train.flavors: '[]'
```

注：如果在添加规格信息过程中，相关信息填写错误，可以按下Esc，输入引号的内容“:q”，按下回车键退出。

注：如果删除“os.modelarts/public.train.flavors”并不会删除全部规格；
“os.modelarts/public.train.flavors”值如果是空，也不会删除全部规格；
“os.modelarts/public.train.flavors”值必须是'[]'才可以删除全部规格。

步骤7 保存修改。上述信息修改完后，按下Esc，输入引号的内容“:wq”，按下回车键保存。如果成功退出，即修改成功。如果未成功修改，则重新从**步骤6**开始执行，直至修改成功。

步骤8 经短暂延时后（1-2分钟左右），使用普通租户账号登录ModelArts控制台，在“模型训练 > 训练作业”的“创建训练作业”中，确认是否已经看不到删除后的公共资源池规格。

----结束

设置作业类型


1. 在资源池列表，找到要设置作业类型的资源池，单击“更多>设置作业类型”。
2. 在“设置作业类型”弹窗中，选择需要设置的作业类型。
3. 选择完成后，单击“确定”，启用作业类型。

扩缩容公共资源池

1. 在资源池列表，找到要扩缩容的公共资源池，单击“扩缩容”进入资源池扩缩容页面。
2. 在“资源池扩缩容”页面，增加或减少“目标总节点数”，单击“提交”启动资源的扩缩容。

增加节点数量表示扩容，减少节点数量表示缩容。请根据本身业务诉求进行调整。

图 5-16 资源池扩缩容



- 扩容前，请先确认ModelArts的资源配额，根据当前的资源配额增加节点数量，避免资源不够导致扩容失败。
以运营管理员账号登录ManageOne运营面，在页面上方选择“组织 > VDC”。在VDC列表页面，单击ModelArts的VDC名称进入详情页面。选择“配额”进入配额页面，可查看ModelArts的资源配额详情。
 - 缩容时，在“资源池扩缩容”页面减少节点数量，是通过随机缩减节点实现的。还可以进入资源池详情页面的“节点”页签，手工选择删除节点实现资源池缩容，具体操作请参见2。
3. 返回资源池列表，当资源池状态变为“运行中”时，表示操作完成，且公共资源池已处于可用状态。如果资源池状态变为“不可用”时，请联系华为技术支持排除故障。

删除公共资源池

1. 在资源池列表，找到要删除的公共资源池。
2. 单击操作列的“删除”，在弹窗中“确定”删除公共资源池。

说明

只支持删除公共资源池。

5.1.3 集群管理

“集群管理”模块用于查看详细的集群信息。

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - a. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
 - b. 单击“登录”。
2. 在服务列表中选择“ModelArts”，进入ModelArts管理控制台。
3. 在左侧菜单栏中选择“资源管理 > 集群管理”进入集群列表。

列表页面展现了ModelArts承载租户用户下所有k8s集群的相关信息，包括集群名称、版本、状态、实例数、资源和所属租户信息。
4. 单击集群名称，进入集群详情页面。

详情页面包含了集群的基本信息、节点信息、网络信息、驱动信息等。

 - “节点”页签呈现了集群中包含的所有节点。单击节点名称可进入节点详情页。
 - “标签”页签呈现了该集群在k8s中自身携带的标签信息。且支持管理标签。

说明

以下字段的标签是系统预置标签，不支持编辑或删除。

- 标签“键”是"cce.kubectl.kubernetes.io/cabinet"
- 标签“键”是"accelerator"
- 标签“键”是"accelerator/huawei-npu"
- 标签“键”是"os.architecture"
- 以“os.modelarts”开头的标签“键”

■ 添加标签

单击“添加标签”，在弹出的“添加标签”页面，可以输入自定义的键值，单击“确定”创建用户自定义标签。

图 5-17 添加标签

图 5-17 展示了“添加标签”的操作界面。该界面是一个名为“添加标签”的对话框，顶部有一个信息图标。对话框内包含两个输入框，分别用于输入“键”和“值”。在“键”输入框左侧有一个红色的星号。对话框底部有两个按钮，分别是红色的“确定”按钮和灰色的“取消”按钮。

■ 编辑标签

单击对应标签操作列的“编辑”，在弹出的“编辑标签”页面中修改标签值，单击“确定”保存修改。标签键不支持修改。

■ 删除标签

单击对应标签操作列的“删除”，在弹出的“删除标签--xx”页面中单击“确定”，即可删除用户自定义标签。

5.1.4 资源池管理

“资源池管理”模块用于管理公共资源池（创建、删除、扩缩容、驱动升级等）以及查看普通用户创建的专属资源池。

ModelArts支持使用公共资源池或专属资源池，公共资源池是所有租户都可以使用的业务资源，专属资源池则为租户特有的业务资源。[查看资源池详情](#)介绍了如何查看公共资源池和专属资源池的详细信息。

在安装过程中，ModelArts默认不会创建公共资源池，需根据实际业务需求，使用ModelArts承载租户用户创建公共资源池，供租户使用。[管理公共资源池](#)介绍了公共资源池的管理操作。

进入资源池列表

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

- a. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
- b. 单击“登录”。
2. 在服务列表中选择“ModelArts”，进入ModelArts管理控制台。
3. 在左侧菜单栏中选择“资源管理 > 资源池管理”进入资源池列表。
列表页面展现了所有资源池（包括公共资源池和专属资源池）的相关信息，其中包括资源池名称、集群名称、状态、类型、实例数、所属租户信息等。

查看资源池详情

1. 在资源池列表，单击资源池名称，进入资源池详情页面。
详情页面包含了资源池的基本信息、所属租户信息等。
 - “作业”页签呈现了运行在该资源池上的作业信息，包括作业名称、作业类型、规格等。
 - “规格”页签呈现了资源池对应的资源规格。
 - “节点”页签呈现了资源池对应的节点信息。
 - “事件”页签呈现了生命周期内系统记载的资源池相关事件信息。
 - “监控”页签呈现了资源池各项资源使用量的图表信息。
2. （可选）若是公共资源池，在“节点”页签，可以通过删除节点实现资源池缩容。
勾选可删除的节点，单击上方“删除”，在弹窗中确认信息后，单击“确定”删除节点。

须知

删除节点操作有可能影响正在运行中的任务，且该动作不可回退，请谨慎操作。

（可选）资源池驱动升级

ModelArts公共资源池支持GPU和NPU驱动升级。在资源池列表，找到要升级驱动的资源池，单击“更多>驱动升级”进行驱动升级，可参考用户指南的“专属资源池>资源池GPU驱动升级”章节。

5.1.5 节点管理

“节点管理”模块用于管理集群中的节点，可以查看节点详细信息，并管理节点。

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - a. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
 - b. 单击“登录”。
2. 在服务列表中选择“ModelArts”，进入ModelArts管理控制台。
3. 在左侧菜单栏中选择“资源管理 > 节点管理”进入节点列表。

列表页面展现了ModelArts承载租户用户下所有节点的相关信息，包括节点名称、集群名称、节点IP等。列表页面上方有“自定义列表项”，用于快速多条件组合搜索节点。如图1所示。

图 5-18 多条件组合搜索节点



4. 在节点列表，单击节点名称，进入节点详情页面。

详情页面包含了节点的基本信息、配置信息、网络信息等。

“标签”页签呈现了该节点在k8s中自身携带的标签信息。且支持管理。

📖 说明

以下字段的标签是系统预置标签，不支持编辑或删除。

- 标签“键”是"cce.kubectl.kubernetes.io/cabinet"
- 标签“键”是"accelerator"
- 标签“键”是"accelerator/huawei-npu"
- 标签“键”是"os.architecture"
- 以“os.modelarts”开头的标签“键”

- 添加标签

单击“添加标签”，在弹出的“添加标签”页面，可以输入自定义的键值，单击“确定”创建用户自定义标签。

图 5-19 添加标签



该对话框用于添加新的标签。它包含以下元素：

- 标题：添加标签
- 输入项：
 - * 键：用于输入标签的键名。
 - 值：用于输入标签的值。
- 操作按钮：
 - 确定：确认并创建标签。
 - 取消：取消操作。

- 编辑标签

单击对应标签操作列的“编辑”，在弹出的“编辑标签”页面中修改标签值，单击“确定”保存修改。标签键不支持修改。

- 删除标签

单击对应标签操作列的“删除”，在弹出的“删除标签--xx”页面中单击“确定”，即可删除用户自定义标签。

“隔离”页签呈现了该节点通过ModelArts中标记的隔离码信息，且支持管理。

表 5-3 节点故障类型及处理方法

故障码	分类	子类	故障描述	说明	处理方式
A050933	节点管理	容错 Failover	训练作业 业务进程 异常退 出，检测 到节点 NPU异 常，当节 点具有该 污点时， 会将节点 上容错 (Failover) 业务迁 移走	发生故障 后，节点 被隔离， 原作业在 其他节点 自动重新 启动；单 资源池内 最多25% 的节点因 该故障码 被隔离	登录资源 池节点， 继续下一 步排查； 故障原因 恢复后， 关闭故障 隔离
A050203	Runtime	掉卡	AI正常卡 数和实际 容量不匹 配	节点规格 定义的卡 数与检测 到的AI卡 数不匹 配；单资 源池内最 多25%的 节点因该 故障码被 隔离	登录资源 池节点， 继续下一 步排查， 故障原因 恢复后， 故障隔离 会自动关 闭
A050802	节点管理	节点运维	未知故障	由运维人 员手动隔 离触发； 单资源池 内最多 100%的节 点因该故 障码被隔 离	排查运维 人员添加 隔离原 因，故障 原因恢复 后，关闭 故障隔离
A200008	节点管理	节点门槛 检测	节点设置 为可用前 的基础检 测	资源池创 建、扩容 自动触 发；单资 源池内最 多100%的 节点因该 故障码被 隔离	无需处 理，节点 的基础功 能项、驱 动配置正 常后会自 动关闭

- 隔离节点操作步骤

- i. 切换到“隔离”页签，单击“添加隔离”，“选择故障”可根据规则描述选择要隔离的故障规则，“操作人”填写可联系的操作人员信息，“描述”填写隔离的原因。填写完成后，单击“确定”，即可添加隔离。
 - ii. 隔离添加完成后，刷新隔离页签列表，即可看到新增的隔离。
- 关闭节点隔离操作步骤
 - i. 切换到“隔离”页签，查看节点已有的隔离列表，根据规则描述选择要关闭隔离的故障规则，选择“操作 > 关闭”，即可关闭此隔离。

5.1.6 隔离节点及关闭节点隔离

资源池节点创建好后，因运行训练、推理等业务，可能会产生疑似节点故障问题，业务在某节点上运行总是会出错。ModelArts是基于资源的可用性，将业务运行在可用的节点上，因此如果节点有疑似故障或者已知故障时，需要将节点隔离，避免业务运行在故障节点上，影响业务排查或硬件更换。

表 5-4 节点故障类型及处理方法

故障码	分类	子类	故障描述	说明	处理方式
A050933	节点管理	容错 Failover	训练作业业务进程异常退出，检测到节点NPU异常，当节点具有该污点时，会将节点上容错（Failover）业务迁移走。	发生故障后，节点被隔离，原作业在其他节点自动重新启动；单资源池内最多25%的节点因该故障码被隔离。	登录资源池节点，继续下一步排查；故障原因恢复后，关闭故障隔离。
A050203	Runtime	掉卡	AI正常卡数和实际容量不匹配。	节点规格定义的卡数与检测到的AI卡数不匹配；单资源池内最多25%的节点因该故障码被隔离。	登录资源池节点，继续下一步排查，故障原因恢复后，故障隔离会自动关闭。
A050802	节点管理	节点运维	未知故障。	由运维人员手动隔离触发；单资源池内最多100%的节点因该故障码被隔离。	排查运维人员添加隔离原因，故障原因恢复后，关闭故障隔离。

故障码	分类	子类	故障描述	说明	处理方式
A200008	节点管理	节点门槛检测	节点设置为可用前的基础检测。	资源池创建、扩容自动触发；单资源池内最多100%的节点因该故障码被隔离。	无需处理，节点的基础功能项、驱动配置正常后会自动关闭。
A050966	节点管理	业务故障	节点上权重预热项清理异常	权重预热的pod被删除，但是节点上存在/tmp/ckpt-warm-up-xxx的tmpfs挂载点残留。	登录资源池节点，继续下一步排查，通过umount卸载残留挂载点。
A050809	节点管理	节点运维	底层硬件亚健康	节点亚健康后，通过重启节点，故障10分钟仍未关闭，MAOS自动升级成该故障。	由BMS介入人工诊断处理。
A050810	节点管理	节点运维	连续多次同一个故障码	同一个节点，同一个故障码，连续出现多次	根据原故障码信息进行定位。压测或人工诊断，确认无问题后人工关闭。
A050803	节点管理	节点运维	未知错误	节点被标记为具有未知故障污点，用于人工标注。和050802区别在于这个可能让业务中断，加上此污点会触发failover（在训练配置规则）。	根据备注处理，详情联系隔离人。 手动创建的，需要手动关闭。

故障码	分类	子类	故障描述	说明	处理方式
A050202	Runtime	业务故障	节点 NotReady	节点不可达，k8sNode存在以下污点之一： node.kubernetes.io/unreachable， node.kubernetes.io/not-ready	1. 先判断是否是pod负载高引起（CCE给出排查方法）。如果是pod负载高引起，需要联系用户降低资源申请。 2. 重启。 3. 重启无法解决，转给CCE处理。
A050123	NPU	其他	NPU网络异常	当前支持dp检测的1520故障 PreSeparate	登录资源池节点，继续下一步排查，故障原因恢复后，故障隔离会自动关闭。
A050124	NPU	其他	NPU网络异常	当前支持dp检测的1520故障 Separate	登录资源池节点，继续下一步排查，故障原因恢复后，故障隔离会自动关闭。

隔离节点操作步骤

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，进入ModelArts中，选择“资源管理 > 节点管理”，通过节点名称搜索要隔离的节点，单击节点名称进入节点详情页。
2. 切换到“隔离”页签，单击“添加隔离”，“选择故障”可根据规则描述选择要隔离的故障规则，“操作人”填写可联系的操作人员信息，“描述”填写隔离的原因。填写完成后，单击“确定”，即可添加隔离。
3. 隔离添加完成后，刷新隔离页签列表，即可看到新增的隔离。

关闭节点隔离操作步骤

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，进入ModelArts中，选择“资源管理 > 节点管理”，通过节点名称搜索要隔离的节点，单击节点名称进入节点详情页。
2. 切换到“隔离”页签，查看节点已有的隔离列表，根据规则描述选择要关闭隔离的故障规则，选择“操作 > 关闭”，即可关闭此隔离。

5.1.7 规格管理

“规格管理”模块用于查看和管理系统中的节点规格和资源规格。节点规格用于IAAS资源的申请，资源规格用于普通用户创建专属资源池。

登录 ModelArts 管理控制台

步骤1 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

1. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：<https://ManageOne运营面的访问地址>。例如，<https://console.demo.com>。
B2B场景的登录地址：<https://ManageOne租户面的访问地址>。例如，<https://tenant.demo.com>。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
2. 单击“登录”。

步骤2 在服务列表中选择ModelArts，进入ModelArts管理控制台。

步骤3 在左侧菜单栏中选择“资源管理 > 规格管理”，单击“节点规格”或“资源规格”可进入相应页面，单击“创建”新增节点规格或资源规格。

----结束

节点规格

“节点规格”页签呈现了该ModelArts承载租户用户下所有注册到OS的规格信息，其中包括名称、类型、CPU架构、CPU/Core、内存、GPU及NPU信息。

- 添加节点规格
在“节点规格”页签，单击“创建”，弹出“添加节点规格”界面。其中“名称”可选择IaaS中已注册存在的所有节点规格。用户可通过虚拟机/裸金属、CPU/GPU/NPU等不同维度进行添加。参数配置说明请参考[虚拟机节点规格和资源规格参数设置说明](#)。
- 编辑节点规格

单击某一节点规格操作列的“编辑”，即可编辑GPU/NPU规格的卡信息（包括卡类型名称、调度资源类型、数量）。架构字段为自动选择，不需要手动点选。

- 删除节点规格

单击某一节点规格右边操作列的“删除”，在弹窗中单击“确定”，即可删除节点规格。

- 当节点规格没有被使用时（没有资源规格关联到该节点规格），可正常删除，不会对业务产生影响。
- 当节点规格被使用时（有资源规格关联到了该节点规格），节点规格不能被删除，单击删除无效，并有提示信息。

资源规格

“资源规格”页签呈现了该ModelArts承载租户用户下所有资源规格的信息，其中包括名称、类型、可见性、磁盘、CPU架构、CPU/Core、内存、GPU、NPU等。

- 添加资源规格

在“资源规格”页签，单击“创建”，弹出“添加资源规格”界面。请参考[虚拟机节点规格和资源规格参数设置说明](#)配置。

**注意**

添加资源规格需基于已添加的节点规格。

- 编辑资源规格

单击某一资源规格操作列的“编辑”，即可编辑资源规格。

- 删除资源规格

- 单击某一资源规格操作列的“删除”，二次确认弹窗中单击“确定”，即可删除资源规格。
- 正在被资源池使用的资源规格无法删除，并有提示信息。

- 资源规格详情

详情页面展示了资源规格的相关信息，包含资源规格的基本信息、资源信息及节点信息。

- “节点规格”页签呈现了该资源规格对应的IaaS中注册的规格。
- “白名单”页签只在该资源规格的“可见性”为“白名单”时显示，包含了可见该资源规格的所有租户ID。单击“可见性”的下拉框，可以修改资源规格的可见性。

说明

若该资源规格已经创建过专属资源池，则不支持修改可见性。

虚拟机节点规格和资源规格参数设置说明

在设置实例规格时，不同实例对应的节点规格和资源规格参数设置不同，具体对应关系可见下表内容。

说明

节点规格和资源规格的显存是一个可选字段，不具有实际含义，仅用于区分同一卡类型名称的不同硬件，具体值以硬件规格实际大小为准。

表 5-5 虚拟机“节点规格”参数设置说明

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	显存	数量
ModelArts CPU 8U32G专属池实例	modelarts-inference.c3.2xlarge.4	虚拟机	CPU	-	-	-	登录 Service OM 界面，在界面上方选择“服务列表 > 资源 > 计算资源”，然后切换到“规格”页签，在规格列表中，搜到想要录入的规格名称，查看配置，查看 pci_pass through :alias 字段，确定卡带数量。部分卡为单卡双带；若卡为单卡单带，则数量为 pci_pass through :alias 字段值；若卡为单卡双带，则数量为 pci_pass through
ModelArts ARM CPU 8U32G专属池实例	modelarts-inference.kc3.2xlarge.4	虚拟机	CPU	-	-	-	
ModelArts GPU T4 8U32G 专属池实例	modelarts-inference.p1.2xlarge.4	虚拟机	GPU	nvidia-t4	nvidia.com/gpu	-	
ModelArts GPU Ant1(40) 8U64G 专属池实例	modelarts.p4s.2xlarge.8	虚拟机	GPU	nvidia-a100-pcie-40	nvidia.com/gpu	-	
ModelArts GPU V100(32) 8U64G 专属池实例	modelarts-training.p2s.2xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU V100(32) 64U512G 专属池实例	modelarts-training.p2s.16xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU V100s(32) 8U64G 专属池实例	modelarts-training.p3s.2xlarge.8	虚拟机	GPU	nvidia-v100s-pcie32	nvidia.com/gpu	-	
ModelArts NPU X86 Snt3 12U24G 专属池实例	modelarts-inference.ai1.3xlarge.2	虚拟机	NPU	ascend-snt3	huawei.com/ascend-310	-	
ModelArts NPU ARM Snt3 12U24G 专属池实例	modelarts-inference.kai1.3xlarge.2	虚拟机	NPU	ascend-snt3	huawei.com/ascend-310	-	
ModelArts NPU ARM Snt3P-300i 16U32G 专属池实例	modelarts-inference.kai3i.4xlarge.4	虚拟机	NPU	ascend-snt3p-300i	huawei.com/ascend-310	-	

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	显存	数量
ModelArts NPU X86 Snt3P-300I 16U32G专属池实例	modelarts-inference.ai3i.4xlarge.4	虚拟机	NPU	ascend - snt3p-300i	huawei.com/ascend-310	-	:alias字段值乘以2) ; 例如300I DUO机型都是单卡双带。
ModelArts NPU ARM Snt3P-300V 16U32G专属池实例	modelarts-inference.kai3v.4xlarge.4	虚拟机	NPU	ascend - snt3p-300v	huawei.com/ascend-310	-	
ModelArts NPU X86 Snt3P-300V 16U32G专属池实例	modelarts-inference.ai3v.4xlarge.4	虚拟机	NPU	ascend - snt3p-300v	huawei.com/ascend-310	-	
ModelArts GPU V100 8U64G专属池实例	modelarts-training.p2s.2xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU 2V100 16U128G专属池实例	modelarts-training.p2s.4xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU 4V100 32U256G专属池实例	modelarts-training.p2s.8xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU 8V100 64U512G专属池实例	modelarts-training.p2s.16xlarge.8	虚拟机	GPU	nvidia-v100-pcie32	nvidia.com/gpu	-	
ModelArts GPU Ant8 8U64G专属池实例	modelarts.p6snl.2xlarge.8	虚拟机	GPU	nvidia-ant8-pcie80	nvidia.com/gpu	-	
ModelArts NPU ARM Snt3P-300I(96G) DUO 24U96G专属池实例	modelarts-inference.kai2pduo.6xlarge.4	虚拟机	NPU	ascend - snt3p-300i	huawei.com/ascend-310	96	

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	显存	数量
ModelArts NPU X86 Snt3P-300I(96G) DUO 24U96G专属池实例	modelarts-inference.ai2pduo.6xlarge.4	虚拟机	NPU	ascend - snt3p-300i	huawei.com/ascend-310	96	
ModelArts NPU ARM Snt3P-300I DUO 16U32G专属池实例	modelarts-inference.kai3iduo.4xlarge.4	虚拟机	NPU	ascend - snt3p-300i	huawei.com/ascend-310	48	
ModelArts NPU X86 Snt3P-300I DUO 16U32G专属池实例	modelarts-inference.ai3iduo.4xlarge.4	虚拟机	NPU	ascend - snt3p-300i	huawei.com/ascend-310	48	
ModelArts CPU X86 8U16G实例	modelarts-ascend-brain.c3.2xlarge.2	虚拟机	CPU	-	-	-	
ModelArts CPU ARM 8U16G实例	modelarts-ascend-brain.kc3.2xlarge.2	虚拟机	CPU	-	-	-	

说明

- 创建“资源规格”时，Billing编码必须为以下表格中列举的内容。若修改为其他内容，可能会导致计量信息异常等问题。
- 创建“资源规格”时，若需要使用大模型，“节点模板”需选择新增的大模型节点模板。
- 资源规格在虚拟机场景包含系统盘和数据盘，支持类型为SSD|SAS|SATA，实际局点需以云存储支持的类型为准。

表 5-6 虚拟机“资源规格”参数设置说明

实例规格名称	名称	Billing编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统 盘	数据 盘	可见性	节点模板
ModelArts CPU 8U32G专属池实例	model arts.v m.cpu .8ud	model arts.v m.cpu. 8ud	参考表 5-7	推理服务/训练作业/新版推理服务	虚拟机	CP U	x8 6	20 0 G	50 0 G	可选择“可见”“不可见”“白名单”。可见：表示该资源规格对所有用户可见。不可见：表示该资源对所有用户都不可见。白名单：表示该资源对部分用户可见，若选择该选	bas e.te mpl ate
ModelArts ARM CPU 8U32G专属池实例	model arts.v m.ar m.8ud	model arts.v m.arm .8ud		推理服务/训练作业/新版推理服务	虚拟机	CP U	ar m6 4	20 0 G	50 0 G		bas e.te mpl ate
ModelArts GPU T4 8U32G专属池实例	model arts.v m.gpu .t4u8	model arts.v m.gpu .t4u8		推理服务/新版推理服务	虚拟机	GP U	x8 6	20 0 G	50 0 G		bas e.te mpl ate
ModelArts GPU Ant1(40) 8U64G专属池实例	model arts.v m.gpu .ant1. 40	model arts.v m.gpu .ant1. 40		推理服务/训练作业	虚拟机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate
ModelArts GPU V100(32) 8U64G专属池实例	model arts.v m.gpu .v100. pcie	model arts.v m.gpu .v100. pcie		训练作业	虚拟机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate

实例规格名称	名称	Billing编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统 盘	数据 盘	可见性	节点模板
ModelArts GPU V100(32) 64U512G 专属池实例	model arts.v m.gpu .8v100 .pcie	model arts.v m.gpu .8v100 .pcie		训练作业	虚拟机	GPU	x86	200G	500G	项，需要额外配置白名单字段。	gpu .vm. with cache template
ModelArts GPU V100s(32) 8U64G 专属池实例	model arts.v m.gpu .v100s .pcie	model arts.v m.gpu .v100s .pcie		训练作业	虚拟机	GPU	x86	200G	500G		gpu .vm. with cache template
ModelArts NPU X86 Snt3 12U24G 专属池实例	model arts.v m.snt 3.12u 24g	model arts.v m.snt 3.12u 24g		推理服务	虚拟机	NPU	x86	200G	500G		snt 3.x86 template
ModelArts NPU ARM Snt3 12U24G 专属池实例	model arts.v m.snt 3.kun. 12u24g	model arts.v m.snt 3.kun. 12u24g		推理服务	虚拟机	NPU	arm64	200G	500G		snt 3.arm template
ModelArts NPU ARM Snt3P-300 I 16U32G 专属池实例	model arts.v m.snt 3p.300i.kun. 16u32g	model arts.v m.snt 3p.300i.kun. 16u32g		推理服务	虚拟机	NPU	arm64	200G	500G		snt 3p.arm template
ModelArts NPU X86 Snt3P-300 I 16U32G 专属池实例	model arts.v m.snt 3p.300i.16u32g	model arts.v m.snt 3p.300i.16u32g		推理服务	虚拟机	NPU	x86	200G	500G		snt 3p.x86 template

实例规格名称	名称	Billin g编码	标签	支持 作业 规格	节点 类型	计算 资源 类型	CP U 架构	系 统 盘	数 据 盘	可见 性	节点 模板
ModelArts NPU ARM Snt3P-300 V 16U32G 专属池实例	model arts.v m.snt 3p.30 0v.kun .16u3 2g	model arts.v m.snt 3p.300 v.kun. 16u32 g		推理 服务	虚拟机	NP U	ar m6 4	20 0 G	50 0 G		snt 3p. arm .te mpl ate
ModelArts NPU X86 Snt3P-300 V 16U32G 专属池实例	model arts.v m.snt 3p.30 0v.16u 32g	model arts.v m.snt 3p.300 v.16u3 2g		推理 服务	虚拟机	NP U	x8 6	20 0 G	50 0 G		snt 3p.x 86.t em plat e
ModelArts GPU V100 8U64G 专属池实例	model arts.v m.gpu .v100. pcie	model arts.v m.gpu .v100. pcie		训练 作业	虚拟机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate
ModelArts GPU 2V100 16U128G 专属池实例	model arts.v m.gpu .2v100 .pcie	model arts.v m.gpu .2v100 .pcie		训练 作业	虚拟机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate
ModelArts GPU 4V100 32U256G 专属池实例	model arts.v m.gpu .4v100 .pcie	model arts.v m.gpu .4v100 .pcie		训练 作业	虚拟机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate

实例规格名称	名称	Billin g编码	标签	支持 作业 规格	节 点 类 型	计 算 资 源 类 型	CP U 架 构	系 统 盘	数 据 盘	可 见 性	节 点 模 板
ModelArts GPU 8V100 64U512G 专属池实例	model arts.v m.gpu .8v100 .pcie	model arts.v m.gpu .8v100 .pcie		训练 作业	虚 拟 机	GP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate
ModelArts GPU Ant8 8U64G 专属池实例	model arts.v m.gpu .ant8. u8	model arts.v m.gpu .ant8. u8		推理 服 务/ 训练 作业	虚 拟 机	NP U	x8 6	20 0 G	50 0 G		gpu .vm. wit h.1c ach e.te mpl ate
ModelArts NPU X86 Snt3P-300 I(96G) DUO 24U96G 专属池实例	model arts.v m.snt 3p.30 0i.duo .24u9 6g	model arts.v m.snt 3p.300 i.duo.2 4u96g		推理 服务	虚 拟 机	NP U	x8 6	20 0 G	50 0 G		snt 3p.x 86.t em plat e
ModelArts NPU ARM Snt3P-300 I(96G) DUO 24U96G 专属池实例	model arts.v m.snt 3p.30 0i.duo .kun.2 4u96g	model arts.v m.snt 3p.300 i.duo.k un.24 u96g		推理 服务	虚 拟 机	NP U	ar m	20 0 G	50 0 G		snt 3p. arm .te mpl ate
ModelArts NPU X86 Snt3P-300 I DUO 16U32G 专属池实例	model arts.v m.snt 3p.30 0i.duo .16u3 2g	model arts.v m.snt 3p.300 i.duo.1 6u32g		推理 服务	虚 拟 机	NP U	x8 6	20 0 G	50 0 G		snt 3p.x 86.t em plat e

实例规格名称	名称	Billing编码	标签	支持作业规格	节点类型	计算资源类型	CPU架构	系统盘	数据盘	可见性	节点模板
ModelArts NPU ARM Snt3P-300 I DUO 16U32G专属池实例	modelarts.v m.snt3p.300i.duo.kun.16u32g	modelarts.v m.snt3p.300i.duo.kun.16u32g		推理服务	虚拟机	NPU	arm	200G	500G		snt3p.arm.template

表 5-7 虚拟机资源规格标签设置说明

实例规格名称	名称	标签key	标签value
ModelArts CPU 8U32G专属池实例	modelarts.vm.cpu.8ud	不涉及	不涉及
ModelArts ARM CPU 8U32G专属池实例	modelarts.vm.arm.8ud	不涉及	不涉及
ModelArts GPU T4 8U32G专属池实例	modelarts.vm.gpu.t4u8	os.modelarts.flavor/computility-per-chip	65
ModelArts GPU Ant1(40) 8U64G专属池实例	modelarts.vm.gpu.ant1.40	os.modelarts.flavor/computility-per-chip	312
ModelArts GPU V100(32) 8U64G专属池实例	modelarts.vm.gpu.v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU V100(32) 64U512G专属池实例	modelarts.vm.gpu.8v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU V100s(32) 8U64G专属池实例	modelarts.vm.gpu.v100s.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts NPU X86 Snt3 12U24G专属池实例	modelarts.vm.snt3.12u24g	os.modelarts.flavor/computility-per-chip	44

实例规格名称	名称	标签key	标签value
ModelArts NPU ARM Snt3 12U24G专属池实例	modelarts.vm.snt3.kun.12u24g	os.modelarts.flavor/computility-per-chip	44
ModelArts NPU ARM Snt3P-300I 16U32G专属池实例	modelarts.vm.snt3p.300i.kun.16u32g	os.modelarts.flavor/computility-per-chip	70
ModelArts NPU X86 Snt3P-300I 16U32G专属池实例	modelarts.vm.snt3p.300i.16u32g	os.modelarts.flavor/computility-per-chip	70
ModelArts NPU ARM Snt3P-300V 16U32G专属池实例	modelarts.vm.snt3p.300v.kun.16u32g	os.modelarts.flavor/computility-per-chip	70
ModelArts NPU X86 Snt3P-300V 16U32G专属池实例	modelarts.vm.snt3p.300v.16u32g	os.modelarts.flavor/computility-per-chip	70
ModelArts GPU V100 8U64G专属池实例	modelarts.vm.gpu.v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU 2V100 16U128G专属池实例	modelarts.vm.gpu.2v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU 4V100 32U256G专属池实例	modelarts.vm.gpu.4v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU 8V100 64U512G专属池实例	modelarts.vm.gpu.8v100.pcie	os.modelarts.flavor/computility-per-chip	125
ModelArts GPU Ant8 8U64G专属池实例	modelarts.vm.gpu.ant8.u8	os.modelarts.flavor/computility-per-chip	312
ModelArts NPU X86 Snt3P-300I(96G) DUO 24U96G专属池实例	modelarts.vm.snt3p.300i.duo.24u96g	os.modelarts.flavor/computility-per-chip	140
		os.modelarts.flavor/dies-per-chip	2

实例规格名称	名称	标签key	标签value
ModelArts NPU ARM Snt3P-300I(96G) DUO 24U96G专属池实例	modelarts.vm.snt3p.300i.duo.kun.24u96g	os.modelarts.flavor/computility-per-chip	140
		os.modelarts.flavor/dies-per-chip	2
ModelArts NPU X86 Snt3P-300I DUO 16U32G专属池实例	modelarts.vm.snt3p.300i.duo.16u32g	os.modelarts.flavor/computility-per-chip	140
		os.modelarts.flavor/dies-per-chip	2
ModelArts NPU ARM Snt3P-300I DUO 16U32G专属池实例	modelarts.vm.snt3p.300i.duo.kun.16u32g	os.modelarts.flavor/computility-per-chip	140
		os.modelarts.flavor/dies-per-chip	2

 说明

标签key “os.modelarts.flavor/computility-per-chip” 表示单卡算力，需根据不同的卡型号获取对应的算力，单位TFLOPS

标签key “os.modelarts.flavor/dies-per-chip” 表示单卡带数，单卡单带时，无需添加此标签，默认标签value值为“1”。部分卡类型如 Snt9b23，为单卡双带，因此标签值为“2”

裸金属节点规格和资源规格参数设置说明

 注意

Snt9、Snt9b、Snt9b23的芯片互联组网模式不同，选择高速网络模式时请务必选择正确，选择错误会导致规格不可用，需重建节点规格。

表 5-8 裸金属“节点规格”参数设置说明

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	高速网络配置	高速网络	高速网络模式	数量
ModelArts NPU Snt9 BMS 专属池实例	physical.kat1.6xlarge	裸金属	NPU	ascend-snt9	huawei.com/ascend-1980	打开高速网络配置开关 说明 部分局点无RoCE交换机，无法创建RoCE网络，且客户场景仅使用单机训练或单机推理，该场景下关闭高速网络配置开关	RoCE	选择01230123，表示8张芯片使用两组网络，每组网络4个网段	进入弹性云服务器或裸金属服务器页面，单击申请弹性云服务器，打开F12，刷新页面，查找flavors接口，将response信息保存为文件，查找相应节点规格，查看pci_passthrough:alias字段，确定卡数量。
	physical.kat2.nl.4xlarge.8							选择00000000，表示8张芯片属于同一网络	进入弹性云服务器或裸金属服务器页面，单击申请弹性云服务器，打开F12，刷新页面，查找flavors接口，将response信息保存为文件，查找相应节点规格，查看pci_passthrough:alias字段，确定卡数量。
	physical.kat2.nl.4xlarge.8.snt9b1								
	physical.kat2.nl.4xlarge.8.snt9b2								
ModelArts NPU Snt9b BMS 专属池实例	physical.kat2.nl.4xlarge.8.snt9b3	裸金属	NPU	ascend-snt9b	huawei.com/ascend-1980				

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	高速网络配置	高速网络	高速网络模式	数量
	physical.kat2nl.48xlarge.8snt9b4								

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	高速网络配置	高速网络	高速网络模式	数量
ModelArts NPU Snt9b23 BMS 专属池实例	physical.kat3e.40xlarge.8.800t.c00[X] [X]为当前局点规划的超节点个数（同一个主机组规划为一个超节点，每个主机组使用一个节点规格），当前最多两个超节点，所以取值可能为c001或c002	裸金属	NPU	ascend-snt9c	huawei.com/ascend-1980			选择000000000000，表示16张芯片属于同一网络	进入弹性云服务器或裸金属服务器页面，单击申请弹性云服务器，打开F12，刷新页面，查找flavors接口，将response信息保存为文件，查找相应节点规格，查看pci_passthrough:alias字段，确定卡带数量。 Snt9b23为单卡双带，则数量值为pci_passthrough:alias字段值。 注意 添加Snt9b23 BMS节点规格，需要填写标签，键填写os.modelarts.flavor/superpod，值填写true。

实例规格名称	名称	类型	架构	卡类型名称	调度资源类型	高速网络配置	高速网络	高速网络模式	数量
ModelArts GPU Ant8 BMS 专属池实例	physical.p7vs.8xlarge	裸金属	GPU	nvidia-ant8-smx4-80	nvidia.com/gpu	打开高速网络配置开关	RoCE	选择00000000，表示8张芯片属于同一网络	进入弹性云服务器或裸金属服务器页面，单击申请弹性云服务器，打开F12，刷新页面，查找flavors接口，将response信息保存为文件，查找相应节点规格，查看pci_passthrough:alias字段，确定卡数量。
ModelArts GPU Ant1 BMS 专属池实例	physical.p7v.8xlarge	裸金属	GPU	nvidia-ant1-smx4-80	nvidia.com/gpu				
ModelArts GPU Hnt8 BMS 专属池实例	physical.p8vs.44xlarge	裸金属	GPU	nvidia-hnt8-nv80	nvidia.com/gpu	打开高速网络配置开关	RoCE	选择00000000，表示8张芯片属于同一网络	进入弹性云服务器或裸金属服务器页面，单击申请弹性云服务器，打开F12，刷新页面，查找flavors接口，将response信息保存为文件，查找相应节点规格，查看pci_passthrough:alias字段，确定卡数量。
ModelArts GPU Hnt1 BMS 专属池实例	physical.p1vs.44xlarge	裸金属	GPU	nvidia-hnt1-nv80	nvidia.com/gpu				

 说明

- 创建“资源规格”时，Billing编码必须为以下表格中列举的内容。若修改为其他内容，可能会导致计量信息异常等问题。
- 创建“资源规格”时，若需要使用大模型，“节点模板”需选择新增的大模型节点模板。
- 创建“资源规格”时，若关联的裸金属节点规格在创建时选择的启动源为云磁盘时，需设置系统盘，值为200G。
- 创建“资源规格”时，若关联的裸金属节点规格属于Snt9b23，若该局点有多个主机组，则节点规格和节点模板的后缀需要配合使用。

表 5-9 裸金属“资源规格”参数设置说明

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CPU 架构	系统盘	数据盘	可见性	节点模板	添加步长
ModelArts NPUSnt9BMS专属池实例	modelarts.kat1.8xlarge	modelarts.kat1.8xlarge	参考表 5-11	训练作业	裸金属	NPU	arm64	-	-	可选择“可见”“不可见”“白名单”。可见：表示该资源规格对所有用户可见。不可见：表示该资源对所有用户都不可见。白名单：表示该资源对部分用户可见，若选择该项，需要额外配置白名单字段。	使用RoCE交换机时：snt9.arm.template 无RoCE交换机时：snt9.arm.without.roc.template 说明 无RoCE交换机时，仅支持单机训练。	-

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统盘	数据盘	可见性	节点模板	添加步长
Model Arts NPUSnt9bBMS专属池实例	model arts .bm .ar m.s nt9 b.k at2 nl.4 8xl arg e.8	model arts .bm .ar m.s nt9 b.k at2 nl.4 8xl arg e.8		推理服务/新版推理/训练作业	裸金属	NPU	arm64	-	-		使用RoCE交换机时: snt9b.arm.template	-
	model arts .bm .ar m.s nt9 b.k at2 nl.4 8xl arg e.8. snt9b1										无RoCE交换机时: snt9b.arm.without.roce.template	-
	model arts .bm .ar m.s nt9 b.k at2 nl.4 8xl arg e.8. snt9b2											-

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统盘	数据盘	可见性	节点模板	添加步长
	model arts .bm .arm.s nt9 b.k at2 nl.4 8xl arg e.8. snt 9b3										说明 无 Ro CE 交换机时，仅支持单机训练、单机推理。选择 snt 9b. ar m. wit ho ut. roc e.t em pla te 会给每一个芯片设置无效的 Ro CE IP 用于标识。	-
	model arts .bm .arm.s nt9 b.k at2 nl.4 8xl arg e.8. snt 9b4											-

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统盘	数据盘	可见性	节点模板	添加步长
ModelArts NPUSnt9b23BMS专属池实例	modelarts.bm.ar.m.snt9c.kat3e.48xlarge.8	modelarts.bm.ar.m.snt9c.kat3e.48xlarge.8		推理服务/新版推理/训练作业	裸金属	NPU	arm64	-	-		snt9c.arm.template.c00[X] [X] 为当前局点规划的超节点个数（同一个主机组规划为一个超节点，每个主机组使用一个节点规格），当前最多两个超节点，所以取值可能为c001或c002	步长设置请参考表 5-10。

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统盘	数据盘	可见性	节点模板	添加步长
Model Arts GPU Ant 8 BM S 专属池实例	model arts .bm .gpu.8 a8x xnv. d	model arts .bm .gpu.8 a8x xnv. d		推理服务/训练作业	裸金属	GPU	x86	-	-	可选择“可见”“不可见”“白名单”。可见：表示该资源规格对所有用户可见。不可见：表示该资源对所有用户都不可见。白名单：表示该资源对部分用户可见，若选择该选项，需要额外配置白名单字段。	gpu.baremetal.ant8.template	-
Model Arts GPU Ant 1 BM S 专属池实例	model arts .hp. s1.i 6l.d	model arts .hp. s1.i 6l.d		推理服务/训练作业	裸金属	GPU	x86	-	-		gpu.baremetal.ant1.template	-

实例规格名称	名称	Billing 编码	标签	支持作业规格	节点类型	计算资源类型	CP U 架构	系统盘	数据盘	可见性	节点模板	添加步长
Model Arts GPU Hnt8 BM S专属池实例	model arts .bm .gpu.hnt8 nv.d	model arts .bm .gpu.hnt8 nv.d		推理服务/训练作业	裸金属	GPU	x86	-	-	可选择“可见”“不可见”“白名单”。可见：表示该资源规格对所有用户可见。不可见：表示该资源对所有用户都不可见。白名单：表示该资源对部分用户可见，若选择该选项，需要额外配置白名单字段。	gpu.baremetal.hnt8.template	-
Model Arts GPU Hnt1 BM S专属池实例	model arts .bm .gpu.hnt1 nv.d	model arts .bm .gpu.hnt1 nv.d		推理服务/训练作业	裸金属	GPU	x86	-	-		gpu.baremetal.hnt1.template	-

表 5-10 ModelArts NPU Snt9b23 BMS 专属池实例超节点步长设置

节点规格	大小	英文描述	中文描述
physical.kat3e.40xlarge.8.800t.c00[X] [X]为当前局点规划的超节点个数（同一个主机组规划为一个超节点，每个主机组使用一个节点规格），当前最多两个超节点，所以取值可能为c001或c002	表示某一批次的超节点的计算节点数。	用户自定义，用于区分超节点的规格	用户自定义，用于区分超节点的规格

表 5-11 ModelArts 裸金属资源规格标签

实例规格名称	名称	标签key	标签value
ModelArts NPU Snt9 BMS专属池实例	modelarts.kat1.8xlarge	os.modelarts.flavor/computility-per-chip	280
ModelArts NPU Snt9b BMS专属池实例	modelarts.bm.arm.snt9b.kat2nl.48xlarge.8	os.modelarts.flavor/computility-per-chip	400
	modelarts.bm.arm.snt9b.kat2nl.48xlarge.8.snt9b1	os.modelarts.flavor/computility-per-chip	400
	modelarts.bm.arm.snt9b.kat2nl.48xlarge.8.snt9b2	os.modelarts.flavor/computility-per-chip	376
	modelarts.bm.arm.snt9b.kat2nl.48xlarge.8.snt9b3	os.modelarts.flavor/computility-per-chip	313

实例规格名称	名称	标签key	标签value
	modelarts. bm.arm.snt 9b.kat2nl.4 8xlarge.8.s nt9b4	os.modelarts.flavor/ computility-per-chip	280
ModelArts NPU Snt9b23 BMS专属池 实例	modelarts. bm.arm.snt 9c.kat3e.48 xlarge.8	os.modelarts.flavor/ computility-per-chip	若机型为Atlas 900 A3 SuperPod (液冷)，则值 为800。 若机型为Atlas 800T A3 (风冷)，则值为752。 若机型为Atlas 800I A3 (风冷)，则值为560。
		os.modelarts.flavor/dies- per-chip	2
ModelArts GPU Ant8 BMS专属池 实例	modelarts. bm.gpu.8a8 xxnv.d	os.modelarts.flavor/ computility-per-chip	312
ModelArts GPU Ant1 BMS专属池 实例	modelarts. hp.s1.i6l.d	os.modelarts.flavor/ computility-per-chip	312
ModelArts GPU Hnt8 BMS专属池 实例	modelarts. bm.gpu.hnt 8nv.d	os.modelarts.flavor/ computility-per-chip	989
ModelArts GPU Hnt1 BMS专属池 实例	modelarts. bm.gpu.hnt 1nv.d	os.modelarts.flavor/ computility-per-chip	989

 说明

标签key “os.modelarts.flavor/computility-per-chip” 表示单卡算力，需根据不同的卡型号获取对应的算力，单位TFLOPS

标签key “os.modelarts.flavor/dies-per-chip” 表示单卡带数，单卡单带时，无需添加此标签，默认标签value值为“1”。部分卡类型如 Snt9b23，为单卡双带，因此标签值为“2”

5.1.8 节点配置管理


“节点配置管理” 模块用于查看和管理系统中的节点配置模板。节点配置模板用于资源规格和集群的创建。

“节点配置”界面呈现了该ModelArts承载租户用户下所有节点模板的信息，其中包括名称、创建时间和描述。

- 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
 - 单击“登录”。
- 在服务列表中选择“AI开发平台ModelArts”，进入ModelArts管理控制台。
- 在左侧菜单栏中选择“资源管理 > 节点配置管理”，进入节点模板列表。单击节点名称进入节点模板详情页面。
- 详情页面展示了节点模板的详细信息，包括“基本信息”和“配置信息”。在“配置信息”中，单击“操作系统/镜像ID”后的，即可修改操作系统或镜像。同时，可将鼠标移动至预览处可查看配置命令详情。

说明

修改“操作系统/镜像ID”前，须确保输入操作系统和镜像的正确性。



5.1.9 资源租户

“资源租户”模块主要用于查看ModelArts的资源租户信息。

- 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。

- 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
- b. 单击“登录”。
 2. 在服务列表中选择“AI开发平台ModelArts”，进入ModelArts管理控制台。
 3. 在左侧菜单栏中选择“资源管理 > 资源租户”，进入资源租户列表。可单击租户名称，查看资源租户详情。

5.1.10 插件

注意

- 当前不支持对npu-driver、icagent、gpu-driver插件进行升级。
- 集群使用的device plugin插件已经由huawei-npu变为了modelarts-device-plugin，优化了一些NPU芯片故障处理流程，并增加了A3超节点机型超平面的可靠性的适配。
- 升级device plugin插件版本（huawei-npu或者modelarts-device-plugin）时，需要关闭卡检测，并且集群中没有正在处于调度阶段的使用npu资源的任务（已经运行的使用npu资源的任务不受影响）。

“插件”模块主要用于查看ModelArts的插件，同时也可对插件进行升级操作。

升级插件

1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - a. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。

- ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
- b. 单击“登录”。
 2. 在服务列表中选择“AI开发平台ModelArts”，进入ModelArts管理控制台。
 3. 在左侧菜单栏中选择“资源管理 > 插件”，进入插件列表。
 4. 在插件列表中，显示了插件类型、状态、版本等信息，可单击集群查看详情，也可选择“操作 > 插件升级”升级插件。

存量集群替换 device plugin 插件

如果需要将集群使用的device插件由huawei-npu手动切换为modelarts-device-plugin，请参考以下文档。

前提条件：

1. 关闭卡检测。
2. 集群中没有正在处于调度阶段的使用npu资源的任务（已经运行的使用npu资源的任务不受影响）。

替换步骤：

1. [登录CDK master节点](#)。
2. 登录ModelArts-Common-Region-POD-Master-0001节点，执行如下命令查看pod，然后找到modelarts-os-apiserver容器。

```
kubectl get pod
```

```
root@ModelArts-Common-Region-POD-Master-0002 ~# kubectl get pod
NAME                                READY   STATUS    RESTARTS   AGE
modelarts-algorancher-8ddcc8d68-cqk42    1/1     Running   0           3d16h
modelarts-algorancher-8ddcc8d68-krc8m    1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-ftsxn      1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-hvsj9      1/1     Running   0           3d16h
modelarts-console-backend-576cbbffdb-d78t7 1/1     Running   0           3d16h
modelarts-console-backend-576cbbffdb-k94g7 1/1     Running   0           3d16h
modelarts-exemplflow-778b8c78fd-mjg67    1/1     Running   0           3d16h
modelarts-exemplflow-778b8c78fd-wglcl    1/1     Running   0           3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8 1/1     Running   0           2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl 1/1     Running   0           2d22h
modelarts-os-apiserver-5cd548c558-sltx5    1/1     Running   0           3d16h
modelarts-os-apiserver-5cd548c558-tzvv2    1/1     Running   0           3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz     1/1     Running   0           3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x     1/1     Running   0           3h24m
```

3. 执行如下命令进入modelarts-os-apiserver容器。
`kubectl exec -it <modelarts-os-apiserver的pod的名字> -- bash`
4. 执行如下命令获取需要切换device plugin插件的资源池对应的cluster的名称。

```
kubectl get clusters
```

```
root@ModelArts-Common-Region-POD-Master-0002 ~# kubectl exec -it modelarts-os-apiserver-bc54d5f76-247ks -- bash
service@modelarts-os-apiserver-bc54d5f76-247ks:~$ kubectl get clusters
NAME                                POOL                                STATUS    CONNECTED    AGE
dispatcher                         dispatcher                         Available True         33d
infer-arm                          infer-arm                         Available True         56d
infer-arm                          infer-arm                         Available True         68d
infer-cpu                          infer-cpu                         Available True         68d
infer-cpu                          infer-cpu                         Available True         68d
infer-snt3                         infer-snt3                        Available True         58d
infer-t4-a                         infer-t4-a                        Available True         58d
pool-2167                          pool-2167                         Available True         41d
```

5. 执行如下命令，然后修改.spec.plugin字段，将其中的huawei-npu子项删除，并添加modelarts-device-plugin子项，修改完保存退出。
`kubectl edit clusters <资源池对应的cluster的名称>`

```
uid: 2700e608-7533-44b7-89a9-274b08132968
spec:
  cluster:
    category: CCE
    containerNetwork:
      cidr: 172.16.0.0/16
      mode: overlay_l2
      flavor: cce.s1.small
    hostNetwork:
      subnet: 81a2253a-7c43-473d-9fc5-651ff07ec4ee
      vpc: 7e0f09cf-63ed-49b5-a710-91ac097da713
      kubernetesSvcIpRange: 10.247.0.0/16
    masters:
      - az: az0.dc0
      platformVersion: cce.16.11
      type: VirtualMachine
      version: v1.25
    nodes:
      - configTemplate: snt9b.arm.template
        extendParams:
          dockerBaseSize: "50"
          runtime: docker
          flavorId: physical.physical.kat2n1.48xlarge.8.snt9b3
        metadata:
          annotations:
            os.modelarts/tms.tags: '[{"key":"regioncode","value":"sa-fb-1"}, {"key":"cloudservicetypecode","value":"hws.service.type.modelarts"}, {"key":"cloudservicetypecode","value":"ModelArts"}, {"key":"instanceid","value":"larts.bm.arm.snt9b.kat2n1.48xlarge.8.snt9b3"}, {"key":"resourcespeccode","value":"larts.bm.arm.snt9b.kat2n1.48xlarge.8.snt9b3"}]'
          network:
            subnet: e86abb4e-2698-4807-a9c3-53c4695fef55
            vpc: 7e0f09cf-63ed-49b5-a710-91ac097da713
          replicas: 2
        plugins:
          - name: icagent
            inputs:
              - ("configs":{"drop_cache":{"mode":"disable"},"image_warm_up":{"id":"image-warm-up-task-97174a95-d31d-4a9b-bfbc-643b34765b0c","image":"swr.sa-fb-1.eima01.com/mindie/mindie-with-model-b07b:v0.0.2"},"classification_v1":{"name":"test2","type":"SWR"},"id":"image-warm-up-task-1ba278c8-c092-453c-879a-56b3b0caabbe","image":"swr.sa-fb-1.eima01.com/xinfer-ds/mindie-2.0.13:v0.0.3"},"name":"test5","type":"SWR"},"id":"image-warm-up-task-7e452fd0-0faa-447a-88bb-b39db2a831dc","image":"swr.sa-fb-1.eima01.com/test-wly/mindspore-2.2_ascend_snt9b:1.1.2"},"name":"test6","type":"SWR"},"id":"image-warm-up-task-64833f50-0a4c-4c7e-b1c1-eb47258f9f71","image":"swr.sa-fb-1.eima01.com/test-wly/mindspore-2.2_ascend_snt9b:1.1.2"},"name":"test7","type":"SWR"},"id":"image-warm-up-task-0ca09e91-70b0-45c5-a595-63eacdb94c4f","image":"swr.sa-fb-1.eima01.com/deepseek/pytorch_2.0:1.2","name":"test8","type":"SWR"}])
            name: os-node-agent
            version: 6.8.0-20250708144224
          - name: volcano
          - name: huawei-npu
          - name: modelarts-device-plugin
          - name: npu-driver
          updateStrategy: idle
          version: 7.5.0-220-24.1.0.3
          name: modelarts-infer-operator
          version: 8.6.0-20250730195221
```

如需要回退，满足相同前置条件后，执行相同步骤，最后修改.spec.plugin字段，将其中的modelarts-device-plugin子项删除，并添加huawei-npu子项。

5.1.11 RoCE 网络

使用VLAN的RoCE网络后，RoCE子网池由于网段有限，无法满足不断增长的租户量，而有些测试租户或不再使用的租户占用着网段而未使用，造成浪费，因此可以管理员统一进行清理。

操作步骤

- 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
 - 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
 - 单击“登录”。
- 在服务列表中选择“AI开发平台ModelArts”，进入ModelArts管理控制台。

3. 在左侧菜单栏中选择“资源管理 > RoCE网络”，进入RoCE网络列表页。
4. 依次对不再需要使用的RoCE网络执行“删除”操作。

5.2 审批流程管理

5.2.1 设置 ModelArts 审批流程

安装ModelArts时默认预置的ModelArts专属资源池/训练作业/推理服务，默认不需要审批流程，用户可以进入管理控制台页面进行创建。也可以通过设置审批流程实现对系统资源的审批和管理能力，ModelArts专属资源池/训练作业/推理服务支持设置资源审批，您可以参考如下操作指导，设置审批流程。

设置后，用户在选择该服务创建专属资源池，创建训练作业或部署服务时，需按照对应的流程审批通过后，才能实施。

设置服务的审批流程

1. 以运营管理员账号登录ManageOne运营面。
 - a. 使用浏览器，登录ManageOne运营面。

登录地址：

非B2B场景：https://*ManageOne运营面的访问地址*。例如，https://console.demo.com。

B2B场景：https://*ManageOne运营管理面的访问地址*。例如，https://admin.demo.com。

ManageOne运营面的访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/运营管理面”相关信息。

登录方式分为“密码认证”和“USB Key认证”。

 - 密码认证：输入账号和密码。

默认账号：**bss_admin**

默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（Portal）”页签中搜索“bss_admin”获取对应的默认密码。首次登录需要修改密码。
 - USB Key认证：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。
 - b. 单击“登录”。
2. 在上方菜单栏选择“系统”，在左侧导航选择“审批流程 > 审批流程管理”。单击“创建审批流程”。
 - 名称：自定义审批流程名称
 - 分类：默认为全部
 - 审批层级：选择需要几级审批

说明

仅在SM系列商密算法场景下支持USB Key方式。

单击确定跳转至流程管理页面，单击画布区域中的控件，在右侧设置控件的参数配置后，单击“保存”完成创建。详细流程设置请参见《[华为云Stack 8.6.0 产品文档](#)》> 用户指南 > 资源发放指南 > 运营管理 > 管理审批流程。

3. 返回审批流程管理页面，发布创建的审批流程，发布成功后状态列为“已发布”。
4. 在左侧导航选择“审批流程 > 流程控制点”。搜索专属资源池/推理/训练，在“创建_ModelArts 专属资源池”/“创建_ModelArts 推理服务”/“创建_ModelArts 训练作业”服务所在行，单击“操作”列的“设置审批流程”。
 - 是否关联审批：是。
 - 是否允许租户设置审批流程：根据实际需要选择是或否。
默认为否，即表示不允许租户设置应用审批流程。
选择“是”，则开启允许租户设置审批流程，在运营租户侧才可以给租户设置应用审批流程。租户内优先使用在租户侧内设置的应用审批流程，如果租户侧内未设置应用审批流程，那么使用管理侧设置的应用审批流程。
 - 选择审批流程：选择上步已创建的审批流程。设置完成后，单击“确定”。

5.3 基础镜像注册

5.3.1 制作、上传并注册 ModelArts 推理预置镜像

当前版本的预置镜像，需要手动进行配置（升级上来的环境原有预置镜像不受影响），否则会在导入模型时提示引擎及运行环境不支持。新安装的环境若需要使用非Custom引擎的模型，需要按照本节指导完成ModelArts预置镜像的制作、上传与注册。升级环境若需要当前版本的新镜像，也需要按照本节指导完成操作。

当前版本配套的预置镜像版本号固定为2.3.0，且都基于amd64架构。预置镜像包括“tf-serving-model-server_2.3.0-tf1.13-python3.7-cpu_x86_64”、“tf-serving-model-server_2.3.0-tf1.13-python3.7-gpu_x86_64”、“tf-serving-model-server_2.3.0-tf2.1-python3.7_x86_64”、“pytorch-model-server_2.3.0-pytorch1.4-python3.7_x86_64”、“pyspark-infer_2.3.0-pyspark2.4.5-python3.7_x86_64”与“xgboost-sklearn-infer_2.3.0-xgb1.2.1-sk10.24.2-python3.7_x86_64”。

准备工作

- 准备一套可以连接外部网络，装有Linux系统并安装18.09.7版本Docker的虚拟机或物理机用作镜像构建节点，以下称“构建节点”。
可以通过执行docker pull、apt-get update/upgrade和pip install命令判断是否可以正常访问外部可用的开源软件仓库，若可以正常访问表示环境已连接外部网络。
- 准备一套可以连接华为云Stack网络，装有Linux系统并安装18.09.7版本Docker的虚拟机或物理机用作镜像上传节点，以下称“上传注册节点”。使用“WinSCP”工具以root用户登录上传注册节点，执行命令“bash --version”查看bash工具的版本号是否为4.4及以上。若不是，则需重新创建一台虚拟机选择更高版本的系统镜像。
若环境可访问ModelArts的推理数据库主节点和SWR提供的EndPoint，则表示已连接华为云Stack网络。
- 参考《[华为云Stack 8.6.0 技术中台与AI数据中台服务软件安装指南](#)》的“AI平台开发(ModelArts)安装指南 > 安装前准备 > 文档、工具和软件包”章节获取ModelArts软件包中的ModelArts_Images.tar.gz安装包。

- 请单击下载软件包Miniconda: [Miniconda3-py37_4.10.3-Linux-x86_64.sh](#)。
- 请单击下载Tensorflow框架使用的推理解释器: [tflite_runtime-2.1.0.post1-cp37-cp37m-linux_x86_64.whl](#)。

须知

上述的虚拟机或物理机需要为amd64架构。建议构建节点安装的Linux系统版本为Ubuntu 18.04。本指导使用/opt目录作为构建任务承载目录, 请确保该目录下可用存储空间大于30GB。Docker的安装请参见[官方文档](#)。MiniConda与tflite安装包为第三方安装包, ModelArts不对其安全相关问题进行负责, 如用户有安全方面的需求, 可以对该安装包进行加固后发布成同样名称的文件上传到构建节点。

操作步骤

1. 使用“WinSCP”工具以root用户登录构建节点, 将“ModelArts_Images.tar.gz”上传到该节点“/opt/”目录下。
2. 使用“PuTTY”工具以root用户登录构建节点。
3. 执行如下命令, 解压“ModelArts_Images.tar.gz”安装包。

```
cd /opt/  
tar -zxvf ModelArts_Images.tar.gz
```
4. 使用“WinSCP”工具以root用户登录构建节点, 将“Miniconda3-py37_4.10.3-Linux-x86_64.sh”上传到“/opt/ModelArts_Images/base”目录下。
5. 使用“WinSCP”工具以root用户登录构建节点, 将“tflite_runtime-2.1.0.post1-cp37-cp37m-linux_x86_64.whl”上传到“/opt/ModelArts_Images/tensorflow/tf2.1-python3.7”目录下。
6. 使用Docker命令拉取基础镜像, 命令如下:

```
docker pull ubuntu:18.04
```

说明

如果拉取速度过慢, 可以使用用户信任的docker仓库, 命令格式为:

```
docker pull {仓库地址}/{命令空间}/ubuntu:18.04
```

7. 拉取成功后需要重新tag镜像, 去除镜像名称中带有的仓库地址和镜像组织前缀, 参考命令如下:

```
docker tag {仓库地址}/{镜像组织}/ubuntu:18.04 ubuntu:18.04
```

须知

该镜像为推理服务的基础镜像, ModelArts不对其相关安全问题进行加固, 如果用户有安全类需求, 可对该镜像进行修改, 最终使用上述命令将更改后的镜像重新tag为ubuntu:18.04即可。

8. 制作用于预置镜像构建的通用镜像。

须知

在预置镜像构建过程中，需要安装第三方软件，ModelArts不对第三方软件的安全性进行分析。如果用户对第三方软件有安全类需求，可使用可信的软件安装源（如华为开源镜像站）进行安装。

对于Ubuntu的官方软件仓库，通过在Dockerfile添加以下命令将安装源配置到基础镜像中对应的系统配置“/etc/apt/sources.list”上即可：

```
cp -a /etc/apt/sources.list /etc/apt/sources.list.bak
sed -i "s@http://.*archive.ubuntu.com@http://repo.huaweicloud.com@g" /etc/apt/sources.list
sed -i "s@http://.*security.ubuntu.com@http://repo.huaweicloud.com@g" /etc/apt/sources.list
```

对于Pypi官方开源组件库，可以通过在Dockerfile中添加以下命令配置：

```
pip config set global.trusted-host repo.huaweicloud.com
pip config set global.index-url https://repo.huaweicloud.com/repository/pypi/simple
```

以上命令已在“ModelArts_Images/base/”下的“nginx.python3.7.dockerfile”文件中的第6至8行与第39至40行预置，若需要可解除注释使用。

a. 逐条执行以下命令，制作镜像：

```
cd /opt/ModelArts_Images/base
docker build -t ubuntu:18.04-nginx-conda37 -f nginx.python3.7.dockerfile .
```

b. 执行本地镜像仓库查询命令，确认用于预置镜像构建的通用镜像（ubuntu:18.04-nginx-conda37）已构建完成。

```
docker images
```

9. 参考表5-12制作相关预置镜像。

须知

在制作预置镜像时也可以选择使用华为开源镜像站提供的Pypi官方开源组件库镜像：

```
PIP_OPTS="--trusted-host repo.huaweicloud.com -i https://repo.huaweicloud.com/repository/pypi/simple --user"
pip install $PIP_OPTS {PACKAGE_NAME}=={VERSION}
```

以上命令已在每个预置镜像的构建“Dockerfile”中以ENV形式预置，若需要可解除注释使用。

表 5-12 制作预置镜像

镜像包名称	执行命令（逐条执行）
tf-serving-model-server_2.3.0-tf1.13-python3.7-cpu_x86_64.tar	1. <code>cd /opt/ModelArts_Images/tensorflow/tf1.13-python3.7-cpu</code> 2. <code>docker build -t tf-serving-model-server:2.3.0-tf1.13-python3.7-cpu -f tf1.13.dockerfile .</code> 3. <code>docker save tf-serving-model-server:2.3.0-tf1.13-python3.7-cpu -o /opt/tf-serving-model-server_2.3.0-tf1.13-python3.7-cpu_x86_64.tar</code> 4. <code>docker rmi -f tf-serving-model-server:2.3.0-tf1.13-python3.7-cpu</code>

镜像包名称	执行命令（逐条执行）
tf-serving-model-server_2.3.0-tf1.13-python3.7-gpu_x86_64.tar	1. <code>cd /opt/ModelArts/Images/tensorflow/tf1.13-python3.7-gpu</code> 2. <code>docker build -t tf-serving-model-server:2.3.0-tf1.13-python3.7-gpu -f cuda10.0/tf1.13.dockerfile .</code> 3. <code>docker save tf-serving-model-server:2.3.0-tf1.13-python3.7-gpu -o /opt/tf-serving-model-server_2.3.0-tf1.13-python3.7-gpu_x86_64.tar</code> 4. <code>docker rmi -f tf-serving-model-server:2.3.0-tf1.13-python3.7-gpu</code>
tf-serving-model-server_2.3.0-tf2.1-python3.7_x86_64.tar	1. <code>cd /opt/ModelArts/Images/tensorflow/tf2.1-python3.7</code> 2. <code>docker build -t tf-serving-model-server:2.3.0-tf2.1-python3.7 -f cuda10.1/tf2.1.dockerfile .</code> 3. <code>docker save tf-serving-model-server:2.3.0-tf2.1-python3.7 -o /opt/tf-serving-model-server_2.3.0-tf2.1-python3.7_x86_64.tar</code> 4. <code>docker rmi -f tf-serving-model-server:2.3.0-tf2.1-python3.7</code>
pytorch-model-server_2.3.0-pytorch1.4-python3.7_x86_64.tar	1. <code>cd /opt/ModelArts/Images/pytorch/pytorch1.4-python3.7</code> 2. <code>docker build -t pytorch-model-server:2.3.0-pytorch1.4-python3.7 -f cuda10.1/pytorch1.4.dockerfile .</code> 3. <code>docker save pytorch-model-server:2.3.0-pytorch1.4-python3.7 -o /opt/pytorch-model-server_2.3.0-pytorch1.4-python3.7_x86_64.tar</code> 4. <code>docker rmi -f pytorch-model-server:2.3.0-pytorch1.4-python3.7</code>
pyspark-infer_2.3.0-pyspark2.4.5-python3.7_x86_64.tar	1. <code>cd /opt/ModelArts/Images/spark_mllib/pyspark2.4.5-python3.7</code> 2. <code>docker build -t pyspark-infer:2.3.0-pyspark2.4.5-python3.7 -f pyspark2.4.5.dockerfile .</code> 3. <code>docker save pyspark-infer:2.3.0-pyspark2.4.5-python3.7 -o /opt/pyspark-infer_2.3.0-pyspark2.4.5-python3.7_x86_64.tar</code> 4. <code>docker rmi -f pyspark-infer:2.3.0-pyspark2.4.5-python3.7</code>

镜像包名称	执行命令（逐条执行）
xgboost-sklearn-infer_2.3.0-xgb1.2.1-sk10.24.2-python3.7_x86_64.tar（整合镜像，用于XGBoost与Scikit_Learn两个引擎）	1. <code>cd /opt/ModelArts_Images/xgboost-sklearn/xgb1.2.1-sk10.24.2-python3.7</code> 2. <code>docker build -t xgboost-sklearn-infer:2.3.0-xgb1.2.1-sk10.24.2-python3.7 -f xgb1.2.1-sk10.24.2.dockerfile .</code> 3. <code>docker save xgboost-sklearn-infer:2.3.0-xgb1.2.1-sk10.24.2-python3.7 -o /opt/xgboost-sklearn-infer_2.3.0-xgb1.2.1-sk10.24.2-python3.7_x86_64.tar</code> 4. <code>docker rmi -f xgboost-sklearn-infer:2.3.0-xgb1.2.1-sk10.24.2-python3.7</code>

10. 将上传工具和制作完成的镜像包上传到注册节点。
 - a. 使用“WinSCP”工具以root用户登录上传注册节点。
 - b. 将“ModelArts_Images.tar.gz”安装包中的上传工具“builtin_image_swr_upload_tool.sh”复制至上传注册节点的/opt/目录下。
 - c. 将9制作完成的预置镜像包文件从构建节点的/opt/目录复制至上传注册节点的/opt/目录下。
11. 在ModelArts安装完成后，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，在服务列表选择ModelArts安装的区域与资源空间，然后选择“应用服务 > 容器镜像服务SWR”，在左侧菜单栏选择“我的镜像”，单击任意镜像名称进入详情页，在“Pull/Push指南”页签获取当前区域的Public Image Address（格式为swr.{region_id}.{external_domain_id}.com）。左侧菜单栏选择“组织管理”，确认组织“modelarts-infers”存在。左侧菜单栏选择“总览”，单击右上角“登录指令”，复制弹窗中的具体命令。
12. 将镜像上传至SWR。支持工具上传和手动上传两种方式。
 - 工具上传：
 - i. 进入10中上传工具所在目录/opt/，执行以下命令打开上传工具“builtin_image_swr_upload_tool.sh”。

```
cd /opt
bash builtin_image_swr_upload_tool.sh
```
 - ii. 根据工具脚本提示输入11中复制的SWR镜像仓库“登录指令”与预置镜像包文件的所在目录，由工具脚本完成预置镜像上传至SWR。

说明

上传工具默认的预置镜像包文件所在目录为/opt，若由于磁盘分区限制等原因未按照10要求将预置镜像包文件复制至/opt目录，根据工具提示输入实际的归档目录即可。

- 手动上传：
 - i. 使用“PuTTY”工具以root用户登录上传注册节点，执行11中最后复制的SWR镜像仓库“登录指令”。
 - ii. 进入9中预置镜像的上传目录/opt/，加载预置镜像文件至本地docker镜像仓库。参考命令如下：

```
cd /opt
docker load -i tf-serving-model-server_2.3.0-tf1.13-python3.7-cpu_x86_64.tar
docker load -i tf-serving-model-server_2.3.0-tf1.13-python3.7-gpu_x86_64.tar
```

```
docker load -i tf-serving-model-server_2.3.0-tf2.1-python3.7_x86_64.tar
docker load -i pytorch-model-server_2.3.0-pytorch1.4-python3.7_x86_64.tar
docker load -i pyspark-infer_2.3.0-pyspark2.4.5-python3.7_x86_64.tar
docker load -i xgboost-sklearn-infer_2.3.0-xgb1.2.1-sklearn0.24.2-python3.7_x86_64.tar
```

- iii. 根据11获得的Public Image Address，完成本地镜像仓库已加载镜像的重命名。参考命令如下：

```
public_image_address={Public Image Address}
image_organization_name="modelarts-infers"
docker tag tf-serving-model-server:2.3.0-tf1.13-python3.7-cpu $
{public_image_address}/{image_organization_name}/tf-serving-model-server:2.3.0-
tf1.13-python3.7-cpu
docker tag tf-serving-model-server:2.3.0-tf1.13-python3.7-gpu $
{public_image_address}/{image_organization_name}/tf-serving-model-server:2.3.0-
tf1.13-python3.7-gpu
docker tag tf-serving-model-server:2.3.0-tf2.1-python3.7 ${public_image_address}/{
image_organization_name}/tf-serving-model-server:2.3.0-tf2.1-python3.7
docker tag pytorch-model-server:2.3.0-pytorch1.4-python3.7 $
{public_image_address}/{image_organization_name}/pytorch-model-server:2.3.0-
pytorch1.4-python3.7
docker tag pyspark-infer:2.3.0-pyspark2.4.5-python3.7 ${public_image_address}/{
image_organization_name}/pyspark-infer:2.3.0-pyspark2.4.5-python3.7
docker tag xgboost-sklearn-infer:2.3.0-xgb1.2.1-sklearn0.24.2-python3.7 $
{public_image_address}/{image_organization_name}/xgboost-sklearn-infer:2.3.0-
xgb1.2.1-sklearn0.24.2-python3.7
```

- iv. 上传本地重命名的镜像（名称前缀包含11获得的Public Image Address），参考命令如下：

```
public_image_address={Public Image Address}
image_organization_name="modelarts-infers"
docker push ${public_image_address}/{image_organization_name}/tf-serving-model-
server:2.3.0-tf1.13-python3.7-cpu
docker push ${public_image_address}/{image_organization_name}/tf-serving-model-
server:2.3.0-tf1.13-python3.7-gpu
docker push ${public_image_address}/{image_organization_name}/tf-serving-model-
server:2.3.0-tf2.1-python3.7
docker push ${public_image_address}/{image_organization_name}/pytorch-model-
server:2.3.0-pytorch1.4-python3.7
docker push ${public_image_address}/{image_organization_name}/pyspark-
infer:2.3.0-pyspark2.4.5-python3.7
docker push ${public_image_address}/{image_organization_name}/xgboost-sklearn-
infer:2.3.0-xgb1.2.1-sklearn0.24.2-python3.7
```

回到ManageOne运营面，选择“应用服务 > 容器镜像服务SWR”，进入镜像组织“modelarts-infers”详情页面，确认可以搜索并查看到以上已完成上传的镜像。

13. 参考[登录ModelArts数据库](#)，进入推理数据库主节点。切换至dbadmin账号，执行以下命令进入/home/dbadmin/upredict目录。
- ```
cd /home/dbadmin/upredict
```

#### 说明

用户可参考[ModelArts数据库节点主备状态判断](#)判断自己所登录节点的状态。

14. 执行以下命令打开注册工具“builtin\_image\_db\_register\_tool.sh”，根据工具脚本提示输入数据库登录账号eiwizarduser的密码，以及依次输入要注册的预置镜像的序号，由工具脚本完成预置镜像注册。

注册信息同步至前端存在一定延时。

```
bash builtin_image_db_register_tool.sh
```

15. 完成以上步骤后，可选择删除构建节点与上传注册节点上的相关文件与路径。参考命令如下：

- 删除构建节点上的相关文件：

```
rm -rf /opt/ModelArts_Images
```
- 删除构建节点或上传注册节点上的镜像包：

```
rm /opt/{镜像包名称}
```

“镜像包名称”由9获取，命令示例：

```
rm /opt/tfserving-model-server_2.3.0-tf1.13-python3.7-cpu_x86_64.tar
```

- 获取预置镜像在本地仓库中的名称、版本号等信息：

```
docker images
```

回显示例如下：

```
[root@fusionclouddeploy images_xxx]# docker images
REPOSITORY TAG IMAGE ID
CREATED SIZE
swr.sa-fb-1.eima02.com/modelarts-infers/xgboost-sklearn-infer 2.3.0-xgb1.2.1-skl0.24.2- 2.17GB
python3.7 c05e03747c20 8 days ago
pyspark-infer 02e9dca79574 8 days ago 2.85GB
2.3.0-pyspark2.4.5-python3.7
swr.sa-fb-1.eima02.com/modelarts-infers/pyspark-infer 2.3.0-pyspark2.4.5-
python3.7 02e9dca79574 8 days ago 2.85GB
pytorch-model-server 57853f667418 8 days ago 5.1GB
2.3.0-pytorch1.4-python3.7
swr.sa-fb-1.eima02.com/modelarts-infers/pytorch-model-server 2.3.0-pytorch1.4-
python3.7 57853f667418 8 days ago 5.1GB
tfserving-model-server 599cf85f078f 8 days ago 5.17GB
2.3.0-tf2.1-python3.7
swr.sa-fb-1.eima02.com/modelarts-infers/tfserving-model-server 2.3.0-tf2.1-
python3.7 599cf85f078f 8 days ago 5.17GB
2.3.0-tf1.13-python3.7-gpu
df8efbaa260a 8 days ago 4.76GB
swr.sa-fb-1.eima02.com/modelarts-infers/tfserving-model-server 2.3.0-tf1.13-python3.7-
gpu df8efbaa260a 8 days ago 4.76GB
2.3.0-tf1.13-python3.7-cpu
f6fe33c99dbe 8 days ago 2.15GB
swr.sa-fb-1.eima02.com/modelarts-infers/tfserving-model-server 2.3.0-tf1.13-python3.7-
cpu f6fe33c99dbe 8 days ago 2.15GB
```

其中，“REPOSITORY”表示仓库中镜像的名称，“TAG”表示该镜像的版本号。

- 删除构建节点或上传注册节点中本地仓库中的镜像：

```
docker rmi -f {镜像的名称}:{版本号}
```

“镜像的名称”和“版本号”由上一步获取，命令示例：

```
docker rmi -f swr.sa-fb-1.eima02.com/modelarts-infers/pyspark-infer:2.3.0-pyspark2.4.5-
python3.7
```

## 5.3.2 注册 ModelArts 训练基础镜像

ModelArts训练提供了选择基础镜像的功能，基础镜像可以通过如下步骤注册。

### 准备工作

准备一套可以连接华为云Stack网络，装有Linux系统并安装18.09.7版本Docker的虚拟机或物理机用作镜像上传节点，以下称“上传注册节点”。

若环境可访问SWR提供的EndPoint，则表示已连接华为云Stack网络。

### 操作步骤

1. 使用“PuTTY”工具以root用户登录构建上传注册节点。
2. 构建基础镜像，假设构建得到的基础镜像为base-image:v1.0。
3. 在ModelArts安装完成后，以[ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面](#)，在服务列表选择ModelArts安装的区域与资源空间，然后选择“应用服务 > 容器镜像服务SWR”，在左侧菜单栏选择“我的镜像”，单击任意镜像名称进入详情页，在“Pull/Push指南”页签获取当前区域的Public Image

Address（格式为`swr.{region_id}.{external_domain_id}.com`）。左侧菜单栏选择“组织管理”，确认组织“modelarts-training-image”存在。左侧菜单栏选择“总览”，单击右上角“登录指令”，复制弹窗中的具体命令。

4. 执行如下命令，重新tag基础镜像到组织“modelarts-training-image”下。  
`docker tag base-image:v1.0 swr.{region_id}.{external_domain_id}.com/modelarts-training-image/base-image:v1.0`
5. 执行如下命令，将基础镜像通过push发送到容器镜像服务SWR。  
`docker push swr.{region_id}.{external_domain_id}.com/modelarts-training-image/base-image:v1.0`
6. 登录容器镜像服务SWR Console，找到base-image镜像，设置该镜像为公开。
7. 操作完成后，即可在基础列表中查询到base-image:v1.0镜像。

## 5.4 GPU/NPU 驱动管理

### 5.4.1 录入新的 GPU 驱动版本

ModelArts资源池支持多版本GPU驱动管理，安装部署时推荐的GPU驱动版本是“470.103.01”，由于GPU硬件资源的不同以及用户业务场景的不同，局点部署时默认选用的GPU驱动版本可能不适用，因此局点管理员可根据实际情况，录入新的驱动版本至ModelArts，以便更好的支撑业务场景。

#### 准备工作

- 获取nvidia驱动包，详细操作请参考《[华为云Stack 8.6.0 技术中台与AI数据中台服务软件安装指南](#)》中“AI平台开发(ModelArts)安装指南 > 安装前准备 > 文档、工具和软件包 > GPU驱动包”章节。
- 以ModelArts服务承载租户使用的二级VDC用户名登录OBS控制台，上传驱动文件至OBS桶，详细操作请参考《[对象存储服务3.0\(OBS\) 使用指南\(for 华为云Stack 8.6.0\)](#)》>《对象存储服务3.0(OBS) 用户指南(for 华为云Stack 8.6.0)》的“上传文件”章节。
  - 上传桶名称：`region_id-modelarts-common-region`，`region_id`以实际区域为准。
  - 上传桶路径：`"/`，即根目录。
  - 若使用obs browser上传，需[获取ModelArts二级VDC管理员的AK/SK](#)。

#### 警告

严禁直接以ModelArts一级或二级VDC管理员登录运营面console，直接删除存量的ak|sk，若执行删除将导致ModelArts服务整体不可用

- 设置驱动文件为匿名公共读权限，如下图所示，详细操作请参考《[对象存储服务3.0\(OBS\) 使用指南\(for 华为云Stack 8.6.0\)](#)》>《对象存储服务3.0(OBS) 用户指南(for 华为云Stack 8.6.0)》的“配置对象ACL”章节。

图 5-20 配置对象 ACL




## 操作步骤

步骤1 登录CDK master节点。

步骤2 执行如下命令，录入GPU驱动新版本信息。

1. 登录ModelArts-Common-Region-POD-Master-0001节点，执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 5-21 查看 pod



2. 执行如下命令登录pod。  
`kubect exec -it ${pod_name} bash`
3. 执行如下命令编辑gpu-driver插件，新增GPU驱动版本。  
`kubect edit pt gpu-driver -o json`

新增内容如下：

```
"440.100": {
 "address": {
 "driver": "https://ei-a3-1-modelarts-common-region.obs3.ei-a3-1.external3.com/NVIDIA-Linux-x86_64-440.100.run"
 },
 "creationTimestamp": "2022-01-04T07:35:15Z"
},
```

其中440.100为nvidia驱动的版本，ei-a3-1-modelarts-common-region为准备工作上传的桶名，obs3.ei-a3-1.external3.com为OBS的endpoint，NVIDIA-



Linux-x86\_64-440.100.run为实际的驱动包文件名。如准备工作中，obs桶截图中的标红链接。

完整效果如下图所示：

图 5-22 完整效果示例

```
{
 "apiVersion": "os.modelarts.huaweicloud/v1",
 "kind": "PluginTemplate",
 "metadata": {
 "creationTimestamp": "2022-08-20T16:55:33Z",
 "generation": 2,
 "labels": {
 "os.modelarts.pluginTemplate/cluster.mandatory": ""
 },
 "name": "gpu-driver",
 "resourceVersion": "483043",
 "uid": "e403dc39-35e3-4af9-a9a2-5efbb9a7b29c"
 },
 "spec": {
 "optional": false,
 "selector": {
 "multiNodeSelector": {
 "anyOf": [
 {
 "nodeFlavorSelector": [
 {
 "matchFields": [
 {
 "field": ".spec.gpu.size",
 "operator": "Gt",
 "values": [
 "0"
]
 }
]
 }
]
 }
]
 }
 },
 "type": "gpuDriver",
 "versions": [
 {
 "address": {
 "driver": "https://ei-a3-1-modelarts-common-region.obs.v3.ei-a3-1.external-a3.com/NVIDIA-Linux-x86_64-440.100.run"
 },
 "creationTimestamp": "2022-01-04T07:35:15Z"
 },
 {
 "address": {
 "driver": "https://ei-a3-1-modelarts-common-region.obs.v3.ei-a3-1.external-a3.com/NVIDIA-Linux-x86_64-470.103.01.run"
 },
 "creationTimestamp": "2022-01-04T07:35:15Z"
 }
]
 }
}
```

编辑完成后，输入wq保存即可。

----结束

## 5.4.2 全量升级 Snt9|Snt9b|Snt9b23 NPU 固件驱动

### 前提条件

- 已录入Snt9|Snt9b|Snt9b23 NPU固件驱动。录入固件驱动需系统管理员操作，具体可参考《[华为云Stack 8.6.0 技术中台与AI数据中台服务扩容指南](#)》> 新建主机组或AZ > 服务配置 > EI企业智能服务 > ModelArts > 附录中的“录入Snt9|Snt9b|Snt9b23 NPU固件驱动”章节。
- 目标固件、驱动版本支持兼容升级。

### 操作步骤

- 以ModelArts承载租户登录ManageOne租户面。
  - 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
    - 登录地址：  
非B2B场景的登录地址：<https://ManageOne运营面的访问地址>。例如，<https://console.demo.com>。  
B2B场景的登录地址：<https://ManageOne租户面的访问地址>。例如，<https://tenant.demo.com>。

访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。

- ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“secondlevel\_vdcuser\_for\_modelarts\_deploy”，获取对应的规划值。
  - 密码：联系环境管理员获取。
- b. 单击“登录”。
2. 选择左上角“服务列表 > EI企业智能 > ModelArts”，切换到“资源池管理”菜单栏。
  3. 在资源池列表中，选择要升级的npu资源池操作列的“驱动升级”。在“驱动升级”弹窗中，选择“目标版本”，待版本更新为目标版本驱动。
  4. 重新制作新驱动版本的裸金属镜像，并更新镜像至ModelArts，以避免新建的资源池仍使用旧的驱动版本。

制作裸金属镜像和注册裸金属镜像可参考[《华为云Stack 8.6.0 技术中台与AI数据中台服务扩容指南》](#) > 新建主机组或AZ > 服务配置 > EI企业智能服务 > ModelArts > 附录中的“制作Snt9|Snt9b裸金属镜像”和“注册裸金属镜像”章节。

## 5.5 添加白名单开关操作

### 5.5.1 增加使用节点本地存储缓存的白名单

当用户依照[《ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)》](#) > [《ModelArts 7.2.1-HCS 使用指南\(for 华为云Stack 8.6.0\)》](#) > 最佳实践 > 使用大模型创建模型部署在线服务章节，部署大模型在线服务时，需要增加“使用节点本地存储缓存”的白名单。本文指导运维人员在接收到用户增加白名单请求时，通过DB变更的方式，为用户增加白名单。

### 登录 UPREDICT 数据库

请参考[登录GaussDB数据库](#)，登录UPREDICT数据库。登录UPREDICT数据库命令如下：

```
gsql -h 127.0.0.1 -d UPREDICT -U {账号名称} -W {密码}
```

其中，{账号名称}和{密码}，可参见[《华为云Stack 8.6.0 账户一览表》](#)，在“B类（EI企业智能）”页签中搜索如下表中节点名称获取。

### 变更 UPREDICT 数据库

在UPREDICT数据库的black\_white\_list表执行如下sql为用户新增白名单：

```
insert into black_white_list(name, control_type) values ('<domain id>', 'dynamic_load_host_cache_volume');
```

替换“<domain id>”为用户真实的Domain ID。

执行如下sql查询变更结果：

```
select * from black_white_list;
```



图 5-23 添加并查询结果

```
UPREDICT=> insert into black_white_list(name, control_type) values ('', 'dynamic_load_host_cache_volume');
INSERT 0 1
UPREDICT=> select * from black_white_list;
 CONTROL_TYPE | NAME
-----+-----
dynamic_load_host_cache_volume |
(1 row)
```

5.5.2 添加终端节点服务白名单（去 roma 实例场景）

当用户依照《ModelArts 7.2.1-HCS 使用指南(for 华为云Stack 8.6.0)》>《ModelArts 7.2.1-HCS 使用指南(for 华为云Stack 8.6.0)》>用户指南 > 部署服务 > 在线服务 > 访问在线服务（VPC访问通道）章节，申请连接ModelArts终端节点按名称查找服务时，需要增加“终端节点服务”的白名单。本文指导运维人员在接收到用户增加白名单请求时，为用户增加白名单。

操作步骤

- 1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，在页面左上角服务列表中，选择“VPC终端节点”服务。
- 2. 左侧导航选择“VPC 终端节点 > 终端节点服务”，查找用户提供的终端节点服务。

图 5-24 查找终端节点服务



- 3. 单击终端节点服务名称进入详情页面，选择“权限管理”页签，单击“添加白名单记录”，添加用户的Domain ID。

图 5-25 添加白名单记录



5.5.3 ModelArts 推理打开 IEF 服务相关开关

ModelArts推理部署时会识别当前环境是否安装ief服务并对相关的特性开关、用户委托进行配置。当IEF服务与ModelArts在同一个工程部署，或者IEF在ModelArts之后部署，则需要手动打开对应的特性开关。本文主要介绍涉及的开关名称和修改方法。

## 操作步骤

1. 登录WIZARDSERVICE数据库。详细登录操作请参见[登录ModelArts数据库](#)。
2. 执行如下命令，使页面可见ief服务在ModelArts的相关功能。  

```
replace INTO CFG_FEATURE_INFO_BY_USER (NAME, OPERATOR, SHOW, UPDATETIME) values ('ma_inference_ief_support','sys_operator', true, floor(extract(epoch from now())));
```
3. 执行如下命令，补充IEF设计的用户委托。  

```
update DEFAULT_AGENCY_GRANT set MODULE='WEBSERVICE|EDGE_POOL', USED = TRUE where DISPLAY_NAME = 'IEF Administrator' and EXISTS (select * from CFG_FEATURE_INFO_BY_USER where name='ma_menu_edge' and show = TRUE);
```

### 5.5.4 开启资源池不限制容器引擎空间大小上限

该文档用于指导运维人员设置“不限制dockerSize大小上限”或“支持dockerSize值为0”时，通过DB变更开启特性白名单的操作。

1. 登录WIZARDSERVICE数据库。详细登录操作请参见[登录ModelArts数据库](#)。
2. 执行如下命令，查询是否开启了容器引擎空间大小不限制上限功能。  

```
select * from CFG_FEATURE_INFO where NAME = 'ma_pool_docker_unlimited';
select * from CFG_FEATURE_INFO where NAME = 'ma_pool_standard_docker_unlimited';
```
3. 执行如下命令，开启容器引擎空间大小不限制上限功能。  

```
update CFG_FEATURE_INFO set SHOW = TRUE where NAME = 'ma_pool_docker_unlimited';
update CFG_FEATURE_INFO set SHOW = TRUE where NAME = 'ma_pool_standard_docker_unlimited';
```

## 5.6（旧版推理）模型及服务管理

### 5.6.1 调整单个模型的大小配额

该文档用于指导运维人员在接到客户调整“单个模型的大小”的配额请求时，通过DB变更的方式，完成配额的调整操作，支撑用户业务。

#### 登录 UPREDICT 数据库

请参考[登录GaussDB数据库](#)登录UPREDICT数据库。

单个模型的大小的配额设置保存在UPREDICT数据库的model\_quota表中。表结构如下：

表 5-13 model\_quota 表结构

| 字段名         | 字段类型                 | 描述                      |
|-------------|----------------------|-------------------------|
| id          | VARCHAR(36) NOT NULL | 随机生成的UUID               |
| project_id  | VARCHAR(64)          | 资源空间ID，配额是project粒度的控制。 |
| quota_type  | VARCHAR(36)          | 配额类型，取值为IMPORT_MODEL    |
| model_quota | bigint               | 模型数量配额                  |

| 字段名                         | 字段类型   | 描述                  |
|-----------------------------|--------|---------------------|
| single_model_file_size_mb   | bigint | 单个模型文件的大小的配额，单位MB   |
| single_app_total_size_mb    | bigint | 单个模型的总大小的配额，单位MB    |
| single_custom_image_size_mb | bigint | 单个自定义镜像的大小的配额，单位MB。 |
| create_at                   | bigint | 记录创建时间              |
| update_at                   | bigint | 记录更新时间              |

## 变更 UPREDICT 数据库

- 变更之前先查询用户的project id对应的配额记录是否已存在。使用如下的sql进行查询：  

```
select * from model_quota where project_id='<用户的project id>;'
```
- 当用户project id对应的配额记录已经存在，执行如下的sql进行修改：  

```
update model_quota set single_app_total_size_mb=<客户需求的应用大小>, update_at=<更新时间> where project_id='<用户的project id>;'
```

其中，“更新时间”使用当前UTC时间戳（毫秒）。
- 当用户project id对应的配额记录不存在，执行如下的sql进行新增：  

```
insert into model_quota(id, project_id, quota_type, model_quota, single_model_file_size_mb, single_app_total_size_mb, single_custom_image_size_mb, create_at, update_at) values ('<随机生成的UUID>', '<用户的project id>', 'IMPORT_MODEL', '1000', 5120, <用户请求的单模型配额大小>, 30720, <创建时间>, <变更时间>);
```

其中，“随机生成的UUID”使用UUID在线生成器工具生成，“quota\_type”固定设置IMPORT\_MODEL，“model\_quota”设置模型数量1000（最新版本用户可创建的模型数量已无限制，该值可随意设置），  
“single\_model\_file\_size\_mb”默认设置5120，  
“single\_custom\_image\_size\_mb”默认设置30720。“创建时间”和“变更时间”保持一致，使用当前UTC时间戳（毫秒）。

### 5.6.2 配置域名证书

ModelArts为在线服务注册的API，默认以IP形式对外提供。如果用户需要通过域名方式提供接口，以使用证书访问服务。您可以参考如下操作指导，为在线服务接口所属分组配置独立域名并添加SSL证书。

#### 前提条件

- 根据您的业务环境，完成域名的注册、解析等任务。下述步骤介绍如何将已有域名配置至华为云Stack内，以便在线服务的API可通过域名方式访问。
- 在执行如下任务前，需确保已配置域名到IP地址的解析。此IP地址为当前环境下在线服务中“API接口地址”对应的IP。

#### 操作步骤

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

1. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
  - 登录地址：  
非B2B场景的登录地址：<https://ManageOne运营面的访问地址>。例如，<https://console.demo.com>。  
B2B场景的登录地址：<https://ManageOne租户面的访问地址>。例如，<https://tenant.demo.com>。  
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
  - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“secondlevel\_vdcuser\_for\_modelarts\_deploy”，获取对应的规划值。
  - 密码：联系环境管理员获取。
2. 单击“登录”。

**步骤2** 在服务列表中选择“应用与数据集成平台 ROMA Connect”，进入ROMA管理控制台。

**步骤3** 左侧导航栏选择“实例”，单击Dispatcher实例的“查看控制台”进入实例信息页面。

**步骤4** 在左侧导航栏选择“服务集成 APIC > API列表”。将用户的服务ID去除连接符“-”后，按API名称进行搜索，找到在线服务相应的接口，获取接口所属分组名称。

#### 说明

- 若所在页面无法找到“所属分组”列，则单击右侧 打开自定义展示列，勾选“所属分组”，即可获取接口的所属分组。
- 若服务开启APP认证，此时会搜索到2个接口，对应两个不同的分组名称，此时需要对两个分组分别进行**步骤5~步骤8**的操作。

**步骤5** 在“服务集成 APIC > API分组”页，找到服务接口所属分组，单击分组名称进入分组详情页。

**步骤6** 在“分组信息”页签，找到“域名管理”，单击“绑定独立域名”，输入自定义域名（该域名需与SSL证书中定义的域名相同），支持最小TLS版本选择“TLS1.2”，单击“确定”，域名绑定成功。

**步骤7** 在绑定成功的独立域名的“操作”栏，选择“添加SSL证书”，输入证书名称、pem编码格式的证书内容与密钥后，单击“确定”，SSL证书添加成功。

**步骤8** 将独立域名与SSL证书提供给用户，由用户进行相应域名解析配置，即可使用证书通过域名方式访问在线服务。

通过域名方式访问在线服务的详细指导，请参见《[ModelArts 7.2.1-HCS 使用指南 \(for 华为云Stack 8.6.0\)](#)》>《[ModelArts 7.2.1-HCS 使用指南 \(for 华为云Stack 8.6.0\)](#)》的“访问在线服务（域名证书）”章节。

----结束

### 5.6.3 获取 ROMA Connect SDK

当普通租户在使用“访问在线服务”功能时，如果此租户没有ROMA Connect实例，则无法直接获取其SDK。可联系管理员获取。

管理员可通过如下操作步骤获取SDK，并提供给普通租户使用。

#### 操作步骤

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

1. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
  - 登录地址：  
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，  
<https://console.demo.com>。  
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，  
<https://tenant.demo.com>。  
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
  - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“secondlevel\_vdcuser\_for\_modelarts\_deploy”，获取对应的规划值。
  - 密码：联系环境管理员获取。
2. 单击“登录”。

**步骤2** 在服务列表选择“应用服务 > 应用与数据集成平台 ROMA Connect”，进入ROMA Connect页面。

**步骤3** 在“实例”中单击Dispatcher实例的“查看控制台”进入实例信息页面。

**步骤4** 在左侧菜单中，选择“服务集成 APIC > 凭据管理”。

**步骤5** 在“凭据管理”页面，切换到“SDKs”页签，选择对应语言的SDK，单击“下载SDK”，即可将对应的SDK下载至本地。

#### 说明

- 当前局点如果未安装roma connect服务，则无法获取SDK。
- 若下载SDK失败，请联系环境管理员配置相应的hosts文件。

----结束

### 5.6.4 基于 ROMA 调用的流式输出卡顿问题优化

通过ROMA调用在线服务，且用户需要使用流式输出时，需要开启环境中ROMA实例的sse\_strategy配置项，不然使用流式输出时会出现卡顿问题。

#### 操作步骤

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

- 步骤2** 首页选择服务列表，搜索ROMA进入云容器引擎 ROMA Connect控制台。
- 步骤3** 在实例页面找到roma-dispatcher实例，点击实例名称进入ROMA实例详情页。
- 步骤4** 进入实例信息>配置参数页，找到sse\_strategy参数，点击右侧操作栏中的编辑按钮，将值改为on后，再点击保存按钮。
- 步骤5** 由于开启sse\_strategy开关会影响响应性能，当业务中不需要使用流式输出时，记得将其关闭。
- 结束

## 5.6.5 修改在线服务超时时间

### Step1 修改 Dispatcher 超时时间

- 步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
- 步骤2** 首页选择服务列表，搜索CCE进入云容器引擎 CCE控制台。
- 步骤3** 在集群管理页面搜索Dispatcher找到modelarts-infer-dispatcher集群，单击集群名称进入集群详情页。
- 步骤4** 选择工作负载>无状态工作负载，找到infer-dispatcher负载，并单击操作列的“升级”。
- 步骤5** 在容器配置下选择环境变量，在变量名称中确认当前是否已存在如下变量，如果已存在，直接修改该变量后面的值；如果不存在，增加一条该环境变量。
- 例如需要修改预测超时时间为5分钟，则需要修改或增加的环境变量以及值分别为：
- spring\_cloud\_gateway\_httpclient\_response\_timeout对应值为300000
  - gateway\_default\_timeout\_seconds对应值为300
  - circuitbreaker\_timeout\_seconds对应值为300
  - circuitbreaker\_slowCallDurationThreshold\_seconds对应值为300
- 结束

### Step2 修改 roma-connect 超时时间

#### 说明

当未安装roma-connect，则跳过本步骤。

- 步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。
- 步骤2** 首页选择服务列表，搜索ROMA进入ROMA Connect控制台。
- 步骤3** 在实例页面找到roma-dispatcher，单击集群名称进入详情页。当没有该实例时，无需进行**Step2 修改roma-connect超时时间**。
- 步骤4** 进入roma-dispatcher，单击“实例信息 > 配置参数”，单击参数backend\_timeout右侧的编辑按钮，例如这里要修改超时时间为5分钟，则修改值为300000ms。
- 结束

## 5.6.6 修改批量服务超时时间

### Step1 修改 batch-agent 超时时间

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

**步骤2** 首页选择服务列表，搜索CCE进入云容器引擎 CCE控制台。

**步骤3** 在集群管理页面搜索Dispatcher找到modelarts-infer-dispatcher集群，单击集群名称进入集群详情页。

**步骤4** 选择工作负载>无状态工作负载，找到infer-batch-agent负载，单击操作列的“升级”。

**步骤5** 在容器配置页面下选择环境变量，在变量名称中确认当前是否已存在变量：MODELARTS\_INFER\_PREDICT\_TIMEOUT，如果已存在，直接修改该变量后面的值，如果不存在，增加一条该环境变量。

新增或修改MODELARTS\_INFER\_PREDICT\_TIMEOUT变量，例如需要修改批量服务超时时间为5分钟，则对应设置值为300000。

图 5-26 新增 MODELARTS\_INFER\_PREDICT\_TIMEOUT 变量



**步骤6** 单击“升级工作负载”，等待负载升级完成。如果因为资源不足导致升级失败时，先将实例数缩容到1，重新执行上述过程，升级成功后再恢复实例数。

----结束

### Step2 修改 Dispatcher 超时时间

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

**步骤2** 首页选择服务列表，搜索CCE进入云容器引擎 CCE控制台。

**步骤3** 在集群管理页面搜索Dispatcher找到modelarts-infer-dispatcher集群，单击集群名称进入详情页。

**步骤4** 选择工作负载>无状态工作负载，找到infer-dispatcher负载，单击操作列的“升级”。

**步骤5** 在容器配置页面下选择环境变量，在变量名称中确认当前是否已存在变量：spring\_cloud\_gateway\_httpclient\_response\_timeout，如果已存在，直接修改该变量后面的值，如果不存在，增加一条该环境变量。

新增环境变量操作如下所示。



例如需要修改预测超时时间为5分钟，则需要修改或增加的环境变量以及值分别为：

- `spring_cloud_gateway_httpclient_response_timeout`对应值为300000。
- `gateway_default_timeout_seconds`对应值为300。
- `circuitbreaker_timeout_seconds`对应值为300。

**步骤6** 单击升级工作负载，等待负载升级完成。如果因为资源不足导致升级失败时，先将实例数缩容到1，重新执行上述过程，升级成功后再恢复实例数。

----结束

### Step3 修改 roma-connect 超时时间

#### 说明

当未安装roma-connect，则跳过本步骤。

**步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面。

**步骤2** 首页选择服务列表，搜索ROMA并进入ROMA Connect控制台。

**步骤3** 在实例页面找到roma-dispatcher并单击集群名称进入详情页。当没有该实例时，无需进行**Step3 修改roma-connect超时时间**。

**步骤4** 进入roma-dispatcher，单击“实例信息 > 配置参数”，单击参数backend\_timeout右侧操作列的“编辑”按钮，例如这里要修改超时时间为5分钟，则修改值为300000ms。

----结束

### Step4 service-manager 修改 api 后端超时时间

**步骤1** 以管理员账号登录CloudCDK界面。

**步骤2** 运维服务中选择CloudAutoDeploy-CDK。

**步骤3** 选择“变更管理 > 服务升级”，然后选择“当前region > ai-pod集群”，搜索service-manager并选择该服务，单击“下一步”。

**步骤4** 在搜索框中搜索配置项apic\_backend\_timeout，修改当前参数，例如需要修改超时时间为5分钟，则这里需要设置为300000，完成后单击“下一步”执行升级并等待升级完成。

----结束

## 5.7 AI Hub 管理

### 5.7.1 AI Hub 管理员账户变更

#### 配置 AI Hub 管理员账号

安装AI Hub工程后，需要配置AI Hub的管理员账号。配置后，该租户主账号及其子账号均为AI Hub的管理员。

**步骤1** 需要客户提供domain\_name和domain\_id。登录ModelArts控制台，单击右上角账号名称，单击“个人设置”，在基本信息页面查看并记录“所属租户”和“租户ID”。



**步骤2** 获取数据库IP地址。

1. 使用浏览器以系统管理员账号登录ManageOne运维面。
  - a. 使用浏览器，通过地址“<https://ManageOne运维面主页的访问地址:31943>”，登录ManageOne运维面，或通过地址“<https://ManageOne主门户的访问地址>”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。
    - 密码方式  
默认账号：bss\_admin  
  
**说明**  
对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。  
默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。
    - USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。  
  
**说明**  
仅在SM系列商密算法场景下支持USB Key方式。
  - b. 单击“登录”。
2. 在ManageOne运维面首页右下角“常用链接”栏中，单击“Service OM”选择相应区域，跳转到对应区域的Service OM平台。
3. 在“服务列表”下方单击“计算资源”，展示虚拟机列表。
4. 在搜索栏输入关键字搜索虚拟机名称，例如“ModelArts-market-manager-Gaussdb”，记录虚拟机的IP地址。

图 5-27 获取数据库 IP 地址

| 名称                                      | 主机ID           | 主机名 | 可用分区 | 状态  | 电源状态 | 规格       | CPU架构/厂商  | IP地址 | 批量迁移 | 迁移热迁移 | 操作       |
|-----------------------------------------|----------------|-----|------|-----|------|----------|-----------|------|------|-------|----------|
| <input type="checkbox"/> ModelArts-m... | C412002D-DC... |     |      | 运行中 | 运行中  | 4核   8GB | X86/Intel |      | 支持   | 支持    | VNC登录 更多 |
| <input type="checkbox"/> ModelArts-m... | AB0C0D2D-DC... |     |      | 运行中 | 运行中  | 4核   8GB | X86/Intel |      | 支持   | 支持    | VNC登录 更多 |

**步骤3** 登录GaussDB数据库。

1. 获取[步骤2.4](#)记录的数据库主备节点的IP地址。
2. 使用Putty工具以opsadmin用户登录GaussDB数据库任一节点，ModelArts-market-manager-Gaussdb-01。  
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
3. 切换su root账号。  
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
4. 执行以下命令查询数据库主备状态。  
**su - dbadmin**  
**querydb**

图 5-28 查看数据库状态

```
[dbadmin@~]$ querydb
Ha state:
LOCAL_ROLE : Primary
STATIC_CONNECTIONS : 1
DB_STATE : Normal
DETAIL_INFORMATION : Normal
```

- “LOCAL\_ROLE”表示节点在主备模式下的角色，值为“Primary”代表主节点，“Standby”代表备节点。
- “DB\_STATE”表示数据库状态，值为“Normal”代表状态正常，否则代表不正常。

5. 以opsadmin用户登录数据库主节点。

```
ssh opsadmin@{ip}
```

其中{ip}为上一步获取到的数据库主节点的IP地址。

6. 执行su root切换root用户。

7. 执行su dbadmin切换数据库用户。

默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签中搜索节点名称获取。

8. 执行如下命令登录高斯数据库。

```
gsqsl -h 127.0.0.1 -d market_manager -U {账号名称} -W {密码}
```

其中{账号名称}和{密码}，请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签中搜索ModelArts-market-manager-Gaussdb节点名称获取。

9. 进入数据库中，执行如下命令：

```
INSERT INTO ADMIN_WHITELIST(DOMAIN_ID,DOMAIN_NAME) VALUES('{domain_id}', '{domain_name}');
```

其中domain\_id和domain\_name为步骤1客户提供的需要配置成管理员的账号，如：INSERT INTO ADMIN\_WHITELIST(DOMAIN\_ID,DOMAIN\_NAME) VALUES('d8126a20db13499c82e060007d1e8348', 'ModelArts\_tester');

----结束

## 删除管理员账号

需要客户提供需要删除管理员账号的domain\_id和domain\_name，删除管理员账号后，该账号及其子账号均为普通账号，不再具有管理员操作权限。

进入数据库中，执行如下命令删除管理员账号：

```
DELETE FROM ADMIN_WHITELIST WHERE DOMAIN_ID='{domain_id}';
```

其中domain\_id，如：DELETE FROM ADMIN\_WHITELIST WHERE DOMAIN\_ID='d8126a20db13499c82e060007d1e8348';

## 5.7.2 AI Hub 管理员运营操作

AI Hub管理员对所有资产（算法、模型、Workflow、镜像）具有运营操作的权限，主要表现为设置资产为缩小权限为私有、置顶推荐、官方、精选等操作，其中镜像类型资产仅涉及置顶推荐操作。ModelArts承载租户用户（ModelArts服务承载租户使用的二级VDC用户名）及其子账号默认配置为AI Hub平台的管理员，具体操作如下：

- 步骤1** 使用管理员账号登录进ModelArts，并在左侧列表中进入到AI Hub平台。
- 步骤2** 进入资产详情页，单击右上方的“缩小权限为私有”，填写修改理由，然后单击“确定”，可以将该资产权限缩小为仅自己可见。权限缩小后，在资产列表中不再展示该资产。对于发布该资产的用户，可以重新设置扩大权限为公开，重新上架资产。
- 步骤3** 进入资产详情页，单击右上方的“置顶推荐”，可以将资产在列表页中置顶。
- 步骤4** 进入资产详情页，单击右上方的“官方”，可以将资产设置“官方”标签。
- 步骤5** 进入资产详情页，单击右上方的“精选”，可以将资产显示在“精选”页签中。

----结束

### 5.7.3 AI Hub 管理员导入资产

#### 操作步骤

- 步骤1** 以ModelArts服务承载租户使用的二级VDC用户名登录OBS Browser+，将本地文件上传到后缀为-modelhub-models的OBS桶里。
1. 登录OBS Browser+。  
“服务提供商”选择“其他对象存储服务”  
“账号名”从LLD的“基本参数”页签获取，查看“参数key”列  
“secondlevel\_vdcuser\_for\_modelarts\_deploy”的规划值  
获取“Access Key ID”和“Secret Access Key”：  
    - a. 以ModelArts服务承载租户使用的二级VDC用户名登录控制台，在页面右上角单击用户账号图标，在下拉列表中选择“个人设置”。
    - b. 在“个人设置”页面，选择“管理访问密钥”，单击“新增访问密钥”获取AK/SK。
  2. 单击后缀为-modelhub-models的OBS桶，进入OBS桶中，单击上传，在“上传对象”页面填写相关参数后，单击“确定”，等待本地文件夹全部上传到OBS桶中，记录OBS对象存储路径。  
参数配置如下：  
“对象权限”选择“私有”  
“存储类别”为“标准存储”  
“上传对象”选择“添加文件夹”，选择本地PC路径
- 步骤2** 导入资产到AI Hub。
1. 以管理员账号登录ManageOne租户面，在服务列表中选择ModelArts，左侧菜单栏选择“AI Hub”，进入AI Hub界面。在右上角“管理中心 > 我的导入”中，单击右侧的“导入”。
  2. 在弹出来的导入详情页中，优先选择批量导入，单击存储路径选择为OBS路径，单击“确定”。

#### 说明

- 当导入类型选择为单个导入时，存储路径需要选择到item\_id-version\_id这一层，例如/487c0f85-2e3e-4f57-bcad-b0338835e02b-VgUetY。
- 当导入类型选择为批量导入时，存储路径需要选择为item\_id-version\_id的上一层，例如/export这一层，export目录下面有多个487c0f85-2e3e-4f57-bcad-b0338835e02b-VgUetY类型的目录。

在“管理中心 > 我的导入”页面，等待导入的资产从草稿状态变为上架状态，即完成了资产导入到ModelArts。

----结束

## 5.8 ModelArts 安装部署后的后续操作

### 5.8.1 ModelArts 细粒度鉴权开启严格模式


ModelArts部署升级后可能会产生细粒度鉴权失效错误。细粒度鉴权是严格模式（strict），升级后变为了非严格模式（loose），导致新开局且使用细粒度鉴权的局点权限控制失效。

#### 操作步骤


1. 登录CloudScope平台，选择“运维服务 > CloudAutoDeploy-CDK”，进入CDK页面。



2. 在左侧菜单栏选择“变更管理 > 服务升级”，Region-集群选择ai-pod，右侧服务搜索modelarts-console-backend，选择modelarts-console-backend服务，单击“下一步”。



3. 参数搜索栏搜索“STRICT\_AUTH\_MODE\_ON”，修改其值为strict，参数搜索栏搜索“quotas\_wait\_service\_timeout”，修改其值为原值+1，单击“下一步”。



4. 确认配置无误后，选择“升级”，等待升级完成。

## 5.8.2 ModelArts 部署或者升级完后，重新部署 SFS Turbo

SFS Turbo（弹性文件系统）是基于NFS网络协议的存储，部分局点在部署或升级完ModelArts后，需要将原先对接的OBS存储切换为SFS Turbo存储，此时需为ModelArts上线SFS Turbo新特性。

### 约束限制

- 局点需部署SFS Turbo服务。
- ModelArts部署安装完成后，再新部署安装SFS Turbo。

### 操作步骤

**步骤1** 登录ModelArts-ConsoleBackend-GaussDB数据库，具体可参见[登录ModelArts数据库](#)。

执行如下命令，开启SFS turbo UI特性。

```
replace INTO CFG_FEATURE_INFO_BY_USER (NAME, OPERATOR, SHOW, UPDATETIME) values ('ma_pool_sfsturbo','sys_operator', TRUE, floor(extract(epoch from now())));
replace INTO CFG_FEATURE_INFO_BY_USER (NAME, OPERATOR, SHOW, UPDATETIME) values ('ma_inference_sfsturbo','sys_operator', TRUE, floor(extract(epoch from now())));
```

**步骤2** 登录CloudScope>工具箱>ConsoleFramework运维平台，在Region关联Service中是否存在modelarts\_sfs，且配置是否正确。



- 若不存在，则手动添加。
- 若存在，需检查地址及端口是否正确。

地址: sfs-turbo-api.{region\_id}.{global\_domain\_name}


端口：9063

### 说明

- region\_id为当前局点的regionId信息，可参考安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“region0\_id”，查看取值，下文后续步骤同此取值。
- global\_domain\_name为当前局点的内部Global域名后缀，可参考安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“global\_domain\_name”，查看取值，下文后续步骤同此取值。

**步骤3** 登录CloudScope，选择服务>CloudAutoDeploy-CDK，进入CloudCDK页面更改modelarts-os资源池相关微服务配置。

1. 以管理员账号登录CloudCDK界面。
2. 选择“变更管理 > 服务升级 > ai-pod(静态纳管)”，容灾局点还需要额外升级ai-pod-dr集群。选中右侧列表中的modelarts-os-apiserver，单击“下一步”。在“升级配置”中更新如下参数的参数值。
  - 将“sfsturbo\_endpoint”的参数值更新为"sfs-turbo-api." + region\_id + '!' + global\_domain\_name + ":9063"
  - 将“sfsturbo\_passthrough\_enabled”的参数值更新为true。
  - 将“CPU\_LIMITS”的参数值更新为当前值+1



| 参数名称                         | 参数类型    | 数据类型    | 当前值   | 修改后  | 修改说明                                                                                 |
|------------------------------|---------|---------|-------|------|--------------------------------------------------------------------------------------|
| sfsturbo_endpoint            | string  | string  | None  | None | 将sfsturbo_endpoint更新为sfs-turbo-api. + region_id + '!' + global_domain_name + ":9063" |
| CPU_LIMITS                   | string  | string  | 5     | 6    | 将CPU_LIMITS更新为当前值+1                                                                  |
| sfsturbo_passthrough_enabled | boolean | boolean | False | True | 将sfsturbo_passthrough_enabled更新为True                                                 |

3. 选择“变更管理 > 服务升级 > ai-pod(静态纳管)”，容灾局点还需要额外升级ai-pod-dr集群，选中右侧列表中的modelarts-os-resource-mgr微服务，单击“下一步”。在“升级配置”中更新如下参数的参数值。
  - 将“sfsturbo\_endpoint”的参数值更新为"sfs-turbo-api." + region\_id + '!' + global\_domain\_name + ":9063"
  - 将“sfsturbo\_internal\_endpoint”的参数值更新为"sfs-turbo-api." + region\_id + '!' + global\_domain\_name + ":9063"
  - 将“sfsturbo\_agency\_domain\_name”的参数值更新为"op\_svc\_sfsturbo"
  - 将“CPU\_LIMITS”的参数值更新为当前值+1。



| 参数名称                        | 参数类型   | 数据类型   | 当前值  | 修改后             | 修改说明                                                                                          |
|-----------------------------|--------|--------|------|-----------------|-----------------------------------------------------------------------------------------------|
| sfsturbo_endpoint           | string | string | None | None            | 将sfsturbo_endpoint更新为sfs-turbo-api. + region_id + '!' + global_domain_name + ":9063"          |
| sfsturbo_internal_endpoint  | string | string | None | None            | 将sfsturbo_internal_endpoint更新为sfs-turbo-api. + region_id + '!' + global_domain_name + ":9063" |
| sfsturbo_agency_domain_name | string | string | None | op_svc_sfsturbo | 将sfsturbo_agency_domain_name更新为op_svc_sfsturbo                                                |
| CPU_LIMITS                  | string | string | 4    | 5               | 将CPU_LIMITS更新为当前值+1                                                                           |

**步骤4** 登录CloudScope，选择服务>CloudAutoDeploy-CDK，进入CloudCDK页面，更改推理相关微服务配置。若ModelArts推理未部署，可跳过当前步骤。

1. 以管理员账号登录CloudCDK界面。
2. 选择“变更管理 > 服务升级 > ai-pod(静态纳管)”，容灾局点还需要额外升级ai-pod-dr集群，选中右侧列表中的modelarts-infers-service-manager，单击“下一步”。在“升级配置”中更新如下参数的参数值。

将“sfs\_turbo\_endpoint”的参数值更新为"https://sfs-turbo." + region\_id + '!' + external\_global\_domain\_name

## 说明

- modelarts-infer推理配置的sfs\_turbo\_endpoint为SFS turbo的APIG地址。
- external\_global\_domain\_name为当前局点的外部域名后缀，请在安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“external\_global\_domain\_name”，查看取值。



**步骤5** 登录CloudScope，选择服务>CloudAutoDeploy-CDK，进入CloudCDK页面，更改新版推理相关微服务配置。若ModelArts新版推理未部署，可跳过当前步骤。

- 以管理员账号登录CloudCDK界面。
- 选择“变更管理 > 服务升级 > ai-pod(静态纳管)”，容灾局点还需要额外升级ai-pod-dr集群，选中右侧列表中的modelarts-infers-manager，单击“下一步”。在“升级配置”中更新如下参数的参数值。

将“efs\_endpoint”的参数值更新为"https://sfs-turbo." + region\_id + '!' + external\_global\_domain\_name

## 说明

- 新版推理配置的efs\_endpoint为SFS turbo的APIG地址。
- external\_global\_domain\_name为当前局点的外部域名后缀，请在安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“external\_global\_domain\_name”，查看取值。



----结束

## 5.8.3 适配 CCE 补丁升级后更改 ModelArts 参数

### 说明

特殊场景如CCE发布补丁，会发布新的CCE插件，ModelArts要想使用这些新插件版本，则需适配更改ModelArts配置的插件版本；若不更改ModelArts配置，存量功能也不受影响，但无法使用CCE补丁发布插件的新特性功能。

## 操作步骤

**步骤1** 登录CloudCDK界面。

- 使用浏览器，登录“CloudScope”。
  - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。



“CloudScope”界面访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“Portal”页签下获取“COP”相关信息。


- 默认账号：**op\_cdk\_sso**
  - 默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“CloudScope Lite”页签下搜索“op\_cdk\_sso”获取CloudAutoDeploy-CDK服务对应的默认密码。
2. 在页面导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CloudCDK界面。

**步骤2** 登录CDK master节点。可参见《[ModelArts 7.2.1-HCS 维护指南\(for 华为云Stack 8.6.0\)](#)》>运维指南的“附录 > 登录CDK master节点”章节。

**步骤3** 执行如下命令，登录pod。

1. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 5-29 查看 pod




| NAME                                          | READY | STATUS  | RESTARTS | AGE   |
|-----------------------------------------------|-------|---------|----------|-------|
| modelarts-algorancher-8ddcc8d68-cqk42         | 1/1   | Running | 0        | 3d16h |
| modelarts-algorancher-8ddcc8d68-krc8m         | 1/1   | Running | 0        | 3d16h |
| modelarts-billing-7d9d4c4dd4-ftsxn            | 1/1   | Running | 0        | 3d16h |
| modelarts-billing-7d9d4c4dd4-hvsj9            | 1/1   | Running | 0        | 3d16h |
| modelarts-console-backend-576cbbfddb-d78t7    | 1/1   | Running | 0        | 3d16h |
| modelarts-console-backend-576cbbfddb-k94g7    | 1/1   | Running | 0        | 3d16h |
| modelarts-exemplflow-778b8c78fd-mjg67         | 1/1   | Running | 0        | 3d16h |
| modelarts-exemplflow-778b8c78fd-wglcl         | 1/1   | Running | 0        | 3d16h |
| modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8 | 1/1   | Running | 0        | 2d22h |
| modelarts-market-manager-cdk-7cfd8bf4d5-gjghl | 1/1   | Running | 0        | 2d22h |
| modelarts-os-apiserver-5cd548c558-sltx5       | 1/1   | Running | 0        | 3d16h |
| modelarts-os-apiserver-5cd548c558-tzvv2       | 1/1   | Running | 0        | 3d16h |
| modelarts-os-job-mgr-594bf4fd4b-6mbdz         | 1/1   | Running | 0        | 3h24m |
| modelarts-os-job-mgr-594bf4fd4b-clj9x         | 1/1   | Running | 0        | 3h24m |
| modelarts-os-resource-mgr-78747979f7-8wqtf    | 1/1   | Running | 0        | 3d16h |
| modelarts-os-resource-mgr-78747979f7-zvr4q    | 1/1   | Running | 0        | 3d16h |
| modelarts-webapp-gateway-cdk-7547d97b55-l7k6j | 1/1   | Running | 0        | 3d16h |
| modelarts-webapp-gateway-cdk-7547d97b55-r6rtz | 1/1   | Running | 0        | 3d16h |

2. 执行如下命令登录pod。
- ```
kubectl exec -it ${pod_name} bash
```


步骤4 升级gpu-beta插件版本，执行**kubectl edit pt gpu-beta**，参考已有版本，复制一个新版本并将目标版本更新为CCE当前支持的最新版本，具体版本号以CCE查询插件市场的最新可用CCE AI套件（NVIDIA GPU）插件版本为准，并将版本下的creationTimestamp设置为当前时间。

图 5-30 升级 gpu-beta 插件版本



步骤5 升级volcano插件版本，执行`kubectl edit pt volcano`，参考已有版本，复制一个新版本并将目标版本更新为CCE当前支持的最新版本，具体版本号以CCE查询插件市场的最新可用Volcano调度器插件版本为准，并将版本下的`creationTimestamp`设置为当前时间。

图 5-31 升级 volcano 插件版本



步骤6 升级huawei-npu插件版本，执行kubect edit pt huawei-npu，参考已有版本，复制一个新版本并将目标版本更新为CCE当前支持的最新版本，具体版本号以CCE查询插件市场的最新可用CCE AI套件（Ascend NPU）插件版本为准，并将版本下的creationTimestamp设置为当前时间。

图 5-32 升级 huawei-npu 插件版本

```
# Please edit the object below. Lines beginning with a # will be ignored,
# and an empty file will abort the edit. If an error occurs while saving this file will be
# reopened with the relevant failures.
#
apiVersion: os.modelarts.huaweicloud/v1
kind: PluginTemplate
metadata:
  creationTimestamp: "2024-06-26T03:07:24Z"
  generation: 3
  labels:
    os.modelarts.plugintemplate/cluster.mandatory: ""
  name: huawei-npu
  resourceVersion: "14422273"
  uid: 3af6bc2c-835f-4da8-964d-03f7fbfb36c2
spec:
  optional: false
  selector:
    multiNodeSelector:
      anyOf:
        - nodeFlavorSelector:
            matchFields:
              - field: .spec.npu.size
                operator: Gt
                values:
                  - "0"
    type: ccePlugin
  versions:
    2.1.1:
      clusterSelector:
        matchFields:
          - field: .spec.cluster.type
            operator: In
            values:
              - VirtualMachine
              - ARM64
          - field: .spec.cluster.version
            operator: Regex
            values:
              - "(v1.21|23|25|27|28|29).*)"
      creationTimestamp: "2024-07-23T09:42:19Z"
      values:
        basic:
          image_version: "2.1.1",
          platform: "linux-amd64",
          swr_addr:
            "swr.hcs-guomi-l.outguomi.com",
            swr_user: "hwofficial",
            rbac_enabled:
              true,
              flavor:
                name: "default",
                resources:
                  limitsCpu: "100m",
                  limitsMem: "200Mi",
                  name: "huawei-npu",
                  requestsCpu: "100m",
                  requestsMem: "200Mi"
              custom:
                check_frequency_failed_threshold: 100,
                check_frequency_fall_times: 3,
                check_frequency_gate: false,
                check_frequency_recover_threshold: 100,
                check_frequency_rise_times: 2,
                container_path: "/usr/local/HiAI_unused",
                host_path: "/usr/local/HiAI_unused"
        2.1.14:
          clusterSelector:
            matchFields:
              - field: .spec.cluster.type
                operator: In
                values:
                  - VirtualMachine
                  - ARM64
              - field: .spec.cluster.version
                operator: Regex
                values:
                  - "(v1.21|23|25|27|28|29).*)"
          creationTimestamp: "2024-09-15T13:26:19Z"
          values:
            basic:
              image_version: "2.1.14",
              platform: "linux-amd64",
              swr_addr:
                "swr.hcs-guomi-l.outguomi.com",
                swr_user: "hwofficial",
                rbac_enabled:
                  true,
                  flavor:
                    name: "default",
                    resources:
                      limitsCpu: "100m",
                      limitsMem: "200Mi",
                      name: "huawei-npu",
                      requestsCpu: "100m",
                      requestsMem: "200Mi"
                    custom:
                      check_frequency_failed_threshold: 100,
                      check_frequency_fall_times: 3,
                      check_frequency_gate: false,
                      check_frequency_recover_threshold: 100,
                      check_frequency_rise_times: 2,
                      container_path: "/usr/local/HiAI_unused",
                      host_path: "/usr/local/HiAI_unused"
            2.1.14:
              clusterSelector:
                matchFields:
                  - field: .spec.cluster.type
                    operator: In
                    values:
                      - VirtualMachine
                      - ARM64
                  - field: .spec.cluster.version
                    operator: Regex
                    values:
                      - "(v1.21|23|25|27|28|29).*)"
              creationTimestamp: "2024-09-15T13:26:19Z"
              values:
                basic:
                  image_version: "2.1.14",
                  platform: "linux-amd64",
                  swr_addr:
                    "swr.hcs-guomi-l.outguomi.com",
                    swr_user: "hwofficial",
                    rbac_enabled:
                      true,
                      flavor:
                        name: "default",
                        resources:
                          limitsCpu: "100m",
                          limitsMem: "200Mi",
                          name: "huawei-npu",
                          requestsCpu: "100m",
                          requestsMem: "200Mi"
                        custom:
                          check_frequency_failed_threshold: 100,
                          check_frequency_fall_times: 3,
                          check_frequency_gate: false,
                          check_frequency_recover_threshold: 100,
                          check_frequency_rise_times: 2,
                          container_path: "/usr/local/HiAI_unused",
                          host_path: "/usr/local/HiAI_unused"
```

----结束

5.9 ModelArts-Common-Proxy 组件健康检查

5.9.1 修复 ModelArts-Common-Proxy os 漏洞后 ModelArts-Common-Proxy 组件健康检查与恢复

前提条件

ModelArts-Common-Proxy节点OS已升级，OS漏洞已修复。

准备工作

获取ModelArts-Common-Proxy组件包，如modelarts-common-proxy_6.1.0.20230620141934_all.tar.gz，以便需要恢复时上传至CloudAutoDeploy-SDK。ModelArts-Common-Proxy组件包获取方式如下：

- 企业用户：使用Support账号登录[华为企业业务网站](#)。选择“软件下载”，搜索包名称获取对应版本的包。
- 运营用户：使用Support账号登录[华为企业业务技术支持](#)。选择“产品软件”，搜索包名称获取对应版本的包。

操作步骤

步骤1 依次登录ModelArts-Common-Proxy组件的所有节点，检查ModelArts-Common-Proxy是否运行正常。若检查通过，则说明ModelArts-Common-Proxy组件运行正常。若检查不通过，则说明ModelArts-Common-Proxy组件运行异常，需进行恢复，执行**步骤2**。

1. 查看squid rpm包是否已安装，执行如下命令。执行后可看到包名，表示已安装squid rpm包。
`rpm -qalgrep squid`
2. 查看端口是否仍在监听，执行如下命令。执行结果显示“LISTEN”，表示端口正在监听中。
`netstat -ntulp|grep 30101`
3. 查看squid进程是否仍在工作，执行如下命令。执行结果显示如“squid -f /etc/squid/squid.conf”进程，表示squid进程正在工作中。
`ps -ef|grep squid`

```
[root@ModelArts-Common-Proxy01 ~]#  
[root@ModelArts-Common-Proxy01 ~]# rpm -qalgrep squid  
squid-4.9-8.oe1.x86_64  
[root@ModelArts-Common-Proxy01 ~]# netstat -ntulp|grep 30101  
tcp        0      0 0.0.0.0:30101 0.0.0.0:*        LISTEN      43457/(squid-1)  
[root@ModelArts-Common-Proxy01 ~]# ps -ef|grep squid  
root      43455      1   0 Jun26 ?        00:00:00 /usr/sbin/squid -f /etc/squid/squid.conf  
squid     43457  43455   0 Jun26 ?        00:00:14 (squid-1) --kid squid-1 -f /etc/squid/squid.conf  
squid     43459  43457   0 Jun26 ?        00:00:01 (logfile-daemon) /var/log/squid/access.log  
squid     159647  43457   0 Jun26 ?        00:00:00 (basic_ncsa_auth) /etc/squid/passwd  
root      1430202 1429704   0 17:40 pts/0    00:00:00 grep --color=auto squid  
[root@ModelArts-Common-Proxy01 ~]#
```

步骤2 恢复ModelArts-Common-Proxy运行异常组件。


1. 上传ModelArts-Common-Proxy组件包至CloudAutoDeploy-SDK。
 - a. 使用浏览器，登录CloudScope平台。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
CloudScope界面访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“COP”相关信息。
 - 默认账号：**op_cdk_sso**
 - 默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“CloudScopeLite”页签下搜索“op_cdk_sso”获取CloudAutoDeploy-CDK服务对应的默认密码。
 - b. 在页面导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-SDK”进入CloudAutoDeploy-SDK界面。

- c. 选择“软件包管理 > SDK包管理”，单击“上传”，上传ModelArts-Common-Proxy组件包。
2. 上线组件ModelArts-Common-Proxy。
 - a. 在页面导航栏选择“运维服务 > 变更管理 > CloudAutoChange”进入CloudAutoChange界面。

说明


访问CloudAutoChange界面的账号必须要有CloudAutoChange_operator或CloudAutoChange_manager角色权限。

- b. 选择“云服务变更 > 服务上线”，选择上线“modelarts-common-proxy”组件。
 - i. 在“资源申请”中，Schema的值需与节点的Schema保持一致，会自动查出该Schema下的ModelArts-Common-Proxy节点。



设置完成后，单击“下一步”。

- ii. 在“部署参数设置”中，在“静态配置”中设置proxy_password、scc_primary_ks_base64、scc_standby_ks_base64参数，获取参数值的方式如下：
 - 1) 在页面导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”进入CloudCDK界面。
 - 2) 选择“变更管理 > 服务升级”，在“ai-pod（静态纳管）”中选择“modelarts-os-apiserver”，然后单击“下一步”。
 - 3) 在“设置参数”的参数列表右上角，分别搜索modelarts_os_proxy_password、scc_primary_ks、scc_standby_ks，其中“当前参数”的值，即分别为proxy_password、scc_primary_ks_base64、scc_standby_ks_base64的参数值。



设置完成后，单击“执行”，等待执行完成，即表示组件已上线。

步骤3 组件重新上线后，再次执行**步骤1**，检查ModelArts-Common-Proxy是否运行正常，检查通过代表恢复完成。

----结束

5.10（旧版推理）在线服务迁移方案

5.10.1 存量 nativev1 子池推理在线服务迁移


背景信息

8.5.0版本前创建的逻辑子池不通过maos接口部署在线服务，maos无法对这类子池部署服务的资源进行限制。在推理workloadmanager数据库中，resource_cluster表的interface_version字段用于区分逻辑子池是否通过maos接口部署在线服务，其中值为nativev1时表示不通过maos接口，值为maosv1时表示通过maos接口。HCS8.5.1版本支持将这类部署在nativev1子池上的在线服务迁移到maosv1子池。

操作步骤

1. 以租户账号登录ModelArts控制台，进入AI专属资源池>弹性集群 Cluster页面。检查待确认的逻辑子池接口是否为nativev1。
 - a. 在资源池列表页面找到待确认的逻辑子池，复制资源池id。

图 5-33 复制资源池 id




- b. [登录推理workloadmanager数据库](#)，查询resource_cluster表，并找到interface_version字段值。其中{cluster_id}填入子池对应资源池id。
- 如果值为maosv1表示该子池使用maos接口部署在线服务，该子池上的服务无需迁移。

▪ 如果值为nativev1表示该子池不使用maos接口部署在线服务，该子池上的在线服务需要迁移到使用maos接口的子池上。

```
select interface_version from resource_cluster where cluster_id = '{cluster_id}';
```
2. 创建支持maosv1接口的子池，用于承接迁移后的在线服务（已存在maosv1接口子池可以跳过这一步）
- a. 在资源池列表页面找到待创建子池的物理池，单击资源池名称进入详情页。

b. 在逻辑子池页签单击“创建逻辑子池”，勾选“推理服务”并设置“保障配额”与“配额上限”，完成后单击确定。


图 5-34 创建逻辑子池



3. 将存量nativev1子池上的在线服务升级到新创建的maosv1子池。
- a. 在线服务列表页面找到待迁移服务，单击操作列的“更多>升级”，并继续在模型列表页面单击“升级”。

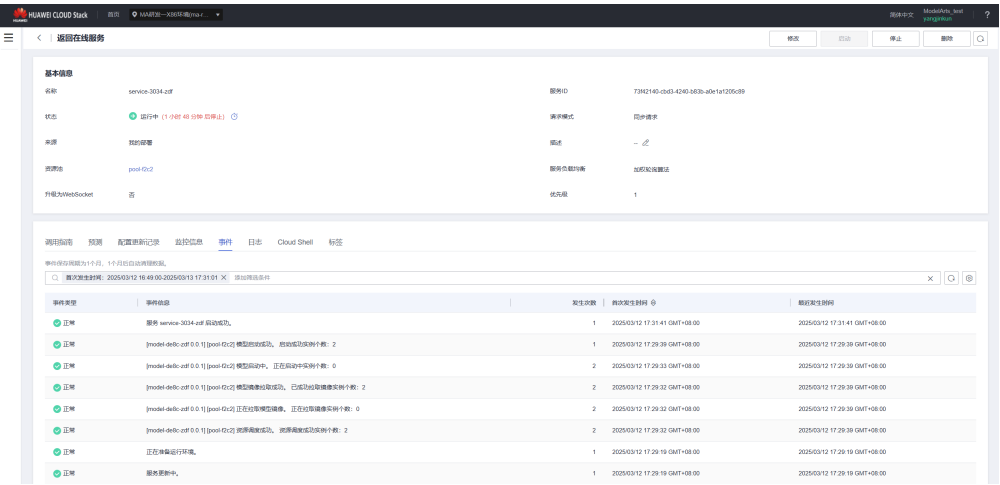
b. 资源池规格选择前面步骤创建的maosv1子池，并单击立即修改。

图 5-35 迁移服务到新资源池



4. 检查升级后的服务，等待服务状态为“运行中”即可。

图 5-36 在线服务运行正常



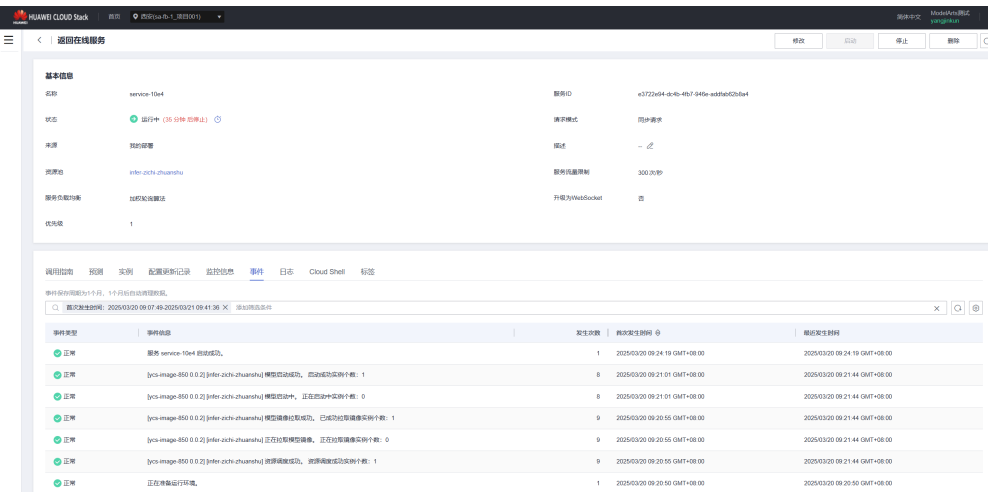
5. 对于灰度发布的模型，需要依次升级对应的模型版本，等待版本1升级完成后，再升级版本2，直到全部升级完成且服务状态为“运行中”。

图 5-37 灰度发布的模型列表



版本1升级后，检查服务状态为“运行中”，然后再次升级版本2，并检查服务状态为“运行中”。

图 5-38 检查服务升级状态



5.10.2 存量 nativev1 物理池推理在线服务迁移

背景信息

HCS8.5.1版本前创建的物理池不通过maos接口部署在线服务，maos无法对这类物理池部署服务的资源进行限制。在推理workloadmanager数据库中，resource_cluster表的interface_version字段用于区分逻辑子池是否通过maos接口部署在线服务，其中值为nativev1时表示不通过maos接口，值为maosv1时表示通过maos接口。在物理池没有服务运行的情况下，HCS8.5.1-430版本支持将存量不通过maos接口部署在线服务的物理池自动修改为通过maos接口部署在线服务的物理池。对于有服务正在运行的存量物理池，可以通过升级的方式将服务升级到其他资源池，之后该物理池将自动修改为走maos接口的物理池。存量物理池不同场景下的处理方案如下：

- 无在线服务的资源池：定时任务直接修改接口为maosv1
- 有在线服务的资源池
 - 存在空闲物理池：通过升级将服务迁移其他空闲的物理池，迁移完成后，定时任务修改接口为maosv1
 - 无空闲物理池：在该物理池下创建逻辑子池，通过升级将服务迁移到逻辑子池下，后续使用逻辑子池代替该物理池
 - 存在训练任务时：存在训练任务时无法创建子池，需要等待训练任务执行结束后进行迁移动作

操作步骤


1. 以租户账号登录ModelArts控制台，进入AI专属资源池>弹性集群 Cluster页面。检查待确认的物理池接口是否为nativev1。确定该物理池存在服务时，可以直接检查物理池作业列表是否有服务来判断接口是否为nativev1，推理作业未在作业列表展示时说明当前接口为nativev1需要处理。
 - a. 在资源池列表页面找到待确认的逻辑子池，复制资源池id。


图 5-39 复制资源池 id



- b. [登录推理workloadmanager数据库](#)，查询resource_cluster表，并找到interface_version字段值。其中{cluster_id}填入物理池对应资源池id。
- 如果值为maosv1表示该物理池使用maos接口部署在线服务，该物理池上的服务无需迁移。
 - 如果值为nativev1表示该物理池不使用maos接口部署在线服务，该物理池上的在线服务需要迁移到使用maos接口的资源池上。
- ```
select interface_version from resource_cluster where cluster_id = '{cluster_id}';
```
- c. 该物理池上存在服务时，直接物理池作业列表页面查看是否存在推理作业

图 5-40 查看作业列表是否存在推理作业






2. 无其他可用资源池时，可以在待迁移的物理池上创建支持maosv1接口的子池，用于承接迁移后的在线服务。（存在其他已对接maos且有剩余资源的资源池时，可以使用该资源池承接服务即可，无需再创建子池）
- a. 在资源池列表页面找到待创建子池的物理池，单击资源池名称进入详情页。
  - b. 在逻辑子池页签单击“创建逻辑子池”，勾选“推理服务”并设置“保障配额”与“配额上限”，完成后单击确定。（用子池代替物理池时，建议设置的与物理池节点数相同的配额值）

图 5-41 创建逻辑子池



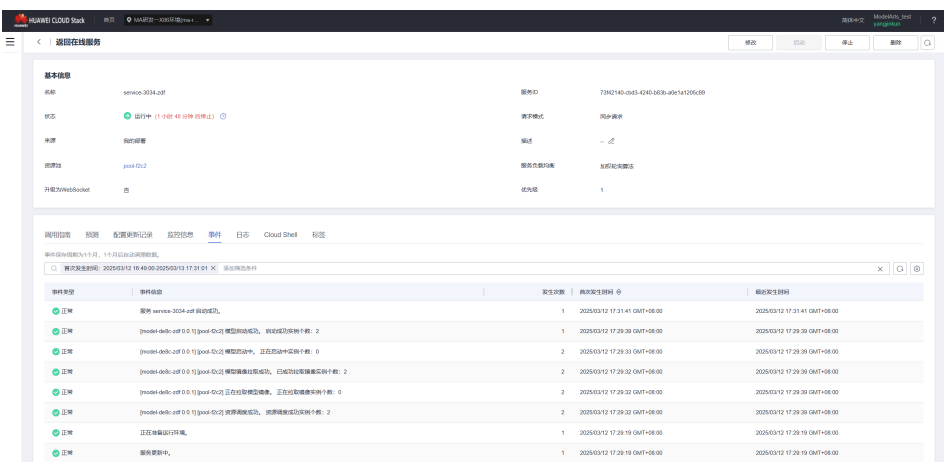
3. 将存量nativev1物理池上的在线服务升级到其他可用资源池或新创建的maosv1子池。
- a. 在线服务列表页面找到待迁移服务，单击操作列的“更多>升级”，并继续在模型列表页面单击“升级”。
  - b. 资源池规格选择其他可用资源池或者前面步骤创建的maosv1子池，并单击立即修改。

图 5-42 迁移服务到新资源池



4. 检查升级后的服务，等待服务状态为“运行中”即可。

图 5-43 在线服务运行正常



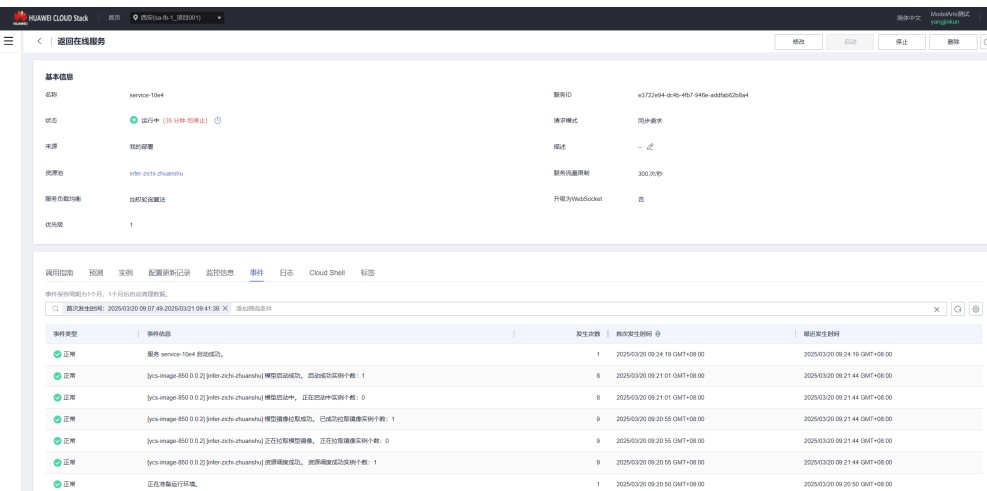
5. 对于灰度发布的模型，需要依次升级对应的模型版本，等待版本1升级完成后，再升级版本2，直到全部升级完成且服务状态为“运行中”。

图 5-44 灰度发布的模型列表




版本1升级后，检查服务状态为“运行中”，然后再次升级版本2，并检查服务状态为“运行中”。

图 5-45 检查服务升级状态



6. 存量nativev1物理池上的服务迁移完成后，10分钟内接口将自动修改为maosv1，可以按照步骤1的方法检查数据库interface\_version字段值是否为maosv1。自动修改完成后，该物理池上部署在线服务可以在资源池作业列表处看到对应的推理作业。

图 5-46 迁移完成后部署在线服务可以在资源池作业列表查看到对应推理作业



5.10.3 推理资源工作空间迁移的手动操作指导

迁移目标

将default工作空间中指定资源池下的所有关联推理资源迁移至新的工作空间。

纳入迁移范围的推理资源包括：ai应用、app code、在线服务、绑定app code的在线服务、灰度的多模型版本在线服务、批量服务、异步在线服务。

说明

- 在AI Hub订阅的模型及其部署在迁移资源池的推理服务不在迁移的范围内。

公共资源池上部署的服务不在迁移范围内。
- 后续的迁移脚本会提示上述资源在迁移动作发生后会失效，建议提前清理。

注意事项

1. 建议推理资源的迁移与资源池的迁移同步进行，期间可能会影响资源作业的正常运行，迁移完成之前不要对迁移涉及的资源池和资源作业进行操作。

2. 新建工作空间需要进行修改企业资源空间id或者部署在线服务等操作，才会触发推理数据库对该工作空间的纳管，否则后续脚本检索工作空间会失败。

## 推理资源迁移操作

1. 登录WORKLOADMANAGER数据库，详细登录操作请参见[登录ModelArts数据库](#)。根据**maos资源池id**查询推理的资源池id列表，**maos资源池id**实际上就是推理资源池详情页面的资源池ID，修改sql语句中\${maos\_pool\_id1}为指定需要迁移的资源池id。  

```
select id from resource_cluster WHERE cluster_id in ('${maos_pool_id1}', '${maos_pool_idxx}');
```
2. 登录upredict数据库，详细登录操作请参见[登录ModelArts数据库](#)。执行如下脚本迁移推理资源检索。

输入\e进行脚本编辑，默认vi编辑器，输入下列脚本并修改脚本中的\${infer\_cluster\_id1~n}，\${old\_workspace\_id}，\${new\_workspace\_id}，然后wq保存后退出。

```
CREATE OR REPLACE FUNCTION migrate_string_arrays_equal(arr1 TEXT[], arr2 TEXT[])
RETURNS BOOLEAN AS $$
BEGIN
 IF ((arr1 IS NULL) OR (array_length(arr1, 1) = 0)) AND ((arr2 IS NULL) OR (array_length(arr2, 1) = 0)) THEN
 RETURN TRUE;
 END IF;

 -- 比较数组长度
 IF array_length(arr1, 1) != array_length(arr2, 1) THEN
 RETURN FALSE;
 END IF;

 -- 排序后比较数组
 RETURN (
 SELECT ARRAY_AGG(e ORDER BY e) FROM UNNEST(arr1) AS e
) = (
 SELECT ARRAY_AGG(e ORDER BY e) FROM UNNEST(arr2) AS e
);
END;
$$ LANGUAGE plpgsql;

CREATE OR REPLACE FUNCTION array_to_in_clause(
 p_array ANYARRAY,
 p_quote_values BOOLEAN DEFAULT TRUE
) RETURNS TEXT AS $$
DECLARE
 v_result TEXT := '';
 v_element TEXT;
 v_first_element BOOLEAN := TRUE;
BEGIN
 IF p_array IS NOT NULL AND array_length(p_array, 1) > 0 THEN
 FOREACH v_element IN ARRAY p_array LOOP
 IF NOT v_first_element THEN
 v_result := v_result || ',';
 ELSE
 v_first_element := FALSE;
 END IF;

 IF p_quote_values THEN
 -- 对字符串类型进行引号转义
 v_result := v_result || quote_literal(v_element);
 ELSE
 -- 对于非字符串类型直接使用
 v_result := v_result || v_element::TEXT;
 END IF;
 END LOOP;
 END IF;
 RETURN v_result;
END;
```

```
END;
$$ LANGUAGE plpgsql;

DO $$
DECLARE

 input_cluster_ids TEXT[] := ARRAY['${infer_cluster_id1}', '${infer_cluster_idn}'];
 new_workspace_id TEXT := '${new_workspace_id}';
 old_workspace_id TEXT := '${old_workspace_id}';
 MIGRATE_SERVICE_STATUS TEXT[] := ARRAY['running', 'concerning', 'finished'];

 MAX_LOOP_TIMES INT := 10;
 loop_times INT := 0;

 cluster_ids TEXT[] := input_cluster_ids;
 tmp_cluster_ids TEXT[];
 service_ids TEXT[];
 model_ids TEXT[];
 model_names TEXT[];
 model_domain_ids TEXT[];
 logic_app_ids TEXT[];
 app_ids TEXT[];
 logic_app_service_ids TEXT[];
 app_service_ids TEXT[];
 market_model_ids TEXT[];
 shared_service_ids TEXT[];

 last_cluster_ids TEXT[];
 last_service_ids TEXT[];
 last_model_ids TEXT[];
 last_logic_app_ids TEXT[];
 last_app_ids TEXT[];

 record_exists BOOLEAN;
BEGIN
 RAISE NOTICE 'input resource cluster id list is: %', cluster_ids;

 SELECT EXISTS(SELECT 1 FROM workspaces WHERE workspace_id = new_workspace_id) INTO
record_exists;
 IF NOT record_exists THEN
 RAISE EXCEPTION 'target workspace not exist %', new_workspace_id;
 END IF;
 record_exists := FALSE;
 SELECT EXISTS(SELECT 1 FROM workspaces WHERE workspace_id = old_workspace_id) INTO
record_exists;
 IF NOT record_exists THEN
 RAISE EXCEPTION 'source workspace not exist %', old_workspace_id;
 END IF;

 LOOP
 -- cluster -> model version
 SELECT ARRAY_AGG(DISTINCT s.model_id) INTO model_ids
 FROM m_services m, service_models s
 WHERE s.model_cluster_id = ANY(cluster_ids) AND m.UPDATE_TIME = s.UPDATE_TIME AND
m.STATUS != 'deleted';
 RAISE NOTICE 'times: %, cluster -> model version is : %', loop_times, model_ids;

 -- model version -> model start
 SELECT ARRAY_AGG(DISTINCT model_name) INTO model_names
 FROM MODELS_ATELIER WHERE model_id = ANY(model_ids);
 RAISE NOTICE 'times: %, model_names is : %', loop_times, model_names;

 SELECT ARRAY_AGG(DISTINCT tenant) INTO model_domain_ids
 FROM MODELS_ATELIER WHERE model_id = ANY(model_ids);
 RAISE NOTICE 'times: %, model_domain_ids is : %', loop_times, model_domain_ids;
```

```
SELECT ARRAY_AGG(DISTINCT model_id) INTO model_ids
FROM MODELS_ATELIER WHERE workspace_id = old_workspace_id AND model_name =
ANY(model_names) AND tenant = ANY(model_domain_ids) AND market_flag = FALSE;
RAISE NOTICE 'times: %, total model_ids is : %', loop_times, model_ids;

SELECT ARRAY_AGG(DISTINCT model_id) INTO market_model_ids
FROM MODELS_ATELIER WHERE workspace_id = old_workspace_id AND model_name =
ANY(model_names) AND tenant = ANY(model_domain_ids) AND market_flag = TRUE;
RAISE NOTICE 'times: %, market_model_ids is : %', loop_times, market_model_ids;
-- model version -> model end

-- model -> services
SELECT ARRAY_AGG(DISTINCT m.service_id) INTO service_ids
FROM m_services m, service_models s
WHERE s.model_id = ANY(model_ids) AND m.UPDATE_TIME = s.UPDATE_TIME AND m.STATUS !=
'deleted';
RAISE NOTICE 'times: %, model -> services is : %', loop_times, service_ids;

-- services -> logic app
SELECT ARRAY_AGG(DISTINCT b.logic_app_id) INTO logic_app_ids FROM logic_service_api l,
logic_app_auth_bind b WHERE l.logic_api_id = b.logic_api_id AND l.service_id = ANY(service_ids);
RAISE NOTICE 'times: %, services -> logic app : %', loop_times, logic_app_ids;

-- services -> app
SELECT ARRAY_AGG(DISTINCT b.app_id) INTO app_ids FROM app_auth_api a, app_auth_bind b
WHERE a.api_id = b.api_id AND a.service_id = ANY(service_ids);
RAISE NOTICE 'times: %, services -> app : %', loop_times, app_ids;

-- logic app -> services
SELECT ARRAY_AGG(DISTINCT l.service_id) INTO logic_app_service_ids FROM logic_service_api l,
logic_app_auth_bind b WHERE l.logic_api_id = b.logic_api_id AND b.logic_app_id = ANY(logic_app_ids);
RAISE NOTICE 'times: %, logic app -> services : %', loop_times, logic_app_service_ids;

-- app -> services
SELECT ARRAY_AGG(DISTINCT a.service_id) INTO app_service_ids FROM app_auth_api a,
app_auth_bind b WHERE a.api_id = b.api_id AND b.app_id = ANY(app_ids);
RAISE NOTICE 'times: %, app -> services : %', loop_times, app_service_ids;

-- 聚合公共资源池services
SELECT ARRAY_AGG(DISTINCT subq.elem) INTO shared_service_ids
FROM (
 SELECT unnest(service_ids || logic_app_service_ids || app_service_ids) AS elem
) subq
WHERE EXISTS (
 SELECT 1
 FROM M_SERVICES m
 WHERE m.SERVICE_ID = subq.elem AND m.CLUSTER_TYPE != 'EXCLUSIVE'
);
RAISE NOTICE 'shared_service_ids : %', shared_service_ids;

-- 聚合services
SELECT ARRAY_AGG(DISTINCT subq.elem) INTO service_ids
FROM (
 SELECT unnest(service_ids || logic_app_service_ids || app_service_ids) AS elem
) subq
WHERE EXISTS (
 SELECT 1
 FROM M_SERVICES m
 WHERE m.SERVICE_ID = subq.elem AND m.CLUSTER_TYPE = 'EXCLUSIVE'
);
RAISE NOTICE 'service_ids : %', service_ids;

-- service -> model version
SELECT ARRAY_AGG(DISTINCT s.model_id) INTO model_ids
FROM m_services m, service_models s
WHERE s.service_id = ANY(service_ids) AND m.UPDATE_TIME = s.UPDATE_TIME AND m.STATUS !=
'deleted';

-- model version -> all model version start
```

```
SELECT ARRAY_AGG(DISTINCT model_name) INTO model_names
FROM MODELS_ATELIER WHERE model_id = ANY(model_ids);
RAISE NOTICE 'times: %, model_names is : %', loop_times, model_names;

SELECT ARRAY_AGG(DISTINCT tenant) INTO model_domain_ids
FROM MODELS_ATELIER WHERE model_id = ANY(model_ids);
RAISE NOTICE 'times: %, model_domain_ids is : %', loop_times, model_domain_ids;

SELECT ARRAY_AGG(DISTINCT model_id) INTO model_ids
FROM MODELS_ATELIER WHERE workspace_id = old_workspace_id AND model_name =
ANY(model_names) AND tenant = ANY(model_domain_ids);
RAISE NOTICE 'times: %, total model_ids is : %', loop_times, model_ids;
-- model version -> all model version end

-- model version -> cluster
SELECT ARRAY_AGG(DISTINCT s.model_cluster_id) INTO tmp_cluster_ids
FROM m_services m, service_models s
WHERE s.model_id = ANY(model_ids) AND m.UPDATE_TIME = s.UPDATE_TIME AND
s.model_cluster_id IS NOT NULL AND m.STATUS != 'deleted' AND m.INFER_TYPE = 'EXCLUSIVE';

-- 聚合cluster ids
IF tmp_cluster_ids IS NOT NULL THEN
 SELECT ARRAY_AGG(DISTINCT elem) INTO cluster_ids
 FROM (
 SELECT unnest(cluster_ids || tmp_cluster_ids) AS elem
) subq;
END IF;
RAISE NOTICE 'times: %, cluster_ids is : %', loop_times, cluster_ids;

IF migrate_string_arrays_equal(cluster_ids, last_cluster_ids)
AND migrate_string_arrays_equal(service_ids, last_service_ids)
AND migrate_string_arrays_equal(model_ids, last_model_ids)
AND migrate_string_arrays_equal(logic_app_ids, last_logic_app_ids)
AND migrate_string_arrays_equal(app_ids, last_app_ids) THEN
 RAISE NOTICE 'success to query all infer resource';
 RAISE NOTICE 'cluster_ids is : %', cluster_ids;
 RAISE NOTICE 'service_ids is : %', service_ids;
 RAISE NOTICE 'model_ids is : %', model_ids;
 RAISE NOTICE 'logic_app_ids is : %', logic_app_ids;
 RAISE NOTICE 'app_ids is : %', app_ids;
 RAISE NOTICE 'market_model_ids is : %', market_model_ids;
 RAISE NOTICE 'shared_service_ids is : %', shared_service_ids;
 EXIT;
END IF;
loop_times := loop_times + 1;
IF loop_times > MAX_LOOP_TIMES THEN
 RAISE EXCEPTION 'query loop exceed max times : %', loop_times;
END IF;
last_cluster_ids := cluster_ids;
last_service_ids := service_ids;
last_model_ids := model_ids;
last_logic_app_ids := logic_app_ids;
last_app_ids := app_ids;
END LOOP;

FOR i IN 1 .. array_length(cluster_ids, 1) LOOP
 IF cluster_ids[i] NOT IN (SELECT unnest(input_cluster_ids)) THEN
 RAISE EXCEPTION 'input cluster id must contains : %', cluster_ids;
 END IF;
END LOOP;

IF market_model_ids IS NOT NULL OR shared_service_ids IS NOT NULL THEN
 RAISE NOTICE '';
 RAISE NOTICE
'=====';
 RAISE NOTICE '如果需要执行脚本输出的迁移操作，以下资源需要单独处理';
 IF market_model_ids IS NOT NULL THEN
 RAISE NOTICE '订阅模型不在迁移范围内，迁移动作发生后，以下模型部署在迁移资源池的服务会
```



```
失效，建议清理';
 RAISE NOTICE '%', array_to_in_clause(market_model_ids);
END IF;
IF shared_service_ids IS NOT NULL THEN
 RAISE NOTICE '公共资源池推理服务不在迁移范围内，迁移发生后，以下服务不会进行迁移，建议清理';
 RAISE NOTICE '%', array_to_in_clause(shared_service_ids);
END IF;
RAISE NOTICE
'=====';
 RAISE NOTICE ";
END IF;

 RAISE NOTICE ";
 RAISE NOTICE
'=====';
 RAISE NOTICE '执行以下sql语句完成迁移工作';
 IF service_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE m_services SET workspace_id = "%" WHERE workspace_id = "%" AND
service_id IN (%);', new_workspace_id, old_workspace_id, array_to_in_clause(service_ids);
 RAISE NOTICE 'UPDATE service_billing SET workspace_id = "%" WHERE workspace_id = "%"
AND service_id IN (%);', new_workspace_id, old_workspace_id, array_to_in_clause(service_ids);
 RAISE NOTICE 'UPDATE SERVICE_TAGS SET workspace_id = "%" WHERE workspace_id = "%"
AND resource_id IN (%);', new_workspace_id, old_workspace_id, array_to_in_clause(service_ids);
 END IF;

 IF model_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE MODELS_ATelier SET workspace_id = "%" WHERE workspace_id = "%"
AND model_id IN (%);', new_workspace_id, old_workspace_id, array_to_in_clause(model_ids);
 END IF;

 IF model_names IS NOT NULL OR model_domain_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE MODEL_NAME_INFO SET workspace_id = "%" WHERE workspace_id =
 "%" AND model_name IN (%) AND domain_id IN (%);', new_workspace_id, old_workspace_id,
array_to_in_clause(model_names), array_to_in_clause(model_domain_ids);
 END IF;

 IF logic_app_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE api_gateway_logic_app SET workspace_id = "%" WHERE workspace_id =
 "%" AND logic_app_id IN (%);', new_workspace_id, old_workspace_id,
array_to_in_clause(logic_app_ids);
 END IF;

 IF app_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE apig_app SET workspace_id = "%" WHERE workspace_id = "%" AND
app_id IN (%);', new_workspace_id, old_workspace_id, array_to_in_clause(app_ids);
 END IF;
 RAISE NOTICE
'=====';
 RAISE NOTICE ";

 RAISE NOTICE ";
 RAISE NOTICE
'=====';
 RAISE NOTICE '如果迁移出现问题，执行以下sql语句进行迁移回滚';
 IF service_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE m_services SET workspace_id = "%" WHERE workspace_id = "%" AND
service_id IN (%);', old_workspace_id, new_workspace_id, array_to_in_clause(service_ids);
 RAISE NOTICE 'UPDATE service_billing SET workspace_id = "%" WHERE workspace_id = "%"
AND service_id IN (%);', old_workspace_id, new_workspace_id, array_to_in_clause(service_ids);
 RAISE NOTICE 'UPDATE SERVICE_TAGS SET workspace_id = "%" WHERE workspace_id = "%"
AND resource_id IN (%);', old_workspace_id, new_workspace_id, array_to_in_clause(service_ids);
 END IF;

 IF model_ids IS NOT NULL THEN
 RAISE NOTICE 'UPDATE MODELS_ATelier SET workspace_id = "%" WHERE workspace_id = "%"
AND model_id IN (%);', old_workspace_id, new_workspace_id, array_to_in_clause(model_ids);
 END IF;
```



## 资源池迁移工作空间操作

在上述推理资源迁移操作中，最终实际要迁移的资源池有多个，每个资源池都需要进行以下处理。

1. 获取资源租户账号并登录CCE，进入CCE集群，获取目标资源池的集群名称。
2. 登录CDK master节点。
3. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 5-47 查看 pod

```
Last login: Wed Aug 24 17:23:16 CST 2022 on pts/1
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectl get pod
NAME READY STATUS RESTARTS AGE
modelarts-algorancher-8ddcc8d68-cqk42 1/1 Running 0 3d16h
modelarts-algorancher-8ddcc8d68-krc8m 1/1 Running 0 3d16h
modelarts-billing-7d9d4c4dd4-ftsvn 1/1 Running 0 3d16h
modelarts-billing-7d9d4c4dd4-hvsj9 1/1 Running 0 3d16h
modelarts-console-backend-576cbbfddb-d78t7 1/1 Running 0 3d16h
modelarts-console-backend-576cbbfddb-k94g7 1/1 Running 0 3d16h
modelarts-exemplflow-778b8c78fd-mjg67 1/1 Running 0 3d16h
modelarts-exemplflow-778b8c78fd-wglcl 1/1 Running 0 3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8 1/1 Running 0 2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl 1/1 Running 0 2d22h
modelarts-os-apiserver-5cd548c558-sltx5 1/1 Running 0 3d16h
modelarts-os-apiserver-5cd548c558-tzv2 1/1 Running 0 3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz 1/1 Running 0 3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x 1/1 Running 0 3h24m
modelarts-os-resource-mgr-78747979f7-8wqtf 1/1 Running 0 3d16h
modelarts-os-resource-mgr-78747979f7-zvr4q 1/1 Running 0 3d16h
modelarts-webapp-gateway-cdk-7547d97b55-l7k6j 1/1 Running 0 3d16h
modelarts-webapp-gateway-cdk-7547d97b55-r6rtz 1/1 Running 0 3d16h
```

4. 执行如下命令登录pod。  
`kubectl exec -it ${pod_name} bash`
5. 执行**kubectl edit pool \${pool\_name}**进入编辑页面，`${pool_name}`为集群名称。

图 5-48 进入编辑页面

```
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectl get po -ninfer
NAME READY STATUS RESTARTS AGE
modelarts-image-packer-546fd55844-jg59d 1/1 Running 0 5h16m
modelarts-image-packer-546fd55844-t54wh 1/1 Running 0 5h16m
modelarts-infers-ctsproxy-686c57c777-47cxp 1/1 Running 0 5h35m
modelarts-infers-ctsproxy-686c57c777-8jjn6 1/1 Running 0 5h35m
modelarts-infers-job-manager-796667c474-6gk9f 1/1 Running 0 5h11m
modelarts-infers-job-manager-796667c474-vhw9 1/1 Running 0 5h11m
modelarts-infers-model-manager-8584f0b05-5sdx 1/1 Running 0 5h17m
modelarts-infers-model-manager-8584f0b05-kdjxx 1/1 Running 0 5h17m
modelarts-infers-monitor-6576cf645-5zmp 1/1 Running 0 5h24m
modelarts-infers-monitor-6576cf645-92cdp 1/1 Running 0 5h24m
modelarts-infers-service-manager-6c6df94759-sgvx2 1/1 Running 0 5h17m
modelarts-infers-service-manager-6c6df94759-vx7fj 1/1 Running 0 5h14m
modelarts-infers-stats-7bc9fc9bf5-4fdwv 1/1 Running 0 5h17m
modelarts-infers-stats-7bc9fc9bf5-nbzj8 1/1 Running 1 5h17m
[service@modelarts-os-apiserver-5fbc8d794-7b1fd modelarts-os-apiserver]$ kubectl edit pool pool-move-workspace-b33fd65d96474f4a8e4a1f96754274fd5
edit cancelled, no changes made
```

将os.modelarts/workspace.id修改为指定的workspace\_id。

图 5-49 修改 workspace.id

```
apiVersion: os.modelarts.huaweicloud/v1
kind: Pool
metadata:
 annotations:
 os.modelarts.pool/scope.external.dependency.infer: '{"type": "Enabled", "status": "True", "message": "Ok", "elb_enable": "True", "cluster_interface_version": "maosv1"}'
 os.modelarts/auto.pay: ""
 os.modelarts/auto.renew: ""
 os.modelarts/billing.mode: "0"
 os.modelarts/order.id: ""
 os.modelarts/period.num: ""
 os.modelarts/period.type: ""
 os.modelarts/promotion.info: ""
 os.modelarts/resource.id: maos-pool-move-workspace-ch4fs
 os.modelarts/service.console.url: ""
 os.modelarts/tenant.domain.name: MA_test
 os.modelarts/tenant.project.name: ma-region-2_MA_Obj_vjp
 os.modelarts/tenant.user.name: Langkai_test
 os.modelarts/tenant.xdomain.type: ""
 creationTimestamp: "2025-04-23T09:16:40Z"
 finalizers:
 - os.modelarts.pool/finalizers
 generation: 2
 labels:
 os.modelarts.pool/biz: private
 os.modelarts/create.from: console
 os.modelarts/enterprise.project.id: "0"
 os.modelarts/name: pool-move-workspace
 os.modelarts/node.prefix: ""
 os.modelarts/order.name: order.pool-move-workspace-fv2rb
 os.modelarts/resource.project.id: 23e30fc411c34a47a481187dbec8f06f
 os.modelarts/tenant.domain.id: e574950610744b2cb5e85b0d4872bf54
 os.modelarts/tenant.project.id: b33fd65d96474f4a0e4af96764274fd5
 os.modelarts/tenant.user.id: bed1df629c594f04b766f4ce2ed51304
 os.modelarts/tenant.xdomain.id: ""
 os.modelarts/workspace.id: "0"
 name: pool-move-workspace-b33fd65d96474f4a0e4af96764274fd5
 resourceVersion: "72908"
 uid: ddb68daa-d8aa-4a9a-b292-7f28710a8aca
spec:
```

## 迁移结果

### 迁移成功

脚本迁移成功后，关联的推理资源全部迁移至指定的工作空间。

### 迁移回滚

当迁移出现问题的时候，应及时回滚。


- 2脚本会用于迁移回滚的sql语句。当迁移出现问题的时候，可以及时回滚。
- 将3脚本中new\_workspace\_id替换为原工作空间id，然后执行回滚。
- 将5中os.modelarts/workspace.id修改为原工作空间id，然后执行回滚。

## 5.11 （新版推理）ModelArts 推理服务创建物理专属网关操作指导

### 5.11.1 概述

本文档描述ModelArts新版推理服务提供物理专属网关的相关操作指导，使用户业务可区分测试、生产或者生产内不同业务分组，用户网络流量分流，提升性能和可靠性。

## 架构概览



用户可通过以下三种方式使用专属Dispatcher进行预测：

- 直接在Console页面进行预测
- 通过EIP调用API进行预测
- 通过VPCEP的方式实现用户VPC和专属Dispatcher的VPC互通，走内网进行预测

## 约束限制

- 当前一个资源空间只能对应一个Dispatcher工作负载。如果用户的Dispatcher性能容量不够，则需要扩容Dispatcher，请参考[扩容Dispatcher](#)。
- 一个region支持最多450个专属Dispatcher。

## 读者对象

本文档主要适用于以下工程师：

- 技术支持工程师
- 维护工程师

### 5.11.2 前提条件

已部署ModelArts新版推理。

参考如下步骤确认是否已部署ModelArts新版推理。

1. [以系统管理员账号登录ManageOne运维面](#)。
2. 在快速通道中选择“云服务”，进入资源监控页面。



3. 单击下方“微服务”，搜索框中按名称搜索“modelarts-infers-manager”，存在搜索结果则说明已部署ModelArts新版推理服务。



### 5.11.3 安装专属 Dispatcher

#### 准备工作

本文档所使用的自动化脚本随版本发布，在support上下载modelarts-test-demo-8.6.0-20251030压缩包，在“infers/data”文件夹下获取“专属dispatcher部署脚本.7z”文件并解压。

#### 说明

“modelarts-test-demo-8.6.0-20251030”压缩包获取方式：

- 企业用户：使用Support账号登录[华为企业业务网站](#)。选择“软件下载”，搜索modelarts-test-demo-8.6.0-20251030，获取demo包。
- 运营用户：使用Support账号登录[华为企业业务技术支持](#)。选择“产品软件”，搜索modelarts-test-demo-8.6.0-20251030，获取demo包。

“modelarts-test-demo-8.6.0-20251030”压缩包解压方式：

- 下载modelarts-test-demo-8.6.0-20251030.z01和modelarts-test-demo-8.6.0-20251030.zip，然后同时选中解压到同一文件夹中。

#### 操作步骤

**步骤1** [登录ModelArts-Common-Proxy节点](#)，将解压的文件放到Proxy节点的同一目录下。

表 5-14 脚本介绍

| 文件名                           | 脚本介绍                          |
|-------------------------------|-------------------------------|
| Api.py                        | 工具脚本，其他脚本的依赖项，不需要用户执行。        |
| params.json                   | 参数配置文件，可通过在此文件添加参数，达到替换参数的效果。 |
| InstallExclusiveDispatcher.py | 创建专属Dispatcher脚本。             |
| CreateVPCEPService.py         | 创建VPC脚本。                      |
| CreateCCEClustr.py            | 创建CCE集群脚本。                    |
| CreateELB.py                  | 创建ELB以及转发策略脚本。                |
| example.sql                   | 依赖项，不需要用户修改。                  |
| main.sh                       | 操作的主文件                        |

脚本的如下参数使用默认配置，如果默认值无法满足要求，可以在params.json添加字段修改参数。支持修改如下参数：

表 5-15 脚本的默认配置参数

| 参数名                       | 参数介绍                                                                |
|---------------------------|---------------------------------------------------------------------|
| exclusive_cluster_name    | 新集群名称，默认为infern-dispatcher-exclusive+时间戳。                           |
| container_domain_name     | ModelArts服务承载租户使用的一级管理VDC名称，默认为“ModelArts_System_VDC”。              |
| container_user_name       | ModelArts服务承载租户使用的二级VDC用户名，默认为“ModelArts_manage_admin”。             |
| project_name              | 资源空间名称，默认与region_id相同。                                              |
| node_nums                 | node节点数量，若不传默认为3。                                                   |
| exclusive_instance_name   | 专属Dispatcher实例名称，默认为infern-dispatcher-exclusive+时间戳。                |
| exclusive_inner_elb_name  | 专属Dispatcher内部ELB名称，默认为elb-infer2-dispatcher-inner-exclusive+时间戳。   |
| exclusive_public_elb_name | 专属Dispatcher公共ELB名称，默认为elb-infer2-dispatcher-public-exclusive +时间戳。 |
| vpcep_service_name        | 终端节点服务名称，默认为dispatcher-exclusive+时间戳。                               |

## 步骤2 创建专属Dispatcher的CCE集群。

1. 修改params.json里的**region\_id**和**global\_domain\_name**参数，后续脚本有需自定义的参数可以根据情况，在params.json添加参数，参考附件params.json脚本可选参数清单。

 说明

- region\_id为当前局点的regionId信息，可参考安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“region0\_id”，查看取值，下文后续步骤同此取值。
- global\_domain\_name为当前局点的内部Global域名后缀，可参考安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，在“基本参数”页签下搜索“global\_domain\_name”，查看取值，下文后续步骤同此取值。

2. 执行脚本。

```
sh main.sh cce_cluster {container_user_password} {root_pwd} {sign}
```

参数描述：

container\_user\_password：ModelArts服务承载租户使用的二级VDC用户密码，联系环境管理员获取。

root\_pwd：新创建的CCE集群node节点密码，密码需符合：长度为8-26位，包含大写字母或小写字母、数字和特殊字符（!@\$%^&\_+=+[]{};./?）

sign：时间戳，格式为yyyymmddhhmm，例如202508211600。

**步骤3** 执行如下脚本创建专属Dispatcher实例。

```
sh main.sh dispatcher {container_user_password} {sign}
```

参数描述：

container\_user\_password：ModelArts服务承载租户使用的二级VDC用户密码（联系环境管理员获取）

sign：时间戳，格式yyyymmddhhmm，例如202508211600，与**步骤2.2**的sign保持一致

图 5-50 专属 Dispatcher 实例创建成功

```
logging.info("create exclusive dispatcher completed")
```

图 5-51 在 CCE 查看创建的实例



**步骤4** 创建ELB。

1. 执行脚本创建内部ELB。

```
sh main.sh inner_elb {container_user_password} {sign}
```

参数描述：

container\_user\_password：ModelArts服务承载租户使用的二级VDC用户密码，联系环境管理员获取。



sign：时间戳，格式yyyymmddhhmm，例如202508211600，与步骤2.2的sign保持一致。

2. 执行脚本创建公共ELB。  
sh main.sh public\_elb {container\_user\_password} {sign}

图 5-52 查看创建的 ELB

| 弹性负载均衡                                         |     |                         |                |                           |                                                                                       |
|------------------------------------------------|-----|-------------------------|----------------|---------------------------|---------------------------------------------------------------------------------------|
| 名称                                             | 状态  | 弹性IP                    | 服务地址           | 子网                        | 监听器（前缀协议/端口）/ 健康检查状态                                                                  |
| elb-infer2-dispatcher-inner-exclusive20250820  | 运行中 | --                      | 192.168.21.129 | IPv4子网: subnet-dispatcher | listener_exclusive202... (HTTPS/30453) 在线<br>listener_exclusive202... (HTTP/30013) 在线 |
| elb-infer2-dispatcher-public-exclusive20250820 | 运行中 | 8.27.17.241(300 Mbit/s) | 192.168.21.85  | IPv4子网: subnet-dispatcher | listener_exclusive202... (HTTPS/443) 在线<br>listener_exclusive202... (HTTP/80) 在线      |

- 步骤5 执行如下脚本创建VPC终端节点服务。  
sh main.sh vpcep\_service {container\_user\_password} {sign} {identifier}

container\_user\_password：ModelArts服务承载租户使用的二级VDC用户密码，联系环境管理员获取。

sign：时间戳，格式yyyymmddhhmm，例如202508211600，与步骤2.2的sign保持一致。

identifier：用户账号的资源空间ID，多个资源空间ID用英文逗号分隔，最多支持配置20个。

- 步骤6 创建VPC终端节点服务执行完成后，在脚本同级目录会生成一个名为exclusive\_dispatcher\_xxx.sql的sql，请参照[登录Mysql数据库](#)登录infrs\_manager数据库，执行该sql。

----结束

5.11.4 扩容 Dispatcher

ModelArts新版推理服务提供物理专属网关，使用户业务可区分测试、生产或者生产内不同业务分组，用户网络流量分流，提升性能和可靠性。当前一个资源空间只能对应一个Dispatcher，如果用户的Dispatcher性能容量不够，需要扩容，请参考本文档扩容Dispatcher。

增加 Dispatcher 实例个数

1. 以[ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面](#)，进入“云容器引擎 CCE”服务的“集群管理”页面，找到infrs-dispatcher-xxx集群。

图 5-53 找到 infers-dispatcher 集群



2. 单击集群名称进入专属Dispatcher的CCE集群，选择“节点管理>节点”，查看节点资源（CPU核数/内存）是否充足。
- 单个节点的CPU核心数/内存要大于节点上Dispatcher实例规格（CPU核数/内存）总和，表示节点充足，请执行3。如果节点规格资源不足，请执行4

图 5-54 单个节点的规格




图 5-55 Dispatcher 工作负载实例规格



3. 进入专属Dispatcher的CCE集群，左边菜单选择“工作负载”，找到专属Dispatcher的工作负载，在“实例个数”列表，单击编辑，增加到目标实例个数。

图 5-56 增加目标实例数




4. 单击搜索框右侧的刷新图标，刷新Dispatcher工作负载的状态。
- a. 如果因为节点资源不足导致增加实例失败，可以在“实例个数”列表，单击编辑，单击出现的“-”号，恢复到原来的实例个数。

图 5-57 节点资源不足，实例调度失败



- b. 然后扩节点，在左边菜单选择“节点管理”，选中“节点”页签，单击“创建节点”，节点规格详见[获取公共Dispatcher节点规格信息](#)的“集群节点规格”。



c. 在“实例个数”列表，单击编辑，增加到目标实例个数。

5.11.5 专属 Dispatcher 升级


1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，进入“云容器引擎 CCE”服务的“集群管理”页面，找到infern-dispatcher-xxx集群。

图 5-58 找到 infern-dispatcher 集群



2. 进入后单击“应用模板>模板实例”，单击“操作”列的“升级”。
3. 选择需要升级的版本，复制左边的yaml文件后，修改image.tag为目标版本后点击升级

图 5-59 升级模板实例



5.11.6 管理专属 Dispatcher 绑定的资源空间

专属Dispatcher创建完成后，如需要修改绑定的资源空间，请参考本章节操作。

1. 根据Dispatcher组名查询需要修改的数据，确认是否为需要增删的数据。（组名为"exclusive"+时间戳+"\_dispatcher\_group"，时间戳与步骤2.2使用的sign参数一致）
- select \* from t\_dispatcher\_group where name = '{dispatcher组名}';
2. 执行如下SQL增删资源空间。
- update t\_dispatcher\_group set identifier = '{修改后的资源空间id列表，英文逗号隔开}' where name = '{dispatcher组名}';
- identifier代表用户账号的资源空间ID。多个资源空间ID用英文逗号分隔，最多支持配置20个。
3. 新增资源空间场景涉及原有服务迁移，请参考新版推理在线服务迁移到新 Dispatcher组手工方案 迁移存量在线服务。

5.11.7 新版推理在线服务迁移到新 Dispatcher 组手工方案

使用场景

不同Dispatcher组之间会有流量隔离，出于流量隔离考虑，会把服务从当前Dispatcher组迁移到新的Dispatcher组。

## 前提条件

1. 确保服务与要迁移的Dispatcher组未绑定，否则“操作步骤”中无法构造出迁移语句。
2. 可以登录mysql，登录操作可参考[登录Mysql数据库](#)。
3. 可以连接redis服务，连接操作可参考《[ModelArts 7.2.1-HCS 维护指南\(for 华为云Stack 8.6.0\)](#)》>参考指南的Redis命令章节。

## 准备工作

- 获取Dispatcher组名称。
  - a. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，在服务列表中搜索“云容器引擎 CCE”，单击进入。
  - b. 在“集群管理”页面，找到要迁移的新Dispatcher组的cce集群“infers-dispatcher-xxxxx”，单击进入。

图 5-60 找到新 Dispatcher 组 infer-dispatcher-xxxxx




- c. 在cce集群内，找到“工作负载>无状态负载”，在“工作负载名称”中找到带“Dispatcher”字样的工作负载，单击进入。

图 5-61 找到 Dispatcher 工作负载



- d. 在“工作负载详情页”，在“容器管理”>“环境变量”中找到变量“ENV\_DISPATCHER\_GROUP”，它的值即为Dispatcher组名称。

图 5-62 记录 Dispatcher 组名称



- 获取服务ID
  - a. 使用用户账号登录ManageOne租户面，在服务列表中搜索“AI开发平台 ModelArts”，单击进入。
  - b. 进入“模型部署”>“在线服务”，找到要迁移的服务，在“名称/ID”列可以复制服务ID。

图 5-63 获取服务 ID



操作步骤

1. 登录mysql，详细操作请参考[登录Mysql数据库](#)。
2. 构造服务迁移的mysql语句、redis语句。

其中构造的字段“sql\_word”、“redis\_word”用于服务迁移。

其中构造的字段“rollback\_sql\_word”、“rollback\_redis\_word”用于回滚迁移的数据。

其中，exclusive\_dispatcher\_group为【dispatcher组名称】，07a0a621-8ff4-420a-b02a-aa17db442a7a为【服务ID】，请替换成实际值。

```
select s.service_name, dispatcher_group_name,
CONCAT('INSERT INTO t_dispatcher_group_service (dispatcher_group_id, id, create_at, update_at,
service_id) VALUES (\',g.id,\', REPLACE(UUID(), '\-\' ,'\') , now(), now(), \', s.service_id, '\');') as
sql_word,
CONCAT('HSET ', g.name, '_dispatcher_service_status_list ', s.service_id, ', ', s.status) as redis_word,
CONCAT('DELETE FROM t_dispatcher_group_service WHERE dispatcher_group_id=\', g.id,\'' AND
service_id=\', s.service_id, '\');') rollback_sql_word,
CONCAT('HDEL ', g.name, '_dispatcher_service_status_list ', s.service_id) as rollback_redis_word
from (select id as service_id, status, name as service_name, 'exclusive_dispatcher_group' as
dispatcher_group_name
from t_service where id='07a0a621-8ff4-420a-b02a-aa17db442a7a') as s
inner join t_dispatcher_group g on g.name = s.dispatcher_group_name
where not exists (select 1 from t_dispatcher_group_service where service_id=s.service_id and
dispatcher_group_id=g.id);
```

执行后生成四条sql语句，后续3、4、6步骤使用。

```

-- Create a table to store the results of the recursive CTE
CREATE TABLE _dispatcher_group_service AS
WITH RECURSIVE _dispatcher_group_service AS (
 SELECT '1' AS _id, '1' AS _parent_id, '1' AS _service_id, '1' AS _dispatcher_group_id, '1' AS _path
 UNION ALL
 SELECT _id, _parent_id, _service_id, _dispatcher_group_id, _path || _service_id || '-' || _dispatcher_group_id
 FROM _dispatcher_group_service
 WHERE _parent_id = 1
)

-- Insert the results of the recursive CTE into the _dispatcher_group_service table
INSERT INTO _dispatcher_group_service
SELECT _id, _parent_id, _service_id, _dispatcher_group_id, _path
FROM _dispatcher_group_service
WHERE _parent_id = 1

-- Create a table to store the results of the recursive CTE
CREATE TABLE _dispatcher_group_service AS
WITH RECURSIVE _dispatcher_group_service AS (
 SELECT '1' AS _id, '1' AS _parent_id, '1' AS _service_id, '1' AS _dispatcher_group_id, '1' AS _path
 UNION ALL
 SELECT _id, _parent_id, _service_id, _dispatcher_group_id, _path || _service_id || '-' || _dispatcher_group_id
 FROM _dispatcher_group_service
 WHERE _parent_id = 1
)

-- Insert the results of the recursive CTE into the _dispatcher_group_service table
INSERT INTO _dispatcher_group_service
SELECT _id, _parent_id, _service_id, _dispatcher_group_id, _path
FROM _dispatcher_group_service
WHERE _parent_id = 1

```

3. 在mysql中插入数据。

执行2中构造的“sql\_word”字段sql语句。

```
INSERT INTO t_dispatcher_group_service (dispatcher_group_id, id, create_at, update_at, service_id)
VALUES ('5f4a2fe6-b0d4-4204-87aa-0ddccdfa4bee', REPLACE(UUID(), '-', ''), now(), now(),
'07a0a621-8ff4-420a-b02a-aa17db442a7a');
```

```
mysql> INSERT INTO t_dispatcher_group_service (dispatcher_group_id, id, create_at, update_at, service_id) VALUES ('514a2f6b-b0d4-4284-87aa-0ddcdcf4bee', REPLACE(UUID(), '-', ''), now(), now(), '07a0a621-8ff4-420a-b02a-a017db442a7a');
(query OK, 1 row affected (0.46 sec))
```

- #### 4. 连接redis服务，添加redis缓存数据。

执行2中构造的“redis\_word”字段redis命令。

```
HSET exclusive_dispatcher_group_dispatcher_service_status_list 07a0a621-8ff4-420a-b02a-aa17db442a7a ERROR
```

```
00>
00> HSET exclusive_dispatcher_group_dispatcher_service_status_list 07a0a621-8ff4-420a-b02a-aal7db442a7a ERRORR
(integer) 1
00>
```

5. 执行如下mysql语句查看服务与Dispatcher组的绑定关系，确认服务是否迁移成功。服务绑定到指定的Dispatcher，说明服务迁移到新Dispatcher成功。

注意：07a0a621-8ff4-420a-b02a-aa17db442a7a为【服务ID】，请替换成实际值。

```
select s.service_id 服务ID, se.name as 服务名称, se.status 服务状态, g.id as dispatcher组ID, g.name as
dispatcher组名称, s.create_at as 关联时间, se.project_id 资源空间ID
from t_dispatcher_group g
inner join t_dispatcher_group_service s on g.id=s.dispatcher_group_id
inner join t_service se on se.id=s.service_id
where s.service_id in
(
'07a0a621-8ff4-420a-b02a-aa17db442a7a'
) order by s.service_id, s.create_at desc;
```



```
mysql> select s.service_id 服务ID, se.name as 服务名称, se.status 服务状态, g.id as dispatcher组ID, g.name as dispatcher组名称, s.create_at as 关联时间, se.project_id 项目ID
-> from t_dispatcher_group g
-> inner join t_dispatcher_group_service s on g.id=s.dispatcher_group_id
-> inner join t_service se on se.id=s.service_id
-> where s.service_id in
-> (
-> '07a0a621-8ff4-420a-b02a-aa17db442a7a'
->)
-> order by s.service_id, s.create_at desc;
```

| 服务ID                                 | 服务名称          | 服务状态  | dispatcher组ID                        | dispatcher组名称              | 关联时间                       | 项目ID          |
|--------------------------------------|---------------|-------|--------------------------------------|----------------------------|----------------------------|---------------|
| 07a0a621-8ff4-420a-b02a-aa17db442a7a | service-obs-1 | ERROR | 5f4a2fe6-b0d4-4204-87aa-8ddccdf4bee  | exclusive_dispatcher_group | 2025-07-02 22:20:22.000000 | ca69b440bb864 |
| 07a0a621-8ff4-420a-b02a-aa17db442a7a | service-obs-1 | ERROR | ca29ce14-b475-4bee-93b4-24951e280c77 | public_dispatcher_group    | 2025-07-02 20:07:22.564523 | ca69b440bb864 |

## 6. 迁移数据回滚（可选）

登录mysql，执行2中构造的“rollback\_sql\_word”字段sql语句，删除服务与Dispatcher的绑定关系。

```
DELETE FROM t_dispatcher_group_service WHERE dispatcher_group_id='5f4a2fe6-b0d4-4204-87aa-8ddccdf4bee' AND service_id='07a0a621-8ff4-420a-b02a-aa17db442a7a';
```

```
mysql> DELETE FROM t_dispatcher_group_service WHERE dispatcher_group_id='5f4a2fe6-b0d4-4204-87aa-8ddccdf4bee' AND service_id='07a0a621-8ff4-420a-b02a-aa17db442a7a';
Query OK, 1 row affected (0.16 sec)
```

登录redis，执行2中构造的“rollback\_redis\_word”字段redis命令，删除服务与Dispatcher的缓存数据。

```
HDEL exclusive_dispatcher_group_dispatcher_service_status_list 07a0a621-8ff4-420a-b02a-aa17db442a7a
```

```
@> HDEL exclusive_dispatcher_group_dispatcher_service_status_list 07a0a621-8ff4-420a-b02a-aa17db442a7a
(integer) 1
```

查看回滚效果

```
select s.service_id 服务ID, se.name as 服务名称, se.status 服务状态, g.id as dispatcher组ID, g.name as dispatcher组名称, s.create_at as 关联时间, se.project_id 资源空间ID
from t_dispatcher_group g
inner join t_dispatcher_group_service s on g.id=s.dispatcher_group_id
inner join t_service se on se.id=s.service_id
where s.service_id in
(
'07a0a621-8ff4-420a-b02a-aa17db442a7a'
)
order by s.service_id, s.create_at desc;
```

```
mysql> select s.service_id 服务ID, se.name as 服务名称, se.status 服务状态, g.id as dispatcher组ID, g.name as dispatcher组名称, s.create_at as 关联时间, se.project_id 项目ID
-> from t_dispatcher_group g
-> inner join t_dispatcher_group_service s on g.id=s.dispatcher_group_id
-> inner join t_service se on se.id=s.service_id
-> where s.service_id in
-> (
-> '07a0a621-8ff4-420a-b02a-aa17db442a7a'
->)
-> order by s.service_id, s.create_at desc;
```

| 服务ID                                 | 服务名称          | 服务状态  | dispatcher组ID                        | dispatcher组名称           | 关联时间                       | 项目ID          |
|--------------------------------------|---------------|-------|--------------------------------------|-------------------------|----------------------------|---------------|
| 07a0a621-8ff4-420a-b02a-aa17db442a7a | service-obs-1 | ERROR | ca29ce14-b475-4bee-93b4-24951e280c77 | public_dispatcher_group | 2025-07-02 20:07:22.564523 | ca69b440bb864 |

1 row in set (0.00 sec)

## 5.11.8 附录

### 5.11.8.1 获取公共 Dispatcher 节点规格信息


1. 以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，进入“云容器引擎 CCE”服务的“集群管理”页面，找到“ifers-dispatcher”集群，单击集群名称进入集群总览页。

图 5-64 找到公共集群 infer-dispatcher



2. 单击左侧菜单的“节点管理”，单击上方的“节点”页签，复制“节点配置”列的信息，第一行是节点所属可用区，第二行是节点规格。

图 5-65 查看节点配置信息



5.11.8.2 登录 Mysql 数据库

- 1. 以系统管理员账号登录ServiceOM平台。
- 2. 在“首页 > 计算资源”中，单击“虚拟机”，进入虚拟机列表页面。
- 3. 在页面右上角通过“名称”搜索“ModelArts-Infers-MySQL”，记录虚拟机的IP地址。



- 4. 使用Putty工具以opsadmin用户登录任一数据库节点，默认密码请参见《华为云Stack 8.6.0 账户一览表》，在“A类（后台）”页签中 搜索节点名称获取。
- 5. 执行ip a，如果结果如下图所示，有浮动ip，则说明当前节点是主节点，可继续执行下列步骤，否则执行4登录另一个节点开始执行。

```
[opsadmin@ModelArts-Infers-MySQL-01 ~]$ ip a
1: lo: <LOOPBACK,UP,LOWER_UP> mtu 65536 qdisc noqueue state UNKNOWN group default qlen 1000
 link/loopback 00:00:00:00:00:00 brd 00:00:00:00:00:00
 inet 127.0.0.1/8 scope host lo
 valid_lft forever preferred_lft forever
2: eth0: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc fq_codel state UP group default qlen 1000
 link/ether fa:16:3e:06:76:8b brd ff:ff:ff:ff:ff:ff
 inet 8.27.51.155/23 brd 8.27.51.255 scope global eth0
 valid_lft forever preferred_lft forever
 inet 8.27.51.157/23 brd 8.27.51.255 scope global secondary eth0:1
 valid_lft forever preferred_lft forever
[opsadmin@ModelArts-Infers-MySQL-01 ~]$
```


- 6. 切换root账号，默认密码请参见《华为云Stack 8.6.0 账户一览表》，在“A类（后台）”页签中 搜索节点名称获取。
- 7. 执行以下命令登录数据库。

```
mysql -uroot -p{密码} -S/data/mysql/tmp/mysql.sock
use infer_manager;
```

其中，密码请参见《华为云Stack 8.6.0 账户一览表》，在“B类（EI企业智能）”页签中搜索节点名称获取。

5.11.8.3 如何获取用户 ID、租户 ID 和资源空间 ID

使用指定账号登录运营面，以承载租户为例，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面，单击右上角账号名称，单击“个人设置”，进入“个人设置”页面，找到“用户ID”“租户ID”和“资源空间列表”下资源空间的“ID”，资源空间ID即资源空间ID。



5.11.8.4 命名规范

| 名称项                           | 规范                                        | 示例                                                 |
|-------------------------------|-------------------------------------------|----------------------------------------------------|
| CCE集群名                        | infern-dispatcher-{特征名+日期}                | infern-dispatcher-exclusive20250529                |
| dispatcher组名<br>( groupName ) | {特征名+日期}_dispatcher_group                 | exclusive20250529_dispatcher_group                 |
| dispatcher实例名                 | {特征名}-dispatcher                          | exclusive-dispatcher                               |
| EIP关联的ELB名                    | elb-infer2-dispatcher-http-{特征名+日期}       | elb-infer2-dispatcher-http-exclusive20250529       |
| 内网ELB名                        | elb-infer2-dispatcher-http-inner-{特征名+日期} | elb-infer2-dispatcher-http-inner-exclusive20250529 |
| 终端节点服务名                       | dispatcher-{特征名+日期}-lan                   | dispatcher-exclusive20250529-lan                   |
| HTTP监听器名                      | listener_{特征名+日期}_HTTP_监听端口               | listener_exclusive20250529_HTTP_30013              |
| HTTPS监听器名                     | listener_{特征名+日期}_HTTPS_监听端口              | listener_exclusive20250529_HTTPS_30453             |
| HTTP后端服务器组名                   | {特征名+日期}_HTTP_业务端口                        | exclusive20250529_HTTP_30013                       |
| HTTPS后端服务器组名                  | {特征名+日期}_HTTPS_业务端口                       | exclusive20250529_HTTPS_30453                      |

## 5.11.8.5 SQL 示例

| 执行顺序 | SQL示例                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1    | <pre>INSERT INTO t_network_channel (id,create_at, project_id, subnet_id, vpc_id, vpcep_service_ids) VALUES ('ec730f83-f4ef-470b-a34a- a90be7831cc8',now(), '718d54d87adc43c287ba895779c2f19d','889a76a1-ddcf-44d1-8df7- f0c98fabf34a','95a65672-ebd7-4977-8994-20eaa795fadf', 'aca7ec68- a9fd-443b-9ae4-3062c40ef343');</pre>                                                                                                                                                                                                                                                          |
| 2    | <pre>INSERT INTO t_cce_cluster (id, create_at, update_at, az_id, name, project_id, project_name, security_group_id, status, subnet_id, type, user_id, vpc_id, service_provider, version, arch, docker_base_size, domain_id) VALUES ('6d1be690-3c7b-11f0-9c67-0255ac1000a0', now(), now(), NULL, 'ifers-dispatcher-exclusive20250529', '718d54d87adc43c287ba895779c2f19d', NULL, NULL, 'ACTIVE', NULL, 'RESOURCE', 'ac22b502b717436b9f772b4fa9f9f961', '95a65672-ebd7-4977-8994-20eaa795fadf', 'MODELARTS', 'v1.25', 'VIRTUALMACHINE', '50', 'd8126a20db13499c82e060007d1e8348');</pre> |
| 3    | <pre>INSERT INTO t_dispatcher_group (id, create_at, name, owner_domain_id, owner_project_id, owner_user_id,public_urls, network_channel_id, strategy, identifier, priority) VALUES ('d3ee2874-3193-4bab-ab6c-246276188192', now(), 'exclusive20250529_dispatcher_group', '718d54d87adc43c287ba895779c2f19d','4d7ab8b22b594c99981c20a 03a7bbc96','cfee21d72c86487b987aa79937368706','8.27.62.115', 'ec730f83-f4ef-470b-a34a-a90be7831cc8', 'BY_PROJECT', 'b33fd65d96474f4a8e4af96764274fd5', 10);</pre>                                                                                 |
| 4    | <pre>INSERT INTO t_dispatcher (id, create_at, security_group_id, status, subnet_id, vpc_id, cluster_id, dispatcher_group_id) VALUES ('b6aa94e7-c021-4728-bf3a-a5139c098d03', now(),'3bd10006-49b7-45a4-af6a-b7356db29ef2', 'RUNNING', '889a76a1-ddcf-44d1-8df7-f0c98fabf34a','95a65672- ebd7-4977-8994-20eaa795fadf','6d1be690-3c7b-11f0-9c67-0255ac1 000a0', 'd3ee2874-3193-4bab-ab6c-246276188192');</pre>                                                                                                                                                                           |
| 5    | <pre>INSERT INTO t_elb (id, create_at, eip, elb_class, name, private_ip, project_id, status, subnet_id, type, user_id, vpc_id, network_channel_id) VALUES ('b79efe82-08cd-4347-9760-72016166cf65', now(), '127.0.0.1', 'performance', 'elb-infer-dispatcher-http-inner-eclusive20250529', '192.18.22.61', '718d54d87adc43c287ba895779c2f19d', 'ACTIVE', '889a76a1-ddcf-44d1-8df7-f0c98fabf34a', 'INFER_INTRANET_CHANNEL', '95a65672- ebd7-4977-8994-20eaa795fadf', '95a65672- ebd7-4977-8994-20eaa795fadf', 'ec730f83-f4ef-470b-a34a- a90be7831cc8');</pre>                            |

| 执行顺序 | SQL示例                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 6    | INSERT INTO t_elb (id, create_at, eip, elb_class, name, private_ip, project_id, status, subnet_id, type, user_id, vpc_id, network_channel_id) VALUES ('6bff95e9-92fb-4db1-93e2-b8b7d5cfcab2', now(), '8.27.62.115', 'performance', 'elb-infer-dispatcher-http-eclusive20250529', '192.18.22.79', '718d54d87adc43c287ba895779c2f19d', 'ACTIVE', '889a76a1-ddcf-44d1-8df7-f0c98fabf34a', 'INFER_PUBLIC_CHANNEL', '95a65672-ebd7-4977-8994-20eaa795fadf', '95a65672-ebd7-4977-8994-20eaa795fadf', 'ec730f83-f4ef-470b-a34a-a90be7831cc8'); |
| 7    | INSERT INTO t_lan_client (id,create_at,type,status,vpc_id,vpcep_client_ips,dispatcher_group_id) VALUES('e2873495-116e-4150-8301-7df7d72103df',now(),'CONSOLE','CREATED','fb0d02b2-2e43-4bb9-922d-edae8983d8c9','8.27.68.115','d3ee2874-3193-4bab-ab6c-246276188192');                                                                                                                                                                                                                                                                   |

## 5.12 ModelArts License 去除试用期校验

### 场景说明

局点通过城市智能中枢（CityIT）和工业智能中枢（IndIT）来集成使用ModelArts，客户只需购买城市智能中枢和工业智能中枢的License，无需单独购买ModelArts的License，此时需完成ModelArts的License配置。

#### 说明

请勿恶意使用当前操作跳过ModelArts试用期过期校验；仅在城市智能中枢（CityIT）和工业智能中枢（IndIT）集成使用ModelArts时执行如下步骤。

### 操作步骤

1. 以管理员账号登录CloudCDK界面。
2. 选择“变更管理 > 服务升级 > ai-pod(静态纳管，容灾局点还需要额外升级ai-pod-dr集群)”，选中右侧列表中的modelarts-os-apiserver，单击“下一步”。在“升级配置”中更新如下参数的参数值。
  - 将“license\_config”的参数值更新为目标值。即在原有值基础上添加“checkExpired”:true, 效果如下图所示。

| 导入JSON文件            |        | 配置清单   |      |                                                                 |
|---------------------|--------|--------|------|-----------------------------------------------------------------|
| 参数名称                | 参数类型   | 数据类型   | 模板参数 | 当前参数                                                            |
| validate_by_license | deploy | string | true | true                                                            |
| license_config      | deploy | string |      | {"checkExpired":true,"compulity":84,"scopeType":"result","vali" |

- 将“CPU\_LIMITS”的参数值更新为当前值+1。

# 6 巡检指南

## 6.1 概述

### 巡检目的

日常巡检的目的是减少系统隐患，确保系统能够长期安全、稳定、可靠地运行，降低维护成本，确保系统进行正常的业务处理。

### 巡检方法

ModelArts巡检内容及方法如[表6-1](#)所示：

表 6-1 巡检方法

| 巡检内容  | 巡检方法                            | 巡检周期 |
|-------|---------------------------------|------|
| 检查告警  | 通过ManageOne告警平台检查告警上报，处理告警。     | 1天   |
| 管控面巡检 | 通过ManageOne运维面上集成的FusionCare巡检。 | 1天   |

## 6.2 检查 ModelArts 告警

对ManageOne运维面上各服务告警进行分析，根据告警列表对每个告警分析其发生的原因、对系统的影响，最后根据分析结果提出解决措施。

### 前提条件

已登录ManageOne运维面。

### 操作步骤

1. 在主菜单中选择“告警 > 告警管理 > 当前告警”，进入告警查看页面。

- 2. 查看告警信息。
  - 有告警信息，执行3。
  - 没有告警信息，结束。
- 3. 定位告警信息。

在搜索结果列表中，单击打开某条告警信息。在打开的告警详情中，根据表6-2列出的需要关注的信息定位服务问题所在。

表 6-2 告警信息

| Key值        | 说明                         |
|-------------|----------------------------|
| 告警流水号       | 便于快速定位问题。                  |
| IP地址/URL/域名 | 用于定位报警主机。                  |
| 定位信息        | 包括租户ID、卷ID、失败区域等关键信息。      |
| 附加信息        | 包括备注和处理记录，便于定位处理人员、跟进处理状态。 |

- 4. 处理告警信息。

具体操作请参考告警帮助。

## 6.3 使用 FusionCare 巡检

### 6.3.1 登录 FusionCare 界面

- 1. 以管理员账号登录ManageOne运维面。
  - a. 使用浏览器，通过地址“https://ManageOne运维面主页的访问地址31943”，登录ManageOne运维面，或通过地址“https://ManageOne主门户的访问地址”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。
    - 密码方式  
默认账号：bss\_admin  
 **说明**  
对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。  
默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。
    - USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。  
 **说明**  
仅在SM系列商密算法场景下支持USB Key方式。
  - b. 单击“登录”。
- 2. 在ManageOne运维面首页，选择“常用链接”区域的“FusionCare(巡检) > 待巡检region名称”，进入FusionCare系统。



### 6.3.2 日常巡检

#### 6.3.2.1 日常巡检项

表 6-3 ModelArts 管控面巡检项

| 巡检项ID  | 巡检项名称                  | 巡检方法       | FusionCare任务场景                                                     | 检查标准                                                                                                                                                                              |
|--------|------------------------|------------|--------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100000 | 检查ModelArts节点的CPU使用情况。 | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>登录该巡检失败的虚拟机节点。</li><li>执行命令：<b>top -bsn 2 grep '%Cpu' awk '{print \$8}'</b></li><li>查看CPU空闲率，使用“1-CPU空闲率=CPU使用率”，查看CPU使用率是否超过80%。</li></ol> |
| 100001 | 检查ModelArts节点的内存使用情况。  | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>登录该巡检失败的虚拟机节点。</li><li>执行命令：<b>free -m</b></li><li>查看mem的total和used值，计算mem的使用率是否超过80%。</li></ol>                                            |
| 100002 | 检查ModelArts节点的磁盘使用情况。  | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>登录该巡检失败的虚拟机节点。</li><li>执行命令：<b>df   grep -v 'tmpfs'   grep -v 'loop'   grep '/dev/'</b></li><li>查看各磁盘挂载的使用率是否超过80%。</li></ol>               |

| 巡检项ID  | 巡检项名称                           | 巡检方法       | FusionCare任务场景                                                     | 检查标准                                                                                                                                                                       |
|--------|---------------------------------|------------|--------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100003 | 检查ModelArts节点的工作空间和日志目录的使用情况。   | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>执行命令：<b>df   grep -v 'tmpfs'   grep -v 'loop'   grep '/dev/'</b></li><li>查看工作空间(/opt/cloud)和日志目录(/var/log)的使用率。</li></ol>            |
| 100004 | 检查ModelArts节点日志目录的大文件列表。        | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <p>检查日志目录下（ /opt/cloud/logs、/var/log ）是否存在文件超过1G。</p> <ul style="list-style-type: none"><li>如果无返回文件列表则表示不存在大文件巡检项检查通过。</li><li>如果返回文件列表则表明存在文件超过1G，此检查项不通过。</li></ul>      |
| 100005 | 检查ModelArts节点ntp状态。             | FusionCare | 日常巡检                                                               | 根据巡检结果，偏移小于60s为正常，连接异常或者偏移大于60s为异常。                                                                                                                                        |
| 100006 | 检查modelarts_infers_manager微服务状态 | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>登录到ModelArts_Common_Region-POD-Master节点。</li><li>执行命令<b>kubectl get pod  grep inferns-manager</b>查看服务状态是否为Running并且状态为1/1。</li></ol> |

| 巡检项ID  | 巡检项名称                               | 巡检方法       | FusionCare任务场景                                                     | 检查标准                                                                                                                                                                                                                      |
|--------|-------------------------------------|------------|--------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100007 | 检查infers-dispatcher集群下微服务状态         | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>通过ModelArts资源承载用户登录CCE页面。</li><li>进入infers-dispatcher集群。</li><li>查看工作负载-无状态负载下modelarts-infers-dispatcher负载的状态是否正常</li><li>查看工作负载-有状态负载下modelarts-infers-watcher负载的状态是否正常</li></ol> |
| 100011 | 检查infers-dispatcher的CCE集群状态         | FusionCare | <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul> | <ol style="list-style-type: none"><li>通过ModelArts资源承载用户登录CCE页面。</li><li>查看infers-dispatcher集群状态是否正常。</li></ol>                                                                                                            |
| 100012 | 检查ModelArts推理infers-dispatcher健康状态。 | FusionCare | 日常巡检                                                               | <ol style="list-style-type: none"><li>通过ModelArts资源承载用户登录CCE页面。</li><li>查看infer-dispatcher集群状态及其工作负载是否正常。</li></ol>                                                                                                       |
| 100048 | 检查proxy节点中squid服务状态。                | FusionCare | 日常巡检                                                               | 执行命令： <b>systemctl status squid.service 2&gt;/dev/null   grep -w Active awk {'print \$2'}</b> 查看squid状态是否正常，active代表状态正常，其他代表状态不正常。                                                                                       |
| 100049 | 检查etcd节点中etcd服务状态。                  | FusionCare | 日常巡检                                                               | 用于管理面备份结果检查，检查etcd服务是否正常。执行命令： <b>python /opt/cloud/etcd/script/checkEtcd.py;echo \$?</b><br>返回值表示etcd状态，0代表状态正常，1代表状态不正常。                                                                                                |
| 100050 | 检查etcd数据存放路径的磁盘空间。                  | FusionCare | 日常巡检                                                               | 用于管理面备份结果检查。通过检查/opt/cloud/etcd/data对应挂的磁盘。如果所在磁盘的使用率大于80%即不通过。                                                                                                                                                           |

| 巡检项ID  | 巡检项名称                              | 巡检方法       | FusionCare任务场景 | 检查标准                                                                                     |
|--------|------------------------------------|------------|----------------|------------------------------------------------------------------------------------------|
| 100051 | 检查ModelArts gaussdb节点中数据存放路径的磁盘空间。 | FusionCare | 日常巡检           | 1. 使用PuTTY工具，以opsadmin用户登录该节点，切换到账号root。<br>2. 查看/opt/ gaussdb目录下 gaussdb 数据存放路径的磁盘空间情况。 |
| 100052 | 检查ModelArts gaussdb主备状态是否正常。       | FusionCare | 日常巡检           | DB_STATE为Normal则正常；否则为异常。                                                                |
| 100053 | 检查ModelArts gaussdb备份状态是否正常。       | FusionCare | 日常巡检           | 查询DB的本地备份是否有近期的备份文件，七天内有备份文件存在则正常，否则异常。                                                  |
| 100054 | 检查ModelArts mysql主备状态是否正常。         | FusionCare | 日常巡检           | 登录mysql巡检失败的节点，查看mysql主备状态是否正常。                                                          |
| 100055 | 检查ModelArts mysql备份状态是否正常          | FusionCare | 日常巡检           | 查询DB的本地备份是否有近期的备份文件，七天内有备份文件存在则正常，否则异常。                                                  |
| 100056 | 检查ModelArts mysql节点中数据存放路径的磁盘空间。   | FusionCare | 日常巡检           | 1. 使用PuTTY工具，以opsadmin用户登录该节点。<br>2. 切换到账号“root”，查看数据存放路径/data的磁盘空间情况。                   |

| 巡检项ID  | 巡检项名称                                         | 巡检方法       | FusionCare任务场景 | 检查标准                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|--------|-----------------------------------------------|------------|----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100057 | 检查ModelArts服务redis连通性的状态。                     | FusionCare | 日常巡检           | <ol style="list-style-type: none"><li>1. 使用PuTTY工具，以opsadmin用户登录巡检失败的节点，并切换到“root”账号。</li><li>2. 执行如下命令，查看Redis connect是否为normal，State是否为online状态。若显示非上述内容，则执行下一步。<br/><pre>python /opt/cloud/redis/script/tools/self_check.py</pre></li><li>3. 执行如下命令，启动redis服务，查看回显状态是否启动Redis成功。若不成功，将命令执行结果与进程日志/opt/cloud/logs/redis/redis.log和ll /opt/cloud/logs/redis/sentinel_26800.log信息反馈给技术支持处理。<br/><pre>python3 /opt/cloud/redis/script/tools/start_redis.py</pre></li></ol> |
| 100060 | 检查imagepacker的CCE集群状态。                        | FusionCare | 日常巡检           | <ol style="list-style-type: none"><li>1. 通过ModelArts资源承载用户登录CCE页面。</li><li>2. 查看modelarts-infer-imagepacker集群状态是否正常。</li></ol>                                                                                                                                                                                                                                                                                                                                            |
| 100061 | 检查dispatcher的CCE集群状态。                         | FusionCare | 日常巡检           | <ol style="list-style-type: none"><li>1. 通过ModelArts资源承载用户登录CCE页面。</li><li>2. 查看modelarts-infer-dispatcher集群状态是否正常。</li></ol>                                                                                                                                                                                                                                                                                                                                             |
| 100063 | 检查modelarts-infer-dispatcher集群中batch-agent状态。 | FusionCare | 日常巡检           | <ol style="list-style-type: none"><li>1. 再次执行该检查项，通过ModelArts资源承载用户登录CCE页面。</li><li>2. 查看batch-agent的无状态负载deployment的状态是否正常。</li></ol>                                                                                                                                                                                                                                                                                                                                    |
| 100065 | 检查modelarts-infer-task的CCE集群状态。               | FusionCare | 日常巡检           | <ol style="list-style-type: none"><li>1. 以ModelArts资源承载用户登录cce页面。</li><li>2. 查看modelarts-infer-task集群状态是否正常。</li></ol>                                                                                                                                                                                                                                                                                                                                                    |
| 100066 | 检查modelarts-infer-task集群中modelarts-task状态。    | FusionCare | 日常巡检           | 再次执行该检查项，以ModelArts资源承载用户登录CCE页面，查看modelarts-task的无状态负载deployment的状态是否正常。                                                                                                                                                                                                                                                                                                                                                                                                 |

| 巡检项ID  | 巡检项名称                                                  | 巡检方法       | FusionCare任务场景                                                         | 检查标准                                                                                                                                                                                          |
|--------|--------------------------------------------------------|------------|------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100067 | 检查modelarts-market-service的CCE集群状态。                    | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 以ModelArts资源承载用户登录CCE页面。</li><li>2. 查看modelarts-market-service集群状态是否正常。</li></ol>                                                                    |
| 100068 | 检查modelarts-market-service的modelarts-market-service状态。 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | 再次执行该检查项，以ModelArts资源承载用户登录CCE页面，查看modelarts-market-service的无状态负载deployment的状态是否正常。                                                                                                           |
| 100100 | 检查modelarts_infers_model_manager微服务状态。                 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectll get pod -n infer grep infer-model-manager</b>查看服务状态是否为Running并且状态为1/1。</li></ol> |
| 100101 | 检查modelarts_infers_service_manager微服务状态。               | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectll get pod -n infer grep service-manager</b>查看服务状态是否为Running并且状态为1/1。</li></ol>     |

| 巡检项ID  | 巡检项名称                             | 巡检方法       | FusionCare任务场景                                                         | 检查标准                                                                                                                                                                                     |
|--------|-----------------------------------|------------|------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100103 | 检查modelarts-infers-ctsproxy微服务状态。 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-CDK-Master节点。</li><li>2. 执行命令<b>kubecttl get pod -n infer grep infer-ctsproxy</b>查看服务状态是否为Running并且状态为1/1。</li></ol> |
| 100104 | 检查modelarts_infers_monitor微服务状态。  | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubecttl get pod -n infer grep infer-monitor</b>查看服务状态是否为Running并且状态为1/1。</li></ol>  |
| 100105 | 检查modelarts_infers_stats微服务状态。    | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubecttl get pod -n infer grep infer-stats</b>查看服务状态是否为Running并且状态为1/1。</li></ol>    |
| 100106 | 检查modelarts_algorancher微服务状态。     | FusionCare | 日常巡检                                                                   | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubecttl get pod grep algorancher</b>查看服务状态是否为Running并且状态为1/1。</li></ol>             |

| 巡检项ID  | 巡检项名称                                | 巡检方法       | FusionCare任务场景                                                         | 检查标准                                                                                                                                                                                      |
|--------|--------------------------------------|------------|------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100107 | 检查modelarts_console_backend微服务状态。    | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectl get pod grep console-backend</b>查看服务状态是否为Running并且状态为1/1。</li></ol>           |
| 100108 | 检查modelarts_image_packer微服务状态。       | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectl get pod -ninfer grep image-packer</b>查看服务状态是否为Running并且状态为1/1。</li></ol>      |
| 100113 | 检查modelarts_billing微服务状态。            | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectl get pod grep billing</b>查看服务状态是否为Running并且状态为1/1。</li></ol>                   |
| 100114 | 检查modelarts_infers_job_manager微服务状态。 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令<b>kubectl get pod -ninfer grep infer-job-manager</b>查看服务状态是否为Running并且状态为1/1。</li></ol> |



| 巡检项ID  | 巡检项名称                       | 巡检方法       | FusionCare任务场景                                                        | 检查标准                                                                                                                                                                                                    |
|--------|-----------------------------|------------|-----------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100115 | 检查modelarts_exemlflow微服务状态。 | FusionCare | <ul style="list-style-type: none"> <li>日常巡检</li> <li>升级前检查</li> </ul> | <ol style="list-style-type: none"> <li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li> <li>2. 执行命令kubectl get pod grep exemlflow查看服务状态是否为Running并且状态为1/1。</li> </ol>                                   |
| 100150 | 检查ECS服务连通性。                 | FusionCare | 日常巡检                                                                  | <ol style="list-style-type: none"> <li>1. 使用ModelArts二级VDC用户（承载租户）登录ManageOne运营面。</li> <li>2. 进入依赖服务ECS页面，查看服务是否正常。</li> </ol>                                                                          |
| 100151 | 检查VPC服务连通性。                 | FusionCare | 日常巡检                                                                  | <ol style="list-style-type: none"> <li>1. 使用ModelArts二级VDC用户（承载租户）登录ManageOne运营面。</li> <li>2. 进入依赖服务VPC页面，查看服务是否正常。</li> </ol>                                                                          |
| 100152 | 检查CCE服务连通性。                 | FusionCare | 日常巡检                                                                  | <ol style="list-style-type: none"> <li>1. 使用ModelArts二级VDC用户（承载租户）登录ManageOne运营面。</li> <li>2. 进入依赖服务CCE页面，查看服务是否正常。</li> </ol>                                                                          |
| 100153 | 检查AOM服务连通性。                 | FusionCare | 日常巡检                                                                  | <ol style="list-style-type: none"> <li>1. 使用ModelArts二级VDC用户（承载租户）登录ManageOne运营面。</li> <li>2. 进入依赖服务AOM页面，查看服务是否正常。</li> </ol>                                                                          |
| 100154 | 检查apic实例状态。                 | FusionCare | 日常巡检                                                                  | <ol style="list-style-type: none"> <li>1. 使用ModelArts二级VDC用户（承载租户）登录ManageOne运营面。</li> <li>2. 单击进入ROMA页面，查看“roma-dispatcher”实例的状态是否正常。</li> </ol> <p><b>说明</b><br/>当前局点如果未安装ROMA Connect服务，则不用检查此项。</p> |

| 巡检项ID  | 巡检项名称                            | 巡检方法       | FusionCare任务场景                                                         | 检查标准                                                                                                                                                                                             |
|--------|----------------------------------|------------|------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100162 | 检查ModelArts推理Dispatcher健康状态。     | FusionCare | 日常巡检                                                                   | <ol style="list-style-type: none"><li>1. 通过ModelArts资源承载用户登录CCE页面。</li><li>2. 查看modelarts-infer-dispatcher集群状态及其工作负载是否正常。</li></ol>                                                              |
| 100217 | 检查云服务服务树正确性。                     | FusionCare | 日常巡检                                                                   | <ol style="list-style-type: none"><li>1. 使用系统管理员账号登录ManageOne运维面，进入ModelArts云服务。</li><li>2. 查看ModelArts拓扑视图结构完整性。</li><li>3. 检查IC agent是否安装，以及状态是否有异常。</li><li>4. 检查ModelArts版本号状态是否异常</li></ol> |
| 100218 | 检查modelarts-webapp-gateway微服务状态。 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-webapp-gateway查看服务状态是否为Running并且状态为1/1。</li></ol>                |
| 100219 | 检查modelarts-os-apiserver微服务状态。   | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-os-apiserver查看服务状态是否为Running并且状态为1/1。</li></ol>                  |

| 巡检项ID  | 巡检项名称                                | 巡检方法       | FusionCare任务场景                                                         | 检查标准                                                                                                                                                                                  |
|--------|--------------------------------------|------------|------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100220 | 检查modelarts-os-job-mgr微服务状态。         | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-os-job-mgr查看服务状态是否为Running并且状态为1/1。</li></ol>         |
| 100221 | 检查modelarts-os-resource-mgr微服务状态。    | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-os-resource-mgr查看服务状态是否为Running并且状态为1/1。</li></ol>    |
| 100222 | 检查modelarts-market-manager-cdk微服务状态。 | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul> | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-market-manager-cdk查看服务状态是否为Running并且状态为1/1。</li></ol> |
| 100223 | 检查modelarts-edge-api微服务状态。           | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li></ul>                 | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-edge-api查看服务状态是否为Running并且状态为1/1。</li></ol>           |
| 100224 | 检查modelarts-edge-dm微服务状态。            | FusionCare | <ul style="list-style-type: none"><li>• 日常巡检</li></ul>                 | <ol style="list-style-type: none"><li>1. 登录到ModelArts_Common_Region-POD-Master节点。</li><li>2. 执行命令kubectl get pod grep modelarts-edge-dm查看服务状态是否为Running并且状态为1/1。</li></ol>            |

| 巡检项ID  | 巡检项名称                               | 巡检方法       | FusionCare任务场景 | 检查标准                                                                                                                            |
|--------|-------------------------------------|------------|----------------|---------------------------------------------------------------------------------------------------------------------------------|
| 100225 | 检查modelarts-authoring-service微服务状态。 | FusionCare | ● 日常巡检         | 1. 登录到ModelArts_Common_Region-POD-Master节点。<br>2. 执行命令kubectl get pod grep modelarts-authoring-service查看服务状态是否为Running并且状态为1/1。 |
| 100226 | 检查modelarts-ascend-brain微服务状态。      | FusionCare | ● 日常巡检         | 1. 登录到ModelArts_Common_Region-POD-Master节点。<br>2. 执行命令kubectl get pod grep modelarts-ascend-brain查看服务状态是否为Running并且状态为1/1。      |
| 100227 | 检查modelarts-system-gateway微服务状态。    | FusionCare | ● 日常巡检         | 1. 登录到ModelArts_Common_Region-POD-Master节点。<br>2. 执行命令kubectl get pod grep modelarts-system-gateway查看服务状态是否为Running并且状态为1/1。    |

6.3.2.2 创建巡检任务

前提条件

- 已登录ManageOne运维面。
- 已完成添加环境信息和节点。

操作步骤

1. [登录FusionCare界面](#)，进入FusionCare的“健康巡检 > 巡检任务”页面。
2. 单击“创建”，进入“创建任务”页面。
3. 根据[表6-4](#)配置任务信息。

表 6-4 健康巡检页面配置信息

| 参数   | 说明                                                                                                                                                                                                                          | 示例   |
|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| 任务名称 | 巡检任务名称。                                                                                                                                                                                                                     | 局点巡检 |
| 任务场景 | 执行巡检任务的场景： <ul style="list-style-type: none"><li>日常巡检</li><li>升级前检查</li></ul>                                                                                                                                               | 日常巡检 |
| 任务策略 | 巡检任务的执行策略。 <ul style="list-style-type: none"><li>实时任务：健康检查任务立即触发，如果此时无别的检查任务正在执行，则立即执行此任务。</li><li>定时任务：在某指定时间内，执行此任务。如选此选项，请配置“执行时间”。</li><li>周期任务：周期性的循环执行，按每周的某一天或几天定时执行健康检查。如选此选项，请配置“执行时间”，可选择“按周执行”或“按月执行”。</li></ul> | 实时任务 |

| 参数     | 说明                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 示例 |
|--------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 巡检对象   | <p>执行巡检任务的目标节点，未选择巡检对象时单击添加巡检对象进行选择。</p> <p>如果已选择巡检对象，单击“选择对象”或“删除”进行增删改。</p> <ul style="list-style-type: none"><li>网络设备：交换机、防火墙</li></ul> <p><b>说明</b></p> <p>选择巡检网络设备后，需选择网络设备巡检方式：</p> <ul style="list-style-type: none"><li>远程SSH：选择远程SSH后，需要在巡检对象列表的“操作”列执行“配置”和“配置巡检密码”：<br/>配置：配置网络设备的对象信息。<br/>配置巡检密码：配置SSH远程登录网络设备的用户名、密码和端口。</li><li>本地文件：线下收集巡检所需信息并按格式打包，以本地文件方式上传到FusionCare系统中进行巡检。<br/>本地文件巡检方式不需要在巡检对象列表的“操作”列执行“配置”和“配置巡检密码”。</li><li>云服务：<br/>管理侧：各服务的管理侧节点。<br/>租户侧管理节点：非租户实例，是各服务在ManageOne CMDb注册的承载租户实例的节点。</li></ul> <p>执行巡检任务需勾选至少一个以上的节点。</p> | -  |
| 启用邮件推送 | 使用邮件推送任务情况。                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | 启用 |

4. 单击“完成”，完成巡检任务创建。创建的巡检任务可以在巡检列表中查看。

6.3.2.3 查看巡检任务

管理员通过查看巡检任务，及时了解巡检任务的状态、执行进度等。

前提条件

- 已登录ManageOne运维面。
- 操作用户所属角色为“Administrators”角色且具有健康巡检的“操作权限”。
- 已创建巡检任务，具体操作请参见[创建巡检任务](#)。

操作步骤

步骤1 [登录FusionCare界面](#)，进入FusionCare的“健康巡检 > 巡检任务”页面。

步骤2 查看巡检任务。巡检任务详情如[表6-5](#)所示。

- 页面上方展示不同任务状态对应的数量，单击对应的状态，下方列表将筛选出对应状态的巡检任务。
- 在列表右上角，按照巡检项目名称，搜索对应的巡检任务。

表 6-5 巡检任务详情

| 参数   | 说明                                                                                                                    | 示例                  |
|------|-----------------------------------------------------------------------------------------------------------------------|---------------------|
| 名称   | 巡检任务名称。                                                                                                               | 日常巡检_EVS            |
| 开始时间 | 巡检任务开始时间。                                                                                                             | 2022/08/30 10:40:06 |
| 执行时间 | 该巡检任务的总执行时间。                                                                                                          | 57分9秒               |
| 状态   | 巡检任务状态： <ul style="list-style-type: none"><li>• 完成：巡检任务已完成。</li><li>• 执行中：巡检任务正在执行中。</li><li>• 未开始：巡检任务未开始。</li></ul> | 完成                  |
| 执行进度 | 巡检任务的执行进度。                                                                                                            | 100%                |
| 任务场景 | 巡检任务的场景： <ul style="list-style-type: none"><li>• 日常巡检</li><li>• 升级前检查</li></ul>                                       | 日常巡检                |
| 任务策略 | 巡检任务类型： <ul style="list-style-type: none"><li>• 实时任务</li><li>• 定时任务</li><li>• 周期任务</li></ul>                          | 实时任务                |

| 参数     | 说明           | 示例        |
|--------|--------------|-----------|
| 对象通过率  | 节点或云服务的通过率。  | 100%      |
| 巡检项通过率 | 巡检项的通过率。     | 100%      |
| 创建人    | 创建巡检任务的用户名称。 | systemman |

----结束

## 相关操作

- 修改巡检任务  
在“巡检任务”列表，选择巡检任务对应“操作 > 修改”，修改巡检任务。目前仅支持修改周期任务。
- 删除巡检任务  
在“巡检任务”列表，勾选巡检任务，单击页面上方的“删除”，删除巡检任务。
- 导出巡检报告
  - a. 在“巡检任务”页面，单击巡检任务对应“操作 > 导出报告”。
  - b. 选择“报告类型”为“基础巡检报告”或“综合巡检报告”。如选择“综合巡检报告”，请填写“客户名称”和“落款”两项参数。

### 说明

综合巡检报告包含FusionCompute、FusionSphere OpenStack、ManageOne和IaaSService产品，报告文件类型为word格式。

- c. 单击“确定”，导出报告。

## 6.3.2.4 查看巡检结果

该任务指导技术支持工程师和维护工程师，查看健康巡检结果和具体故障的处理建议。

## 前提条件

- 已登录ManageOne运维面。
- 操作用户所属角色为“Administrators”角色且具有健康巡检的“操作权限”。
- 本次健康巡检任务已经执行完成。

## 操作步骤

1. [登录FusionCare界面](#)，进入FusionCare的“健康巡检 > 巡检任务”页面。
2. 单击已完成的巡检任务名称链接，跳转至任务的详情页面。
3. 在任务详情页面，执行如[表6-6](#)操作。



表 6-6 任务详情页面相关操作

| 任务名称             | 相关操作                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 查看巡检任务基本信息       | 在“基本信息”区域查看当前巡检任务的名称、状态等信息。                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| 查看对象通过率和巡检项通过率   | 以饼图形式展示对象通过率和巡检项通过率，可选择“按环境查看”和“按产品查看”。                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
| 查看部件检查结果/租户侧检查结果 | <p>查看本次巡检任务中巡检项的故障详情。</p> <ol style="list-style-type: none"><li>在“部件检查结果”或“租户侧检查结果”页签中单击“巡检项故障详情”页签，在“故障对象”列中展示故障的巡检对象。</li><li>在“故障对象”列，单击具体的故障检查项，弹出该故障检查项的检查结果。</li><li>单击“检查项ID”列的链接，可查看该检查项故障的处理建议。</li></ol> <p>查看本次任务中每个对象的状态。</p> <ol style="list-style-type: none"><li>在“部件检查结果”或“租户侧检查结果”页签中单击“对象检查详情”页签，可查看每个巡检对象的状态。</li><li>单击对象操作列的“详情”，弹出“详情”窗口，可查看该对象在本次巡检任务中所巡检的检查项的结果。</li><li>单击“检查项ID”列的链接，可查看该检查项故障的处理建议。</li></ol> <p><b>说明</b></p> <ul style="list-style-type: none"><li>对象状态通过所巡检的检查项的检查结果来确定，状态包括通过和不通过。所有检查项都通过的情况下，状态为通过，如果巡检对象中包含至少一个不通过的检查项，此对象的状态就为不通过。</li><li>若master节点的少数巡检项不通过，过程信息为“Can not check microservice health. reason is : 'NoneType' object has no attribute 'get'”可单击操作列的“重试”进行重新巡检。</li><li>单击某一对象或者巡检项操作列的“重试”，可重新巡检该对象或者巡检项。</li></ul> |
| 导出巡检报告           | <ol style="list-style-type: none"><li>单击页面右上角“导出报告”。</li><li>选择“报告类型”为“基础巡检报告”或“综合巡检报告”。如选择“综合巡检报告”，请填写“客户名称”和“落款”两项参数。</li></ol> <p><b>说明</b></p> <p>综合巡检报告包含FusionCompute、FusionSphere OpenStack、ManageOne和IaaSService产品，报告文件类型为word格式。</p> <ol style="list-style-type: none"><li>单击“确定”，报告导出。</li></ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |

## 相关操作

- 重新巡检：在任务详情页面的右上角，单击“重试”可重新巡检本任务。
- 删除：在任务详情页面的右上角，单击“删除”可删除本巡检任务。

## 6.3.3 自动化验收

### 6.3.3.1 自动化验收用例

表 6-7 ModelArts 自动化验收用例

| 用例ID   | 用例名称                                    | 验收方法       | FusionCare任务场景                                                                          | 检查标准                                                                                    |
|--------|-----------------------------------------|------------|-----------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|
| 100300 | 创建VDC、项目、租户、分配外网、VPC、子网、增加安全组规则、获取系统架构。 | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | 成功创建VDC、项目、租户、分配外网、VPC子网、增加安全组规则、获取系统架构。                                                |
| 100301 | 添加ModelArts授权。                          | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | 成功创建委托modelarts_agency、添加ModelArts授权。                                                   |
| 100302 | 创建网络和资源池。                               | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | <ul style="list-style-type: none"><li>● 成功创建网络。</li><li>● 成功创建资源池。</li></ul>            |
| 100303 | 查询专属资源池列表。                              | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | 成功查询专属资源池列表。                                                                            |
| 100304 | 查询模型列表（未安装推理请勿选择）。                      | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | <ul style="list-style-type: none"><li>● 成功查询AI应用列表。</li><li>● 该用例仅在安装推理环境时选择。</li></ul> |
| 100305 | 查询服务列表（未安装推理请勿选择）。                      | FusionCare | <ul style="list-style-type: none"><li>● 部署后验收</li><li>● 升级后验收</li><li>● 扩容后验收</li></ul> | <ul style="list-style-type: none"><li>● 成功查询在线服务列表。</li><li>● 该用例仅在安装推理环境时选择。</li></ul> |

| 用例ID   | 用例名称                        | 验收方法       | FusionCare任务场景                                                                    | 检查标准                                                                                       |
|--------|-----------------------------|------------|-----------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| 100306 | 查询训练作业列表（未安装训练请勿选择）。        | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | <ul style="list-style-type: none"><li>成功查询训练作业列表。</li><li>该用例仅在安装训练环境时选择。</li></ul>        |
| 100307 | 查询AI Hub算法列表（未安装训练高级版请勿选择）。 | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | <ul style="list-style-type: none"><li>成功查询AI Hub算法列表。</li><li>该用例仅在安装训练高级版环境时选择。</li></ul> |
| 100308 | 查询Workflow列表（未安装训练高级版请勿选择）。 | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | <ul style="list-style-type: none"><li>成功查询Workflow列表。</li><li>该用例仅在安装训练高级版环境时选择。</li></ul> |
| 100309 | 查询服务列表（未安装新版推理请勿选择）         | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | <ul style="list-style-type: none"><li>成功查询新版推理服务列表。</li><li>该用例仅在安装新版推理时选择。</li></ul>      |
| 100398 | 删除资源池。                      | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | <ul style="list-style-type: none"><li>成功删除资源池。</li><li>成功删除网络。</li></ul>                   |
| 100399 | 删除子网、VPC、租户、资源空间、VDC。       | FusionCare | <ul style="list-style-type: none"><li>部署后验收</li><li>升级后验收</li><li>扩容后验收</li></ul> | 成功删除子网、VPC、租户、资源空间、VDC。                                                                    |

### 6.3.3.2 新建自动化验收任务

**步骤1** 在FusionCare主菜单中选择“自动化验收”，在左侧导航栏中选择“验收任务”。

**步骤2** 在“验收任务”页面，单击左上角的“创建”，进入新建验收任务页面。

**步骤3** 在“基本信息”中填写如下信息：

- “任务名称”：只能包含汉字、英文字母、数字和下划线，长度为1~16个字符且不能为“null”。
- “任务场景”：按照实际需求选择相应的场景。
- “客户云”：选择对应的客户云。
- “启用截图”：不勾选。

**步骤4** 在“对象用例选择”中选择如下信息：

- “选择对象”：勾选ModelArts。
- “选择用例”：根据实际环境选择巡检用例，默认勾选全部巡检用例。

**步骤5** 参数配置。

1. 全部云服务设置。

- 通过界面进行参数配置

- 单击“全部云服务”下拉菜单。
- 在“参数列表”中根据集群实际信息填写“参数值”。
- 勾选“全部云服务”，并单击“校验”。
- 在“参数列表”的“校验结果”列查看各个参数校验结果是否全部通过。

- （可选）通过模板进行参数配置。

- 单击“导出模板”，等待模板下载至本地，根据集群实际信息填写“参数值”，填写完成后保存至本地。
- 单击“导入参数”，选择保存至本地的模板，单击“上传”。
- 勾选“全部云服务”，并单击“校验”。
- 在“参数列表”的“校验结果”列查看各个参数校验结果是否全部通过。

2. ModelArts服务参数设置。

- 通过界面进行参数配置。

- 单击“ModelArts”下拉菜单。
- 在“参数列表”中根据集群实际信息填写“参数值”。
- 勾选“ModelArts”，并单击“校验”。
- 在“参数列表”的“校验结果”列查看各个参数校验结果是否全部通过。

- （可选）通过模板进行参数配置。

- 单击“导出模板”，等待模板下载至本地，根据集群实际信息填写“参数值”，填写完成后保存至本地。
- 单击“导入参数”，选择保存至本地的模板，单击“上传”。
- 勾选“ModelArts”，并单击“校验”。

- 在“参数列表”的“校验结果”列查看各个参数校验结果是否全部通过。

 说明

如有未通过的参数，请检查参数值是否填写错误，重新填写参数值，并重新校验直至通过。

**步骤6** 单击“立即创建”。

----结束

6.3.3.3 查看自动化验收任务执行状态

- 在FusionCare主菜单中选择“自动化验收”。
- 在左侧导航栏中选择“验收任务”。
- 在“验收任务”页面可查看新建的验收任务，并查看该任务状态。

表 6-8 参数说明

| 参数        | 说明                             |
|-----------|--------------------------------|
| 任务名称      | 创建任务的名称。                       |
| 任务状态      | 任务状态，包含执行中、完成、挂起、失败和未开始。       |
| 开始时间      | 任务开始时间。                        |
| 执行时间      | 任务执行时间。                        |
| 执行进度      | 任务执行进度。                        |
| 任务场景      | 当前创建的自动化验收任务场景。                |
| 不通过用例/总用例 | 不通过的用例数和任务执行的总用例数。             |
| 创建人       | 创建任务的用户。                       |
| 操作        | 重试：重新执行验收任务。<br>导出报告：导出用例执行报告。 |

6.3.3.4 查看验收任务详情

- 在FusionCare主菜单中选择“自动化验收”。
- 在左侧导航栏中选择“验收任务”。
- 在“验收任务”页面，单击验收任务名称，进入验收任务详情页面。
  - 基本信息：**包含该任务的任务名称、状态、开始时间等，可导出验收报告、重新执行验收任务和删除验收任务。
  - 验收结果：**
    - 云服务：可查看云服务的通过状态。

- 用例结果统计：可查看云验收用例通过状态。
- 查看验收任务结果：  
单击“操作”列的“用例详情”，进入用例详情页面，可查看各个验收用例详情，包含验收目的、预置条件、验收过程、验收结果、备注等。  
单击验收结果未通过任务的左侧下拉按钮，可查看未通过用例的用例ID、用例名称、验收结果等。
- 验收详情：  
包含验收前用例、验收用例和验收后用例的状态。

| 参数    | 说明                                                                                                                                                                                                                     |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 用例ID  | 单击用例ID，可跳转到该用例的巡检项联机帮助页面。                                                                                                                                                                                              |
| 用例名称  | 验收用例的名称。                                                                                                                                                                                                               |
| 所属云服务 | 验收用例所属的云服务。                                                                                                                                                                                                            |
| 验收结果  | 验收用例的结果。                                                                                                                                                                                                               |
| 操作    | 查看验收用例的过程信息、用例详情、用例日志等。 <ul style="list-style-type: none"><li>• 单击“详情”，页面显示验收目的、预置条件、验收过程、验收结果等信息。</li><li>• 单击“查看日志”，页面显示当前用例ID，展开后显示“log”，单击“log”后，在日志中有trace_id等日志信息。</li><li>• 单击“下载日志”，将下载“用例ID.zip”文件。</li></ul> |

6.3.3.5 导出并查看任务报告

1. 在FusionCare主菜单中选择“自动化验收”。
2. 在左侧导航栏中选择“验收任务”。
3. 单击需要导出验收报告的任务名称“操作 > 导出报告”。
4. 等待下载完成，在本地解压后，打开报告，即可查看各个巡检用例的执行结果。

# 7 备份与恢复

## 7.1 概述

### 7.1.1 场景说明

ModelArts通过对DB的数据进行备份，保证在原数据被破坏或损坏的情况下可以恢复业务。

#### 备份场景

为了避免操作失误或者重大灾难（例如突然断电）时，数据丢失，系统会自动备份重要的配置文件和关键业务数据。

ModelArts备份的关键数据库数据如表7-1所示。

表 7-1 备份的数据库数据

| 云服务       | 备份数据类型 | 描述                          | 归属模块 | 数据库    |
|-----------|--------|-----------------------------|------|--------|
| ModelArts | 管理面DB  | ModelArts-dev-GaussDB       | 公共   | DBM数据库 |
| ModelArts | 管理面DB  | S-ModelArts-infer-GaussDB   | 推理   | DBM数据库 |
| ModelArts | 管理面DB  | ModelArts-iva-GaussDB       | 推理   | DBM数据库 |
| ModelArts | 管理面DB  | S-ModelArts-billing-GaussDB | 公共   | DBM数据库 |
| ModelArts | 管理面DB  | S-ModelArts-job-MySQL       | 训练   | DBM数据库 |
| ModelArts | 管理面DB  | S-ModelArts-workflow-MySQL  | 工作流  | DBM数据库 |

| 云服务       | 备份数据类型   | 描述                                | 归属模块                | 数据库      |
|-----------|----------|-----------------------------------|---------------------|----------|
| ModelArts | 管理面DB    | ModelArts-market-manager-Gaussdb  | AI Hub              | DBM数据库   |
| ModelArts | 管理面DB    | S-ModelArts-authoring-MySQL       | ModelArts_Developer | DBM数据库   |
| ModelArts | 管理面DB    | S-ModelArts-AscendBrain-MySQL     | 昇腾云脑                | DBM数据库   |
| ModelArts | 管理面DB    | S-ModelArts-infer-GaussDB         | Edge                | DBM数据库   |
| ModelArts | 管理面DB    | S-ModelArts-infer-manager-MySQL   | 新版推理                | DBM数据库   |
| ModelArts | 管理面Redis | cmw-redis-modelarts-infer-manager | 新版推理                | Redis中间件 |

## 恢复场景

维护工程师遇到操作失误导致数据损坏或丢失时，需要对关键数据进行恢复操作。

在对系统部件进行重大操作（如升级、重大数据调整等）后，系统有可能出现异常或未达到预期结果。此时，需要对其进行回退，回退过程中需要进行数据恢复操作。

### 7.1.2 备份与恢复策略

ModelArts管理面的数据支持通过ManageOne运维面统一备份到第三方SFTP服务器，如有需要再将ManageOne统一备份的文件进行恢复。

#### 说明

- 恢复数据库时需注意：
1. 与用户设置的恢复时间点强相关。
  2. 选择在恢复时间点前备份的文件进行恢复。
  3. 当恢复时间点之前有多份备份文件，则选择在当前恢复时间点前最近的备份文件进行恢复。



表 7-2 ModelArts DBM 数据库的备份与恢复策略说明

| DBM数据库                                                                                                                                           | 备份策略                                                                                                                                                                              | 恢复策略                                |
|--------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| S-ModelArts-infer-GaussDB<br>S-ModelArts-billing-GaussDB<br>S-ModelArts-dev-GaussDB<br>ModelArts-iva-GaussDB<br>ModelArts-market-manager-Gaussdb | <b>ManageOne统一备份数据库</b><br><br>系统支持定期自动全量备份到第三方SFTP服务器。<br><br>若使用第三方SFTP备份服务器，默认保留最近30天的数据。若需修改保留天数，到COP->CloudBCM->配置中心->配置管理->业务配置，修改BACKUP_DATA_AGING_PERIOD_CONFIG配置项的配置值即可。 | <b>恢复GaussDB</b>                    |
| S-ModelArts-job-MySQL                                                                                                                            |                                                                                                                                                                                   | <b>恢复MySQL</b>                      |
| S-ModelArts-workflow-MySQL                                                                                                                       |                                                                                                                                                                                   |                                     |
| S-ModelArts-authoring-MySQL-POD-MySQL                                                                                                            |                                                                                                                                                                                   |                                     |
| S-ModelArts-AscendBrain-MySQL                                                                                                                    |                                                                                                                                                                                   |                                     |
| S-ModelArts-infer-manager-MySQL                                                                                                                  |                                                                                                                                                                                   |                                     |
| cmw-redis-modelarts-infer-manager                                                                                                                | 当前Redis实例设置了3个RDB文件备份检测的定时任务：<br><br>1. 每1小时执行一次检查，如果有1次key修改就进行备份。<br><br>2. 每5分钟执行一次检查，如果有100次key修改就进行备份。<br><br>3. 每1分钟执行一次检查，如果有10000次key修改就进行备份。                             | 当Redis发生重启或下电后恢复时，将自动从RDB文件中恢复备份数据。 |

7.2 备份数据

### 7.2.1 ManageOne 统一备份数据库

ModelArts管理面的数据支持通过ManageOne运维面对接第三方SFTP服务器进行统一备份，相关介绍请参见《[华为云Stack 8.6.0 产品文档](#)》的“备份恢复”下的“备份管理”章节。

ManageOne运维面支持统一备份的ModelArts数据库如表7-3所示。

表 7-3 统一备份的数据库

| 服务               | ManageOne显示的CloudDB名称            | 说明                                       |
|------------------|----------------------------------|------------------------------------------|
| ModelArts推理服务    | S-ModelArts-infer-GaussDB        | 推理组件Infer的数据库（Edge共用）                    |
|                  | ModelArts-lva-POD-GaussDB        | 推理组件Infer的数据库                            |
| ModelArts训练管理    | S-ModelArts-job-MySQL            | ModelArts训练管理数据库                         |
| ModelArts工作流     | S-ModelArts-workflow-MySQL       | ModelArts Workflow管理数据库                  |
| ModelArts AI Hub | ModelArts-market-manager-Gaussdb | AI Hub的数据库                               |
| ModelArts_Dev    | S-ModelArts-authoring-MySQL      | authoring的数据库                            |
| 昇腾云脑             | S-ModelArts-AscendBrain-MySQL    | 昇腾云脑的数据库                                 |
| ModelArts新版推理    | S-ModelArts-infer-manager-MySQL  | 新版推理组件的数据库                               |
| ModelArts公共组件    | S-ModelArts-billing-GaussDB      | 公共组件Billing的数据库                          |
|                  | S-ModelArts-dev-GaussDB          | 公共组件ModelArts-ConsoleBackend-GaussDB的数据库 |

 说明

如果增加备份失败，请参见《[华为云Stack 8.6.0 产品文档](#)》的“维护指南 > 运维指南 > 常见问题 > 云管平台 > FAQs > 用ManageOne统一备份CloudDB时显示失败”进行处理。

## 7.3 恢复数据

### 7.3.1 恢复 ManageOne 统一备份的数据库

### 7.3.1.1 恢复 GaussDB

#### 前提条件

- 具备一台可以与节点正常通信的本地PC。
- 已获取SFTP备份服务器的IP地址、账号和密码。
- 已获取数据库主备双节点的账户和密码。

数据库节点的opsadmin和root账户的默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签搜索相关节点名称获取。

表 7-4 数据库对应的节点名称

| 数据库名称                            | 节点名称                             |
|----------------------------------|----------------------------------|
| S-ModelArts-dev-GaussDB          | ModelArts-ConsoleBackend-GaussDB |
| S-ModelArts-infer-GaussDB        | ModelArts-Infer-GaussDB          |
| S-ModelArts-billing-GaussDB      | ModelArts-Billing-GaussDB        |
| ModelArts-iva-GaussDB            | ModelArts-Iva-POD-GaussDB        |
| ModelArts-market-manager-Gaussdb | ModelArts-market-manager-Gaussdb |

- 已准备跨平台远程访问工具，如“PuTTY”。
- 已准备网络传输工具，如“WinSCP”。
- 数据恢复前，建议确保已无正在执行的系统操作。包括资源集群的创建、扩容、缩容，业务发放，配置系统管理子网，服务器上下电、重启等。
- 数据恢复时请勿执行系统操作。

#### 操作步骤

以数据库ModelArts-infer-GaussDB为例介绍恢复由ManageOne统一备份的数据库的操作步骤，实际操作过程中需要按如下步骤依次恢复上述GaussDB：

**步骤1** 参考[判断GaussDB的主备节点](#)，获取数据库ModelArts-infer-GaussDB主节点IP地址，数据库节点名称请参见[前提条件](#)。

**步骤2** 获取ManageOne统一备份的备份文件并上传至ModelArts-infer-GaussDB主节点。

1. 使用WinSCP登录SFTP备份服务器，下载备份的文件，备份路径为：  
{备份目录}/{regionId}--backupday-om-clouddb/CloudDB/{数据库名称}/full。
2. 使用WinSCP将下载的备份文件传到主节点上，建议传到目录/opt/backup下。

#### 说明

备份文件可以根据备份任务中配置的SFTP服务器备份路径和用户名密码信息，直接使用WinSCP工具登录SFTP备份服务器后下载到本地，然后手动上传至ModelArts-infer-GaussDB节点，为方便后续操作，建议主、备ModelArts-infer-GaussDB节点都上传。

**步骤3** 登录数据库主节点和备节点，切换root用户，分别执行以下命令加载环境变量。

```
source /etc/profile
```

**步骤4** 分别在数据库主备节点，停止主备数据库的HA服务。先停备节点，再停主节点。

```
escape_ha
```

**步骤5** 在数据库主节点，以root用户执行以下命令，进行备份数据的恢复。

```
python /opt/gaussdb/dbmha/backup_restore/CloudDB_restore.py -f /opt/backup/DB/
gaussdb_900_xxxx_full_XXXXXXX.tar.gz
```

当出现提示“Restore success.”，表示数据库临时实例恢复成功。

**步骤6** 执行以下命令，查看gauss服务进程，获取gauss\_dir即如下样例中加粗部分内容。

```
ps -ef | grep gauss | grep -v grep
```

样例：`/opt/gaussdb/dbprogram/bin/gaussdb -D /opt/gaussdb/  
restoregaussdb_7777`

**步骤7** 恢复出临时实例之后，服务可以连接临时实例，按需融合新老数据，然后关闭**步骤5**恢复的临时数据库实例。原数据库和端口保持不变。关闭恢复的数据库临时实例命令如下。

```
su - dbadmin
gs_ctl stop -D {gauss_dir}
```

{gauss\_dir}为**步骤6**查询所得，例如：`/opt/gaussdb/restoregaussdb_777`

例如：`gs_ctl stop -D /opt/gaussdb/restoregaussdb_7777`


**步骤8** 数据恢复完成之后，先后在数据库主节点、备节点以root用户执行以下命令，启动HA服务。

```
attach_ha
```

**步骤9** 在数据库主节点，以dbadmin命令执行以下命令，查看数据库恢复后的状态。

```
dbstatus
```

图 7-1 检查数据库的状态



| node_ip         | ha_status | db_status | SDK_Master      | db_role | rep_state | sync | delay | heartbeat_time      | check_time          |
|-----------------|-----------|-----------|-----------------|---------|-----------|------|-------|---------------------|---------------------|
| 192.168.160.199 | online    | online    | 192.168.160.199 | Primary | Normal    | 99%  | 7280  | 2022-03-09 20:26:51 | 2022-03-09 20:26:52 |
| 192.168.162.208 | online    | online    | 192.168.160.199 | Standby | Normal    | 99%  | 7280  | 2022-03-09 20:26:51 | 2022-03-09 20:26:48 |
| 192.168.165.238 | online    | online    | 192.168.160.199 | Standby | Normal    | 99%  | 7280  | 2022-03-09 20:26:51 | 2022-03-09 20:26:49 |

----结束

### 7.3.1.2 恢复 MySQL

#### 前提条件

- 具备一台可以与节点正常通信的本地PC。
- 已获取SFTP备份服务器的IP地址、账号和密码。
- 已获取数据库主备双节点的账户和密码。

数据库节点的opsadmin和root账户的默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签搜索相关节点名称获取。

数据库的dbadmin账户的默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签搜索相关节点名称获取。

表 7-5 数据库对应的节点名称

| 数据库名称                 | 节点名称                        |
|-----------------------|-----------------------------|
| modelarts-algorancher | S-ModelArts-job-MySQL       |
| modelarts_workflow    | S-ModelArts-workflow-MySQL  |
| authoring             | S-ModelArts-authoring-MySQL |
| sreascenddb           | S-ModelArts-brain-MySQL     |
| infers_manager        | ModelArts-Infers-MySQL      |

- 已准备跨平台远程访问工具，如“PuTTY”。
- 已准备网络传输工具，如“WinSCP”。
- 数据恢复前，建议确保已无正在执行的系统操作。包括资源集群的创建、扩容、缩容，业务发放，配置系统管理子网，服务器上下电、重启等。
- 数据恢复时请勿执行系统操作。

## 操作步骤

以数据库**modelarts-algorancher**为例介绍恢复由ManageOne统一备份的数据库的操作步骤，实际操作过程中需要按如下步骤依次恢复上述表1中对应的mysql数据库：

**步骤1** 获取S-ModelArts-job-MySQL节点IP地址。

1. 以管理员账号[登录ModelArts-Common-Proxy节点](#)。
2. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
3. 在名称右侧输入框中，搜索数据库节点名称并获取节点的内网IP地址，数据库节点名称请参见表7-5。

### 说明

内网网段参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx\_export\_all\_v2\_CN.xlsx》，搜索“external\_relay\_network”获取对应的网段值。


**步骤2** 获取ManageOne统一备份的备份文件并上传至S-ModelArts-job-MySQL主节点。

1. 主备节点判断

以opsadmin用户登录数据库节点，并切换为root用户，执行以下命令：

```
mysql -udbadmin -p{密码} -P7306 -S/data/mysql/tmp/mysql.sock -e 'show variables like "read_only"'
```

图 7-2 返回结果示例



```
mysql: [warning] Using a password on the command line is insecure.
+-----+-----+
| Variable_name | Value |
+-----+-----+
| read_only | ON |
+-----+-----+
```

回显中通过read\_only的value值来判断主备节点：

- ON: 表示该节点为备节点
  - OFF: 表示该节点为主节点。
2. 下载备份文件并上传到数据库主节点

使用WinSCP登录SFTP备份服务器，下载备份的文件，备份路径为：

{备份目录}/{regionId}--backupday-om-clouddb/CloudDB/S-ModelArts-job-MySQL/full。

使用WinSCP将下载的备份文件传到主节点上，建议传到主节点 **/home/backup** 目录下。

#### 说明

**备份目录**为配置的SFTP备份服务器的备份目录。

备份文件可以根据备份任务中配置的SFTP服务器备份路径和用户名密码信息，直接使用WinSCP工具登录SFTP备份服务器后下载到本地，然后手动上传至S-ModelArts-job-MySQL节点。为方便后续操作，建议主、备S-ModelArts-job-MySQL节点都上传。

### 步骤3 使用备份的文件恢复数据。主备节点判断参考[步骤2.1](#)。

1. 以opsadmin用户登录S-ModelArts-job-MySQL主节点，然后执行**su - root**命令切换到root用户，执行以下命令，使用备份文件创建临时数据库。  

```
python /data/dbmha/backup_restore/CloudDB_restore.py -p 3306 -f /home/backup/backup_file.tar.gz
```
2. 临时数据库创建成功后，执行以下命令导出sql数据文件。以**modelarts\_algorancher**数据库为例，将**modelarts\_algorancher**数据库的结构和数据，包括存储过程、触发器等导出保存到**modelarts\_algorancher\_0302.sql**文件中。（恢复其他数据库需要将“**modelarts\_algorancher**”改为目标数据库名称，保存文件名建议“数据库名+日期.sql”格式）  

```
/data/mysql/base/bin/mysqldump --defaults-file={临时库配置} -udbadmin -p{密码} -P3306 --hex-blob --opt --routines --triggers --single-transaction --set-gtid-purged=OFF --master-data=2 --databases modelarts_algorancher > /backup/modelarts_algorancher_0302.sql
```

#### 说明

临时库配置为[步骤3.1](#)执行完恢复数据库的临时库配置文件地址，如上一个步骤图中的：

/data/mysql/cn-global-2\_S-ModelArts-job-MySQL\_2022-03-07-08-38-59+0800\_3306/my.cnf

3. 在S-ModelArts-job-MySQL主节点上，使用**modelarts\_algorancher\_0302.sql**文件恢复数据。  

```
mysql --defaults-file=/data/mysql/etc/my.cnf -uroot -P7306 -p{密码} -e 'source /backup/modelarts_algorancher_0302.sql';
```
4. 终止临时数据库进程。  

```
kill $(lsof -i:3306 -t)
```

----结束

# 8 安全管理

## 8.1 账户管理

### 8.1.1 账户一览表

ModelArts服务的系统内各管理节点、数据库及集群节点的默认账户信息，请参考《[华为云Stack 8.6.0 账户一览表](#)》。

- 日常运维账户、特权账户，如系统管理员账户admin/root，请参见“A类（后台）”页签。
- 系统内部账号、其他账号，供系统内部使用或机机对接使用，请参见“B类（EI企业智能）”页签。

#### 说明

账户一览表的“ModelArts推理资源池节点”中，后续将不展示业务容器的默认账户信息。因为资源池的业务容器中，一般都是有基础镜像或者自定义镜像的，用户账户具有不确定性。

### 8.1.2 账户安全设置

ModelArts的账户安全设置请参见华为云Stack的相关安全策略及设置，可访问《[华为云Stack 8.6.0 产品文档](#)》的“维护指南 > 运维指南 > 安全管理”章节获取。

### 8.1.3 修改账户密码

#### 8.1.3.1 修改操作系统账户密码

##### 操作场景

建议管理员定期修改管理面虚拟机的操作系统账户的登录密码，以提升系统运维安全性。

##### 操作步骤

ModelArts管理面虚拟机的密码修改，可参考《[华为云Stack 8.6.0 产品文档](#)》的“修改账户密码”章节处理。

### 8.1.3.2 修改租户面账户密码

#### 操作场景

建议定期修改ModelArts承载租户等租户面的登录密码，以提升账户安全性。

#### 前提条件

管理员修改密码时需要使用具备一定复杂度的密码，建议执行该操作前，规划好系统应用账号的新密码。

- 密码必须包含如下至少3种不同类型字符的组合：
  - 至少一个小写字母
  - 至少一个大写字母
  - 至少一个数字
  - 至少一个特殊字符：`~!@#\$\$%^&\*()-\_+=[]{}|;:\",./?
- 密码不能和账号或者账号的倒写一样。
- 密码必须包含特殊字符。

#### 操作步骤

管理员可直接在管理控制台修改账户密码。

**步骤1** 登录ManageOne租户面，鼠标移动至账户处，在下拉列表选择“个人设置”。

**步骤2** 在“个人设置”页面，选择“安全设置 > 修改”，进入“修改密码”页面。

**步骤3** 按照界面提示逐步修改密码。单击“确定”，完成密码修改。

----结束

### 8.1.3.3 修改管理面 modelarts-common-proxy 组件的 proxy\_admin 密码

#### 操作场景

建议管理员定期修改管理面modelarts-common-proxy的组件的密码凭据，以提升系统运维安全性。

#### 前提条件

管理员修改modelarts-common-proxy密码时需要使用具备一定复杂度的密码，建议执行该操作前，规划好系统应用账号的新密码。

- 密码必须包含如下至少3种不同类型字符的组合：
  - 至少一个小写字母
  - 至少一个大写字母
  - 至少一个数字
  - 至少一个特殊字符：`~!@#\$\$%^&\*()-\_+=[]{}|;:\",./?
- 密码不能和账号或者账号的倒写一样。
- 密码必须包含特殊字符。



## 操作步骤

1. 使用Putty工具，登录CDK master节点，具体可参见[登录CDK master节点](#)。
2. 获取modelarts-common-proxy服务对应账号的新加密的密码凭据，设置目标明文为new\_proxy\_password，加密后的密文后面使用“proxy\_password\_scc”来代替。

- a. 执行如下命令查询modelarts-os-apiserver pod。

```
kubectrl get po | grep modelarts-os
```

回显如下，第一列为pod名称。

```
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectrl get po | grep modelarts-os
modelarts-os-apiserver-69954d6976-bmzb7 1/1 Running 0 2d20h
modelarts-os-apiserver-69954d6976-rh9tv 1/1 Running 0 2d20h
modelarts-os-job-mgr-78464cbd7f-9nxhz 1/1 Running 0 2d20h
modelarts-os-job-mgr-78464cbd7f-k9gtf 1/1 Running 0 2d20h
modelarts-os-resource-mgr-76675c46b8-d4544 1/1 Running 0 2d20h
modelarts-os-resource-mgr-76675c46b8-g2rx9 1/1 Running 0 2d20h
```

- b. 执行如下命令登录modelarts-os-apiserver pod。

```
kubectrl exec -ti modelarts-os-apiserver-69954d6976-bmzb7 bash
```

其中modelarts-os-apiserver-69954d6976-bmzb7需替换为实际环境的modelarts-os-apiserver pod名称。回显如下：

```
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectrl exec -ti modelarts-os-apiserver-69954d6976-bmzb7 bash
[service@modelarts-os-apiserver-69954d6976-bmzb7 modelarts-os-apiserver /]$
```

- c. 执行如下命令获取加密后的modelarts-common-proxy服务的密码凭据值。

```
/usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
```

粘贴{proxy\_password}，以获取加密后的SK值，后面使用“container\_sk\_scc”来代替。回显如下：

```
[service@modelarts-os-apiserver-69954d6976-bmzb7 modelarts-os-apiserver /]$ /usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
Please input plain text:{new_proxy_password}
{proxy_password_scc}
```

3. 执行命令获取训练modelarts-algorancher cdk组件配置项cce\_transparent\_proxy所需加密后的modelarts-common-proxy的加密数据。

```
/usr/local/seccomponent/bin/CryptoAPI -d -f /opt/cloud/algorancher/scc.conf
```

设置当前密文值为{cce\_transparent\_proxy\_current}，通过解密获取到的明文值为{cce\_transparent\_proxy\_current\_plain}

```
[service@modelarts-algorancher-5b95dbbc85-dj25n /]$ /usr/local/seccomponent/bin/CryptoAPI -d -f /opt/cloud/algorancher/scc.conf
Please input plain text:{cce_transparent_proxy_current_scc}
{cce_transparent_proxy_current_plain}
```

### 说明

cce\_transparent\_proxy\_current\_plain格式为：http://{user\_name}:{old\_proxy\_password}@{regionLb}:30101


则cce\_transparent\_proxy配置项的目标明文值需替换为：http://{user\_name}:{new\_proxy\_password}@{regionLb}:30101

执行命令，获取训练所需新cce\_transparent\_proxy的值。


回显如下：

```
[service@modelarts-os-apiserver-69954d6976-bmzb7 modelarts-os-apiserver /]$ /usr/local/seccomponent/bin/CryptoAPI -d -f /opt/cloud/algorancher/scc.conf
Please input plain text:http://{user_name}:{new_proxy_password}@{regionLb}:30101
{cce_transparent_proxy_current_dest}
```


4. 使用CloudAutoChange同版本升级，更新modelarts-common-proxy的配置，从而更新密码。请登录CloudScope，选择运维服务 > CloudAutoChange > 云服务变更 > 服务升级，选择region，勾选modelarts-common-proxy组件的schema，执行下一步。



将目标版本与当前版本设置为相同版本。



在配置项渲染右侧，重新填写proxy\_password的值proxy\_password\_scc，单击执行，等待同版本升级完成。



5. 使用系统管理员登录CloudCDK修改cdk微服务参数，具体修改的配置见[表8-1](#)，以modelarts-os-apiserver为例：
  - a. **以管理员账号登录CloudCDK界面。**
  - b. 选择“变更管理 > 服务升级 > ai-pod(静态纳管)”，容灾局点还需要额外升级ai-pod-dr集群。选中右侧列表中的modelarts-os-apiserver，单击“下一步”。在“升级配置”中更新modelarts\_os\_proxy\_password，CPU\_LIMITS的参数值。

应用名称modular-oc-apserver-v85\_64-0x3c2f18d870b1732ef3ee3e2c3b9Regioncn-sh-1

位置参数

| 参数名称                      | 参数类型   | 数据类型   | 值                                                        | 描述信息                                                      |
|---------------------------|--------|--------|----------------------------------------------------------|-----------------------------------------------------------|
| CPU_LIMITS                | deploy | string | 5                                                        | 0                                                         |
| modular_oc_proxy_password | deploy | string | AAAAAAAAAAAAAAAAAAAAAGAAAAGgZhgJ43nBMRtYVMRfBuRXUzCmgqD3 | AAAAAAAAAAAAAAAAAAAAAEHjZghgJ43nBMRtYVMRfBuRXUzCmgqD3DeCa |

创建时间更新时间戳(毫秒)

表 8-1 参数配置

| cdk微服务组件                        | 修改参数                                 | 值                                    |
|---------------------------------|--------------------------------------|--------------------------------------|
| modelarts-os-apiserver          | modelarts_os_proxy_password          | {proxy_password_scc}                 |
|                                 | CPU_LIMITS                           | 当前值+1，例如：当前值为4，则可设置目标值为5             |
| modelarts-os-job-mgr            | pandora_proxy_password               | {proxy_password_scc}                 |
|                                 | CPU_LIMITS                           | 当前值+1，例如：当前值为4，则可设置目标值为5             |
| modelarts-os-resource-mgr       | pandora_proxy_password               | {proxy_password_scc}                 |
|                                 | CPU_LIMITS                           | 当前值+1，例如：当前值为4，则可设置目标值为5             |
| modelarts-algorancher           | cce_transparent_proxy                | {cce_transparent_proxy_current_dest} |
|                                 | RESOURCES_LIMITS_CPU                 | 当前值+1，例如：当前值为4，则可设置目标值为5             |
| modelArts-infer-service-manager | cce_internal_endpoint_proxy_password | {proxy_password_scc}                 |
| modelarts-image-packer          | imagepacker_rse_proxy_pwd            | {proxy_password_scc}                 |

8.1.3.4 修改管理面数据库密码

gaussdb数据库实例用户密码修改参考：

```
ALTER USER myuser IDENTIFIED BY 'mypassword';
```

mysql数据库实例用户密码修改参考：

```
ALTER USER myuser IDENTIFIED BY 'mypassword';
```

📖 说明

修改密码后，微服务会出现断服，请及时修复微服务的数据库密码密文配置。

在modelarts-os-apiserver中执行如下加密命令：

```
/usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
```

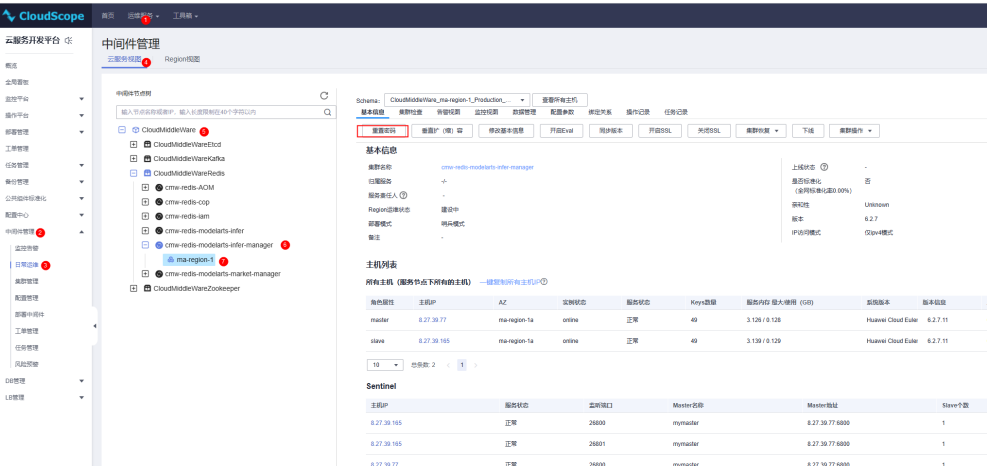
| 微服务                              |                                  | 配置项                           |
|----------------------------------|----------------------------------|-------------------------------|
| ModelArts-Infer-GaussDB          | modelarts-infers-service-manager | db_pg_password                |
|                                  |                                  | db_wl_password                |
|                                  | modelarts-infers-job-manager     | db_pg_password                |
|                                  |                                  | spring_datasource_password    |
|                                  | modelarts-infers-model-manager   | db_pg_password                |
|                                  | modelarts-infers-monitor         | spring_datasource_password    |
|                                  | modelarts-infers-stats           | spring_datasource_password    |
|                                  |                                  |                               |
| ModelArts-Iva-POD-GaussDB        | modelarts-infer-task(cce 微服务)    | jdbc.password                 |
| ModelArts-Billing-GaussDB        | modelarts-os-apiserver           | maos_db_encrypted_password    |
|                                  | modelarts-os-job-mgr             | maos_db_encrypted_password    |
|                                  | modelarts-os-resource-mgr        | billing_db_encrypted_password |
|                                  |                                  | maos_db_encrypted_password    |
|                                  | modelarts-billing                | gaussdb_password              |
|                                  | modelArts-infer-service-manager  | db_bill_password              |
|                                  | modelarts-exemlflow              | billingDB_encrypted_password  |
|                                  | modelarts-algorancher            | billingDB_encrypted_password  |
| ModelArts-ConsoleBackend-GaussDB | modelarts-console-backend-cdk    | SPRING_DATASOURCE_PASSWORD    |
| ModelArts-market-manager-Gaussdb | modelarts-market-manager-cdk     | SPRING_DATASOURCE_PASSWORD    |
| S-ModelArts-workflow-MySQL       | modelarts-exemlflow-cdk          | database_encrypted_password   |
| S-ModelArts-job-MySQL            | modelarts-algorancher            | database_encrypted_password   |

| 微服务                                   |                             | 配置项                        |
|---------------------------------------|-----------------------------|----------------------------|
| S-ModelArts-authoring-MySQL-POD-MySQL | modelarts-authoring-service | SPRING_DATASOURCE_PASSWORD |
| S-ModelArts-AscendBrain-MySQL         | modelarts-ascend-brain      | db_pwd                     |
|                                       | modelarts-system-gateway    | cm_db_pass                 |
| ModelArts-Infers-MySQL                | modelArts-infers-manager    | SPRING_DATASOURCE_PASSWORD |

8.1.3.5 修改 Redis 数据库实例用户密码

- 使用浏览器以系统管理员登录CloudScope界面。
  - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
  - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
  - 默认账号：op\_cdk\_sso
  - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
- 上方导航栏选择“运维服务 > 变更管理 > CloudBCM”，进入云服务开发平台页面。
- 单击中间件管理 > 日常运维，在云服务视图页签单击CloudMiddleWare > CloudMiddleWareRedis > cmw-redis-modelarts-infer-manager > {region\_id}。

图 8-1 重置密码



- 在“基本信息”页签下，点击重置密码，输入原密码和新密码。

 说明

修改密码后，微服务会出现断服，请及时修复微服务的数据库密码密文配置。

旧密码可参考下面的配置项获取：

在modelarts-os-apiserver中执行如下解密命令：

```
/usr/local/seccomponent/bin/CryptoAPI -i 317 -d -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
```

新密码在modelarts-os-apiserver中执行如下加密命令：

```
/usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
```

| 微服务                       |                             | 配置项                   |
|---------------------------|-----------------------------|-----------------------|
| CCE服务 infers-dispatcher集群 | modelarts-infers-dispatcher | redisConfig.password: |
|                           | modelarts-infers-watcher    | redisConfig.password: |
| CDK服务 ai-pod集群            | modelarts-infers-manager    | redis_password        |

## 8.2 证书管理

### 8.2.1 背景信息

ModelArts管控面相关证书信息，请参考《[华为云Stack 8.6.0 证书一览表](#)》。

为网络安全考虑，您需要更换预置证书或定期更换证书，以免证书过期。

表 8-2 替换证书

| 类型      | 说明       |
|---------|----------|
| 租户面证书替换 | 不涉及。     |
| 管控面证书替换 | 请参考如下章节。 |

### 背景信息

安全证书可以为网站的机密数据提供加密传输功能，为了提高安全性，建议企业替换为业界权威CA机构颁发的商业安全证书。

⚠ 注意

- 建议申请或制作加密算法为AES128、公钥长度为RSA2048、签名算法为SHA256的安全证书。
- 安全证书的访问密码和私钥密码中不能有以下13种字符：“|”、“;”、“&”、“\$”、“<”、“>”、“\_”、“!”、“\”、“@”、“(”、“)”、“.”。
- 安全证书私钥密码长度不得超过15位。
- 证书进行格式转换或分离操作前，请先备份源证书文件，防止操作错误需要重新制作证书。

- 数字证书是一个经证书授权中心数字签名的包含公开密钥拥有者信息以及公开密钥的文件。用户向CA机构申请完并拥有自己的证书后，就会有一个特定的仅为本人所知的私有密钥，用这个密钥进行解密和签名从而保证系统文件的安全性。
- 由根证书直接签发的设备证书称为一级证书链。由根证书再通过签名证书（又称“二级根证书”）签发的设备证书称为二级证书链。本节中介绍的自签名证书制作方法签发的是一级证书链。
- 使用二级证书链，增强了通信的安全性。各网元至少支持二级证书链，如果用户需要使用二级证书链，建议向权威证书机构申请安全证书。
- 证书文件可分为根证书、签名证书、设备证书、私钥、私钥密码，前4种分别命名为“root.pem”、“root\_CA.pem”、“servercert.pem”、“serverkey.pem”，并将私钥密码保存到“key\_password.txt”文件中。

📖 说明

- 证书机构返回的证书可能不含有签名证书“root\_CA.pem”，或签名证书“root\_CA.pem”有可能合在根证书或设备证书中。
- 制作的自签名证书是没有签名证书“root\_CA.pem”的。

制作安全证书，有两种方式：

- **证书机构返回的证书**  
用户向证书机构提供通用信息后，申请得到的证书。
- **通过制作请求文件申请的证书**  
使用OpenSSL工具制作证书请求文件后，使用证书请求文件向证书机构申请得到的证书。

📖 说明

建议使用通过权威证书机构签发的安全证书。

## 数据规划

申请或制作证书过程中需要配置的主要参数说明如表8-3所示。

表 8-3 参数说明

| 字段名称         | 参数说明                | 示例 |
|--------------|---------------------|----|
| Country Name | 表示国家名称。请根据局点名称自行设置。 | CN |

| 字段名称                     | 参数说明                  | 示例                                        |
|--------------------------|-----------------------|-------------------------------------------|
| State or Province Name   | 表示州或省名称。请根据局点名称自行设置。  | GD                                        |
| Locality Name            | 表示市名称。请根据局点名称自行设置。    | SZ                                        |
| Organizational Name      | 表示组织名称。请根据局点名称自行设置。   | huawei                                    |
| Organizational Unit Name | 表示组织单元名称。请根据局点名称自行设置。 | huawei                                    |
| Common Name              | 表示证书主体通用名。            | 自定义。<br><b>说明</b><br>域名可以使用通用格式，如“*.com”。 |

## 证书机构返回的证书

- 如果证书公司直接返回的是根证书、签名证书、设备证书、私钥、私钥密码，前4种分别命名为“root.pem”、“root\_CA.pem”、“servercert.pem”、“serverkey.pem”。
- 如果证书公司返回的是“.cer”或“.p7b”后缀格式的文件，例如“certnew.cer”、“certnew.p7b”，请使用OpenSSL工具转换证书格式和分离证书，具体请参考[证书格式转换](#)。最后，将转换好的证书文件都导入对应的网元系统。

最后获取到根证书、签名证书、设备证书、私钥、私钥密码，前四种分别命名为“root.pem”、“root\_CA.pem”、“servercert.pem”、“serverkey.pem”，并将私钥密码保存到“key\_password.txt”文件中。

请参考7生成pkcs12文件。

## 8.2.2 modelarts-console-backend 证书替换

**步骤1** 执行如下命令生成keystore文件。

```
keytool -genkey -alias modelarts-console-backend-cert -keyalg RSA -keysize 4096 -dname "CN=Huawei-Cloud-ModelArtsConsole,O=Huawei,C=CN" -validity 3650 -keystore modelarts-console-backend.keystore
```

**步骤2** 执行如下命令生成csr文件。

```
keytool -certreq -alias modelarts-console-backend-cert -file modelarts-console-backend-cert.csr -keystore modelarts-console-backend.keystore
```

**步骤3** 申请证书。

- 访问证书申请地址：<https://cloudscope.huaweisre.com/ocm/?locale=zh-cn#/cert-mgmt/not-business-cert/list>
- 选择“证书管理>非商业证书”，然后单击页面右上角“申请证书”，打开证书申请页；
- 选择“新增”，单击“下一步”，填写证书基本信息。



其中“CA供应商”选择“HWPKI”；“选择签发CA”选择“Huawei Cloud CA HCS”；“有效期”自行选择，建议10年；“密钥算法”选择“RSA4096”；“签名哈希算法”选择“SHA256”；其余默认。单击“下一步”。

4. 绑定组件“modelarts-console-backend-cdk”，“证书场景”选择“https认证证书”，单击“下一步”。
5. 在“证书确认”弹框页选择“确认”，填写“SRE经理审批”和“申请事由”，单击“确认提交”，跟踪审批，完成证书申请。

#### 步骤4 证书导入keystore。

下载申请的证书文件，执行如下命令，将证书分别导入keystore文件：

```
keytool -import -file server.pem -alias modelarts-console-backend-pem-cert -keystore modelarts-console-backend.keystore
keytool -import -alias modelarts-console-backend-EquipmentCA -v -trustcacerts -file chain.pem -keystore modelarts-console-backend.keystore
```

#### 步骤5 执行如下命令，查看keystore相关配置信息是否正确。


```
keytool -list -v -keystore modelarts-console-backend.keystore
```

#### 步骤6 执行如下命令，对keystore文件内容进行base64编码：

```
base64 modelarts-console-backend.keystore
```

#### 步骤7 登录CloudCDK更新keystore配置。

1. 使用浏览器以系统管理员登录CloudScope界面。
  - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
  - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
  - 默认账号：op\_cdk\_sso
  - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
3. 进入 变更管理 > 服务升级菜单页面，选择对应集群及命名空间，勾选modelarts-console-backend实例。



4. 单击下一步，修改部署参数：修改 SECRET\_MODELARTS\_CONSOLE\_BACKEND\_KEYSTORE参数为步骤6生成的字符串、修改参数resources.limits.memory，在原来值的基础上增大或减小0.1，单击“下一步”进行升级。

升级完成表示证书替换完成。

----结束

## 8.2.3 modelarts-webapp-gateway 证书替换

### 8.2.3.1 证书制作

#### 通过制作请求文件申请的证书

1. 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

2. 执行cd *目的路径*命令进入合适的目录。
  3. 执行如下命令生成私钥文件“server.key”。
- 其中example为私钥的加密密码，具体操作以实际情况为准。
- openssl的参数说明可以参考[openssl官方文档](#)。

```
openssl genrsa -aes256 -out server.key 2048
```

根据提示输入如下相应的信息。

```
Enter pass phrase for serverkey.pem:
#输入私钥的加密密码example。
Verifying - Enter pass phrase for serverkey.pem:
#再次输入私钥的加密密码example。
```

#### 说明

请妥善保存设置的私钥密码，需要在导入证书时输入。

4. 执行如下命令生成证书请求文件“server.csr”。
- 这里的私钥密码example和前面设置的加密密码保持一致。

```
openssl req -new -key server.key -out server.csr -sha256
```

根据提示输入如下相应的信息。

```
Enter pass phrase for server.key:
#输入私钥的加密密码<example>。
You are about to be asked to enter information that will be incorporated into your certificate request.
What you are about to enter is what is called a Distinguished Name or a DN. There are quite a few
fields but you can leave some blank. For some fields there will be a default value,
If you enter '.', the field will be left blank.

Country Name (2 letter code) [AU]:CN
#此处以CN举例，可以根据局点名称自行设置，例如UK。
State or Province Name (full name) [Some-State]:zhejiang
#此处以zhejiang举例，可以根据局点名称自行设置，例如beijing。
Locality Name (eg, city) []:hz
#此处以hz举例，可以根据局点名称自行设置，例如London。
Organization Name (eg, company) [Internet Widgits Pty Ltd]:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Organizational Unit Name (eg, section) []:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Common Name (eg, YOUR name) []:Joy
#此处以Joy举例，可自定义。
Email Address []:111111.com
#Email地址，此处以111111.com举例。
Please enter the following 'extra' attributes to be sent with your certificate request
#证书密码和证书颁发公司名称，这里以example和huawei为例。
A challenge password []:example
An optional company name []:huawei
```

5. 生成私钥pem。
- ```
openssl rsa -in server.key -outform PEM -out server.pem
```

6. 生成CRT证书。

```
openssl x509 -req -days 365 -in server.csr -sha256 -signkey server.key -out server.crt
```

8.2.3.2 证书替换

支持替换证书的微服务主要是modelarts-webapp-gateway微服务。

前提条件

已经在[证书制作](#)获取到证书文件server.crt和私钥文件server.pem。

操作步骤

1. 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

2. 对证书文件server.crt进行base64编码，获取到server.crt的Base64编码文件。

```
base64 -w 0 server.crt
```
3. 对私钥文件server.pem进行SCC加密，加密的密文为server.pem的值，结果记为SCC加密server.pem。
 - a. 将HCC Turnkey节点的server.pem进行Base64编码，并将编码后的结果保存到 server_base64.pem文件中。

```
base64 server.pem > server_base64.pem
```
 - b. [登录CDK master节点](#)的modelarts-webapp-gateway-cdk容器。

```
kubect exec -it modelarts-webapp-gateway-cdk-85857fd968-6w64l bash
```


modelarts-webapp-gateway-cdk-85857fd968-6w64l需要替换为实际的POD名称。
 - c. 执行如下命令创建并编辑待加密的文件：添加3.a的server_base64.pem的内容，然后按Esc键，再输入:wq保存。

```
cd /tmp  
vi server_base64.pem
```
 - d. 执行如下命令运行python。

```
python3
```


执行如下命令，对文件进行SCC加密。输出结果引号内的值即为“SCC加密server.pem”。

```
import sys  
import base64  
sys.path.append("/usr/local/seccomponent/lib/")  
from CryptoAPI import CryptoAPI  
api = CryptoAPI()  
api.initialize("/opt/cloud/webapp-gateway/scc.conf")  
file = open('/tmp/server_base64.pem', 'r')  
base64_content = file.read()  
content = base64.b64decode(base64_content)  
file.close()  
api.encrypt(content)  
  
退出python。  
exit()
```
 - e. 执行如下命令删除待加密的文件。

```
rm server_base64.pem
```
4. 使用浏览器以系统管理员登录CloudScope界面。

- 登录地址：<https://CloudScope>界面的访问地址。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
5. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
 6. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，选中modelarts-webapp-gateway，单击“下一步”进入参数配置。
 7. 变更配置项参数，具体参数见下表。同时修改RESOURCES_REQUESTS_MEMORY参数，在其原来值的基础上+/- 0.1，保证服务能被重新调度。

表 8-4 Secret 说明

配置项名称	配置项值
server_cert_base64_file	参见2获取的base64编码server.crt。
scc_encrypted_server_key_file	参见3获取的SCC加密server.pem。

8. 单击“下一步”，单击“升级”，等待服务升级完成。升级完成表示证书替换完成。

8.2.4 公共组件证书替换

步骤1 访问如下链接，进行证书申请：

<http://hwpmi.huawei.com/pki/#!jalor/workflow/template/startProcessForm.html?processKey=applyCert&code=SSL>

申请完成后会得到三个文件：“cert.key”、“cert.pem”和“key证书密码”。

步骤2 执行如下命令，对cert.key、cert.pem文件内容进行base64编码。

```
base64 cert.key  
base64 cert.pem
```

步骤3 SCC加密证书密码。

1. 登录CDK master节点的image-packer的容器。

2. 执行如下命令进入billing pod：

```
kubect exec -it `kubect get pods | grep bill | awk '{print $1}' | tail -n 1` bash
```

3. 执行如下命令导入环境变量。

```
export SERVER_PATH=/opt/cloud/billing  
export LOG_PATH=/opt/cloud/logs/billing  
export PATH=/opt/cloud/3rdComponent/python3/bin:$PATH  
export PYTHONPATH=/opt/cloud/billing:/opt/cloud/3rdComponent/gaussdb:/usr/local/seccomponent/lib:$PYTHONPATH  
export LD_LIBRARY_PATH=/opt/cloud/3rdComponent/gaussdb:$LD_LIBRARY_PATH  
export BILLING_APP_USER=service  
export BILLING_APP_USERGROUP=servicegroup  
export SECRET_PATH=/opt/cloud/encoded-secrets
```

- python3加密证书密码，替换的xxxxx为证书密码。

```
python3
from billing.common.cryptography import cryptography
cryptography.encrypt("xxxxx")
```

步骤4 更新Image-packer和Billing的CDK服务配置。

- Billing的配置：
BILLING_SSL_CERT_KEY 对应Base64编码后的cert.key
BILLING_SSL_CERT_PEM 对应Base64编码后的cert.pem
SSL_KEY_PWD 对应SCC加密后的证书密码
- Image-packer的配置：
IMAGEPACKER_SSL_CERT_KEY 对应Base64编码后的cert.key
IMAGEPACKER_SSL_CERT_PEM 对应Base64编码后的cert.pem
SSL_KEY_PWD 对应SCC加密后的证书密码

----结束

8.2.5 推理管控面证书替换

8.2.5.1 证书制作

安全证书可以为网站的机密数据提供加密传输功能，为了提高安全性，建议企业替换为业界权威CA机构颁发的商业安全证书。

注意

- 建议申请或制作加密算法为AES128、公钥长度为RSA2048、签名算法为SHA256的安全证书。
- 安全证书的访问密码和私钥密码中不能有以下13种字符：“|”、“;”、“&”、“\$”、“<”、“>”、“_”、“!”、“\”、“@”、“(”、“)”、“.”。
- 安全证书私钥密码长度不得超过15位。
- 证书进行格式转换或分离操作前，请先备份源证书文件，防止操作错误需要重新制作证书。

背景信息

- 数字证书是一个经证书授权中心数字签名的包含公开密钥拥有者信息以及公开密钥的文件。用户向CA机构申请完并拥有自己的证书后，就会有一个特定的仅为本人所知的私有密钥，用这个密钥进行解密和签名从而保证系统文件的安全性。
- 由根证书直接签发的设备证书称为一级证书链。由根证书再通过签名证书（又称“二级根证书”）签发的设备证书称为二级证书链。本节中介绍的自签名证书制作方法签发的是一级证书链。
- 使用二级证书链，增强了通信的安全性。各网元至少支持二级证书链，如果用户需要使用二级证书链，建议向权威证书机构申请安全证书。
- 证书文件可分为根证书、签名证书、设备证书、私钥、私钥密码，前4种分别命名为“root.pem”、“root_CA.pem”、“servercert.pem”、“serverkey.pem”，并将私钥密码保存到“key_password.txt”文件中。

 说明

- 证书机构返回的证书可能不含有签名证书“root_CA.pem”，或签名证书“root_CA.pem”有可能合在根证书或设备证书中。
- 制作的自签名证书是没有签名证书“root_CA.pem”的。

制作安全证书，有三种方式：

- **证书机构返回的证书**
用户向证书机构提供通用信息后，申请得到的证书。
- **通过制作请求文件申请的证书**
使用OpenSSL工具制作证书请求文件后，使用证书请求文件向证书机构申请得到的证书。
- **制作自签名证书**
直接使用java keytool工具制作自签名证书。

 说明

建议使用通过权威证书机构签发的安全证书。

数据规划

申请或制作证书过程中需要配置的主要参数说明如表1所示。

表 8-5 参数说明

字段名称	参数说明	示例
Country Name	表示国家名称。请根据局点名称自行设置。	CN
State or Province Name	表示州或省名称。请根据局点名称自行设置。	GD
Locality Name	表示市名称。请根据局点名称自行设置。	SZ
Organizational Name	表示组织名称。请根据局点名称自行设置。	huawei
Organizational Unit Name	表示组织单元名称。请根据局点名称自行设置。	huawei
Common Name	表示证书主体通用名。	自定义。 说明 域名可以使用通用格式，如“*.com”。

证书机构返回的证书

- 如果证书公司直接返回的是根证书、签名证书、设备证书、私钥、私钥密码，前4种分别命名为“root.pem”、“root_CA.pem”、“servercert.pem”、“serverkey.pem”。
- 如果证书公司返回的是“.cer”或“.p7b”后缀格式的文件，例如“certnew.cer”、“certnew.p7b”，请使用OpenSSL工具转换证书格式和分离证书，具体请参考[证书格式转换](#)。最后，将转换好的证书文件都导入对应的网元系统。

最后获取到根证书、签名证书、设备证书、私钥、私钥密码，前四种分别命名为“root.pem”、“root_CA.pem”、“servercert.pem”、“serverkey.pem”，并将私钥密码保存到“key_password.txt”文件中。

执行如下命令生成pkcs12文件，会生成modelarts-infers.pfx证书文件；其中servercert.pem为设备证书，serverkey.pem为证书私钥。

```
openssl pkcs12 -export -in servercert.pem -inkey serverkey.pem \
-out modelarts-infers.pfx -name modelarts-infers \
-CAfile root_CA.pem -caname root
```

通过制作请求文件申请的证书

1. 以root用户登录Linux操作系统，且该系统上已安装OpenSSL工具。
2. 执行cd *目的路径*命令进入目录。
3. 执行如下命令生成私钥文件“serverkey.pem”。

其中example为私钥的加密密码，具体操作以实际情况为准。

openssl的参数说明可以参考openssl官方文档：<https://www.openssl.org/docs/manmaster/man1/>

```
openssl genrsa -aes256 -out serverkey.pem 4096
```

根据提示输入如下相应的信息。

```
Enter pass phrase for serverkey.pem:
#输入私钥的加密密码example。
Verifying - Enter pass phrase for serverkey.pem:
#再次输入私钥的加密密码example。
```

📖 说明

请妥善保存设置的私钥密码，需要在导入证书时输入。

4. 执行如下命令生成证书请求文件“server.csr”。
- 这里的私钥密码example和前面设置的加密密码保持一致。

```
openssl req -new -key serverkey.pem -out server.csr
```

根据提示输入如下相应的信息，注意CSR的主题需要满足：以O=Huawei,C=CN结尾，CN=“Huawei-Cloud-服务名-模块名”。

```
Enter pass phrase for serverkey.pem:
#输入私钥的加密密码example。
You are about to be asked to enter information that will be incorporated into your certificate request.
What you are about to enter is what is called a Distinguished Name or a DN. There are quite a few
fields but you can leave some blank For some fields there will be a default value,
If you enter '.', the field will be left blank.
-----
Country Name (2 letter code) [AU]:CN
#此处以CN举例，可以根据局点名称自行设置，例如UK。
State or Province Name (full name) [Some-State]:zhejiang
#此处以zhejiang举例，可以根据局点名称自行设置，例如beijing。
Locality Name (eg, city) []:hz
#此处以hz举例，可以根据局点名称自行设置，例如Lundon。
```



```
Organization Name (eg, company) [Internet Widgits Pty Ltd]:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Organizational Unit Name (eg, section) []:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Common Name (eg, YOUR name) []:Joy
#此处以Joy举例，可自定义。
Email Address []:111111.com
#Email地址，此处以111111.com举例。
Please enter the following 'extra' attributes to be sent with your certificate request
#证书密码和证书颁发公司名称，这里以example和huawei为例。
A challenge password []:example
An optional company name []:huawei
```

5. 将证书请求文件“server.csr”发送给证书制作公司申请签发证书。
6. 请参考[证书机构返回的证书](#)获取证书。
7. 执行如下命令生成**pkcs12 文件**，会生成**modelarts-infers.pfx**证书文件；其中servercert.pem为设备证书，serverkey.pem为证书私钥。

```
openssl pkcs12 -export -in servercert.pem -inkey serverkey.pem \
-out modelarts-infers.pfx -name modelarts-infers \
-CAfile root_CA.pem -caname root
```

制作自签名证书

1. 在java官方网站下载并安装jdk。
本文以“jdk8”，操作系统是“win10 64位”为例介绍。例如安装到“D:\opt\jdk1.8.0_212\”。
2. 制作证书。
在计算机上选择“开始 > 运行”，输入cmd，弹出“cmd.exe”命令输入框，执行cd D:\opt\jdk1.8.0_212命令进入jdk安装目录下的“bin”目录，执行如下命令：

```
keytool -genkeypair -alias modelarts-infers -keyalg RSA -keysize 4096 -storetype PKCS12 -
keystore modelarts-infers.pfx -validity 3650
其中3650为证书有效期，keytool的详细参数说明可以参考：https://docs.oracle.com/javase/8/docs/technotes/tools/windows/keytool.html
输入密钥库口令：
再次输入新口令：
您的名字与姓氏是什么？
[Unknown]: xx
您的组织单位名称是什么？
[Unknown]: xx
您的组织名称是什么？
[Unknown]: xx
您所在的城市或区域名称是什么？
[Unknown]: xx
您所在的省/市/自治区名称是什么？
[Unknown]: xx
该单位的双字母国家/地区代码是什么？
[Unknown]: xx
CN=xx, OU=xx, O=xx, L=xx, ST=xx, C=xx是否正确？
[否]: 是
```

相应信息可以按实际情况填写，需要记录密钥库口令。

命令运行完成后，在当前目录下会生成证书的**pkcs12**文件modelarts-infers.pfx。

8.2.5.2 密钥和证书更新

为满足安全的密钥更新要求，需要提供密钥更新的能力，更新密钥需要考虑到旧密钥的兼容性，旧密钥要能够支持解密，且最新加密要使用新的密钥。

SCC的工作原理是解密会根据密文中的hash判断使用的密钥，不用指定密钥，只要primary.ks中有旧密钥即可。在加密时默认会自动使用最新的密钥，因此密钥更新就简单了，直接在primary.ks文件中添加一个新的密钥即可。

1. 登录CDK master节点的model-manager容器。

2. 执行如下命令获取原始的primary.ks等文件：

```
kubectl cp modelarts-infers-model-manager-69d987679f-2mv5x:opt/cloud/modelarts-infers-model-manager/sec/ ./ -n infer
```

其中**modelarts-infers-model-manager-69d987679f-2mv5x**替换为实际的模型管理的pod名。

需要将该目录拷贝到待执行命令的linux机器，可以使用scp命令，命令如下：

```
scp -r sec root@192.168.1.100:/root/
```

上述命令将当前主机的sec目录拷贝到192.168.1.100主机的/root目录下。

拷贝加解密工具到执行机器，cd到sec目录下执行如下命令添加新的密钥到primary.ks。

```
java -jar secComponentApi-1.0.0-jar-with-dependencies.jar -p ./primary.ks -s ./standby.ks -u
```

-p 选项为primary.ks文件路径

-s选项为standby.ks文件路径

另外，可通过该工具进行加解密：

加密命令为：

```
java -jar secComponentApi-1.0.0-jar-with-dependencies.jar -p ./primary.ks -s ./standby.ks -e 'xxx'
```

其中-e选项为待加密的明文。

解密命令为：

```
java -jar secComponentApi-1.0.0-jar-with-dependencies.jar -p ./primary.ks -s ./standby.ks -d '<待解密密文>='
```


其中-d选项为待解密的密文。

3. 使用浏览器以系统管理员登录CloudScope界面。

- 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
- CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
- 默认账号：op_cdk_sso
- 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。

4. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。

5. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，例如选中service-manager（其余微服务操作类似），单击“下一步”进入参数配置。



6. 通过cdk进行更新升级，更新或者添加配置项。

文件的编码命令为：base64 -w 0 待编码文件。
file_path配置项的修改需要和secret_mount_decode_path配置项保持一致。

```
"scc_primary_ks": "primary.ks文件base64编码",
"scc_standby_ks": "standby.ks文件base64编码",
"server_ssl_key_store_file": "modelarts-infers.pfx文件base64编码",
"secret_mount": "true",需要设置为true
"scc_primary_keystore_file_path": "/opt/cloud/decoded-secrets", 不需要修改
"scc_standby_keystore_file_path": "/opt/cloud/decoded-secrets ", 不需要修改
"server_ssl_key_store": "file:///opt/cloud/decoded-secrets/modelarts-infers.pfx",不需要修改
"server_ssl_key_store_password": "使用scc加密的证书密钥库口令密文",
"server_ssl_key_password": "使用scc加密的证书密钥库口令密文",
```

表 8-6 参数说明

参数名	是否必选	参数说明
scc_primary_ks	否（需要更新scc密钥时填写）	scc primary.ks文件base64编码
scc_standby_ks	否（需要更新scc密钥时填写）	scc standby.ks文件base64编码
scc_primary_keystore_file_path	否（需要更新scc密钥时填写）	scc primary.ks文件路径，固定为/opt/cloud/decoded-secrets
scc_standby_keystore_file_path	否（需要更新scc密钥时填写）	scc standby.ks文件路径，固定为/opt/cloud/decoded-secrets
secret_mount	是	是否挂载密钥文件，需要填是
server_ssl_key_store_file	是	modelarts-infers.pfx文件base64编码
server_ssl_key_store_password	是	使用scc加密的证书密钥库口令密文
server_ssl_key_password	是	使用scc加密的证书密钥库口令密文

7. 更新管控面微服务model-manager，service-manager，ctxproxy，stats，monitor，job-manager组件，观察业务是否正常，运行正常即代表证书更新成功。

8.2.5.3 证书格式转换

本节介绍转化证书格式和分离证书的方法。

前提条件

已在openssl官网下载软件并安装。

转换证书

证书格式转化请参考表1，分离证书方法请参考表2。

转换证书格式：在计算机上选择“开始 > 运行”，输入cmd，弹出“cmd.exe”命令输入框，执行cd C:\OpenSSL-Win64\bin命令进入OpenSSL安装目录下的“bin”目录，执行如下命令。

说明

- 如果OpenSSL工具安装在D盘，例如“D:\OpenSSL-Win64\bin”，请依次执行如下命令。
 - 进入D盘：d:
 - 进入“bin”目录：cd \OpenSSL-Win64\bin
- 转化证书格式时，请将待转化的证书文件保存在OpenSSL安装目录“OpenSSL\bin”下，即与OpenSSL执行程序“openssl.exe”放在同一个目录下，才能执行命令进行转化。

表 8-7 证书格式转化

格式说明	转化方法	备注
.pem格式转为.der格式	- 如果转换根证书，执行如下命令： openssl.exe x509 -in sc_root.pem -inform PEM -out sc_root.der -outform DER - 如果转换服务器证书，执行如下命令： openssl.exe x509 -in sc_cert.pem -inform PEM -out sc_cert.der -outform DER - 如果转换私钥文件，执行如下命令： openssl.exe pkcs8 -topk8 -nocrypt -in sc_key.pem -inform PEM -passin pass:sc_key_password -out sc_key.der -outform DER	- sc_root表示CA根证书 - sc_cert表示服务器证书 - sc_key表示私钥文件 - sc_key_password表示私钥密码
.pem格式转为.cer格式	- 如果转换根证书，执行如下命令： openssl.exe x509 -in sc_root.pem -inform PEM -out sc_root.cer -outform DER - 如果转换服务器证书，执行如下命令： openssl.exe x509 -in sc_cert.pem -inform PEM -out sc_cert.cer -outform DER - 如果转换私钥文件，执行如下命令： openssl.exe pkcs8 -topk8 -nocrypt -in sc_key.pem -inform PEM -passin pass:sc_key_password -out sc_key.cer -outform DER	

格式说明	转化方法	备注
.pem格式转为.pfx格式	执行如下命令：openssl.exe pkcs12 -export -out sc.pfx -inkey sc_key.pem -passin pass: sc_key_password -in sc_cert.pem 说明 .pfx格式证书是由服务器证书和私钥文件合并而成。	
.cer格式转为.pem	执行如下命令：openssl.exe x509 -inform der -in sc_cert.cer -out sc_cert.pem	
.p7b格式转为.pem	执行如下命令：openssl.exe pkcs7 -in sc_root.p7b -print_certs -outform PEM -out sc_root.pem	
.pem格式转化为.crt	执行如下命令：openssl.exe x509 -outform pem -in sc_cert.pem -out sc_cert.crt	

表 8-8 证书分离方法

前提条件	证书说明	操作步骤	备注
针对转换为.pem后缀格式的证书文件，例如“certs.pem”。	文件可能包含的三种证书说明： 根证书： 如果参数“subject”与参数“issuer”的对应的参数值相同，则其下“BEGIN CERTIFICATE”至“END CERTIFICATE”内容为根证书文件，如“sc_root.pem”。	1. 使用文本编辑工具（如 Notepad）打开文件，查看证书文件内容。 2. 分别复制相应内容，参考以下步骤，分离出3个证书文件，例如“sc_root.pem”、“root_CA.pem”、“sc_cert.pem”。 a. 新建证书文件并命名为“root.pem”。 b. 使用文本编辑工具打开文件。 c. 粘贴复制内容。 d. 保存并退出编辑工具。 说明 为了安全起见，请妥善保管源证书文件。	“sc_root.pem”表示根证书文件。
	服务器证书： 如果参数“subject”与参数“issuer”的对应的参数值不相同，且参数“subject”对应的值中包含服务器信息（例如：IP地址或域名等），则其下“BEGIN CERTIFICATE”至“END CERTIFICATE”内容为设备证书文件，如“sc_cert.pem”。		“sc_cert.pem”表示服务器证书。

前提条件	证书说明	操作步骤	备注
	签名证书（二级根证书）： 如果参数“subject”与参数“issuer”的对应的参数值不相同，且不是设备证书，参数“issuer”对应的值与根证书文件中参数“issuer”对应的值相同，则其下“BEGIN CERTIFICATE”至“END CERTIFICATE”内容为签名证书文件，如“root_CA”。 说明 签名证书有可能合在根证书或设备证书中。		“root_CA.pem”表示签名证书。

8.2.6 训练管控面证书替换

8.2.6.1 证书制作

通过制作请求文件申请的证书

1.

使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```
2.

执行cd *目的路径*命令进入合适的目录。
3.

执行如下命令生成私钥文件“server.key”。

其中example为私钥的加密密码，具体操作以实际情况为准。

```
openssl genrsa -aes256 -out server.key 2048
```

根据提示输入如下相应的信息。

```
Enter pass phrase for serverkey.pem:
#输入私钥的加密密码example。
Verifying - Enter pass phrase for serverkey.pem:
#再次输入私钥的加密密码example。
```

 **说明**

请妥善保存设置的私钥密码，需要在导入证书时输入。
4.

执行如下命令生成证书请求文件“server.csr”。

这里的私钥密码example和前面设置的加密密码保持一致。

```
openssl req -new -key server.key -out server.csr -sha256
```

根据提示输入如下相应的信息。

```
Enter pass phrase for serverkey:
#输入私钥的加密密码example。
You are about to be asked to enter information that will be incorporated into your certificate request.
```

What you are about to enter is what is called a Distinguished Name or a DN. There are quite a few fields but you can leave some blank For some fields there will be a default value, If you enter '.', the field will be left blank.

Country Name (2 letter code) [AU]:CN

#此处以CN举例，可以根据局点名称自行设置，例如UK。

State or Province Name (full name) [Some-State]:zhejiang

#此处以zhejiang举例，可以根据局点名称自行设置，例如beijing。

Locality Name (eg, city) []:hz

#此处以hz举例，可以根据局点名称自行设置，例如Lundon。

Organization Name (eg, company) [Internet Widgits Pty Ltd]:huawei

#此处以huawei举例，可以根据局点名称自行设置，例如bank。

Organizational Unit Name (eg, section) []:huawei

#此处以huawei举例，可以根据局点名称自行设置，例如bank。

Common Name (eg, YOUR name) []:Joy

#此处以Joy举例，可自定义。

Email Address []:111111.com

#Email地址，此处以111111.com举例。

Please enter the following 'extra' attributes to be sent with your certificate request

#证书密码和证书颁发公司名称，这里以example和huawei为例。

A challenge password []:example

An optional company name []:huawei

5. 生成私钥pem。

```
openssl rsa -in server.key -outform PEM -out server.pem
```

6. 生成CRT证书。

```
openssl x509 -req -days 365 -in server.csr -sha256 -signkey server.key -out server.crt
```

8.2.6.2 证书替换

ModelArts-train支持替换证书的微服务主要是modelarts-algorancher、modelarts-exemlflow这2个微服务替换证书方式一致。

前提条件

已经在[证书制作](#)获取到证书文件server.crt和私钥文件server.pem。

操作步骤

1. 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

2. 执行如下命令对证书文件server.crt进行base64编码，获取到“base64编码server.crt”文件。

```
base64 -w 0 server.crt
```

3. 对私钥文件server.pem进行SCC加密，加密的密文为server.pem的值，结果记为“SCC加密server.pem”。

- a. 执行如下命令将HCC Turnkey节点的server.pem进行Base64编码，并将编码后的结果保存到server_base64.pem文件中。

```
base64 server.pem > server_base64.pem
```

- b. 登录CDK master节点的modelarts-algorancher容器。

```
kubectrl exec -it modelarts-algorancher-5c48b5d749-77827 bash
```

modelarts-algorancher-5c48b5d749-77827 需要替换为实际的POD名称。

- c. 执行如下命令创建并编辑待加密的文件：添加3.a的server_base64.pem的内容，然后按Esc键，再输入:wq保存。

```
cd /tmp
vi server_base64.pem

d. 执行如下命令运行python。
python3

执行如下命令，对文件进行SCC加密。输出结果引号内的值即为“SCC加密server.pem”
import sys
import base64
sys.path.append("/usr/local/seccomponent/lib/")
from CryptoAPI import CryptoAPI
api = CryptoAPI()
api.initialize("/opt/cloud/algorancher/scc.conf")
file = open('/tmp/server_base64.pem', 'r')
base64_content = file.read()
content = base64.b64decode(base64_content)
file.close()
api.encrypt(content)

执行如下命令退出python
exit()

e. 执行如下命令删除待加密的文件。
rm server_base64.pem
```

注：上述内容为algorancher的示例，若是exemplflow服务，则将上述的algorancher替换为exemplflow。

4. 使用浏览器以系统管理员登录CloudScope界面。
- 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。

- CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。

- 默认账号：op_cdk_sso

- 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
5. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
6. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，例如选中modelarts-algorancher（其余微服务操作类似），单击“下一步”进入参数配置。
7. 变更配置项参数，具体参数见下表。同时修改RESOURCES_LIMITS_MEMORY参数保证服务能被重新调度。

表 8-9 Secret 说明

配置项名称	配置项值
server_cert_base64_file	参见2获取的base64编码server.crt。
scc_encrypted_server_key_file	参见3获取的SCC加密server.pem。

8. 单击“下一步”，单击“升级”，等待服务升级完成。升级完成表示证书替换完成。

8.2.7 OS 管控面证书替换

8.2.7.1 证书制作

获取更换前的证书 CA 并获取新 CA

1. 登录CDK master节点。
2. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod。

图 8-2 查看 pod

```
Last login: Wed Aug 24 17:23:16 CST 2022 on pts/1
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectl get pod
```

NAME	READY	STATUS	RESTARTS	AGE
modelarts-algorancher-8ddcc8d68-cqk42	1/1	Running	0	3d16h
modelarts-algorancher-8ddcc8d68-krc8m	1/1	Running	0	3d16h
modelarts-billing-7d9d4c4dd4-ftsxn	1/1	Running	0	3d16h
modelarts-billing-7d9d4c4dd4-hvsj9	1/1	Running	0	3d16h
modelarts-console-backend-576cbbffdb-d78t7	1/1	Running	0	3d16h
modelarts-console-backend-576cbbffdb-k94g7	1/1	Running	0	3d16h
modelarts-exemlflow-778b8c78fd-mjg67	1/1	Running	0	3d16h
modelarts-exemlflow-778b8c78fd-wqlcl	1/1	Running	0	3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8	1/1	Running	0	2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl	1/1	Running	0	2d22h
modelarts-os-apiserver-5cd548c558-sltx5	1/1	Running	0	3d16h
modelarts-os-apiserver-5cd548c558-tzvv2	1/1	Running	0	3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz	1/1	Running	0	3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x	1/1	Running	0	3h24m
modelarts-os-resource-mgr-78747979f7-8wqtf	1/1	Running	0	3d16h
modelarts-os-resource-mgr-78747979f7-zvr4q	1/1	Running	0	3d16h
modelarts-webapp-gateway-cdk-7547d97b55-17k6j	1/1	Running	0	3d16h
modelarts-webapp-gateway-cdk-7547d97b55-r6rtz	1/1	Running	0	3d16h

3. 执行如下命令登录pod。
`kubectl exec -it ${pod_name} bash`
4. 获取服务端CA内容，设置获取到的值为server_ca.crt。
`cat /opt/cloud/modelarts-os/modelarts-os-apiserver/config/ca.crt`
5. 获取服务端k8s CA内容，设置获取到的值为k8s_server_ca.crt。
`cat /opt/cloud/modelarts-os/modelarts-os-apiserver/secret/webhook_ca_bundle |base64 -d`
6. 获取客户端etcd CA内容，设置获取到的值为etcd_client_ca.crt。
`cat /opt/cloud/modelarts-os/modelarts-os-apiserver/secret/etcd-ca.pem`
7. 获取制作新证书的新CA，设置最终获取到的CA证书信任链为new_ca.crt。
 - a. 通过Turnkey获取新CA信息，并创建new_ca.crt，将新CA对应对的公钥文件sub.pem追加至new_ca.crt中。
`path_cert=/home/data/certs/modelarts_os_20250925`
`mkdir -p $path_cert`
`touch $path_cert/new_ca.crt`
`cd /home/data/certs/Turnkey/ca/rsa/`

```
[root@localhost rsa]# pwd
/home/data/certs/Turnkey/ca/rsa
[root@localhost rsa]# ll
total 20
-rw----- 1 hcci servicetools 3434 Sep 24 10:51 subca.key
-rw----- 1 hcci servicetools 128 Sep 24 10:51 subca.key.pwd
-rw----- 1 hcci servicetools 4165 Sep 24 10:51 subca.pem
-rw-r--r-- 1 hcci servicetools 41 Sep 23 20:48 subca.srl
[root@localhost rsa]#
```


 说明

HCS 8.6.0及之后版本，Turnkey提供了局点统一CA获取的方式;目录：/home/data/certs/Turnkey/ca/rsa/

- b. 若客户有指定新CA，设为custom.crt，将custom.crt内容追加到new_ca.crt文件中，在最后加换行符；若无，则跳过当前步骤。
- c. 将server_ca.crt内容追加到new_ca.crt文件中，在最后加换行符。
- d. 若k8s_server_ca.crt与server_ca.crt内容不一致，则将k8s_server_ca.crt内容追加到new_ca.crt文件中，在最后加换行符；否则跳过。
- e. 若etcd_client_ca.crt与k8s_server_ca.crt、server_ca.crt内容均不一致，则将etcd_client_ca.crt内容追加至new_ca.crt文件中，在最后加换行符；否则跳过。

8. 最终new_ca.crt文件即为ModelArts OS的新CA。

重新生成证书

重新生成新证书，用于各个组件，并根据各组件所需，进行加密生成加密配置项。

步骤1 登录Turnkey节点，并执行如下命令，创建服务端证书目录。

```
path_cert=/home/data/certs/modelarts_os_20250925
rm -rf $path_cert/server/server.key
rm -rf $path_cert/server/server.csr
mkdir -p $path_cert/server
```

步骤2 在Turnkey节点上创建服务端证书配置openssl.conf，执行 vi /home/data/certs/modelarts_os_20250925/server/openssl.conf，文件内容如下。

```
[ req ]
default_bits = 2048
prompt = no
default_md = sha256
distinguished_name = dn

[ dn ]
CN = ModelArts_OS_Server
C = CN
ST = Guangdong
L = Shenzhen
O = Cloud
OU = CloudService

[ v3_ca ]
basicConstraints = critical, CA:TRUE, pathlen:1
keyUsage = critical, digitalSignature, cRLSign, keyCertSign
subjectKeyIdentifier = hash
authorityKeyIdentifier = keyid:always,issuer
[ alt_names ]
IP.1 = 127.0.0.1
DNS.1 = localhost
DNS.2 = modelarts-os.myhuaweicloud.com

[ usr_cert ]
basicConstraints = CA:FALSE
keyUsage = critical, digitalSignature, keyEncipherment, nonRepudiation, keyAgreement
extendedKeyUsage = serverAuth, clientAuth
subjectAltName = @alt_names
```

步骤3 生成ModelArts OS服务端密码加密后的私钥。

```
openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out $path_cert/server/server.key -aes-256-cbc
```

```
[root@localhost server]# openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out spath_cert/server/server.key -aes-256-cbc
.....++++
Enter PEM pass phrase: 
Verifying - Enter PEM pass phrase: 
[root@localhost server]# ll
```

说明

输入密码需注意，假设密码为：password_cert，需重复输入2次进行确认。

步骤4 提取ModelArts OS服务端私钥明文。

```
openssl rsa -in $path_cert/server/server.key -out $path_cert/server/server_no_password.key
```

```
[root@localhost home]# openssl rsa -in $path_cert/server/server.key -out $path_cert/server/server_no_password.key
Enter pass phrase for /home/data/certs/modelarts_os_20250925/server/server.key:
writing RSA key
```

 说明

此处输入的密码为服务端私钥密码，即**步骤3**的密码password_cert。

步骤5 生成ModelArts OS服务端csr。

```
openssl req -new -key $path_cert/server/server.key -out $path_cert/server/server.csr -config $path_cert/server/openssl.conf -extensions usr_cert
```

```
[root@localhost server]# openssl req -new -key $path_cert/server/server.key -out $path_cert/server/server.csr -config $path_cert/server/openssl.conf -extensions usr_cert
Enter pass phrase for /home/data/certs/modelarts_os_20250925/server/server.key:
[root@localhost server]#
```

 说明

此处输入的密码为服务端私钥密码，即**步骤3**的密码password_cert。

步骤6 获取局点Turnkey统一CA私钥密码。

```
export turnkey_ca_password=`cat /home/data/certs/Turnkey/ca/rsa/subca.key.pwd`  
su hcci -s /bin/bash -c "export PYTHONPATH=/opt/cloud/hcci/src/HCCI;/opt/Python39/bin/python3 -c 'from  
platforms.utils.security import crypt;import os; print(crypt.decrypt(os.getenv(\"turnkey_ca_password\")))'"
```

```
root@localhost:~# python3 --help
python3 local_server.py export turnkey_ca_password cat /home/data/certs/turnkey/ca/rsa/turnkey_ca_pub.pem
python3 local_server.py su hcc1 -c 'ls /dev/shm -c' export PYTHONPATH=/opt/cloud/hcc1/src/HCC1/./opt/Python3/bin/python3 -c 'from platforms.utils.security import
crypt;import os; print(crypt.decrypt(os.getenv("turnkey_ca_password")))'
python3 local_server.py su hcc1 -c 'ls /dev/shm -c' export PYTHONPATH=/opt/cloud/hcc1/src/HCC1/./opt/Python3/bin/python3 -c 'from platforms.utils.security import
crypt;import os; print(crypt.decrypt(os.getenv("turnkey_ca_password")))'

root@localhost:~# python3 local_server.py su hcc1 -c 'ls /dev/shm -c' export PYTHONPATH=/opt/cloud/hcc1/src/HCC1/./opt/Python3/bin/python3 -c 'from platforms.utils.security import
crypt;import os; print(crypt.decrypt(os.getenv("turnkey_ca_password")))'
```

步骤7 生成ModelArts OS服务端签名证书。

```
openssl x509 -req -in $path_cert/server/server.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -
CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -out $path_cert/server/server.pem -days
36500 -extfile $path_cert/server/openssl.conf -sha256 -extensions usr_cert
```

```
[root@localhost server]# openssl x509 -req -in spath_cert/server/server.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -o spath_cert/server/server.pem -days 36500 -extfile spath_cert/server/openssl.conf -sha256 -extensions usr_cert
Signature ok
subject=CN = ModelA_OS_Server, C = CN, ST = Guangdong, L = Shenzhen, O = Cloud, OU = CloudService
Getting CA Private Key
Enter pass phrase for /home/data/certs/Turnkey/ca/rsa/subca.key: 
```

说明

此处输入的密码为局点Turnkey统一CA 私钥密码，即**步骤6**获取的密码。

步骤8 获取服务端证书及私钥相关信息。

```
[root@localhost server]# ll
total 20
-rw-r----- 1 root root 657 Oct 11 16:18 openssl.conf
-rw-r----- 1 root root 1720 Oct 11 16:19 server.csr
-rw----- 1 root root 3434 Oct 11 16:19 server.key
-rw----- 1 root root 3243 Oct 11 16:20 server_no_password.key
-rw-r----- 1 root root 2139 Oct 11 16:29 server.pem
[root@localhost server]# pwd
/home/data/certs/modelarts os 20250925/server
```

步骤9 登录Turnkey节点，并执行如下命令，创建客户端证书目录。

```
path_cert=/home/data/certs/modelarts_os_20250925
rm -rf $path_cert/client/client.key
rm -rf $path_cert/client/client.csr
mkdir -p $path_cert/client
```

步骤10 在Turnkey节点上创建服务端证书配置openssl.conf，执行 vi /home/data/certs/modelarts_os_20250925/client/openssl.conf，文件内容如下。

```
[ req ]
default_bits = 2048
prompt = no
default_md = sha256
distinguished_name = dn

[ dn ]
CN = ModelArts-cmwetcd-maos-client
C = CN
ST = Guangdong
L = Shenzhen
O = Cloud
OU = CloudService

[ v3_ca ]
basicConstraints = critical, CA:TRUE, pathlen:1
keyUsage = critical, digitalSignature, cRLSign, keyCertSign
subjectKeyIdentifier = hash
authorityKeyIdentifier = keyid:always,issuer

[ usr_cert ]
basicConstraints = CA:FALSE
keyUsage = critical, digitalSignature, keyEncipherment, nonRepudiation, keyAgreement
extendedKeyUsage = serverAuth, clientAuth
```

步骤11 生成ModelArts OS客户端私钥。

```
openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out $path_cert/client/client.key -aes-256-cbc
```

```
-rw-r----- 1 root root 552 Sep 26 09:38 openssl.conf
[root@localhost client]# openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out $path_cert/client/client.key -aes-256-cbc
.....++++
.....++++
Enter PEM pass phrase:
Verifying - Enter PEM pass phrase:
[root@localhost client]#
```

 说明

输入密码需记住，假设密码为：password_cert，需重复输入2次进行确认，请与服务端证书密码保持一致。

步骤12 提取ModelArts OS客户端私钥明文。

```
openssl rsa -in $path_cert/client/client.key -out $path_cert/client/client_no_password.key
```

```
[root@localhost home]# openssl rsa -in $path_cert/server/server.key -out $path_cert/server/server_no_password.key
Enter pass phrase for /home/data/certs/modelarts_os_20250925/server/server.key:
writing RSA key
```

 说明

输入密码为**步骤11**生成私钥时的密码。

步骤13 生成ModelArts OS客户端csr。

```
openssl req -new -key $path_cert/client/client.key -out $path_cert/client/client.csr -config $path_cert/client/openssl.conf -extensions usr_cert
```

```
[root@localhost client]# openssl req -new -key $path_cert/client/client.key -out $path_cert/client/client.csr -config $path_cert/client/openssl.conf -extensions usr_cert
Enter pass phrase for /home/data/certs/modelarts_os_20250925/client/client.key:
[root@localhost client]#
```

 说明

此处输入的密码为客户端私钥密码，即步骤11的密码password_cert。

步骤14 生成ModelArts OS客户端签名证书。

```
openssl x509 -req -in $path_cert/client/client.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -out $path_cert/client/client.pem -days 36500 -extfile $path_cert/client/openssl.conf -sha256 -extensions usr_cert
```

```
[root@localhost client]# openssl x509 -req -in $path_cert/client/client.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -o $path_cert/client/client.pem -days 36500 -extfile $path_cert/client/openssl.conf -sha256 -extensions usr_cert
Signature ok
subject=CN = ModelArts-cmwtcd-maos-client, C = CN, ST = Guangdong, L = Shenzhen, O = Cloud, OU = CloudService
Getting CA Private Key
Enter pass phrase for /home/data/certs/Turnkey/ca/rsa/subca.key:  
[root@localhost client]#
```

 说明

此处输入的密码为局点Turnkey统一CA私钥密码，即步骤6获取的密码。

步骤15 获取客户端证书及私钥相关信息。

```
[root@localhost client]# ll
total 20
-rw-r----- 1 root root 1736 Oct 11 16:27 client.csr
-rw----- 1 root root 3434 Oct 11 16:26 client.key
-rw----- 1 root root 3247 Oct 11 16:27 client_no_password.key
-rw-r----- 1 root root 2069 Oct 11 16:30 client.pem
-rw-r----- 1 root root 551 Oct 11 16:26 openssl.conf
[root@localhost client]# pwd
/home/data/certs/modelarts_os_20250925/client
```

----结束

梳理获取到的证书信息

表 8-10 获取到的证书信息

用途	路径	说明
CA	/home/data/certs/modelars_os_20250925/new_ca.crt	CA证书
服务端	/home/data/certs/modelars_os_20250925/server/server.key	服务端密码加密私钥
服务端	/home/data/certs/modelars_os_20250925/server/server_no_password.key	服务端明文私钥
服务端	/home/data/certs/modelars_os_20250925/server/server.pem	服务端证书
客户端	/home/data/certs/modelars_os_20250925/client/client.key	客户端密码加密私钥
客户端	/home/data/certs/modelars_os_20250925/client/client_no_password.key	客户端明文私钥
客户端	/home/data/certs/modelars_os_20250925/client/client.pem	客户端证书

```
[root@localhost modelarts_os_20250925]# ls -alR ./
./:
total 24
drwxr-x---  4 root root          4096 Oct 14 17:16 .
drwxr-x--- 29 hcci servicetools 4096 Oct 11 16:18 ..
drwxr-x---  2 root root          4096 Oct 11 16:30 client
-rw-----  1 root root          4165 Oct 14 17:15 new_ca.crt
drwxr-x---  2 root root          4096 Oct 11 16:29 server

./client:
total 28
drwxr-x---  2 root root 4096 Oct 11 16:30 .
drwxr-x---  4 root root 4096 Oct 14 17:16 ..
-rw-r-----  1 root root 1736 Oct 11 16:27 client.csr
-rw-----  1 root root 3434 Oct 11 16:26 client.key
-rw-----  1 root root 3247 Oct 11 16:27 client_no_password.key
-rw-r-----  1 root root 2069 Oct 11 16:30 client.pem
-rw-r-----  1 root root  551 Oct 11 16:26 openssl.conf

./server:
total 28
drwxr-x---  2 root root 4096 Oct 11 16:29 .
drwxr-x---  4 root root 4096 Oct 14 17:16 ..
-rw-r-----  1 root root  657 Oct 11 16:18 openssl.conf
-rw-r-----  1 root root 1720 Oct 11 16:19 server.csr
-rw-----  1 root root 3434 Oct 11 16:19 server.key
-rw-----  1 root root 3243 Oct 11 16:20 server_no_password.key
-rw-r-----  1 root root 2139 Oct 11 16:29 server.pem
[root@localhost modelarts_os_20250925]#
```

8.2.7.2 证书替换

ModelArts-OS支持替换证书的微服务主要是modelarts-os-apiserver、modelarts-os-resource-mgr、modelarts-os-job-mgr，这3个微服务的证书一致并且替换证书方式一致。

替换 modelarts-os-apiserver 证书

1. 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

2. 执行如下命令获取server_cert_file的内容，并将文件内容进行Base64编码。

```
cat /home/data/certs/modelarts_os_20250925/server/server.pem |base64 -w 0
```
3. 执行如下命令获取server_no_password_key_decode_gcrypt_base64的内容，并将文件内容进行Base64编码。
 - a. 在HCC Turnkey节点上获取无密码的server_key base64字符串。

```
cat /home/data/certs/modelarts_os_20250925/server/server_no_password.key |base64 -w 0
```
 - b. 在modelarts-os-apiserver容器里导入无密码的server_key base64字符串。

```
export server_no_password_key='${server_no_password_key}'
echo $server_no_password_key |base64 -d >/opt/cloud/modelarts-os/modelarts-os-apiserver/server_no_password.key
```
 - c. 对文件进行加密，获取对应gcrypt加密后的文件并进行Base64编码。

```
chmod 777 /opt/cloud/modelarts-os/gcrypt-tool
/opt/cloud/modelarts-os/gcrypt-tool -usage=encode -algType=gcrypt -inputFilePath=/opt/cloud/
```

```
modelarts-os/modelarts-os-apiserver/server_no_password.key -outputFilePath=/opt/cloud/  
modelarts-os/modelarts-os-apiserver/server_no_password_gcrypt.key  
cat /opt/cloud/modelarts-os/modelarts-os-apiserver/server_no_password_gcrypt.key|base64 -w 0
```

[illegible]

4. 在HCC Turnkey上执行如下命令获取root_ca_file的内容，并将文件内容进行Base64编码。

```
cat /home/data/certs/modelarts_os_20250925/new_ca.crt |base64 -w 0
```

- 在HCC Turnkey上执行如下命令获取root_ca_file_decode的内容，并将文件内容进行Base64编码。

```
export root_ca_file=`cat /home/data/certs/modelarts_os_20250925/new_ca.crt |base64 -w 0`  
python -c '  
import base64; import os;  
root_ca_file_decode=bytes.decode(base64.b64decode(os.getenv("root_ca_file"))).replace("\n","\n")  
print (root_ca_file_decode)
```

6. 获取client_cert_key_decode_gcrypt的内容。

- a. 在HCC Turnkey上节点上执行如下命令，获取无密码的client_key的Base64字符串。

```
cat /home/data/certs/modelarts_os_20250925/client/client_no_password.key |base64 -w 0
```

- b. 在modelarts-os-apiserver容器中导入无密码的client_key Base文件。

```
export client_no_password_key='${client_no_password_key}'
echo $client_no_password_key |base64 -d >/opt/cloud/modelarts-os/modelarts-os-apiserver/
client_no_password.key
```

- c. 对导入的文件进行加密，获取对应gcrypt加密后的文件内容。

```
chmod 777 /opt/cloud/modelarts-os/gcrypt-tool
/opt/cloud/modelarts-os/gcrypt-tool -usage=encode -algType=gcrypt -inputFilePath=/opt/cloud/
modelarts-os/modelarts-os-apiserver/client_no_password.key -outputFilePath=/opt/cloud/
modelarts-os/modelarts-os-apiserver/client_no_password_gcrypt.key
cat /opt/cloud/modelarts-os/modelarts-os-apiserver/client_no_password_gcrypt.key
```

[illegible]

7. 在HCC Turnkey上执行如下命令，获取client_cert_file_decode的内容，并将文件内容进行Base64编码。

```
export client_cert_file='cat /home/data/certs/modelarts_os_20250925/client/client.pem |base64 -w 0`
python -c '
import base64; import os;
client_cert_file_decode=bytes.decode(base64.b64decode(os.getenv("client_cert_file"))).replace("\n","\n")
print (client_cert_file_decode)
```


8. 获取tls_key_scc_base64文件内容。

- a. 在HCC Turnkey节点上获取无密码的server_key的Base64字符串。

```
cat /home/data/certs/modelarts_os_20250925/server/server_no_password.key |base64 -w 0
```

- b. 在modelarts-os-apiserver容器中导入无密码的server_key的Base64字符串。
export server_no_password_key='\${server_no_password_key}'

- c. 在modelarts-os-apiserver容器中创建加密文件python脚本scc_enc.py，执行vi scc_enc.py，内容如下：

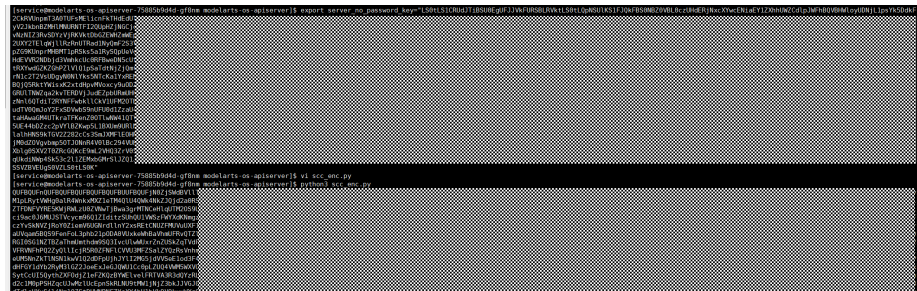
```
import base64
import sys
import os

def scc_encrypt(plain_input):
    sys.path.append("/usr/local/seccomponent/lib/")
    from CryptoAPI import CryptoAPI
    cryptoAPI = CryptoAPI()
    cryptoAPI.initialize("/opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf")
    encrypt_str = cryptoAPI.encrypt(plain_input,int(os.getenv("scc_domain_id")))
    cryptoAPI.finalize()
    return encrypt_str

if __name__ == '__main__':
    import base64; import os;

    server_no_password_key_decode=bytes.decode(base64.b64decode(os.getenv("server_no_password_key")))
    server_no_password_key_decode_scc=scc_encrypt(server_no_password_key_decode)
    print(base64.b64encode(server_no_password_key_decode_scc.encode("utf-8")).decode('utf-8'))
```

执行python3 scc_enc.py

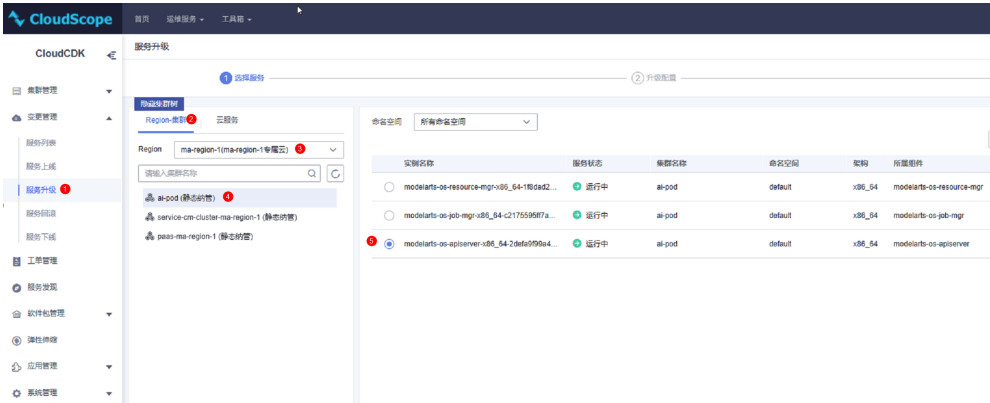


9. 使用浏览器以系统管理员登录CloudScope界面。

- 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
- CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
- 默认账号：op_cdk_sso
- 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。

10. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。

11. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，选中modelarts-os-apiserver，单击“下一步”进入参数配置。



12. 变更参数的参数值即可，此值为步骤1-8获取的变量名。

参数名称	参数类型	数据类型	模板参数	当前参数
apiserver.crt	deploy	string		
ca.crt	deploy	string		
webhook.k8s.crt	deploy	string		

表 8-11 修改 modelarts-os-apiserver 配置项

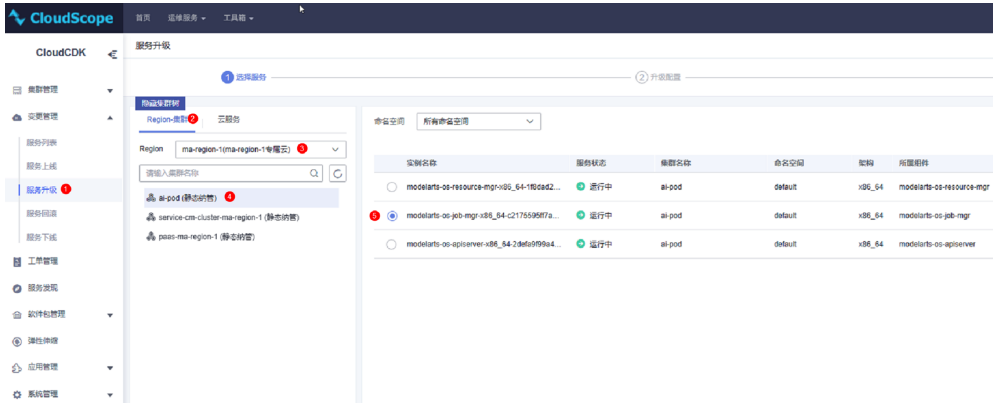
配置项名	对应步骤1-8中的变量名
etcd_ca.pem	\$root_ca_file_decode
etcd_client_key.pem	\$client_cert_file_decode
etcd_client.pem	\$client_cert_file_decode
ca.crt	\$server_cert_file
apiserver.crt	\$server_cert_file
apiserver_key	\$server_no_password_key_decode_gcrypt_base64

配置项名	对应步骤1-8中的变量名
kubeconfig	<pre>{ "apiVersion": "v1", "clusters": [{ "cluster": { "server": "https://127.0.0.1:8898", "insecure-skip-tls-verify": true }, "name": "kubernetes" }], "contexts": [{ "context": { "cluster": "kubernetes", "user": "kubernetes-admin" }, "name": "kubernetes-admin@kubernetes" }], "current-context": "kubernetes-admin@kubernetes", "kind": "Config", "preferences": {}, "users": [{ "name": "kubernetes-admin", "user": { "client-certificate-data": "\$server_cert_file", "client-key-data": "\$server_no_password_key_decode_gcrypt_base64" } }] }</pre>
ca_bundle	\$root_ca_file
webhook_tls.crt	\$server_cert_file
webhook_tls_key	\$server_no_password_key_decode_gcrypt_base64
CPU_LIMITS	当前modelarts-os-apiserver的微服务CPU_LIMITS值+1

13. 单击“下一步”，单击“升级”，等待服务升级完成。

替换 modelarts-os-job-mgr 组件证书

- 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
- 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
- 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，选中modelarts-os-job-mgr，单击“下一步”进入参数配置。



4. 变更参数的参数值即可，此值为步骤1-8获取的变量名。

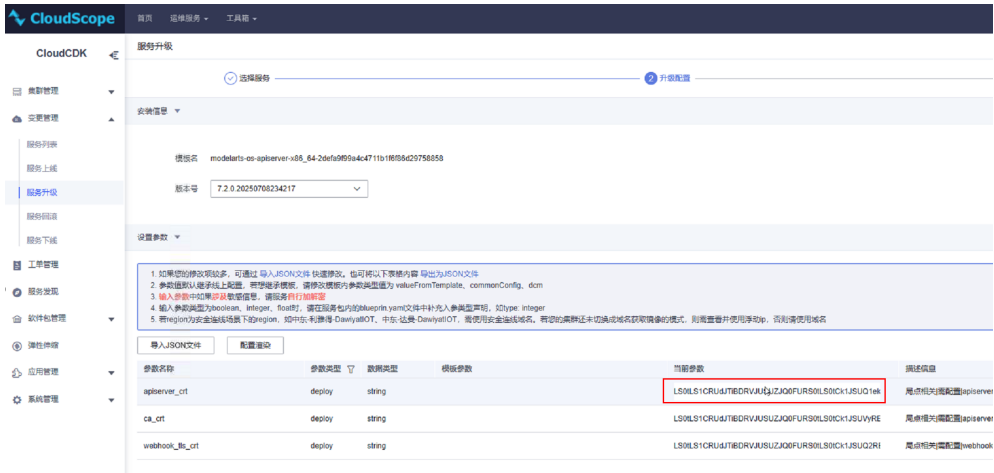


表 8-12 modelarts-os-job-mgr 修改配置项

配置项名	对应步骤1-8获取的变量名
apiserver_cert	\$server_cert_file
apiserver_key	\$server_no_password_key_decode_g crypt_base64
CPU_LIMITS	当前modelarts-os-job-mgr的微服务 CPU_LIMITS值+1

5. 单击“下一步”，单击“升级”，等待服务升级完成。

8.2.8 AI Hub 管控面证书替换

8.2.8.1 证书制作

通过制作请求文件申请的证书

- 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《华为云Stack 8.6.0 账户一览表》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

2. 执行**cd 目的路径**命令进入合适的目录。
3. 执行如下命令生成私钥文件“server.key”。

其中example为私钥的加密密码，具体操作以实际情况为准。openssl的参数说明可以参考[openssl官方文档](#)。

```
openssl genrsa -aes256 -out server.key 2048
```

根据提示输入如下相应的信息。

```
Enter pass phrase for serverkey.pem:  
#输入私钥的加密密码example。  
Verifying - Enter pass phrase for serverkey.pem:  
#再次输入私钥的加密密码example。
```

说明

请妥善保存设置的私钥密码，需要在导入证书时输入。

4. 执行如下命令生成证书请求文件“server.csr”。
- 这里的私钥密码example和前面设置的加密密码保持一致。

```
openssl req -new -key server.key -out server.csr -sha256
```

根据提示输入如下相应的信息。

```
Enter pass phrase for server.key:  
#输入私钥的加密密码example。  
You are about to be asked to enter information that will be incorporated into your certificate request.  
What you are about to enter is what is called a Distinguished Name or a DN. There are quite a few  
fields but you can leave some blank For some fields there will be a default value,  
If you enter '.', the field will be left blank.  
-----  
Country Name (2 letter code) [AU]:CN  
#此处以CN举例，可以根据局点名称自行设置，例如UK。  
State or Province Name (full name) [Some-State]:zhejiang  
#此处以zhejiang举例，可以根据局点名称自行设置，例如beijing。  
Locality Name (eg, city) []:hz  
#此处以hz举例，可以根据局点名称自行设置，例如London。  
Organization Name (eg, company) [Internet Widgits Pty Ltd]:huawei  
#此处以huawei举例，可以根据局点名称自行设置，例如bank。  
Organizational Unit Name (eg, section) []:huawei  
#此处以huawei举例，可以根据局点名称自行设置，例如bank。  
Common Name (eg, YOUR name) []:Joy  
#此处以Joy举例，可自定义。  
Email Address []:111111.com  
#Email地址，此处以111111.com举例。  
Please enter the following 'extra' attributes to be sent with your certificate request  
#证书密码和证书颁发公司名称，这里以example和huawei为例。  
A challenge password []:example  
An optional company name []:huawei
```

5. 生成私钥pem。

```
openssl rsa -in server.key -outform PEM -out server.pem
```
6. 生成CRT证书。

```
openssl x509 -req -days 365 -in server.csr -sha256 -signkey server.key -out server.crt
```
7. 生成p12证书。

```
openssl pkcs12 -export -out cert.p12 -inkey server.key -in server.crt
```
8. 执行以下命令对证书进行Base64编码。

```
base64 -w 0 cert.p12
```

8.2.8.2 modelarts-market-manager 证书替换


ModelArts-ai-hub支持替换证书的微服务主要是modelarts-market-service、modelarts-market-manager，这2个微服务的证书一致并且替换证书方式一致。

前提条件

已获取新的替换证书，并将证书内容进行了Base64编码。

操作步骤

1. 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
3. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，例如选中modelarts-market-manager，单击“下一步”进入参数配置。
4. 修改SSL_CERT_P12的参数值为8生成的字符串。



5. 单击“下一步”，单击“升级”，等待服务升级完成。升级完成表示证书替换完成。


8.2.8.3 modelarts-market-service 证书替换

前提条件


- 已获取新的cert.p12替换证书，并将证书内容进行了base64转码。

操作步骤

1. 使用二级承载租户登录CCE服务，找到modelarts-market-service集群，单击集群名称进入。
2. 单击“配置与密钥”，切换至“密钥”页签，找到“market-service-secret”密钥，单击更新。



3. 在弹出的更新密钥窗口，单击键值为“cert.p12”操作列的“编辑”。




4. 将证书进行Base64编码后添加到值内，并单击“确定”。



5. 选中“工作负载”下的“无状态负载”，找到“market-service-secret”工作负载，单击操作列的“升级”。



6. 修改“容器-1”的配额后，单击“升级工作负载”。



升级完成表示证书替换完成。

8.2.9 开发环境管控面证书替换

8.2.9.1 证书制作

通过制作请求文件申请的证书

- 以root用户登录Linux操作系统，且该系统上已安装OpenSSL工具，OpenSSL的参数说明可以参考[openssl官方文档](#)。
 - 执行`cd 目的路径`命令进入合适的目录。
 - 执行如下命令生成私钥文件“server.key”。
- openssl genrsa -aes256 -out server.key 3072

根据提示输入如下私钥的加密密码，以“example”为例，记为ssl_key_password。

```
Enter pass phrase for serverkey.pem:  
#输入私钥的加密密码example。  
Verifying - Enter pass phrase for serverkey.pem:  
#再次输入私钥的加密密码example。
```

说明

- 以上“example”仅作为示例，请勿作为实际密码使用，真实密码时以用户需求为准。
 - 请妥善保存设置的私钥密码，需要在导入证书时输入。
- 执行如下命令生成证书请求文件“server.csr”。
- 这里的私钥密码example和前面设置的加密密码保持一致。
- openssl req -new -key server.key -out server.csr -sha256
- 根据提示输入如下相应的信息。
- Enter pass phrase for server.key:
#输入私钥的加密密码example。
You are about to be asked to enter information that will be incorporated into your certificate request.
What you are about to enter is what is called a Distinguished Name or a DN. There are quite a few
fields but you can leave some blank For some fields there will be a default value,
If you enter '.', the field will be left blank.

```
-----
Country Name (2 letter code) [AU]:CN
#此处以CN举例，可以根据局点名称自行设置，例如UK。
State or Province Name (full name) [Some-State]:zhejiang
#此处以zhejiang举例，可以根据局点名称自行设置，例如beijing。
Locality Name (eg, city) []:hz
#此处以hz举例，可以根据局点名称自行设置，例如London。
Organization Name (eg, company) [Internet Widgits Pty Ltd]:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Organizational Unit Name (eg, section) []:huawei
#此处以huawei举例，可以根据局点名称自行设置，例如bank。
Common Name (eg, YOUR name) []:Joy
#此处以Joy举例，可自定义。
Email Address []:111111.com
#Email地址，此处以111111.com举例。
Please enter the following 'extra' attributes to be sent with your certificate request
#证书密码和证书颁发公司名称，这里以ModelHub@123和huawei为例。
A challenge password []:Dev@123
An optional company name []:huawei
```

5. 执行如下命令生成私钥pem。
openssl rsa -in server.key -outform PEM -out server.pem
6. 执行如下命令生成CRT证书。
openssl x509 -req -days 365 -in server.csr -sha256 -signkey server.key -out server.crt
7. 执行如下命令生成p12证书。
openssl pkcs12 -export -out cert.p12 -inkey server.key -in server.crt

8.2.9.2 证书替换

证书清单

表 8-13 证书清单


证书名称	功能描述
cert.p12	开发环境AuthoringService服务端证书。

操作步骤

说明

证书替换前请先获取证书内容以及证书加密密码。

1. 对证书密码进行SCC加密。
 - a. 登录CDK master节点的modelarts-authoring-service的容器。
kubect exec -it modelarts-authoring-service-6dd46b7bc-42klf bash
modelarts-authoring-service-6dd46b7bc-42klf 需要替换为实际的POD名称。
 - b. 执行加密命令。
/usr/local/seccomponent/bin/CryptoAPI -e -f /opt/cloud/3rdComponent/scc/kmc.conf -i 317
在输入提示框中输入3记录的ssl_key_password进行加密。
2. 保存证书密文，按照以下步骤将该密文更新到数据库中。
 - a. 进入ServiceOM，查询数据库所在虚拟机，找到如下名称的虚拟机。



b. 登录虚拟机，并执行如下命令登录数据库：
`mysql -udbadmin -pxxxxxxxx -P7306 -S/data/mysql/tmp/mysql.sock`

c. 执行如下命令查询是否主节点：
`SHOW VARIABLES LIKE 'read_only';`

如果值为off，表示为主节点，则执行如下命令：

其中，ssl_scc_password表示证书加密密码，执行sql时需要替换为实际值

```
INSERT INTO t_sysparam VALUES ('server.ssl.key-password', 1, 'wushan.zookeeper.ssl.trust-store-location', 0, '${ssl_scc_password}');  
INSERT INTO t_sysparam VALUES ('server.ssl.key-store-password', 1, 'wushan.zookeeper.ssl.trust-store-location', 0, '${ssl_scc_password}');
```

3. 使用浏览器以系统管理员登录CloudScope界面。

- 登录地址：<https://CloudScope>界面的访问地址。例如，<https://cloudscope.demo.com>。
- CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
- 默认账号：op_cdk_sso
- 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。

4. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。

5. 左侧选择“变更管理 > 服务升级 > Region-集群 > ai-pod”，选中需要替换证书的微服务名称，搜索modelarts-authoring-service，选中查询结果，单击“下一步”进入参数配置。

6. 执行以下命令，对证书进行Base64编码。 `base64 -w 0 cert.p12`

7. 搜索参数SSL_CERT_P12，使用6中Base64编码后的值替换；搜索参数resources.requests.memory，在原值的基础上减去0.1。



8. 单击“下一步”，单击“升级”，等待服务升级完成。升级完成表示证书替换完成。

8.2.10 昇腾云脑管控面证书替换

8.2.10.1 证书制作

证书清单

表 8-14 证书清单

证书名称	功能描述
modelarts-brain.jks	昇腾云脑jks证书

操作步骤

1. 在java官方网站下载并安装jdk。
本文以“jdk8”，操作系统是“win10 64位”为例介绍。例如安装到“D:\opt\jdk1.8.0_212\”。
2. 在计算机上选择“开始 > 运行”，输入cmd，弹出“cmd.exe”命令输入框，执行`cd D:\opt\jdk1.8.0_212`命令进入jdk安装目录下的“bin”目录，执行如下命令：

```
./keytool -genkey -alias modelarts-brain -keyalg RSA -keysize 4096 -dname "CN=modelarts-brain.myhuaweicloud.com, OU=Huawei Cloud,O=Huawei, C=CN" -ext SAN=dns:modelarts-brain.myhuaweicloud.com -keystore modelarts-brain.jks -validity 365
```


-validity表示生成的证书有效期是多少天。keytool的详细参数说明可以参考：
<https://docs.oracle.com/javase/8/docs/technotes/tools/windows/keytool.html>
按回车执行，会提示需要输入口令。输入口令并确认后，会生成modelarts-brain.jks文件。
需要记录密钥库口令。

📖 说明

请妥善保存设置的密钥库口令，需要在证书替换时使用。
命令运行完成后，在当前目录下会生成证书modelarts-brain.jks。
可以使用如下命令查看证书的有效期。

```
./keytool -list -v -keystore modelarts-brain.jks
```

8.2.10.2 证书替换

📖 说明

证书替换前请先获取证书内容以及证书加密密码。

1. 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso

- 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
3. 执行以下命令，对modelarts-brain.jks使用base64编码，得到配置项modelarts-brain.jks的值。
base64 -w 0 modelarts-brain.jks
4. 使用SCC对新证书的密码加密，得到配置项ssl_keystore_password的值。

a. 登录CDK master节点的modelarts-ascend-brain容器。
kubectl exec -it modelarts-ascend-brain-6dd46b7bc-42klf bash

modelarts-ascend-brain-6dd46b7bc-42klf需要替换为实际的POD名称。

b. 执行加密命令。
/opt/cloud/3rdComponent/jre/bin/java -jar -Dspring.profiles.active=cli -Dwushan.scc.crypto.domainId=317 -Dwushan.scc.crypto.logPath=/opt/cloud/logs/scc/ -Dwushan.scc.crypto.primaryKeyStoreFile=/opt/cloud/scc/primary.keystore -Dwushan.scc.crypto.standbyKeyStoreFile=/opt/cloud/scc/standby.keystore /opt/cloud/modelarts-brain/tool/dalf-admin-scc-generator-1.0.0.jar -e 证书制作中记录的密钥库口令
5. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，搜索modelarts-ascend-brain，选中查询结果。单击“下一步”进入参数配置。



需要变更的参数如下：

说明

参数替换前，建议先将配置值备份。

表 8-15 需要变更的参数

配置项名称	配置项值
modelarts-brain.jks	3得到的值。
ssl_keystore_password	\${SCC(xxxxxxxx)} 使用4得到的值替换xxxxxxxx。

参数值替换后，单击升级。

8.2.11 推理 2.0 管控面证书替换

8.2.11.1 证书制作

操作步骤

步骤1 使用PuTTY工具以sopuser用户登录HCC Turnkey工具所在主节点，默认密码参考《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签，搜索“HCC Turnkey虚拟机”获取sopuser的密码。

执行以下命令切换到root用户。

```
su - root
```

步骤2 执行如下命令，创建服务端证书目录。

```
path_cert=/home/data/certs/modelarts_infers_20250925
rm -rf $path_cert/server/server.key
rm -rf $path_cert/server/server.csr
mkdir -p $path_cert/server
```

步骤3 在HCC Turnkey节点上执行vi /home/data/certs/modelarts_infers_20250925/server/openssl.conf命令创建服务端证书配置openssl.conf，并添加如下文件内容。

```
[ req ]
default_bits = 2048
prompt = no
default_md = sha256
distinguished_name = dn

[ dn ]
CN = modelarts
C = CN
ST = Guangdong
L = Shenzhen
O = Huawei
OU = Huawei Cloud

[ v3_ca ]
basicConstraints = critical, CA:TRUE, pathlen:1
keyUsage = critical, digitalSignature, cRLSign, keyCertSign
subjectKeyIdentifier = hash
authorityKeyIdentifier = keyid:always,issuer


[ alt_names ]
IP.1 = 127.0.0.1
DNS.1 = localhost
DNS.2 = *.infer.modelarts.huawei.com

[ usr_cert ]
basicConstraints = CA:FALSE
keyUsage = critical, digitalSignature, keyEncipherment, nonRepudiation, keyAgreement
extendedKeyUsage = serverAuth, clientAuth
subjectAltName = @alt_names
```

步骤4 执行如下命令生成ModelArts Infers服务端私钥。

```
openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out $path_cert/server/server.key -aes-256-cbc
```

图 8-3 生成 ModelArts Infers 服务端私钥



```
[root@localhost server]# openssl genpkey -algorithm RSA -pkeyopt rsa_keygen_bits:4096 -out $path_cert/server/server.key -aes-256-cbc
.....
Enter PEM pass phrase: 
Verifying - Enter PEM pass phrase: 
[root@localhost server]# ll
total 16
```

说明

输入密码时需注意：假设密码为password_cert，需重复输入2次进行确认。

步骤5 执行如下命令生成ModelArts Infers服务端CSR。

```
openssl req -new -key $path_cert/server/server.key -out $path_cert/server/server.csr -config $path_cert/server/openssl.conf -extensions usr_cert
```

图 8-4 生成 ModelArts Infers 服务端 CSR

```
[root@localhost server]# openssl req -new -key $path_cert/server/server.key -out $path_cert/server/server.csr -config $path_cert/server/openssl.conf -extensions usr_cert
Enter pass phrase for /home/data/certs/modelarts_os_20250925/server/server.key:
[root@localhost server]#
```

说明

此处输入的密码为服务端私钥密码，即上一步的密码password_cert。

步骤6 执行如下命令获取局点HCC Turnkey统一CA私钥密码。

```
export turnkey_ca_password=`cat /home/data/certs/Turnkey/ca/rsa/subca.key.pwd`
su hcci -s /bin/bash -c "export PYTHONPATH=/opt/cloud/hcci/src/HCCI/;/opt/Python39/bin/python3 -c 'from platforms.utils.security import crypt;import os; print(crypt.decrypt(os.getenv(\"turnkey_ca_password\")))'"
```

```
[root@localhost server]# export turnkey_ca_password=`cat /home/data/certs/Turnkey/ca/rsa/subca.key.pwd`
[turnkey_ca_password]`[root@localhost server]# su hcci -s /bin/bash -c "export PYTHONPATH=/opt/cloud/hcci/src/HCCI/;/opt/Python39/bin/python3 -c 'from platforms.utils.security import
rt crypt;import os; print(crypt.decrypt(os.getenv(\"turnkey_ca_password\")))'"
q[turnkey_ca_password]
[root@localhost server]#
```

步骤7 执行如下命令生成ModelArts Infers服务端签名证书。

```
openssl x509 -req -in $path_cert/server/server.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -out $path_cert/server/server.pem -days 36500 -extfile $path_cert/server/openssl.conf -sha256 -extensions usr_cert
```

```
[root@localhost server]# openssl x509 -req -in $path_cert/server/server.csr -CA /home/data/certs/Turnkey/ca/rsa/subca.pem -CAkey /home/data/certs/Turnkey/ca/rsa/subca.key -CAcreateserial -o
ut $path_cert/server/server.pem -days 36500 -extfile $path_cert/server/openssl.conf -sha256 -extensions usr_cert
Signature ok
subject=CN = ModelArts_OS_Server, C = CN, ST = Guangdong, L = Shenzhen, O = Cloud, OU = CloudService
Getting CA Private Key
Enter pass phrase for /home/data/certs/Turnkey/ca/rsa/subca.key:
[root@localhost server]#
```

说明

此处输入的密码为局点HCC Turnkey统一CA私钥密码，即**步骤6**获取的密码。

步骤8 获取服务端证书及私钥相关信息。**图 8-5** 获取服务端证书及私钥相关信息

```
[root@localhost server]# ll
total 16
-rw----- 1 root root 658 Sep 25 23:14 openssl.conf
-rw-r----- 1 root root 1720 Sep 25 23:37 server.csr
-rw----- 1 root root 3434 Sep 25 23:36 server.key
-rw-r----- 1 root root 2139 Sep 25 23:52 server.pem
[root@localhost server]# pwd
/home/data/certs/modelarts_os_20250925/server
```

步骤9 执行如下命令生成cert.pkcs12文件。

```
openssl pkcs12 -export -in server.pem -inkey server.key -out cert.pkcs12 -name "ModelArts"
```

说明

此处输入的密码为服务端私钥密码，即**步骤4**的密码password_cert。

步骤10 执行以下命令对证书使用base64编码。

```
base64 -w 0 cert.pkcs12
```

图 8-6 对证书使用 base64 编码



----结束

8.2.11.2 证书替换

操作步骤

说明

证书替换前请先获取证书内容以及证书加密密码。

步骤1 对证书密码进行SCC加密。

- 1. **登录CDK master节点**，执行**kubectl get pod**命令查看pod，然后找到modelarts-infers-manager容器对应的pod并登录。
kubectl get pod

```
[root@ModelArts-Common-Region-POD-Master-0003 ~]#  
[root@ModelArts-Common-Region-POD-Master-0003 ~]# kubectl get pod  
NAME                                READY   STATUS    RESTARTS   AGE  
modelarts-algorancher-7c894d576f-gjnjt    1/1     Running   0           2d18h  
modelarts-algorancher-7c894d576f-t6v5n    1/1     Running   0           2d18h  
modelarts-ascend-brain-84fcf85b55-hpb2q    1/1     Running   0           2d5h  
modelarts-ascend-brain-84fcf85b55-rfdf5    1/1     Running   0           2d5h  
modelarts-authoring-service-589ff66889-7mn8c 1/1     Running   0           2d20h  
modelarts-authoring-service-589ff66889-bq5bh 1/1     Running   0           2d20h  
modelarts-billing-6f546bd4c-gtw48         1/1     Running   0           2d20h  
modelarts-billing-6f546bd4c-vzvl5         1/1     Running   0           2d20h  
modelarts-console-backend-5c954d6f89-6sh4t 1/1     Running   0           2d20h  
modelarts-edge-api-7bb458867d-kmv94       1/1     Running   0           3h26m  
modelarts-edge-api-v2-857bbb8ccb-gtv2j    1/1     Running   0           2d5h  
modelarts-edge-dm-d458f8f5b-hchjh        1/1     Running   0           4h35m  
modelarts-edge-dm-d458f8f5b-qhphj4       1/1     Running   0           4h35m  
modelarts-edge-dm-v2-56bb9747d6-rftf2    1/1     Running   0           11d  
modelarts-exemlflow-55d94bf6d9-mfpb9     1/1     Running   0           2d20h  
modelarts-exemlflow-55d94bf6d9-qh7sf     1/1     Running   0           2d20h  
modelarts-infers-manager-556745649d-65hrf 1/1     Running   0           74m  
modelarts-infers-manager-556745649d-69l2q 1/1     Running   0           68m  
modelarts-market-manager-cdk-877b66c6-7gv2j 1/1     Running   0           52d  
modelarts-market-manager-cdk-877b66c6-brxcw 1/1     Running   0           18d  
modelarts-market-manager-cdk-877b66c6-nhmgr 0/1     Terminating 1           52d  
modelarts-os-apiserver-9bcd6d8c8-cvcpq    1/1     Running   0           2d20h  
modelarts-os-apiserver-9bcd6d8c8-trr8f    1/1     Running   0           2d20h  
modelarts-os-job-mgr-57b4fb74b9-kkp5b    1/1     Running   0           2d20h  
modelarts-os-job-mgr-57b4fb74b9-z4htg    1/1     Running   0           2d20h  
modelarts-os-resource-mgr-7674796b5f-f5fvm 1/1     Running   0           2d20h  
modelarts-os-resource-mgr-7674796b5f-ps5xf 1/1     Running   0           2d20h  
modelarts-system-gateway-657d98db9f-l6kbw 1/1     Running   0           2d20h  
modelarts-system-gateway-657d98db9f-n6qqz 1/1     Running   0           2d20h  
modelarts-webapp-gateway-cdk-85857fd968-c9h4g 1/1     Running   0           2d20h  
modelarts-webapp-gateway-cdk-85857fd968-cj4nt 1/1     Running   0           2d20h
```

执行如下命令登录pod。

```
kubectl exec -it modelarts-infers-manager-556745649d-69l2q bash
```

modelarts-infers-manager-556745649d-69l2q需要替换为实际的POD名称。

- 2. 执行加密命令。
/usr/local/seccomponent/bin/CryptoAPI -e -f /opt/cloud/3rdComponent/scc/kmc.conf -i 317
在输入提示框中输入明文密码进行加密。（ password_cert ）

步骤2 参考**登录MySQL数据库**指导登录到新版推理数据库节点（ ModelArts-Infers-MySQL ），参考如下update语句修改 “t_sysparam” 表参数值。


执行sql时需要替换为实际值（ 使用**步骤1.2**生成的值替换变量'\$ {server_ssl_key_password_scc}' ）

```
update t_sysparam set value='${server_ssl_key_password_scc}' where name = 'server.ssl.key-password';  
update t_sysparam set value='${server_ssl_key_password_scc}' where name = 'server.ssl.key-store-  
password';
```

```
mysql> update t_sysparam set value= 'AAAAA' where name = 'server.ssl.key-password';  
Query OK, 1 row affected (0.35 sec)  
Rows matched: 1 Changed: 1 Warnings: 0  
  
mysql> update t_sysparam set value= 'AAAAA' where name = 'server.ssl.key-store-password';  
Query OK, 1 row affected (0.27 sec)  
Rows matched: 1 Changed: 1 Warnings: 0  
  
mysql> select * from t_sysparam where name in ('server.ssl.key-password', 'server.ssl.key-store-password');  
mysql>  
+-----+-----+-----+-----+-----+  
| name | cacheable | comment | encrypted | value |  
+-----+-----+-----+-----+-----+  
| server.ssl.key-password | 1 | server.ssl.key-password | 1 | AAAAA |  
| server.ssl.key-store-password | 1 | server.ssl.key-store-password | 1 | AAAAA |  
+-----+-----+-----+-----+-----+  
2 rows in set (0.00 sec)
```

步骤3 升级CDK服务modelarts-infers-manager

1. 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope>界面的访问地址。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
3. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，搜索modelarts-infers-manager，选中查询结果。单击“下一步”进入参数配置。



4. 搜索参数SSL_CERT_PASSWORD，使用步骤1生成的值替换。
5. 搜索参数SSL_CERT_P12，使用步骤10生成的值替换。单击下一步确认信息后进行升级。
6. 左侧选择变更管理>服务列表，搜索“modelarts-infers-manager”，单击对应的服务“详情”，跳转后将下面两个pod删除，手动重启服务使证书生效。

----结束

8.2.12 system-gateway 管控面证书替换

8.2.12.1 证书制作

证书清单

表 8-16 证书清单

证书名称	功能描述
RSE.jks	system-gateway jks证书

操作步骤

1. 在java官方网站下载并安装jdk。
本文以“jdk8”，操作系统是“win10 64位”为例介绍。例如安装到“D:\opt\jdk1.8.0_212\”。
2. 在计算机上选择“开始 > 运行”，输入cmd，弹出“cmd.exe”命令输入框，执行cd D:\opt\jdk1.8.0_212命令进入jdk安装目录下的“bin”目录，执行如下命令：

```
./keytool -genkey -alias modelarts-system-gateway -keyalg RSA -keysize 4096 -dname "CN=modelarts-system-gateway.myhuaweicloud.com, OU=Huawei Cloud,O=Huawei, C=CN" -ext SAN=dns:modelarts-system-gateway.myhuaweicloud.com -keystore RSE.jks -validity 365
```


-validity表示生成的证书有效期是多少天。
敲回车执行，会提示需要输入口令。输入口令并确认后，会生成RSE.jks文件。
需要记录密钥库口令。

说明

请妥善保存设置的密钥库口令，需要在证书替换时使用。
命令运行完成后，在当前目录下会生成证书modelarts-brain.jks。
可以使用如下命令查看证书的有效期。

```
./keytool -list -v -keystore RSE.jks
```

8.2.12.2 证书替换

说明

证书替换前请先获取证书内容以及证书加密密码。

1. 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。

3. 执行以下命令，对jks使用base64编码，得到配置项server_ssl_key_store_file的值。
base64 -w 0 RSE.jks
4. 使用SCC对新证书的密码加密，得到配置项server_ssl_key_password的值。

a. 登录CDK master节点的modelarts-system-gateway的容器。
kubect exec -it modelarts-system-gateway-678d95bd8d-6vrrm bash

modelarts-system-gateway-678d95bd8d-6vrrm 需要替换为实际的POD名称。

b. 执行加密命令。
/usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/modelarts-system-gateway/config/sec/scc.conf

输入证书制作中记录的密钥库口令，生成加密后的字符串。
5. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，搜索system-gateway，选中查询结果。单击“下一步”进入参数配置。
需要变更的参数如下：
参数替换前，建议先将配置值备份。

表 8-17 替换配置值

配置项名称	配置项值
server_ssl_key_store_file	3得到的值。
server_ssl_key_password	\${SCC(xxxxxxxx)} 使用4得到的值替换xxxxxxxx

参数值替换后，单击“升级”。

8.2.13 Edge 管控面证书替换

8.2.13.1 证书制作

证书清单

表 8-18 证书清单

证书名称	功能描述
modelarts-edge.pfx	modelarts-edge pfx证书
root.jks	root jks证书

操作步骤

1. 在java官方网站下载并安装jdk。
本文以“jdk8”，操作系统是“win10 64位”为例介绍。例如安装到“D:\opt\jdk1.8.0_212\”。

2. 在计算机上选择“开始 > 运行”，输入cmd，弹出“cmd.exe”命令输入框，执行cd D:\opt\jdk1.8.0_212命令进入jdk安装目录下的“bin”目录，执行如下命令生成modelarts-edge.pfx：

```
./keytool -genkey -alias modelarts-edge -keyalg RSA -keysize 4096 -dname "CN=modelarts, OU=Huawei Cloud,O=Huawei, C=CN" -storetype PKCS12 -keystore modelarts-edge.pfx -validity 365
```

-validity表示生成的证书有效期是多少天。

敲回车执行，会提示需要输入口令。输入口令并确认后，会生成modelarts-edge.pfx文件。

需要记录密钥库口令。

执行如下命令生成root.jks：

```
./keytool -genkey -alias hilens-root -keyalg RSA -keysize 4096 -dname "CN=modelarts, OU=Huawei Cloud,O=Huawei, C=CN" -storetype JKS -keystore root.jks -validity 365
```

敲回车执行，会提示需要输入口令。输入口令并确认后，会生成root.jks文件。

需要记录密钥库口令。

说明

请妥善保存设置的密钥库口令，需要在证书替换时使用。

3. 命令运行完成后，在当前目录下会生成证书modelarts-edge.pfx和root.jks。可以使用如下命令查看证书的有效期。

```
./keytool -list -v -keystore modelarts-edge.pfx  
./keytool -list -v -keystore root.jks
```

8.2.13.2 证书替换

说明

证书替换前请先获取证书内容以及证书加密密码。

1. 使用浏览器以系统管理员登录CloudScope界面。
 - 登录地址：<https://CloudScope界面的访问地址>。例如，<https://cloudscope.demo.com>。
 - CloudScope界面访问地址请参见安装自动化变更平台组件时由HCC Turnkey导出的部署参数表中“Portal”页签的“COP”相关信息。
 - 默认账号：op_cdk_sso
 - 默认账号密码，请参见《[华为云Stack 8.6.0 账户一览表](#)》的“CloudScopeLite”页签，搜索该账户对应的默认密码。
2. 上方导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”，进入CDK界面。
3. 执行以下命令，对modelarts-edge.pfx使用base64编码，得到配置项default_keystore的值。

```
base64 -w 0 modelarts-edge.pfx
```
4. 执行以下命令，对root.jks使用base64编码，得到配置项root_jks的值。

```
base64 -w 0 root.jks
```
5. 使用SCC对新证书的密码加密。
 - a. 登录CDK master节点的modelarts-edge-api的容器。

```
kubect exec -it modelarts-edge-api-678d95bd8d-6vrrm bash
```

modelarts-edge-api-678d95bd8d-6vrrm 需要替换为实际的POD名称。
 - b. 执行加密命令。

```
/usr/local/seccomponent/bin/CryptoAPI -i 317 -e -f /opt/cloud/hilens-api/config/scc.conf
```

输入证书制作中记录的密钥库口令，生成加密后的字符串。

6. 左侧选择“变更管理 > 服务升级”，选中需要替换证书的微服务名称，搜索 edge-api和edge-dm，选中查询结果。单击“下一步”进入参数配置。
- 需要变更的参数如表8-19：
- 参数替换前，建议先将配置值备份。

表 8-19 替换配置值

配置项名称	配置项值
default_keystore	3得到的值。
server_ssl_key_password	\${ENC(xxxxxxx)}使用5得到的值替换xxxxxxx。
server_ssl_key_store_password	\${ENC(xxxxxxx)}使用5得到的值替换xxxxxxx。
root_jks	4得到的值。
cert_root_passwd	5得到的值。

参数值替换后，单击“升级”。

8.3 安全加固

ModelArts相关的安全加固项，请参见《[华为云Stack 8.6.0 安全加固项一览表](#)》。

8.4 安全维护

提供日常安全维护方面的建议，包括账户、密码和日志维护建议。用户在制定安全管理方面的制度时，可以参考并加以落实。

账户维护建议

建议系统管理员对账号例行检查，检查的内容包括：

- 操作系统、数据库的账号是否必要，临时账号是否已删除。
- 账号的权限是否合理。
- 对账号的登录、操作日志进行检查和审计。
- 保管好节点运维账号，严格控制节点运维账号的权限和发放范围。避免节点的重要文件被随意修改。

密码维护建议

用户身份验证是应用系统的门户。用户的账号和密码的复杂性、有效期等需根据客户的安全要求进行配置。

对密码的维护建议如下：

- 系统提供的所有的默认密码，包括操作系统、数据库、预置用户等的默认密码，都必须在安装完成后进行修改。
- 每隔90天修改一次密码。
- 专人保管主机root密码。
- 密码传递时要进行加密，尽量避免通过邮件传递密码。
- 密码需要加密存储。
- 系统移交时提醒客户更改密码。
- 操作系统输入密码时，支持直接输入和交互式输入两种方式。直接输入密码有可能存在密码泄露的风险。请执行命令时以交互式方式输入密码。
- 必须在密码过期之前完成修改。

日志维护建议

利用日志记录来帮助发现非法操作、非法登录用户等异常情况。系统对于重要业务的操作需要记录日志。通过日志文件来定位异常。

9 服务监控

9.1 概述

监控目的

日常监控的目的主要是对ModelArts的服务状态、性能指标等健康状态进行监控，以保障现网的服务能力。

监控内容

ModelArts支持通过ManageOne统一监控平台进行指标监控，监控内容包括管控面和租户面监控指标、租户资源详情和管控面节点指标。

9.2 查看监控指标

9.2.1 查看租户资源

操作场景

通过ManageOne运维面，租户管理员可以查看相关ModelArts租户资源的基本信息。

操作步骤

1. [以系统管理员账号登录ManageOne运维面](#)。
2. 在主菜单中选择“监控 > 资源监控”，进入“资源监控”页面。
3. “资源分类”选择“云服务”，“当前可选类别”选择“ModelArts服务”，在下方列表中单击名称进入详情页面。
4. 在详情页面，可在“租户实例”页面查看“ModelArts 推理AI模型”、“ModelArts AI节点”、“ModelArts 资源池”、“ModelArts 推理服务”、“ModelArts 训练作业”、“ModelArts 新版推理服务”、“ModelArts 工作空间”的租户资源相关信息。

 说明

ModelArts 推理服务中的异步、批量和边缘服务暂未对接监控指标，待后续功能补齐。

9.2.2 查看云服务资源

操作场景

通过华为云Stack系统可以收集ModelArts服务的指标信息及运行状态信息。及时对异常指标产生告警，发送信息提醒运维人员，保障业务可用性。

操作步骤

1. [以系统管理员账号登录ManageOne运维面](#)。
2. 在主菜单中选择“监控 > 资源监控”，进入“资源监控”页面。
3. “资源分类”选择“云服务”，“当前可选类别”选择“ModelArts服务”，在下方列表中单击名称进入详情页面。
4. 在云服务详情页面，可在左侧菜单栏中查看云服务基本信息，包括概览、拓扑视图、监控视图、组件列表、租户实例，也可在告警列表、自动作业、异常主机定位、运行日志、账号管理和昇腾云脑中进行其他操作维护。
 - 在左侧导航单击“拓扑视图”，查看拓扑视图详情。
 - 查看当前云服务节点间的逻辑关系。
 - 将鼠标移到某个资源图标上，弹框展示资源的名称、ID、类型等信息。
 - 当资源运行状态出现异常时，可查看各层的哪些资源受到了影响。
 - 双击资源图标，跳转到对应资源的“拓扑视图”页面，仅部分资源支持跳转。
 - 左侧导航单击“监控视图”，选择节点、指标等查看节点的监控详情。
 - 左侧导航单击“组件列表”，可查看组件和关联资源的告警信息，包括云服务、微服务、微服务实例、部署节点、管理虚拟机、宿主机等。
 - 左侧导航单击“租户实例”，可查看“ModelArts 推理AI模型”、“ModelArts AI节点”、“ModelArts 资源池”、“ModelArts 新版推理服务”“ModelArts 推理服务”、“ModelArts 训练作业”和“ModelArts 工作空间”。
 - 左侧导航单击“告警列表”，显示云服务所关联资源的告警信息。
 - 单击管理面“当前告警”页签，可查看管理面当前告警列表信息。
 - 单击管理面“屏蔽告警”页签，可查看屏蔽告警列表信息。
 - 单击管理面“历史告警”页签，可查看历史告警列表信息。
 - 单击租户面“当前告警”页签，可查看租户面上报的当前告警。
 - 左侧导航单击“自动作业”，可查看作业管理、编排管理和操作管理。
 - 左侧导航单击“异常主机定位”，可分析并定位出现异常的主机，并指导运维人员执行规避操作，以缩短故障恢复时间。
 - 左侧导航单击“运行日志”，可查看或下载管理面日志。

- 左侧导航单击“账号管理”，可查看当前服务所有的账号，并支持对账号进行延期、修改和校验等操作。在账号列表页，可单击账号名，进入账号详情，查看账号的基本信息、关联组件和历史任务。
- 左侧导航单击“昇腾云脑”，可跳转至昇腾云脑页面进行AI作业运维。昇腾云脑使用指南请参考[ModelArts 7.2.1-HCS 维护指南\(for 华为云Stack 8.6.0\)](#) 01>《昇腾云脑使用手册(for 华为云Stack 8.6.0)》。

📖 说明

关于更多ManageOne云服务资源监控的介绍及详细操作请参考《[华为云Stack 8.6.0 产品文档](#)》的“资源监控”章节。

9.2.3 查看虚拟机资源

操作场景

系统管理员可通过ManageOne运维面的“监控”功能，对ModelArts服务的管控面虚拟机进行监控，包括节点的概览、资源详情、拓扑视图、当前告警和性能视图。

操作步骤

1. [以系统管理员账号登录ManageOne运维面](#)。
2. 在主菜单中选择“监控 > 资源监控”，进入“资源监控”页面。
3. “资源分类”选择“云服务”，“当前可选类别”选择“ModelArts服务”，在下方列表中单击名称进入详情页面。
4. 在云服务详情页面，左侧菜单栏单击“组件列表”，“分类”选择“关联资源”，“当前可选类别”选择“管理虚拟机”，查看虚拟机资源。
5. 单击虚拟机名称进入“概览信息”列表，显示虚拟机的“基本信息”、“告警”和“组件运行状态”情况。
 - 在左侧导航单击“拓扑视图”，查看拓扑视图详情。
 - 查看当前资源与各层级资源间的逻辑关系。
 - 将鼠标移到某个资源图标上，弹框展示资源的名称、ID、类型等信息。
 - 当资源运行状态出现异常时，可查看各层的哪些资源受到了影响。
 - 双击资源图标，跳转到对应资源的“拓扑视图”页面，仅部分资源支持跳转。
 - 左侧导航单击“监控视图”，可选择不同“指标”来查看此虚拟机的相关指标信息。
 - 左侧导航单击“组件列表”，可查看网卡和管理磁盘。
 - 默认进入“网卡”页面，此页面展示虚拟机的Mac地址、状态等信息。
 - 单击“管理磁盘”页签，可查看磁盘信息。
 - 左侧导航单击“告警列表”，显示此虚拟机对应的告警信息，也可在告警列表的操作列对告警进行确认、清除和发送邮件通知等操作。

9.3 监控指标一览表

管控面监控指标

表 9-1 ModelArts-Region 监控表

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
modelarts-gaussdb	ModelArts_region_cloud_disk健康检查。	/opt目录下磁盘容量。	/opt/backup /opt/cloud /opt/gaussdb	6005008 ModelArts管理区节点磁盘容量告警 [/opt/cloud]。
		/var/log目录所挂磁盘空间。	-	6005007 ModelArts管理区节点磁盘容量告警 [/var/log]。
	ModelArts_gaussdbcore健康检查。	GaussDB目录所挂磁盘空间。	-	6005001 ModelArts高斯数据库磁盘容量不足。
		gaussdb进程状态。		6005002 ModelArts高斯数据库进程异常。
	ModelArts Region区节点登录用户密码过期检查。	Region节点登录用户密码状态。	-	6005047 ModelArts管理区节点密码过期告警。
modelarts-mysql	ModelArts_region_cloud_disk健康检查。	/var/log目录所挂磁盘空间。	-	6005007 ModelArts管理区节点磁盘容量告警 [/var/log]。
	ModelArts MySQL健康检查。	mysql数据目录磁盘空间。	-	6005015 ModelArts MySQL数据库磁盘容量不足。
		mysql进程状态。		6005016 ModelArts MySQL数据库进程异常。
	ModelArts Region区节点登录用户密码过期检查。	Region节点登录用户密码状态。	-	6005047 ModelArts管理区节点密码过期告警。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
modelarts - common- proxy	ModelArts_region_disk健康检查。	/var/log目录所挂磁盘空间。	-	6005007 ModelArts管理区节点磁盘容量告警[/var/log]。
	ModelArts Proxy服务进程和端口指标监控。	ModelArts Proxy服务端口状态。	-	6005034 ModelArts Proxy服务端口异常。
		ModelArts Proxy服务进程状态。		6005033 ModelArts Proxy服务进程异常。
	ModelArts Region区节点登录用户密码过期检查。	Region节点登录用户密码状态。	-	6005047 ModelArts管理区节点密码过期告警。
modelarts -etcd	ModelArts_etcd健康检查。	etcd目录所挂磁盘的磁盘空间。	-	6005004 ModelArts Etcd数据库磁盘容量不足。
		etcd进程状态。		6005003 ModelArts Etcd数据库进程异常。
	ModelArts Region区节点登录用户密码过期检查。	Region节点登录用户密码状态。	-	6005047 ModelArts管理区节点密码过期告警。
ModelArts-Region 所有微服务	对应节点OS性能监控项。	CPU使用率，可用物理内存，物理内存使用率，可用虚拟内存，虚拟内存使用率。	-	OS相关告警。
modelarts -db	ModelArts AI Hub和推理服务依赖的redis服务进程状态监控。	redis服务进程状态。	-	6005060 ModelArts Redis数据库进程异常。
	ModelArts_region_disk健康检查。	/var/log目录所挂磁盘空间。	-	6005007 ModelArts管理区节点磁盘容量告警[/var/log]。
		/opt/cloud目录所挂磁盘空间	-	6005008 ModelArts管理区节点磁盘容量告警[/opt/cloud]。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts节点登录用户密码过期检查。	节点登录用户密码状态。	-	6005047 ModelArts管理区节点密码过期告警。

表 9-2 ModelArts-POD 集群监控表

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
modelarts-cdk-cluster-master	ModelArts CDK集群证书检查。	ModelArts CDK证书过期状态。	modelarts-algorancher modelarts-billing modelarts-console-backend modelarts-image-packer modelarts-infers-ctsproxy modelarts-infers-job-manager modelarts-infers-model-manager modelarts-infers-monitor modelarts-infers-service-manager modelarts-infers-stats modelarts-task modelarts-os-apiserver modelarts-os-resource-mgr modelarts-os-job-mgr modelarts-webapp-gateway-cdk modelarts-market-manager-cdk modelarts-exemplflow modelarts-edge-api modelarts-edge-dm modelarts-ascend-brain modelarts-infers-manager modelarts-system-gateway	6005055 ModelArts CDK微服务CA证书过期告警。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts CDK集群服务健康检查。	ModelArts CDK服务状态。	modelarts-billing modelarts-console-backend modelarts-image-packer modelarts-infers-ctsproxy modelarts-infers-job-manager modelarts-infers-model-manager modelarts-infers-monitor modelarts-infers-service-manager modelarts-infers-stats modelarts-os-apiserver modelarts-os-job-mgr modelarts-os-resource-mgr modelarts-algorancher modelarts-webapp-gateway-cdk modelarts-market-manager-cdk modelarts-exemlflow modelarts-edge-api modelarts-edge-dm modelarts-ascend-brain modelarts-infers-manager modelarts-system-gateway	6005023 ModelArts CDK微服务状态异常。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts CDK服务副本监控。	cdk集群服务副本数状态。	modelarts-algorancher modelarts-billing modelarts-console-backend modelarts-image-packer modelarts-infers-ctsproxy modelarts-infers-job-manager modelarts-infers-model-manager modelarts-infers-monitor modelarts-infers-service-manager modelarts-infers-stats modelarts-os-apiserver modelarts-os-job-mgr modelarts-os-resource-mgr modelarts-webapp-gateway-cdk modelarts-market-manager-cdk modelarts-exemlflow modelarts-edge-api modelarts-edge-dm modelarts-ascend-brain modelarts-infers-manager modelarts-system-gateway	6005042 ModelArts CDK微服务实例个数异常。
	ModelArts CDK集群node节点健康检查。	ModelArts cdk集群节点状态。	cdk服务节点ip	6005041 ModelArts CDK节点状态异常。
	ModelArts pod区节点登录用户密码过期检查。	cdk节点登录用户密码状态。	-	6005048 ModelArts 下沉管理区节点密码过期告警。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts CCE集群健康检查。	ModelArts CCE集群状态。	modelarts-infer-dispatcher modelarts-infer-imagepacker modelarts-infer-task modelarts-market-service modelarts-ascend-brain infers-dispatcher	6005021 ModelArts CCE集群上服务状态异常。
	ModelArts CCE集群CPU使用率监控。	ModelArts CCE集群CPU使用率。	modelarts-infer-dispatcher modelarts-infer-imagepacker modelarts-infer-task modelarts-market-service modelarts-ascend-brain infers-dispatcher	6005045 ModelArts CCE集群CPU使用率告警。
	ModelArts CCE集群内存使用率监控。	ModelArts CCE集群内存使用率。	modelarts-infer-dispatcher modelarts-infer-imagepacker modelarts-infer-task modelarts-market-service modelarts-ascend-brain infers-dispatcher	6005046 ModelArts CCE集群内存使用率告警。
	ModelArts CCE微服务副本监控。	CCE集群服务副本个数状态。	modelarts-infer-dispatcher-deployments-infer-batch-agent modelarts-infer-dispatcher-deployments-infer-dispatcher modelarts-infer-task-deployments-modelarts-infer-task modelarts-market-service-deployments-modelarts-market-service infers-dispatcher-deployments-modelarts-infers-dispatcher infers-dispatcher-statefulsets-modelarts-infers-watcher	6005050 ModelArts CCE集群上服务实例个数异常。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts 微服务健康检查。	ModelArts CCE微服务状态。	modelarts-infer-dispatcher-deployments-infer-batch-agent modelarts-infer-dispatcher-deployments-infer-dispatcher modelarts-infer-task-deployments-modelarts-infer-task modelarts-market-service-deployments-modelarts-market-service infers-dispatcher-deployments-modelarts-infers-dispatcher infers-dispatcher-statefulsets-modelarts-infers-watcher	6005020 ModelArts CCE集群状态异常。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts服务elb端口健康检查。	ModelArts服务elb端口状态。	modelarts_billing_endpoint modelarts_console_backend_endpoint modelarts_image_packer_endpoint modelarts_infers_ctsproxy_endpoint modelarts_infers_model_manager_endpoint modelarts_infers_monitor_endpoint modelarts_infers_service_manager_endpoint modelarts_infers_stats_endpoint modelarts_job_manager_endpoint modelarts_os_apiserver_endpoint modelarts_os_job_mgr_endpoint modelarts_os_resource_mgr_endpoint modelarts-algorancher_endpoint modelarts-webapp-gateway-cdk_endpoint modelarts_market_manager_cdk_endpoint modelarts_exemlflow_cdk_endpoint modelarts_edge_api_endpoint modelarts_edge_dm_endpoint modelarts-ascend-brain-endpoint modelarts-infers-manager modelarts-system-gateway-endpoint	6005049 ModelArts管理区到CDK微服务连通性异常。

微服务名称	监控指标组	监控项内监控指标	指标维度	触发告警
	ModelArts ak/sk状态监控。	ModelArts 资源租户 ak/sk过期状态。	modelarts_container_AKSK	6005032 ModelArts 承载租户账号异常。
	ModelArts apic实例状态监控。	ModelArts 推理apic状态。	roma-dispatcher roma-task	6005031 ModelArts APIC实例异常。
modelarts-cdk-cluster-node	ModelArts _pod_disk 健康检查。	/var/log目录所挂磁盘空间。	-	6005013 ModelArts 下沉管理区节点磁盘容量告警[/var/log]。
		/opt/cloud目录所挂磁盘空间。		6005014 ModelArts 下沉管理区节点磁盘容量告警[/opt/cloud]。
	ModelArts pod区节点登录用户密码过期检查。	cdk节点登录用户密码状态。	-	6005048 ModelArts 下沉管理区节点密码过期告警。
ModelArts-POD所有微服务	对应节点OS性能监控项。	CPU使用率，可用物理内存，物理内存使用率，可用虚拟内存，虚拟内存使用率。	-	OS相关告警。

租户面性能监控

表 9-3 ModelArts 性能监控指标

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
cpu_usage	model_id	CPU 使用率	统计租户服务的 CPU 使用率。	linux	60	172800	float	%	N A	%	0	70%	是
mem_usage	model_id	内存使用率	统计租户服务的内存使用率。	linux	60	172800	float	%	N A	%	0	70%	是
gpu_util	model_id	GPU 使用率	统计租户服务的 GPU 使用率。	linux	60	172800	float	%	N A	%	0	70%	是
gpu_mem_usage	model_id	GPU 显存使用率	统计租户服务的 GPU 显存使用率。	linux	60	172800	float	%	N A	%	0	70%	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
successfully_called_times	model_id、service_id	调用成功次数	统计租户调用服务的成功次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
failed_called_times	model_id、service_id	调用失败次数	统计租户调用服务的失败次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
total_called_times	model_id、service_id	调用次数	统计租户调用服务的次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
avg_latency	service_id	平均延迟毫秒数	统计api接口平均响应延时。	linux	60	172800	float	ms	NA	ms	0	30000	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
req_count_2xx	service_id	2xx响应次数	统计api接口2xx响应的次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
req_count_4xx	service_id	4xx异常次数	统计api接口返回4xx异常的次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
req_count_5xx	service_id	5xx异常次数	统计api接口返回5xx异常的次数。	linux	60	172800	int	Count/min	NA	Count/min	0	5000	是
infer_service_request_count_2xx	source	2xx响应次数	该指标用于统计在线服务在一个周期内调用接口响应码格式2xx的次数	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_request_count_4xx	source	4xx异常次数	该指标用于统计在线服务在一个周期内调用接口响应码格式4xx的次数	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是
infer_service_request_count_5xx	source	5xx异常次数	该指标用于统计在线服务在一个周期内调用接口响应码格式5xx的次数	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_request_count_failed	source	调用失败数	该指标用于统计在线服务在一个周期内调用接口失败的次数	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是
infer_service_request_count_total	source	调用总次数	该指标用于统计在线服务在一个周期内调用接口的次数	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_request_cost_avg	source	在线服务接口调用平均时延	该指标用于统计在线服务在一个周期内调用接口的平均时延	linux	60	172800	float	ms	NA	ms	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_request_connect_count	source	在线服务当前连接数	该指标用于统计在线服务在指标采集时刻的实时连接数量	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是
infer_service_token_count	source	在线服务token产生数量	该指标用于统计在线服务一个统计周期内token的产生数量	linux	60	172800	float	Count/min	NA	Count/min	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_first_token_avg_seconds	source	首token的平均时延	该指标用于统计一个周期内首token的平均时延(TTF T)	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_first_token_min_seconds	source	首token的最小时延	该指标用于统计一个周期内获取到首token的最小时延	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_first_token_max_seconds	source	首token的最大时延	该指标用于统计一个周期内获取到首token的最大时延	linux	60	172800	float	ms	NA	ms	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_per_token_avg_seconds	source	每个 token 的平均输出时延	该指标用于统计一个周期内每个 token 的平均输出时延（不含首 token, TPOT）	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_per_token_min_seconds	source	每个 token 的最小输出时延	该指标用于统计一个周期内每个 token 的最小输出时延（不含首 token, TPOT）	linux	60	172800	float	ms	NA	ms	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_per_token_max_seconds	source	每个 token 的最大输出时延	该指标用于统计一个周期内每个 token 的最大输出时延（不含 token, TPOT）	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_token_latency_avg_seconds	source	token 的总耗时的平均值	该指标用于统计一个周期内输出 token 的总耗时的平均值	linux	60	172800	float	ms	NA	ms	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
infer_service_token_latency_min_seconds	source	token的总耗时最小值	该指标用于统计一个周期内输出token的总耗时的最小值	linux	60	172800	float	ms	NA	ms	0	NA	是
infer_service_token_latency_max_seconds	source	token的总耗时的最大值	该指标用于统计一个周期内输出token的总耗时的最大值	linux	60	172800	float	ms	NA	ms	0	NA	是
ma_container_cpu_limit_core	container_id	CPU内核总量	该指标用于统计测量对象申请的CPU核总量。	linux	60	172800	float	core	NA	core	1	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_cpu_used_core	container_id	CPU 内核占用量	该指标用于统计测量对象已经使用的CPU核个数	linux	60	172800	float	core	NA	core	0	NA	是
ma_container_cpu_util	container_id	CPU 使用率	该指标用于统计测量对象的CPU使用率。	linux	60	172800	float	%	NA	%	0	70%	是
ma_container_memory_capacity_megabytes	container_id	内存总量	该指标用于统计测量对象申请的物理内存总量。	linux	60	172800	float	兆字节（Megabytes）	NA	兆字节（Megabytes）	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_memory_used_megabytes	container_id	物理内存使用量	该指标用于统计测量对象实际已经使用的物理内存（对应container_memory_working_set_bytes当前内存工作集（working set）使用量。（工作区内存使用量=活跃的匿名页和缓存，以及	linux	60	172800	float	兆字节（Megabytes）	NA	兆字节（Megabytes）	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
			file-baked页<=container_memory_usage_bytes))										
ma_container_memory_util	container_id	物理内存使用率	该指标用于统计测量对象已使用内存占申请物理内存总量的百分比。	linux	60	172800	float	%	NA	%	0	70%	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_npu_hbm_bytes	container_id	AI 处理器 HBM 内存总量	昇腾系列 AI 处理器 HBM 总内存（昇腾 snt9 AI 处理器专属）	linux	60	172800	float	字节（Byte）	NA	字节（Byte）	0	NA	是
ma_container_npu_hbm_usage_bytes	container_id	AI 处理器 HBM 内存使用量	昇腾系列 AI 处理器 HBM 内存使用量（昇腾 snt9 AI 处理器专属）	linux	60	172800	float	字节（Byte）	NA	字节（Byte）	0	NA	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_npu_hbm_util	container_id	AI处理器HBM内存使用率	昇腾系列AI处理器HBM内存使用率（昇腾snt9 AI处理器专属）	linux	60	172800	float	%	NA	%	0	70%	是
ma_container_npu_hbm_util	container_id	NPU显存使用率	该指标用于统计测量对象已使用的NPU显存占NPU存储容量的百分比。	linux	60	172800	float	%	NA	%	0	70%	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_npu_ai_core_util	container_id	NPU 使用率	该指标用于统计测量对象的NPU使用率。	linux	60	172800	float	%	N A	%	0	70%	是
ma_container_npu_general_util	container_id	NPU 整体利用率	昇腾系列AI处理器NPU整体利用率，包括对aicore和aivector的整体统计。（驱动版本24.1.RC2及其以后支持）	linux	60	172800	float	%	N A	%	0	70%	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_gpu_util	container_id	GPU 使用率	该指标用于统计测量对象的GPU使用率。	linux	60	172800	float	%	N A	%	0	70%	是
ma_container_gpu_mem_total_megabytes	container_id	GPU 显存容量	该指标用于统计训练任务的显存容量。	linux	60	172800	float	M B	N A	MB	0	N A	是
ma_container_gpu_mem_used_megabytes	container_id	GPU 显存使用量	该指标用于统计测量对象已使用的显存。	linux	60	172800	float	M B	N A	MB	0	N A	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_gpu_memory_util	container_id	GPU 显存使用率	该指标用于统计测量对象已使用的显存占显存容量的百分比。	linux	60	172800	float	%	NA	%	0	70%	是
ma_container_network_receive_bytes	container_id	下行速率	该指标用于统计测试对象的入方向网络流速。	linux	60	172800	float	字节/秒（Bytes/Second）	NA	字节/秒（Bytes/Second）	0	70%	是

指标名称	维度名称	显示名	描述	实例规格	上报周期（单位：秒）	数据存活时间（单位：秒）	数据类型	指标最小单位	单位进制	指标单位集合	最小阈值	建议阈值	指标是否告警
ma_container_network_transmit_bytes	container_id	上行速率	该指标用于统计测试对象的出方向网络流速。	linux	60	172800	float	字节/秒（Bytes/Second）	NA	字节/秒（Bytes/Second）	0	70%	是

9.4 设置阈值告警

当需要为监控对象的特定事件提供告警服务时，管理员可通过设置告警阈值来自定义告警发生和恢复的条件。只有为性能监控任务的监控指标配置了性能告警阈值后，告警才会发生或恢复。

说明

告警发生或恢复的实时性与性能监控任务的采集周期相关，只有采集到性能指标后，告警才会发生或恢复。

前提条件

管理员具有“性能数据查询”和“监控配置管理”权限。

操作步骤

1. 以系统管理员账号登录[ManageOne运维面](#)。
2. 在主菜单中选择“监控 > 监控配置”。
3. 在左侧导航中选择“阈值告警规则”，单击右上角“创建”，新增告警阈值。

表 9-4 阈值告警规则信息

配置项	参数	说明
基本信息	名称	创建阈值告警规则的名称。
	描述	描述信息。
	启用状态	启用或停用该规则。
监控范围	资源类型	选择监控对象的资源类别。
	监控模板	选择监控模板。
	资源范围	- 指定范围：按照范围选择对象。如果选定范围内的资源对象有增减，则用户的监控对象会自动更新，可“按位置”或“按VDC”选择。 - 指定实例：自由选择监控对象。在弹框列表中选择具体的实例。
阈值设置-静态阈值	阈值类型	静态阈值
	阈值条件	阈值条件：仅当阈值类型为“静态阈值”存在，可选单指标或多指标。 - 单指标：仅支持添加一个指标。 - 多指标：可添加多个指标，在满足任意或所有条件时触发告警。
	重复次数	“重复次数”：取值范围（1 - 10），该阈值条件的触发次数累积达到设定的重复次数，则认为该条件被满足，会自动执行告警上报或告警恢复操作。
	告警级别	“告警级别”：告警的级别。其中包括：紧急、重要、次要、提示。
阈值设置-动态阈值	阈值类型	动态阈值，单击“添加指标”，勾选待添加的指标，单击“确定”。

配置项	参数	说明
	-	指标名称：所选择指标的名称，动态阈值中仅支持添加一个指标。 关注的方向：指标值超过合理区间的边界时上报告警。 • 大于：指标值大于合理区间的上边界时上报告警。 • 小于：指标值小于合理区间的下边界时上报告警。 • 大于或小于：指标值大于合理区间的上边界或小于合理区间的下边界时上报告警。 灵敏度：指标值偏离合理区间的相对程度，用户请根据业务需求选择相应的灵敏度。 • 低灵敏度（1-3）：指标值偏离合理区间较大时触发阈值告警。对指标偏离合理区间的容忍程度较高，用户接受告警量较少。 • 中灵敏度（4-6）：指标值偏离合理区间中等时触发阈值告警。对指标偏离合理区间的容忍程度适中，用户接受告警量适中。 • 高灵敏度（7-10）：指标值偏离合理区间较小时触发阈值告警。对指标偏离合理区间的容忍程度较低，用户接受告警量较多。 告警的重复次数：该阈值条件的触发次数累积达到设定的重复次数，则认为该条件被满足，会自动执行告警上报或告警恢复操作。 告警级别：告警的级别。其中包括：紧急阈值、重要阈值、次要阈值、提示阈值。 告警频率：在一定时间内上报告警的次数，避免相同告警重复上报。

 说明

- 选择的资源类型不同，界面显示也不同，具体以实际显示为准。
 - 当阈值策略不用时，可单击某条阈值策略“操作”列的“删除”将其删除。
4. 单击“完成”，完成告警阈值的配置。

10 高危操作

10.1 禁用操作一览表

ModelArts服务在日常操作与维护过程中禁止进行的操作，否则会影响业务的正常运行。

表 10-1 禁用操作

操作对象	操作名称	风险描述
操作系统	禁止以root用户启动Tomcat。	以root用户启动主要进程会导致DMK升级失败，日志丢失，问题难以定位。
	禁止修改配置文件中关键进程侦听的端口号。	修改关键进程侦听的端口号会导致服务不可用。
	禁止使用select * from xx for update语句。	会使得数据库表被锁。
	禁止使用vi命令查看配置文件。	习惯操作可能导致文件被误修改，建议使用view和cat查看。
	禁止修改ModelArts二级VDC用户（承载租户）默认的AK/SK。	此操作将导致ModelArts服务异常。
	禁止删除dispatcher、batch-agent服务。	此操作将导致在线服务不可用。
	禁止删除modelarts-infer-task服务。	此操作将导致在线服务异步请求模式不可用。
	禁止用户操作etcd服务，modelarts-os-apiserver、modelarts-os-resource-mgr、modelarts-os-job-mgr服务。	此操作将导致资源调度以及任务下发能力不可用。

操作对象	操作名称	风险描述
	禁止用户操作modelarts-algorancher、modelarts-webapp-gateway服务。	此操作将导致ModelArts训练服务不可用。
	禁止用户操作modelarts-exemlflow服务。	此操作将导致ModelArts Workflow服务不可用。
	禁止用户操作modelarts-ascend-brain和modelarts-system-gateway服务	此操作将导致ModelArts 昇腾云脑服务不可用。
	禁止删除ModelArts二级VDC用户（承载租户）默认dispatcher部署节点。	此操作将导致在线服务不可用。
	禁止删除ModelArts二级VDC用户（承载租户）默认CCE集群。	此操作将导致ModelArts服务异常。
日志	禁止删除系统日志、接口日志、调测日志。	- 可能会导致数据丢失或关键日志文件丢失，出现问题无法定位根因。 - 进程运行过程中删除，导致进程占用的磁盘空间无法释放，必须杀进程来释放占用的空间。
数据库	禁止在数据库操作运行实例和集群信息表。	可能会造成数据错乱。
资源池	禁止修改资源池节点用户名、密码。	可能会造成节点不可用。
推理服务	禁止删除承载租户下的在线服务“infer-batch-agent”。	此操作将导致批量服务不可用。
AI Hub	禁止删除承载租户下的无状态负载“modelarts-market-service”。	此操作导致AI Hub资产搬运功能不可用，导致资产发布和订阅后使用失败。

10.2 高危操作一览表

ModelArts服务在日常操作与维护过程中涉及的高危操作，需要严格按照操作指导进行，否则可能会影响业务的正常运行。

高危操作风险等级说明：

- 高：对于可能直接导致业务失败、数据丢失、系统不能维护、系统资源耗尽的高危操作。
- 中：对于可能导致安全风险及可靠性降低的高危操作。

- 低：高、中风险等级外的其他高危操作。

系统操作类

表 10-2 系统操作类高危操作

操作对象	操作名称	风险描述	风险等级	应对措施
系统	修改DBM内部数据库密码	修改密码过程中会导致业务中断。	中	修改内部对接账户后，确保及时修改管理面各个节点的配置文件中的密码。
	恢复数据库数据	操作不当会导致部分管理数据丢失。	中	● 在对数据库进行数据恢复操作时，需要选择正确时间点的备份数据进行恢复操作。 ● 数据恢复后，检查系统是否正常运行。
	变更业务目录的文件权限	导致业务数据下发失败。	中	● 排查业务目录下文件的属组及权限。 ● 观察业务下发是否正常。
	修改modelarts-common-proxy组件密码	修改后会导致使用modelarts-common-proxy的微服务组件无法通过此代理访问租户面业务，影响训练作业的状态、在线服务的状态等	中	修改modelarts-common-proxy组件密码后，同步修改modelarts管理组件使用modelarts-common-proxy的密码
	使用下述命令删除某些文件或目录： find、grep、fgrep、xargs、rm *、rm -rf	可能会导致误删除某些不能恢复的重要文件从而引发更大的问题。	高	必须在其他环境上经过测试或评估执行命令后的结果，确认不破坏系统的情况下才可执行。
	修改ModelArts二级VDC用户（承载租户）的project	导致整个ModelArts功能不可用。	高	-
	修改ModelArts二级VDC用户（承载租户）的AK/SK	导致整个ModelArts功能不可用。	高	-
	修改ModelArts二级VDC用户（承载租户）的容器镜像	可能导致服务发布异常。	高	-
	使用ModelArts二级VDC用户（承载租户）做业务操作	会导致用户误删ModelArts系统预置信息（如CCE集群、AK/SK等），从而导致系统不可用。	高	-

操作对象	操作名称	风险描述	风险等级	应对措施
	dispatcher节点绑定EIP	会导致ModelArts预测不可用。	高	删除绑定EIP，重跑PEP工步。

资源操作类

表 10-3 资源操作类高危操作

操作对象	操作名称	风险描述	风险等级	应对措施
ModelArts服务	删除模型	导致后续不可使用该模型部署服务。	高	● 必须在客户同意的维测时段操作。 ● 必须由维护人员执行。 ● 必须得到客户的同意后方可操作。
	停止服务	导致用户业务中断。	中	● 必须在客户同意的维测时段操作。 ● 必须由维护人员执行。 ● 必须得到客户的同意后方可操作。
	删除服务	导致用户业务中断。	中	● 必须在客户同意的维测时段操作。 ● 必须由维护人员执行。 ● 必须得到客户的同意后方可操作。
	删除资源池	造成已运行服务失败。	高	● 必须在客户同意的维测时段操作。 ● 必须由维护人员执行。 ● 必须得到客户的同意后方可操作。
	缩容资源池节点	造成该节点下已运行作业失败。	高	● 必须在客户同意的维测时段操作。 ● 必须由维护人员执行。 ● 必须得到客户的同意后方可操作。

操作对象	操作名称	风险描述	风险等级	应对措施
	删除或修改/opt/cloud/modelarts-infers-model-manager/config下配置文件	造成模型管理业务流程无法正常运行。	高	- 原则上服务部署后无需修改。 - 若有临时修改的场景，必须得到客户的同意后方可操作。
	停止训练作业	导致用户业务中断。	中	- 必须在客户同意的维测时段操作。 - 必须由维护人员执行。 - 必须得到客户的同意后方可操作。
	删除训练作业	导致用户业务中断。	中	- 必须在客户同意的维测时段操作。 - 必须由维护人员执行。 - 必须得到客户的同意后方可操作。
	删除Workflow	导致用户业务中断。	中	- 必须在客户同意的维测时段操作。 - 必须由维护人员执行。 - 必须得到客户的同意后方可操作。

11 附录

11.1 常用登录操作

以系统管理员账号登录 ManageOne 运维面

1. 使用浏览器，通过地址“<https://ManageOne运维面主页的访问地址:31943>”，登录ManageOne运维面，或通过地址“<https://ManageOne主门户的访问地址>”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。

- 密码方式

默认账号：bss_admin

说明

对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。

默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。

- USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。

说明

仅在SM系列商密算法场景下支持USB Key方式。

2. 单击“登录”。

以运营管理员账号登录 ManageOne 运营面

1. 使用浏览器，登录ManageOne运营面。

登录地址：

非B2B场景：<https://ManageOne运营面的访问地址>。例如，<https://console.demo.com>。

B2B场景：<https://ManageOne运营管理面的访问地址>。例如，<https://admin.demo.com>。

ManageOne运营面的访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《[xxx_export_all_v2_CN.xlsx](#)》，在“Portal”页签下获取“ManageOne运营面/运营管理面”相关信息。

登录方式分为“密码认证”和“USB Key认证”。

- 密码认证：输入账号和密码。

默认账号：**bss_admin**

默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（Portal）”页签中搜索“bss_admin”获取对应的默认密码。首次登录需要修改密码。

- USB Key认证：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。

说明

仅在SM系列商密算法场景下支持USB Key方式。

2. 单击“登录”。

以 AI 公共二级 VDC 用户登录 ManageOne 租户面

1. 使用浏览器，以AI公共二级VDC用户登录ManageOne。

- 登录地址：

非B2B场景的登录地址：**[https://ManageOne运营面的访问地址](#)**。例如，[https://console.demo.com](#)。

B2B场景的登录地址：**[https://ManageOne租户面的访问地址](#)**。例如，[https://tenant.demo.com](#)。

访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。

- AI公共二级VDC用户（技术中台和AI数据中台服务部署使用二级管理VDC用户名）：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_deploy”获取对应的规划值。
- 密码：联系环境管理员获取。

2. 单击“登录”。

以 ModelArts 承载租户一级管理 VDC 用户登录 ManageOne 租户面

1. 使用浏览器，以ModelArts承载租户一级管理VDC用户登录ManageOne。

- 登录地址：

非B2B场景的登录地址：**[https://ManageOne运营面的访问地址](#)**。例如，[https://console.demo.com](#)。

B2B场景的登录地址：**[https://ManageOne租户面的访问地址](#)**。例如，[https://tenant.demo.com](#)。

访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。

- ModelArts承载租户一级管理VDC用户：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“firstlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
- 密码：联系环境管理员获取。

2. 单击“登录”。

以 ModelArts 服务承载租户使用的二级 VDC 用户名登录 ManageOne 租户面

1. 使用浏览器，以ModelArts服务承载租户使用的二级VDC用户名登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，
https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，
https://tenant.demo.com。
访问地址参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“ManageOne运营面/租户面”相关信息。
 - ModelArts服务承载租户使用的二级VDC用户名：参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签下搜索“secondlevel_vdcuser_for_modelarts_deploy”，获取对应的规划值。
 - 密码：联系环境管理员获取。
2. 单击“登录”。

以系统管理员账号登录 ServiceOM 平台

1. 使用浏览器以系统管理员账号登录ManageOne运维面。
 - a. 使用浏览器，通过地址“https://ManageOne运维面主页的访问地址31943”，登录ManageOne运维面，或通过地址“https://ManageOne主门户的访问地址”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。
 - 密码方式
默认账号：bss_admin
说明
对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。
默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。
 - USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。
说明
仅在SM系列商密算法场景下支持USB Key方式。
 - b. 单击“登录”。
2. 在ManageOne运维面首页右下角“常用链接”栏中，单击“Service OM”选择相应区域，跳转到对应区域的Service OM平台。

以管理员账号登录 CloudCDK 界面

1. 使用浏览器，登录CloudScope平台。

- 登录地址：<https://CloudScope>界面的访问地址。例如，<https://cloudscope.demo.com>。
CloudScope界面访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“COP”相关信息。
 - 默认账号：**admin**
 - 默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“CloudScopeLite”页签中搜索“**admin**”获取CloudAutoDeploy-CDK服务对应的默认密码。
2. 在页面导航栏选择“运维服务 > 变更管理 > CloudAutoDeploy-CDK”进入CloudCDK界面。
 3. 在“集群管理 > 集群运维”中选择当前区域的专属云。
专属云的region-id请参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“基本参数”页签中搜索“region0_id”获取对应参数。

图 11-1 集群运维



登录 ServiceCM 界面

步骤1 使用浏览器，登录ManageOne运维面。

- 登录地址：<https://ManageOne>运维面主页的访问地址:31943，登录ManageOne运维面。或通过地址“<https://ManageOne>主门户的访问地址”，登录ManageOne主门户，选择“运维中心（OC）”，登录ManageOne运维面。
ManageOne运维面访问地址请参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表中“2.3 Portal”页签的“ManageOne运维面”相关信息。
- 密码方式：输入账号和密码。
默认账号：**bss_admin**，默认密码请咨询系统管理员或者参考《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签中，“ManageOne运维面”账户对应的默认密码。

说明

对于从8.2.0或更早版本升级上来的ManageOne，默认账号为admin。

- USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。

 说明

仅在SM系列商密算法场景下支持USB Key方式。

步骤2 在运维面首页的“常用链接”中，单击“ServiceCM”，选择区域后进入ServiceCM界面。

步骤3 在ServiceCM插件列表界面，选择“自助开发平台 > modelarts-system-manager”，进入ModelArts ServiceCM界面。

----结束

11.2 登录 ModelArts-Common-Proxy 节点

1. 使用浏览器以系统管理员账号登录ManageOne运维面。
 - a. 使用浏览器，通过地址“<https://ManageOne运维面主页的访问地址:31943>”，登录ManageOne运维面，或通过地址“<https://ManageOne主门户的访问地址>”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。

- 密码方式

默认账号：bss_admin

 说明

对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。

默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。

- USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。

 说明

仅在SM系列商密算法场景下支持USB Key方式。

- b. 单击“登录”。
2. 在ManageOne运维面首页右下角“常用链接”栏中，单击“Service OM”选择相应区域，跳转到对应区域的Service OM平台。
 3. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
 4. 使用Putty工具以opsadmin用户登录任一ModelArts-Common-Proxy节点。

```
ssh opsadmin@<ModelArts-Common-Proxy节点IP>
```

 - ModelArts-Common-Proxy节点IP：在3的页面名称右侧输入框中，搜索“ModelArts-Common-Proxy”，获取并记录任意一个ModelArts-Common-Proxy节点的IP地址。
 - opsadmin账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts-Common-Proxy”获取。
 5. 切换为root用户。

```
su - root
```

root账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts-Common-Proxy”获取。

11.3 登录 CDK master 节点

1. 使用浏览器以系统管理员账号登录ManageOne运维面。
 - a. 使用浏览器，通过地址“<https://ManageOne运维面主页的访问地址:31943>”，登录ManageOne运维面，或通过地址“<https://ManageOne主门户的访问地址>”，登录ManageOne主门户，选择“运维中心（OC）”，进入ManageOne运维面。

- 密码方式

默认账号：bss_admin

 说明

对于从8.2.0或更早版本升级上来的ManageOne，默认账号为“admin”。

默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（Portal）”页签获取对应账户的默认密码。

- USB Key方式：插入已预置用户证书的USB Key，选择设备和用户证书，并输入PIN码。

 说明

仅在SM系列商密算法场景下支持USB Key方式。

- b. 单击“登录”。
2. 在ManageOne运维面首页右下角“常用链接”栏中，单击“Service OM”选择相应区域，跳转到对应区域的Service OM平台。
 3. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
 4. 获取CDK集群Master节点IP。

在名称右侧输入框中，搜索“ModelArts_Common_Region-POD-Master”，获取并记录任意一个Master节点的内网IP地址。

 说明

- 如果是容灾环境，可搜索“ModelArts_Common_Region-POD-DR-Master”，获取并记录任意一个容灾Master节点的内网IP地址。
 - 内网网段参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《[xxx_export_all_v2_CN.xlsx](#)》，搜索“external_relay_network”获取对应的网段值。
 - 在开通通信矩阵的场景下，需要临时开通ModelArts-Common-Proxy节点到CDK集群Master节点的22端口。
 - 源IP：为ModelArts-Common-Proxy节点IP，参见[登录ModelArts-Common-Proxy节点](#)获取的IP地址。
 - 源端口：设置为“Any”。
 - 目的IP：为CDK集群Master节点的内网IP地址。
 - 目的端口：22。
5. [登录ModelArts-Common-Proxy节点](#)。
 6. 从ModelArts-Common-Proxy节点以opsadmin用户登录CDK Master节点。
`ssh opsadmin@<Master节点IP>`

- Master节点IP：为4获取的IP地址。
 - opsadmin账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts_Common_Region-POD-Master”获取。
7. 切换为root用户。
- su - root**
- root账号的默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts_Common_Region-POD-Master”获取。

11.4 登录 CDK node 节点

1. [以系统管理员账号登录ServiceOM平台](#)。
2. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
3. 获取CDK集群Node节点IP。
在名称右侧输入框中输入Node节点名称，例如输入“ModelArts_Common_Region-POD-Node-”，获取并记录对应Node节点的内网IP地址。

说明

- 如果是容灾环境，可搜索“ModelArts_Common_Region-POD-DR-Node-”，获取并记录对应Node节点的内网IP地址。
 - **内网网段**参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，搜索“external_relay_network”获取对应的网段值。
 - 在开通通信矩阵的场景下，需要临时开通ModelArts-Common-Proxy节点到CDK集群Node节点的22端口。
 - 源IP：为ModelArts-Common-Proxy节点IP，参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“工具生成的ip参数”页签下搜索“ModelArts-Common-Proxy”获取任一IP地址。
 - 源端口：设置为“Any”。
 - 目的IP：为CDK集群Node节点的内网IP地址。
 - 目的端口：22。
4. [登录ModelArts-Common-Proxy节点](#)。
 5. 从ModelArts-Common-Proxy节点以opsadmin用户登录CDK Node节点。
ssh opsadmin@<Node节点IP>
 - Node节点IP：为3获取的IP地址。
 - opsadmin账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts_Common_Region-POD-Node-XXXX”获取。
 6. 切换为root用户。
su - root
root账号的默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts_Common_Region-POD-Node-XXXX”获取。

11.5 登录 Dispatcher 集群节点

本节以“modelarts-infer-dispatcher-node”为例介绍登录Dispatcher集群节点的操作步骤，若登录其他集群节点，则替换节点名称即可。

1. [以系统管理员账号登录ServiceOM平台](#)。
2. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
3. 获取Dispatcher节点IP地址。

在名称右侧输入框中，搜索“modelarts-infer-dispatcher-node”，获取并记录任意一个节点的内网IP地址。

说明

- 内网网段参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，搜索“external_relay_network”获取对应的网段值。
 - 在开通通信矩阵的场景下，需要临时开通ModelArts-Common-Proxy节点到Dispatcher节点的22端口。
 - 源IP：为ModelArts-Common-Proxy节点IP，参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“工具生成的ip参数”页签下搜索“ModelArts-Common-Proxy”获取任一IP地址。
 - 源端口：设置为“Any”。
 - 目的IP：为Dispatcher节点的内网IP地址。
 - 目的端口：22。
4. [登录ModelArts-Common-Proxy节点](#)。
 5. 从ModelArts-Common-Proxy节点以opsadmin用户登录Dispatcher集群节点。
ssh opsadmin@<Dispatcher集群节点IP>
 - Dispatcher集群节点IP：为步骤3获取的IP地址。
 - opsadmin账户的默认密码：请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签中，搜索“modelarts-infer-dispatcher-node”获取。

11.6 在 CDK master 节点获取组件日志

执行如下步骤，可以在CDK master节点获取ctsproxy、service-manager等组件的日志。

1. [登录CDK master节点](#)。
2. 执行如下命令查看ModelArts服务的Pod容器。
kubectl get po (旧版推理模块需要加-n infer指定命名空间)

根据回显信息获取组件所在的Pod名称：

NAME	READY	STATUS	RESTARTS	AGE
.....				
modelarts-infers-model-manager-664d4bcc9b-v262z	1/1	Running	0	1h
modelarts-infers-service-manager-56699c4576-k4vnc	1/1	Running	0	16h
modelarts-infers-monitor-76c9b6f65d-2l4rv	1/1	Running	0	8d
modelarts-infers-ctsproxy-5fb46c6cbd-c9hrd	1/1	Running	0	9d
modelarts-infers-stats-7c586d94dd-2njm4	1/1	Running	0	24d

```
modelarts-infers-stats-7c586d94dd-8jj2j    1/1    Running    0    25d
.....
```

3. 执行如下命令访问具体的容器。
kubect exec -it xxxxx bash (推理模块需要加-n infer指定命名空间)
其中, “xxxxx” 为上一步获取的组件的Pod名称 (例如ctsproxy、service-manager等)。
4. 执行如下命令进入logs目录, 并获取日志。以下为举例, 不同组件logs路径不同, 各个组件logs路径请参考《[ModelArts 7.2.1-HCS 维护指南\(for 华为云Stack 8.6.0\)](#)》>参考指南>日志参考的“CDK集群日志”章节。
cd /opt/cloud/logs/

11.7 登录 ModelArts 数据库

不同类型的数据库登录方式不同:

- [登录GaussDB数据库](#)
- [登录MySQL数据库](#)

获取数据库 IP 地址

1. [以系统管理员账号登录ServiceOM平台](#)。
2. 单击“服务列表>资源>计算资源”, 进入计算资源页面, 单击“虚拟机”, 展示虚拟机列表。
3. 在页面右上角通过“名称”搜索虚拟机, 例如“ModelArts-Infer-GaussDB”, 记录虚拟机的IP地址。

图 11-2 获取数据库 IP 地址



虚拟机									
+ 新增虚拟机 + 新增虚拟机 + 新增虚拟机 + 新增虚拟机									
名称	主机ID	主机组	可用分区	状态	电源状态	规格	CPU架构/厂商	IP地址	批量冷迁移
ModelArts-inf...	BC6E486B-1E...			运行中	运行中	4核 8GB	X86/Intel		支持
ModelArts-inf...	7C7E50B4-B8...			运行中	运行中	4核 8GB	X86/Intel		支持
ModelArts-inf...	1F8544FB-153...			运行中	运行中	4核 8GB	X86/Intel		支持

登录 GaussDB 数据库

1. 参考[获取数据库IP地址](#), 获取数据库主备节点的IP地址。
2. 使用Putty工具以opsadmin用户登录GaussDB数据库任一节点, 例如ModelArts-Infer-GaussDB-01。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》, 在“A类(后台)”页签中搜索节点名称获取。
3. 执行**su - root**切换到root用户。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》, 在“A类(后台)”页签中搜索节点名称获取。
4. 执行**su - dbadmin**切换数据库用户。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》, 在“B类(EI企业智能)”页签中搜索节点名称获取。
5. 执行**querydb**命令查询数据库主备状态。如果当前节点是主节点, 跳过6、7、8, 直接执行9。

图 11-3 查看数据库状态

```
[dbadmin@127.0.0.1 ~]$ querydb
Ha state:
LOCAL_ROLE           : Primary
STATIC_CONNECTIONS   : 1
DB_STATE              : Normal
DETAIL_INFORMATION   : Normal
```

- “LOCAL_ROLE”表示节点在主备模式下的角色，值为“Primary”代表主节点，“Standby”代表备节点。
- “DB_STATE”表示数据库状态，值为“Normal”代表状态正常，否则代表不正常。

6. 以opsadmin用户登录数据库主节点。

```
ssh opsadmin@{ip}
```

其中{ip}为上一步获取到的数据库主节点的IP地址。

7. 执行su - root切换root用户。

8. 执行su - dbadmin切换数据库用户。

默认密码请参见《华为云Stack 8.6.0 账户一览表》，在“B类（EI企业智能）”页签中搜索节点名称获取。

9. 执行如下命令登录高斯数据库。

```
gsql -h 127.0.0.1 -d {数据库名称} -U {账号名称} -W {密码}
```

{数据库名称}可从下表获取，{账号名称}推荐使用dbadmin账号，{密码}请参见《华为云Stack 8.6.0 账户一览表》，在“EI企业智能服务”页签中搜索如下表中数据库节点名称，查看“dbadmin”账号密码的获取方式。

表 11-1 数据库名称

模块	数据库名称	数据库节点名称
推理	JOBMANAGER	ModelArts-Infer-GaussDB
	MONITOR	
	STATS	
	UPREDICT	
	WORKLOADMANAGER	
	MA_EDGE	
	IVA	ModelArts-Iva-POD-GaussDB
公共	BILLING	ModelArts-Billing-GaussDB
	MAOS	
	WIZARDSERVICE	ModelArts-ConsoleBackend-GaussDB
AI Hub	market_manager	ModelArts-market-manager-Gaussdb

登录 MySQL 数据库

1.

参考[获取数据库IP地址](#)，获取数据库主备节点的IP地址。
2.

使用Putty工具以opsadmin用户登录MySQL数据库任一节点，例如S-ModelArts-job-MySQL-01。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
3.

切换root账号。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
4.

执行以下命令登录数据库。
`mysql -u {账号名称} -p P7306 -S /data/mysql/tmp/mysql.sock`
Password for user {账号名称}:

其中，账号名称的默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签中搜索如下表中节点名称获取。

`use {数据库名称};`

“数据库名称”可在[表11-2](#)中获取。

表 11-2 数据库名称

模块	数据库名称	数据库节点名称
训练	modelarts_algorancher	S-ModelArts-job-MySQL
Workflow	modelarts_workflow	S-ModelArts-workflow-MySQL
ModelArts_Dev	authoring	S-ModelArts-authoring-MySQL-POD-MySQL
昇腾云脑	sreascenddb	S-ModelArts-brain-MySQL
新版推理	infers_manager	ModelArts-Infers-MySQL

11.8 数据老化清理机制

用户在界面执行删除在线服务、删除在线服务版本等操作，在数据库层面只是记录了删除状态，实际数据库中还保留该数据，会保留30天。

在ModelArts管理面部署完成之后，后台会起定时任务对如下表的数据做定时清理。

清理策略如下表所示，会按删除顺序进行数据老化清理，老化后的数据将被永久删除。

表 11-3 数据老化清理策略

删除顺序	表名	被用户删除掉的数据保留时间（天）
1	t_hpa_event,t_service_unit_model,t_service_unit_code,t_service_unit_health,t_intranet_connection,t_server_vpcep,t_service_log_config,t_kubeinfer_pod	30
2	t_hpa_rule,t_lan_client,t_kubeinfer_instance,t_service_instance_unit	30
3	t_hpa_policy,t_kubeinfer_cr,t_service_instance_group	30
4	t_service_version	30
5	t_service_dynamic_routing,t_service	30

11.9 数据库修改 ModelArts 推理导入模型大小限制与本地缓存限制

修改导入模型大小限制

1. 登录ModelArts的upredict数据库后（登录方式参考[登录ModelArts数据库](#)），执行select语句查询model_quota表信息。

```
select * from model_quota where project_id = {project_id};
```
2. 执行后如果存在对应的数据，则执行下述命令。single_file_size为需要设置的单个模型导入大小限制（单位为MB），例如{30720}。

```
update model_quota set single_model_file_size_mb = {single_file_size} where project_id = {project_id};
```
3. 执行后如果查找不到对应的数据，则执行下述命令。

```
INSERT INTO model_quota(ID, project_id, quota_type, model_quota, single_model_file_size_mb, single_app_total_size_mb, single_custom_image_size_mb, create_at, update_at) VALUES ({id}, {project_id}, {type}, {quota},{single_file_size},{total_size},{image_size}, {create_time}, {update_time});
```

各参数定义如下：

 - {id}：数据ID，与project_id保持一致即可。
 - {project_id}：资源空间ID，获取方式参考《[ModelArts 7.2.1-HCS API参考 \(for 华为云Stack 8.6.0\)](#)》的“获取资源空间ID和名称”章节。
 - {type}：模型操作类型，本节填入{'IMPORT_MODEL'}即可。
 - {quota}：用户可创建模型数量，例如{1000}。
 - {single_file_size}：单个模型文件大小限制（单位为MB），例如{30720}。
 - {total_size}：单个模型总大小限制（单位为GB），例如{307200}。
 - {image_size}：单个模型导入镜像大小限制（单位为MB），例如{307200}。
 - {create_time}：模型配额创建时间，推荐填入当前时间，时间格式是时间戳，例如{1722495008688}。
 - {update_time}：模型配额更新时间，推荐填入当前时间，时间格式是时间戳，例如{1722495008688}。

修改本地缓存限制

登录ModelArts的upredict数据库后（登录方式参考[登录ModelArts数据库](#)），执行insert语句往black_white_list表插入信息，其中CONTROL_TYPE是控制类型，本次修改固定为dynamic_load_host_cache_volume即可，domain_id是需要修改的账号的租户id。

```
insert into black_white_list set ('CONTROL_TYPE','NAME') values ('dynamic_load_host_cache_volume',  
{domain_id});
```

11.10 ModelArts 数据库节点主备状态判断

背景信息

ModelArts使用的数据库会有01、02两个节点，且互为主备。当一台主DB节点异常故障时，备DB节点会自动升主，保证了系统的可靠性。

不同类型的数据库主备节点判断方式不同：

- [判断GaussDB的主备节点](#)
- [判断MySQL的主备节点](#)

获取数据库 IP 地址

1. [以系统管理员账号登录ServiceOM平台](#)。
2. 单击“服务列表>资源>计算资源”，进入计算资源页面，单击“虚拟机”，展示虚拟机列表。
3. 在搜索栏输入关键字搜索虚拟机名称，例如“ModelArts-Infer-GaussDB”，记录虚拟机的IP地址。

图 11-4 获取数据库 IP 地址



判断 GaussDB 的主备节点

1. 参考[获取数据库IP地址](#)，获取数据库主备节点的IP地址。
2. 使用Putty工具以opsadmin用户登录GaussDB数据库任一节点，例如ModelArts-Infer-GaussDB-01。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
3. 切换root账号。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
4. 执行以下命令查询数据库主备状态。

```
su - dbadmin  
querydb
```

图 11-5 查看数据库状态

```
[dbadmin@~]$ querydb
Ha state:
LOCAL_ROLE           : Primary
STATIC_CONNECTIONS   : 1
DB_STATE              : Normal
DETAIL_INFORMATION    : Normal
```

- “LOCAL_ROLE”表示节点在主备模式下的角色，值为“Primary”代表主节点，“Standby”代表备节点。
- “DB_STATE”表示数据库状态，值为“Normal”代表状态正常，否则代表不正常。

判断 MySQL 的主备节点

1. 参考[获取数据库IP地址](#)，获取数据库主备节点的IP地址。
2. 使用Putty工具以opsadmin用户登录MySQL数据库任一节点，例如S-ModelArts-job-MySQL-01。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
3. 切换root账号。
默认密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索节点名称获取。
4. 执行以下命令查询数据库主备状态。

```
mysql -udbadmin -p{密码} -P7306 -S/data/mysql/tmp/mysql.sock -e 'show variables like "read_only"'
```

其中，dbadmin的密码请参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI 企业智能）”页签中搜索节点名称获取。

图 11-6 查询数据库主备状态

```
mysql: [warning] Using a password on the command line
+-----+
| Variable_name | Value |
+-----+
| read_only     | ON    |
+-----+
```

如图所示，“read_only”为“ON”表示该节点为数据库备节点，“read_only”为“OFF”表示该节点为数据库主节点。

11.11 获取管理员的 Token

当通过调用API接口进行相关业务操作时，需要先获取Token。本章节提供两种方法获取管理员Token。

- [使用Postman获取管理员Token](#)
- [登录ModelArts Common-Proxy虚拟机获取管理员Token](#)

使用 Postman 获取管理员 Token

1. 提前下载Postman工具。
2. 获取Token所需的参数信息。
从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签获取如表11-4所示参数对应的值。

表 11-4 获取参数值

参数名称	对应表中的参数名称	参数说明
float_ip	shubao_lb_float_ip	APIGW LB虚拟机浮动IP。
external_domain_name	external_global_domain_name	外部域名后缀。
container_user_name	secondlevel_vdcuser_for_modelarts_deploy	ModelArts服务承载租户使用的二级VDC用户名。
container_user_password	secondlevel_vdcpassword_modelarts_for_deploy	ModelArts服务承载租户使用的二级VDC用户密码。
container_domain_name	firstlevel_vdcname_for_modelarts_deploy	ModelArts服务承载租户使用的一级管理VDC名称。
region_id	region0_id	Region ID。
project_name	region0_id	资源空间名称。

3. （可选，若已配置则跳过）在本地hosts文件中添加global域名信息，如下所示：
{float_ip} iam-apigateway-proxy.{region_id}.{external_domain_name}

4. 使用Postman获取Token。其中加粗的斜体字段由2获取。

- 请求方法：POST
- 请求URL：
`https://iam-apigateway-proxy.{region_id}.{external_domain_name}/v3/auth/tokens`
- 请求Header：
`headers = {"Content-Type": "application/json"}`
- 请求Body：

```
{
  "auth": {
    "identity": {
      "methods": ["password"],
      "password": {
        "user": {
          "name": "{container_user_name}",
          "password": "{container_user_password}",
          "domain": {
            "name": "{container_domain_name}"
          }
        }
      }
    }
  },
  "scope": {
    "project": {
      "name": "{project_name}"
    }
  }
}
```



```
}  
}  
}
```

5. 返回状态码“201 Created”后，在响应Header中获取“X-Subject-Token”的值即为Token。

登录 ModelArts Common-Proxy 虚拟机获取管理员 Token

1. 准备获取Token所需的参数值。

表 11-5 获取 Token 所需的参数值

参数	描述	获取方式
internal_domain_name	内部global域名后缀	从安装ModelArts服务时由HCC Turnkey工程导出的《xxx_export_all_v2_CN.xlsx》文件的“基本参数”页签中搜索“global_domain_name”获取。
container_user_name	secondlevel_vdcuser_for_modelarts_deploy	ModelArts服务承载租户使用的二级VDC用户名。
container_user_password	secondlevel_vdcpassword_modelarts_for_deploy	ModelArts服务承载租户使用的二级VDC用户密码（联系环境管理员获取）。
container_domain_name	firstlevel_vdcname_for_modelarts_deploy	ModelArts服务承载租户使用的一级管理VDC名称。
project_name	region0_id	资源空间名称。

2. 登录ModelArts服务Common-Proxy虚拟机。
登录ServiceOM，前往服务列表 > 计算资源 > 虚拟机页面，搜索名称为**ModelArts-Common-Proxy**的虚拟机，任选其中一个虚拟机的IP地址通过SSH命令登录。

```
ssh opsadmin@<ModelArts-Common-Proxy节点IP>
```

opsadmin账号的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“A类（后台）”页签中搜索“ModelArts-Common-Proxy”获取。

3. 使用curl命令获取Token。其中加粗斜体的参数值由1获取。

执行命令如下：

```
curl -kv -X POST https://iam-cache-proxy.{internal_domain_name}:26335/v3/auth/tokens -H 'Content-Type: application/json; charset=utf-8' -d '{  
  {  
    "auth": {  
      "identity": {  
        "methods": ["password"],  
        "password": {  
          "user": {  
            "name": "{container_user_name}",  
            "password": "{container_user_password}",  
            "domain": {
```

```
    "name": "{container_domain_name}"
  }
}
},
"scope": {
  "project": {
    "name": "{project_name}"
  }
}
}
```

4. 返回状态码“201”后，获取“X-Subject-Token”的值即为Token。

11.12 获取资源租户账号并登录 CCE

背景信息

公共资源池的资源租户和专属资源池的资源租户，可以登录ModelArts管理面modelarts-os-apiserver容器组件获取资源租户信息，具体操作请参见[获取租户的资源租户账号](#)。

获取资源租户的用户名和密码后，可以访问CCE服务，查看资源所属集群信息，访问CCE的操作请参见[使用资源租户账号登录CCE](#)。

获取租户的资源租户账号

步骤1 以ModelArts资源池所在租户账号登录ManageOne租户面。

1. 使用浏览器，登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：[https://ManageOne运营面的访问地址](#)。例如，[https://console.demo.com](#)。
B2B场景的登录地址：[https://ManageOne租户面的访问地址](#)。例如，[https://tenant.demo.com](#)。
- 租户的用户名和密码：联系环境管理员获取。
2. 单击“登录”。

步骤2 单击右上角的账号名称，选择“个人设置”，进入个人中心。

步骤3 在个人设置界面获取“租户ID”（domain_id），当前账号所属的租户ID。

步骤4 登录ModelArts管理面组件modelarts-os-apiserver微服务容器。

1. [登录CDK master节点](#)。
2. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 11-7 查看 pod

```
Last login: Wed Aug 24 17:23:16 CST 2022 on pts/1
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectl get pod
NAME                                READY   STATUS    RESTARTS   AGE
modelarts-algorancher-8ddcc8d68-cqk42    1/1     Running   0           3d16h
modelarts-algorancher-8ddcc8d68-krc8m    1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-ftsxn      1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-hvsj9      1/1     Running   0           3d16h
modelarts-console-backend-576cbbfddb-d78t7 1/1     Running   0           3d16h
modelarts-console-backend-576cbbfddb-k94g7 1/1     Running   0           3d16h
modelarts-exemplar-778b8c78fd-mjg67     1/1     Running   0           3d16h
modelarts-exemplar-778b8c78fd-wglcl     1/1     Running   0           3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8 1/1     Running   0           2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl 1/1     Running   0           2d22h
modelarts-os-apiserver-5cd548c558-sltx5   1/1     Running   0           3d16h
modelarts-os-apiserver-5cd548c558-tzvv2   1/1     Running   0           3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz    1/1     Running   0           3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x    1/1     Running   0           3h24m
modelarts-os-resource-mgr-78747979f7-8wqtf 1/1     Running   0           3d16h
modelarts-os-resource-mgr-78747979f7-zvr4q 1/1     Running   0           3d16h
modelarts-webapp-gateway-cdk-7547d97b55-l7k6j 1/1     Running   0           3d16h
modelarts-webapp-gateway-cdk-7547d97b55-r6rtz 1/1     Running   0           3d16h
```

3. 执行如下命令登录pod。
kubectl exec -it \${pod_name} bash

步骤5 在modelarts-os-apiserver微服务容器中查看资源租户账号信息。

1. 执行如下命令查看资源租户的账号信息中的用户名和加密密码。
kubectl get rt tenant.{domain_id} -o yaml

图 11-8 查看用户名和加密密码

```
[service@modelarts-os-apiserver-5cd548c558-sltx5 ~]$ kubectl get rt tenant.e0e0f61d6ab404e86d0fd10b8af07a -o yaml
apiVersion: os.modelarts.huaweicloud/v1
kind: ResourceTenant
metadata:
  annotations:
    os.modelarts/tenant.domain.name: ModelArts_test
  creationTimestamp: "2024-05-23T06:00:53Z"
  finalizers:
    - os.modelarts.resourcetenant/finalizers
  generation: 3
  labels:
    os.modelarts/tenant.domain.id: e0e0f61d6ab404e86d0fd10b8af07a
    os.modelarts/tenant.user.id: 190a03654cb148f0bbad77983fc8df3a
  name: tenant.e0e0f61d6ab404e86d0fd10b8af07a
  resourceVersion: "35030"
  uid: ea628501-a2f4-4dd3-8ef0-01f3a931f3bf
spec:
  agencies:
    - name: cce_admin_trust
      trustDomain:
        name: op_svc_cce
        method: password
        password: AAAAAgAAAAAAAE9AAAAAAAEYVNBFnZvpHxPdbcb50R10K95rK2HqCfwgJMDcmwMFAEAAAAEAAAAAAAEI138g02yZYUrz3+d+7Ssnc=
        projects:
          - name: sa-fb-1_5d37f47e02d34025a08d1ff36f63c34e
          - name: sa-fb-1_7ebfcd3fbc14245ab496de8881d604
      status:
        agencies:
          - creationTimestamp: "2024-05-23T06:00:56Z"
            id: 546d0303f1fc45719c1bef330748a55d
            name: cce_admin_trust
            trustDomain:
              id: 041c88a2924545ac2594e0c54216b02
              name: op_svc_cce
            domain:
              id: c1ea2fbc1893474681b7eb74ce783d86
              name: op_svc_modelarts_e0e0f61d6ab404e86d0fd10b8af07a_sa-fb-1
              projects:
                - id: 54ba57c732704dd6a28afe4379adaf74
                  name: sa-fb-1_5d37f47e02d34025a08d1ff36f63c34e
                  password: AAAAAgAAAAAAAE9AAAAAAAEYVNBFnZvpHxPdbcb50R10K95rK2HqCfwgJMDcmwMFAEAAAAEAAAAAAAEI138g02yZYUrz3+d+7Ssnc=
                  passwordUpdateTimestamp: "2024-05-23T07:33:21Z"
```

2. 执行如下命令解密资源租户的加密密码。
/usr/local/seccomponent/bin/CryptoAPI -d -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf

图 11-9 解密资源租户的加密密码

```
[service@modelarts-os-apiserver-5cd548c558-sltx5 ~]$ /usr/local/seccomponent/bin/CryptoAPI -d -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/scc.conf
Please input encrypt text:
解密明文
[service@modelarts-os-apiserver-5cd548c558-sltx5 ~]$
```

相关参数说明如下：

- {domain_id}是步骤3获取的“租户ID”。

----结束

使用资源租户账号登录 CCE

步骤1 使用获取的资源租户用户名和密码登录ManageOne运营面。

- 非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，https://console.demo.com。
- B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，https://tenant.demo.com。

⚠ 注意

若ManageOne页面提示资源租户密码过期，请勿直接在页面上修改密码，请参考“ModelArts修改资源租户密码”修改密码，避免页面改密后，ModelArts业务异常；

步骤2 登录ManageOne后，修改URL使服务列表显示CCE服务。

- 在URL中加上“cce2.0”，例如“https://console.hcsd.gov.cn/xxxx”修改为“https://console.hcsd.gov.cn/**cce2.0**”。
- 将URL中的?region=后的内容替换成查询到的资源租户创建cce集群的project名称。

图 11-10 URL 名称



步骤3 在页面左上角，根据获取的资源空间“ID”选择服务所属的集群。

----结束

11.13 登录 modelarts-os-apiserver 获取或修改对象

背景信息

部分非标局点存在非标硬件或非标规格，导致在特定场景下，需要对已录入的规格、插件等对象做特定修改。

登录 modelarts-os-apiserver 获取或修改对象

步骤1 登录ModelArts管理面组件modelarts-os-apiserver微服务容器。

登录CDK master节点。

1. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 11-11 查看 pod

```
Last login: Wed Aug 24 17:23:16 CST 2022 on pts/1
[root@ModelArts-Common-Region-POD-Master-0002 ~]# kubectl get pod
NAME                                READY   STATUS    RESTARTS   AGE
modelarts-algorancher-8ddcc8d68-cqk42    1/1     Running   0           3d16h
modelarts-algorancher-8ddcc8d68-krc8m    1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-ftsxn      1/1     Running   0           3d16h
modelarts-billing-7d9d4c4dd4-hvsj9      1/1     Running   0           3d16h
modelarts-console-backend-576cbbfddb-d78t7 1/1     Running   0           3d16h
modelarts-console-backend-576cbbfddb-k94g7 1/1     Running   0           3d16h
modelarts-exemplflow-778b8c78fd-mjg67    1/1     Running   0           3d16h
modelarts-exemplflow-778b8c78fd-wglcl    1/1     Running   0           3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8 1/1     Running   0           2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl 1/1     Running   0           2d22h
modelarts-os-apiserver-5cd548c558-sltx5    1/1     Running   0           3d16h
modelarts-os-apiserver-5cd548c558-tzvv2    1/1     Running   0           3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz     1/1     Running   0           3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x     1/1     Running   0           3h24m
modelarts-os-resource-mgr-78747979f7-8wqtf 1/1     Running   0           3d16h
modelarts-os-resource-mgr-78747979f7-zvr4q 1/1     Running   0           3d16h
modelarts-webapp-gateway-cdk-7547d97b55-l7k6j 1/1     Running   0           3d16h
modelarts-webapp-gateway-cdk-7547d97b55-r6rtz 1/1     Running   0           3d16h
```

2. 执行如下命令登录pod。
kubectl exec -it \${pod_name} bash

步骤2 执行命令用于查看或修改对象。

表 11-6 对象查看及修改命令大全

对象类别	说明	查看对象列表命令	查看具体对象详情命令	修改具体对象命令
ModelArts节点规格	虚拟机或裸金属节点规格，录入到ModelArts后，ModelArts使用该规格创建虚拟机或裸金属作为资源池的计算节点，ModelArts使用者不可见	kubectl get nf	kubectl get nf {name} -o yaml	kubectl edit nf {name}
ModelArts资源规格	ModelArts的资源规格，用户可见	kubectl get rf	kubectl get rf {name} -o yaml	kubectl edit rf {name}
ModelArts节点模板	ModelArts的每个资源规格会绑定对应的节点模板，用来初始化节点，如设置dockersize、设置docker/kubernetes分区比例等	kubectl get nct	kubectl get nct {name} -o yaml	kubectl edit nct {name}
ModelArts节点配置项	ModelArts的节点模板包含多个节点配置项，每个配置项包含一个shell执行脚本，用于配置虚拟机昇腾驱动、安全加固等	kubectl get nci	kubectl get nci {name} -o yaml	kubectl edit nci {name}

对象类别	说明	查看对象列表命令	查看具体对象详情命令	修改具体对象命令
ModelArts插件模板	volcano、npu、icagent等插件，用于控制局点插件的版本配套、安装控制	kubectl get pt	kubectl get pt {name} -o yaml	kubectl edit pt {name}
ModelArts虚拟资源模板	算力切分的虚拟资源模板	kubectl get vrt	kubectl get vrt {name} -o yaml	kubectl edit vrt {name}
ModelArts网络	ModelArts的network对象，由用户或管理员创建，与用户资源租户下的vpc对应	kubectl get network	kubectl get network {name} -o yaml	kubectl edit network {name}
ModelArts资源池	ModelArts的资源池对象，由用户或管理员创建	kubectl get pool	kubectl get pool {name} -o yaml	kubectl edit pool {name}
ModelArts资源池节点	ModelArts的资源池下的节点对象	kubectl get pnode	kubectl get pnode {name} -o yaml	kubectl edit pnode {name}
ModelArts资源租户	ModelArts的网络、资源池对应的vpc、虚拟机节点、裸金属节点创建在资源租户下	kubectl get rt	kubectl get rt {name} -o yaml	高危操作，不推荐使用
ModelArts RoCE网络	ModelArts的昇腾裸金属计算节点需要RoCE网络	kubectl get cm	kubectl get cm {name} -o yaml	kubectl edit cm {name}

 说明

查看具体对象详情命令或修改具体对象命令中，若需要填写{name}参数，该参数查询方法为：查看对象列表命令返回值中的NAME列，如下示例为modelarts节点规格列表查询示例。

图 11-12 查询示例

```
[service@modelarts-os-apiserver-59544554b9-rdp5w modelarts-os-apiserver]$ kubectl get nf
```

NAME	CPU	MEMORY	NPU_SIZE	NPU_TYPE	GPU_SIZE	GPU_TYPE	AGE
modelarts-inference.ai3v.4xlarge.4	16	32Gi	1	ascend-snt3p-300v			13d
modelarts-inference.c3.2xlarge.4	8	32Gi					13d
modelarts-inference.kai1.3xlarge.2	12	24Gi	4	ascend-snt3			13d
modelarts-inference.kai3i.4xlarge.4	16	32Gi	1	ascend-snt3p-300i			13d
modelarts-inference.kai3v.4xlarge.4	16	32Gi	1	ascend-snt3p-300v			13d
modelarts-inference.kc3.2xlarge.4	8	32Gi					13d

----结束

11.14 修改资源租户密码

背景信息

资源租户的密码会过期，导致在特定场景下需要通过资源租户登录ManageOne运营面时，会提示修改密码，但修改资源租户的密码会导致ModelArts的新增业务受损，因此需要能够通过ModelArts修改密码或将新密码设置给ModelArts。

获取租户的资源租户账号信息

步骤1 以ModelArts资源池所在租户账号登录ManageOne租户面。

1. 使用浏览器，登录ManageOne。
 - 登录地址：
非B2B场景的登录地址：**https://ManageOne运营面的访问地址**。例如，
https://console.demo.com。
B2B场景的登录地址：**https://ManageOne租户面的访问地址**。例如，
https://tenant.demo.com。
 - 租户的用户名和密码：联系环境管理员获取。
2. 单击“登录”。


步骤2 单击右上角的账号名称，选择“个人设置”，进入个人中心。

步骤3 在个人设置界面获取“租户ID”（domain_id），当前账号所属的租户ID。

步骤4 登录ModelArts管理面组件modelarts-os-apiserver微服务容器。

1. **登录CDK master节点。**
2. 执行**kubectl get pod**命令查看pod，然后找到modelarts-os-apiserver容器对应的pod并登录。

图 11-13 查看 pod



NAME	READY	STATUS	RESTARTS	AGE
modelarts-algorancher-8ddcc8d68-cqk42	1/1	Running	0	3d16h
modelarts-algorancher-8ddcc8d68-krc8m	1/1	Running	0	3d16h
modelarts-billing-7d9d4c4dd4-ftsxn	1/1	Running	0	3d16h
modelarts-billing-7d9d4c4dd4-hvsj9	1/1	Running	0	3d16h
modelarts-console-backend-576cbbfddb-d78t7	1/1	Running	0	3d16h
modelarts-console-backend-576cbbfddb-k94g7	1/1	Running	0	3d16h
modelarts-exemlflow-778b8c78fd-mjg67	1/1	Running	0	3d16h
modelarts-exemlflow-778b8c78fd-wglcl	1/1	Running	0	3d16h
modelarts-market-manager-cdk-7cfd8bf4d5-b8fc8	1/1	Running	0	2d22h
modelarts-market-manager-cdk-7cfd8bf4d5-gjghl	1/1	Running	0	2d22h
modelarts-os-apiserver-5cd548c558-sltx5	1/1	Running	0	3d16h
modelarts-os-apiserver-5cd548c558-tzvv2	1/1	Running	0	3d16h
modelarts-os-job-mgr-594bf4fd4b-6mbdz	1/1	Running	0	3h24m
modelarts-os-job-mgr-594bf4fd4b-clj9x	1/1	Running	0	3h24m
modelarts-os-resource-mgr-78747979f7-8wqtf	1/1	Running	0	3d16h
modelarts-os-resource-mgr-78747979f7-zvr4q	1/1	Running	0	3d16h
modelarts-webapp-gateway-cdk-7547d97b55-l7k6j	1/1	Running	0	3d16h
modelarts-webapp-gateway-cdk-7547d97b55-r6rtz	1/1	Running	0	3d16h

3. 执行如下命令登录pod。
kubectl exec -it \${pod_name} bash

步骤5 在modelarts-os-apiserver微服务容器中查看资源租户账号信息。

1. 执行如下命令查看资源租户的账号信息中的用户名和加密密码。
kubectl get rt tenant.{domain_id} -o yaml

图 11-14 查看资源租户的账号信息

```

[service@modelarts-os-apiserver-6c5c87fff4-7svh2 modelarts-os-apiserver]$ kubectll get rt -oyaml
apiVersion: os.modelarts.huaweicloud/v1
kind: ResourceTenant
metadata:
  annotations:
    os.modelarts/tenant.domain.name: ModelArts_System_VDC
  creationTimestamp: "2023-03-06T03:38:10Z"
  finalizers:
    - os.modelarts.resourceTenants/finalizers
  generation: 2
  labels:
    os.modelarts/tenant.domain.id: fc21ce91b4cb421e928449e7f24849db
    os.modelarts/tenant.user.id: 06c7bb4e52f045e68d8996501bdf0e
  name:
  resourceVersion: "2380"
  uid: a9272888-92aa-4d76-a5f6-0557907fe6bb
spec:
  agencies:
    - name: cce_admin_trust
      trustDomain:
        name: op_svc_cce
      method: password
      password:
      projects:
        - name: e1-a3-1
status:
  agencies:
    - creationTimestamp: "2023-03-05T19:38:14Z"
      id: de00dfff34f54ccd8d8edb84d6b7ccc7
      name: cce_admin_trust
      trustDomain:
        id: 3d30142f1ed94092971beb002a108264
        name: op_svc_cce
  domain:
    id: 0196fd22e1a54c27b8e8c8537d2e311d
    name: op_svc
  projects:
    - id: 58ff7c28c20945878dc7385e1ecd1bf5
      name: e1-a3-1
  user:
    id: 4d78ec62e4c34266b0b5cd54ec418aa7
    name: op_svc
    password:
    passwordUpdateTimestamp: "2023-03-06T03:38:12Z"
[service@modelarts-os-apiserver-6c5c87fff4-7svh2 modelarts-os-apiserver]$

```

其中：

- status.domain.id为资源租户的domain_id，设为rt_domain_id
- status.domain.name为资源租户的domain_name，设为rt_domain_name
- status.user.id为资源租户的用户_id，设为rt_user_id
- status.user.name为资源租户的用户_name，设为rt_user_name
- status.projects[0].id为资源租户的项目project_id，设为rt_project_id

步骤6 获取新密码的加密密文，设新密码对应的加密密文为new_password_scc。

```
scc_domain_id=`env|grep scc_domain_id|awk -F "=" '{print $2}'`
```

```
/usr/local/seccomponent/bin/CryptoAPI -e -i $scc_domain_id -f /opt/cloud/modelarts-os/modelarts-apiserver/config/sec/scc.conf
```

图 11-15 获取新密码的加密密文

```

[service@modelarts-os-apiserver-888865b-2647 ~]$ sudo cat /etc/passwd | grep sec_domain_id | awk -F ":" '{ print $2 }'
[service@modelarts-os-apiserver-888865b-2647 ~]$ sudo cat /usr/local/seccomponent/bin/CryptoMPI -e | sed 's/domain_id -f /opt/cloud/modelarts-os/modelarts-os-apiserver/config/sec/sec/'
Please input plain text: test
*****
[service@modelarts-os-apiserver-888865b-2647 ~]$
[service@modelarts-os-apiserver-888865b-2647 ~]$

```

----结束

场景一：通过 ModelArts 修改资源租户的密码

在modelarts-os-apiserver微服务容器中创建一个json文件，命名tenant_new.json，内容如下，并替换其中的{domain_id}和{new_password_scc}。

```
{
  "apiVersion": "os.modelarts.huaweicloud/v1",
  "kind": "ResourceTenant",
  "metadata": {
    "name": "tenant.{domain_id}"
  },
  "spec": {
    "password": "{new_password_scc}"
  }
}
```


执行如下命令即通过ModelArts给资源租户设置新的密码。

```
kubectl apply -f tenant_new.json --validate=false
```

场景二：通过 ManageOne 运营面修改资源租户的密码后，同步修改 ModelArts 的中存储的资源租户密码

在modelarts-os-apiserver微服务容器中创建一个json文件，命名tenant_new.json，内容如下，并替换其中的{domain_id}和{new_password_scc}、{rt_domain_id}、{rt_domain_name}、{rt_user_name}、{rt_user_id}以及{rt_project_id}。

```
{
  "apiVersion": "os.modelarts.huaweicloud/v1",
  "kind": "ResourceTenant",
  "metadata": {
    "annotations": {
      "os.modelarts/managed": "{\"auth_type\":\"password\",\"domain_name\":\"{rt_domain_name}\",\"domain_id\":\"{rt_domain_id}\",\"user_name\":\"{rt_user_name}\",\"user_id\":\"{rt_user_id}\",\"password\":\"{new_password_scc}\",\"project_id\":\"{rt_project_id}\"}"
    },
    "name": "tenant.{domain_id}"
  },
  "spec": {
    "password": "{new_password_scc}"
  }
}
```

执行如下命令，将新的资源租户密码设置给ModelArts。

```
kubectl apply -f tenant_new.json --validate=false
```

11.15 登录 ModelArts 资源池的节点

1. 以系统管理员账号登录ServiceOM平台。
2. 在Service OM平台，获取资源池节点的内网网地址。（“资源池节点”的默认前缀为“os-node-created-”）

说明

- 内网网段参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，搜索“external_relay_network”获取对应的网段值。
- 在开通通信矩阵的场景下，需要临时开通ModelArts-Common-Proxy节点到资源池节点的22端口。
 - 源IP：为ModelArts-Common-Proxy节点IP，参见安装ModelArts服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“工具生成的ip参数”页签下搜索“ModelArts-Common-Proxy”获取任一IP地址。
 - 源端口：设置为“Any”。
 - 目的IP：为资源池节点的内网网地址。
 - 目的端口：22。
- 对于虚拟机：在“服务列表 > 资源 > 计算资源”中，单击“虚拟机”，进入虚拟机列表。

在名称右侧输入框中，搜索节点名称“os-node-created-”，获取并记录要登录的资源池节点的内网IP地址。
- 对于裸金属：在“服务列表 > 裸金属资源”中，单击“裸金属实例”，进入裸金属实例列表。

- i. 在名称右侧输入框中，搜索实例名称“os-node-created-”。
- ii. 单击要登录的实例节点名称，进入实例详情页。
- iii. 在实例详情页的“业务网卡信息”列表中，找到与其他IP地址不在同一网段的IP地址，并复制其“网络ID”第一个中划线前的内容。

图 11-16 唯一网段 IP 地址和网络 ID

业务网卡信息		IP地址	弹性IP	状态	网段ID	网络ID
MAC地址						
网卡名称		192.168.1.101	当前网卡没有绑定弹性IP地址。	运行中	74877bcb-4381-4712-b03a-0af188a28000	74877bcb-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.102	当前网卡没有绑定弹性IP地址。	运行中	74877bcb-4381-4712-b03a-0af188a28000	74877bcb-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.103	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.104	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.105	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.106	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.107	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.108	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.109	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000
网卡名称		192.168.1.110	当前网卡没有绑定弹性IP地址。	运行中	49962111-4381-4712-b03a-0af188a28000	49962111-4381-4712-b03a-0af188a28000

- iv. 在“服务列表 > 网络资源”中，单击“虚拟网络”，进入虚拟网络列表。在页面右上角通过“ID”搜索2.iii中复制的内容。
 - v. 单击搜索到的虚拟网络名称，进入详情页。在详情页切换到“查看关联云服务器”页签，在列表中找到与2.ii相同的实例名称，获取并记录要登录的资源池节点的内网IP地址。
3. [登录ModelArts-Common-Proxy节点](#)。
 4. 登录资源池目标节点。

ssh opsadmin@<资源池节点内网IP>

su - root

opsadmin账户和root账户的默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》，在“B类（EI企业智能）”页签中，搜索“ModelArts 资源池节点”获取。

11.16 登录 OpenStack 首节点

1. 执行以下命令，登录OpenStack首节点IP地址。OpenStack首节点IP地址，参见安装华为云Stack基础服务时由HCC Turnkey导出的部署参数表《xxx_export_all_v2_CN.xlsx》，在“Portal”页签下获取“FusionSphere OpenStack安装部署界面（CPS）”网址中的IP地址。

ssh fsp@openstack首节点ip

- 默认账号：fsp。
- 默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（后台）”页签中“OpenStack节点”对应账户的默认密码。

2. 执行以下命令，切换至root用户。

su - root

默认密码：参见《[华为云Stack 8.6.0 账户一览表](#)》的“A类（后台）”页签中“OpenStack节点”对应账户的默认密码。

3. 执行以下命令，完成环境变量的导入。

source set_env

- a. 输入“1”，使用内置DC管理员（dc_admin）的OpenStack Keystone V3鉴权。

11.18 打开 ModelArts UI 特定功能特性开关

1. [登录ModelArts-ConsoleBackend-GaussDB数据库](#)。
2. 执行以下命令，查询特性开关，记录NAME的值。

```
SELECT NAME,MODULE,SHOW,DESCRIPTION,OPERATOR FROM PUBLIC.CFG_FEATURE_INFO;
```
3. 执行以下命令，打开特性开关。

```
replace INTO CFG_FEATURE_INFO_BY_USER (NAME, OPERATOR, SHOW, UPDATETIME) values ('{NAME}', TRUE, floor(extract(epoch from now())));
```
4. 执行以下命令，关闭特性开关。

```
replace INTO CFG_FEATURE_INFO_BY_USER (NAME, OPERATOR, SHOW, UPDATETIME) values ('{NAME}', FALSE, floor(extract(epoch from now())));
```

11.19 获取新版推理 CA 证书

当客户在制作推理镜像时，如果启用了HTTPS，可能需要使用推理平台的CA证书来校验客户端证书，因此需要获取推理平台所使用的CA证书。

操作步骤

- 步骤1** 以[ModelArts服务承载租户使用的二级VDC用户名登录ManageOne租户面](#)。
- 步骤2** 在服务列表选择“计算 > 云容器引擎CCE”，进入CCE服务。
- 步骤3** 集群管理页面显示了所有的CCE集群，单击“[infern-dispatcher](#)”集群，进入“集群信息”页面。
- 步骤4** 选择“配置与密钥 > 密钥”，搜索“[modelarts-infern-watcher-secret](#)”，单击操作列的“更多 > 查看yaml”，最后复制ca-cert.pem的内容。

图 11-19 查看 yaml


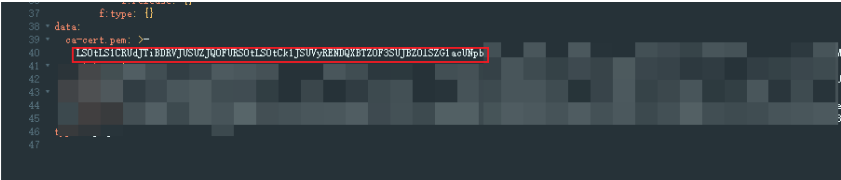


图 11-20 复制 ca-cert.pem 的内容



- 步骤5** 将[步骤4](#)获取到的内容经过base64解码，并将解码后的文件保存到本地，文件命名为“ca-cert.pem”。

----结束